

Sprawozdanie 1

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-02

Spis treści

0.1	Wstęp	1
0.2	Opis danych	1
0.3	Analiza opisowa	4
0.4	Analiza opisowa z podziałem na grupy	13
0.5	Podsumowanie - wnioski	15

0.1 Wstęp

Głównym celem naszego raportu jest przeanalizowanie bazy danych zawierającej informacje o klientach firmy telekomunikacyjnej w celu przewidzenia ich zachowań związanych z rezygnacją z usług firmy.

Baza danych „Telco Customer”, na której będziemy pracować, została pobrana ze strony Kaggle (tu należy wstawić link). Jest to fikcyjny zbiór danych zawierający informacje o klientach firmy telekomunikacyjnej świadczącej usługi telefonii stacjonarnej oraz inne usługi telekomunikacyjne w Kalifornii.

0.2 Opis danych

Tabela 1: Podsumowanie danych (kolumny 1-5)

customerID	gender	SeniorCitizen	Partner	Dependents	tenure
0002-ORFBO: 1	Female:3488	Min. :0.0000	No :3641	No :4933	Min. : 0.00
0003-MKNFE: 1	Male :3555	1st Qu.:0.0000	Yes:3402	Yes:2110	1st Qu.: 9.00
0004-TLHLJ: 1		Median :0.0000			Median :29.00
0011-IGKFF: 1		Mean :0.1621			Mean :32.37
0013-EXCHZ: 1		3rd Qu.:0.0000			3rd Qu.:55.00
0013-MHZWF: 1		Max. :1.0000			Max. :72.00

(Other) :7037

Tabela 2: Podsumowanie danych (kolumny 6-10)

PhoneService	MultipleLines	InternetService	OnlineSecurity
No : 682	No :3390	DSL :2421	No :3498
Yes:6361	No phone service: 682	Fiber optic:3096	No internet service:1526
	Yes :2971	No :1526	Yes :2019

Tabela 3: Podsumowanie danych (kolumny 11-15)

OnlineBackup	DeviceProtection	TechSupport
No :3088	No :3095	No :3473
No internet service:1526	No internet service:1526	No internet service:1526
Yes :2429	Yes :2422	Yes :2044

Tabela 4: Podsumowanie danych (kolumny 16-21)

StreamingTV	StreamingMovies	Contract
No :2810	No :2785	Month-to-month:3875
No internet service:1526	No internet service:1526	One year :1473
Yes :2707	Yes :2732	Two year :1695

Tabela 5: Podsumowanie danych (kolumny 16-21)

PaperlessBilling	PaymentMethod	MonthlyCharges	TotalCharges	Churn
No :2872	Bank transfer (automatic):1544	Min. : 18.25	Min. : 18.8	No :5174
Yes:4171	Credit card (automatic) :1522	1st Qu.: 35.50	1st Qu.: 401.4	Yes:1869
	Electronic check :2365	Median : 70.35	Median :1397.5	
	Mailed check :1612	Mean : 64.76	Mean :2283.3	
		3rd Qu.: 89.85	3rd Qu.:3794.7	
		Max. :118.75	Max. :8684.8	
			NA's :11	

Powyższe tabele (tu można dodać odnośniki) przedstawiają statystyki opisowe dla każdej z analizowanych cech, dzięki czemu możliwe jest wstępne zapoznanie się z danymi oraz identyfikacja podstawowych nieprawidłowości.

Tabela 6: Typy oraz opisy zmiennych

	Typ	Opis
customerID	factor	Id klientów
gender	factor	płeć (K/M)
SeniorCitizen	integer	Senior
Partner	factor	Posiadanie Partnera
Dependents	factor	Finansowa odpowiedzialność
tenure	integer	Licza miesięcy, w których osoba był aktywnym klientem
PhoneService	factor	Czy klient ma usługi telefoniczne
MultipleLines	factor	Czy klient ma wiele linii telefonicznych
InternetService	factor	Firma zapewniająca internet
OnlineSecurity	factor	Czy klient ma bezpieczeństwo w sieci
OnlineBackup	factor	czy ma kopię zapasową
DeviceProtection	factor	Czy ma ochronę urządzeń
TechSupport	factor	Czy ma wsparcie techniczne
StreamingTV	factor	Czy ma pakiet z serwisem stramingowym
StreamingMovies	factor	Czy ma platforme do strmigowania filmów
Contract	factor	Okres umowy
PaperlessBilling	factor	Nie papierowe billingi
PaymentMethod	factor	Metoda płatności
MonthlyCharges	numeric	Miesięczna kwota płatności
TotalCharges	numeric	Całkowita kwota płatności
Churn	factor	Czy jest aktywnym klientem

```
dane$customerID <- NULL
```

```
dane$SeniorCitizen <- factor(dane$SeniorCitizen,
```

```

levels = c(0, 1),
labels = c("No", "Yes"))

dane$TotalCharges[is.na(dane$TotalCharges)] <- 0

```

Analizowana przez nas baza danych zawiera 7043 przypadków oraz 20 cech.

W danych występuje cecha CustomerID, która jednoznacznie identyfikuje klienta. Ze względów prywatności oraz ponieważ nie wnosi ona informacji istotnych dla analizy zachowań klientów, kolumna ta została usunięta z dalszej analizy.

Zmienna SeniorCitizen pierwotnie była zakodowana wartościami 0 i 1, gdzie 1 oznaczało klienta będącego seniorem. Dla lepszej czytelności i interpretowalności danych zmieniono kodowanie na wartości tekstowe: No – klient nie jest seniorem, Yes – klient jest seniorem.

Występują braki danych w kolumnie TotalCharges jest ich 0 i są kodowane za pomocą Na. Na potrzeby analizy zdecydowano się zastąpić wartości NA zerami. Wynika to z charakterystyki zmiennej – TotalCharges oznacza łączną kwotę zapłaconą przez klienta. W przypadku nowych klientów brak tej wartości nie oznacza błędu danych, lecz fakt, że nie zdążyli oni jeszcze dokonać żadnej płatności. Potwierdza to obecność niezerowych wartości w kolumnie MonthlyCharges, która wskazuje bieżące opłaty abonamentowe – kwotę, jaką klient płaci miesięcznie za usługi firmy telekomunikacyjnej.

Dodatkowo uwzględniono zmienną tenure, określającą liczbę miesięcy, przez które klient pozostaje w firmie. Zaobserwowano, że obserwacje z brakującymi wartościami w TotalCharges mają wartość tenure równą 0, co sugeruje, że są to nowi klienci, którzy nie zakończyli jeszcze pierwszego pełnego miesiąca korzystania z usług.

W kolumnie **TotalCharges** mogą występować wartości odstające. Świadczy o tym fakt, że średnia wartość tej zmiennej jest znacznie wyższa od mediany, co wskazuje na możliwą obecność ekstremalnych obserwacji. Ponieważ średnia jest statystyką wrażliwą na wartości odstające, różnica między średnią a medianą sugeruje, że niektóre płatności klientów są znacznie wyższe od typowych.

0.3 Analiza opisowa

Następnie przeprowadzimy analizę opisową, dzięki której poznamy strukturę oraz charakterystykę zmiennych. W ramach tej analizy dokonamy przeglądu poszczególnych cech, analizując ich rozkłady, podstawowe statystyki opisowe oraz identyfikując ewentualne nieprawidłowości.



Tabela 7: Miary położenia i rozproszenia zmiennych ilościowych

	tenure	MonthlyCharges	TotalCharges
Srednia	32.37	64.76	2279.73
Mediana	29.00	70.35	1394.55
Odchylenie	24.56	30.09	2266.79


Wariancja	603.17	905.41	5138357.17
Min	0.00	18.25	0.00
Q1	9.00	35.50	398.55
Q3	55.00	89.85	3786.60
Max	72.00	118.75	8684.80

Powyższy wykres (tu można dodać odnośnik) przedstawia podstawowe statystyki opisowe dla zmiennych ilościowych ciągłych, takie jak średnia, wariancja, wartości minimalne i maksymalne oraz pierwszy i trzeci kwartył.

Na podstawie wstępnej analizy danych można przypuszczać, że w zmiennej TotalCharges występują wartości odstające, na co wskazuje zauważalna różnica między średnią a medianą. W przypadku pozostałych zmiennych ich rozkłady wydają się być bardziej równomierne, bez wyraźnych oznak obecności wartości ekstremalnych.



Histogram liczby miesiecy



Powyższe histogramy (tu można dodać odnośnik) przedstawiają rozkład zmiennych TotalCharges oraz MonthlyCharges.


Zmienna MonthlyCharges oznacza kwotę, jaką klient zobowiązany jest zapłacić w danym miesiącu za świadczone usługi. Jej rozkład jest stosunkowo równomierny, z widoczną koncentracją wartości w średnich przedziałach cenowych.

Natomiast w przypadku zmiennej TotalCharges rozkład jest silnie prawoskośny, co oznacza, że większość klientów zapłaciła stosunkowo niewielkie łączne kwoty, a niewielka liczba klientów poniosła znacznie wyższe koszty. Może to sugerować występowanie wartości odstających.

Powyższy wykres (tu można dodać odnośnik) przedstawia rozkład zmiennej tenure, określającej liczbę miesięcy, przez które klient korzysta z usług firmy.

Średnia oraz mediana tej zmiennej wynoszą około 30 miesięcy (tabela), co wskazuje, że przeciętny klient pozostaje w firmie przez około 2,5 roku. Rozkład zmiennej sugeruje obecność zarówno nowych klientów, jak i tych z dłuższym stażem, co może mieć istotne znaczenie w analizie rezygnacji z usług.

Na wykresie można zauważyć stosunkowo dużą liczbę nowych klientów, natomiast klientów o dłuższym stażu jest mniej. Może to sugerować, że część klientów rezygnuje z usług firmy na wcześniejszym etapie współpracy, co wskazuje na potencjalnie wyższe ryzyko odejścia wśród nowych klientów.




Na powyższym wykresie (znowu odnoscik) zostały przedstawione rozkłady danych d=ciągłych na boxplotach.

Zmienna Total Charges wykazuje silną prawoskośność (asymetrię dodatnią). Mediana znajduje się stosunkowo nisko, co sugeruje, że większość klientów wygenerowała dotychczas niewielki przychód skumulowany. Może to wynikać z dużej liczby nowych użytkowników lub klientów korzystających z najtańszych planów taryfowych. Zauważalny jest jednak górny „wąs” wykresu, który sięga poziomu 8000 jednostek, co wskazuje na obecność grupy lojalnych klientów o długim stażu, którzy przynieśli firmie znaczne przychody.

Rozkład zmiennej Monthly Charges jest zbliżony do równomiernego. Pudełko obejmuje zakres od około 35 do 90 jednostek, co odzwierciedla szerokie zróżnicowanie oferty firmy. Wskazuje to, że baza klientów składa się w podobnym stopniu zarówno z osób wybierających tańsze pakiety podstawowe, jak i z klientów decydujących się na droższe opcje premium.

Wykres zmiennej Tenure również pokazuje rozkład równomierny i symetryczny. Oznacza to, że w zbiorze danych znajduje się zrównoważony miks klientów: zarówno nowi użytkownicy o niskim stażu, jak i osoby związane z firmą od wielu lat.



Następnie zostały zbadane kształty rozkładu zmiennych ciągłych przy użyciu wykresów gęstości jądrowej.

Na pierwszym wykresie (Total Charges) obserwujemy silną prawoskośność, z najwyższym szczytem w okolicy zera. Wskazuje to, że większość klientów to nowi użytkownicy lub osoby generujące niskie rachunki.



Na wykresie Monthly Charges widoczne są dwa szczyty (bimodalny rozkład): pierwszy przy niskich wartościach (ok. 25 jednostek) reprezentuje klientów korzystających z najtańszych ofert, natomiast drugi, przy ok. 70 jednostek, obejmuje użytkowników wybierających droższe pakiety.

Wykres zmiennej Tenure ma również dwa szczyty, co świadczy o dużej liczbie klientów o bardzo krótkim stażu lub takich co szybko zrezygnowali z usług. Na drugim końcu są klienci bardzo lojalni, którzy są z firmą przez długi czas.

Tabela 8: Tabela licznosci dla danych jakościowych

gender	Female:3488	Male :3555	
SeniorCitizen	No :5901	Yes:1142	
Partner	No :3641	Yes:3402	
Dependents	No :4933	Yes:2110	
PhoneService	No : 682	Yes:6361	
MultipleLines	No :3390	No phone service: 682	Yes :2971
InternetService	DSL :2421	Fiber optic:3096	No :1526
OnlineSecurity	No :3498	No internet service:1526	Yes :2019
OnlineBackup	No :3088	No internet service:1526	Yes :2429
DeviceProtection	No :3095	No internet service:1526	Yes :2422
TechSupport	No :3473	No internet service:1526	Yes :2044
StreamingTV	No :2810	No internet service:1526	Yes :2707
StreamingMovies	No :2785	No internet service:1526	Yes :2732
Contract	Month-to-month:3875	One year :1473	Two year :1695
PaperlessBilling	No :2872	Yes:4171	
PaymentMethod	Bank transfer (automatic):1544	Credit card (automatic) :1522	Electronic check :2
Churn	No :5174	Yes:1869	



Powyższa tabela przedstawia iloczności dla zmiennych jakościowych.



Na powyższych wykresach widzimy rozkład klientów względem wyboru umowy oraz metody płatności.

Najczęściej wybraną formą umowy jest „miesiąc na miesiąc”, co daje klientom większą elastyczność i ułatwia rezygnację, a jednocześnie jest atrakcyjne dla nowych użytkowników, którzy nie chcą wiązać się długoterminowo.

Najczęstszą metodą płatności jest elektroniczny czek, co wskazuje na preferencje klientów względem tradycyjnych, ale wygodnych sposobów regulowania należności.



Na powyższych wykresach obserwujemy podział klientów pod względem posiadania usługi


telefonicznej. Widać, że zdecydowana większość klientów decyduje się na tę opcję.

Na wykresie dotyczącym usługi internetowej najczęściej klientów wybiera pakiet Fiber, natomiast nieco mniej osób korzysta z DSL. Istnieje także grupa klientów, którzy nie korzystają z internetu w ramach oferty firmy.

```
plot(dane$MonthlyCharges, dane$TotalCharges,
     main = "Wykres rozrzutu: MonthlyCharges vs TotalCharges",
     xlab = "MonthlyCharges",
     ylab = "TotalCharges",
     pch = 19, col = "blue")

# Dodanie linii regresji liniowej (opcjonalnie)
abline(lm(TotalCharges ~ MonthlyCharges, data = dane), col = "red", lwd = 2)
```


Wykres rozrzutu: MonthlyCharges vs TotalCharges



```
# cor(dane$MonthlyCharges, dane$TotalCharges, use = "complete.obs")
```


Na wykresie (odnośnik) można zauważyć liniową zależność między zmiennymi Monthly Charges a Total Charges. Czerwona linia przedstawia linię regresji liniowej, pokazującą ogólny trend wzrostu całkowitych opłat wraz ze wzrostem opłat miesięcznych.

im dłużej klient, tym większa suma opłat



Na wykresie (odnośnik) można zauważyć liniową zależność między zmiennymi Tenure (liczba miesięcy jako klient) a Total Charges. Czerwona linia przedstawia linię regresji liniowej, pokazującą ogólny trend wzrostu całkowitych opłat wraz ze wzrostem stażu klienta.


Czy starsi klienci płacą więcej/mniej miesięcznie?




Na wykresie (odnośnik) przedstawiono zależność między zmiennymi Tenure (liczba miesięcy jako klient) a Monthly Charges. Czerwona linia wskazuje linię regresji liniowej. Warto jednak zauważyć, że wykres nie ujawnia żadnej wyraźnej zależności – wartości Monthly Charges są rozproszone w całym zakresie Tenure, co sugeruje, że wysokość miesięcznych opłat nie zależy od długości stażu klienta.

0.4 Analiza opisowa z podziałem na grupy



Histogram MonthlyCharges według Churn





MonthlyCharges według gru



```
##
##           No      Yes
## Female 0.4926556 0.5024077
## Male   0.5073444 0.4975923
```





I opisać to wszystko podpunkt b z etapu 3

0.5 Podsumowanie - wnioski