

# Sprawozdanie 1

## Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-03

## Spis treści

|   |                                      |    |
|---|--------------------------------------|----|
| 1 | Wstęp                                | 1  |
| 2 | Opis danych                          | 2  |
| 3 | Analiza opisowa                      | 5  |
| 4 | Analiza opisowa z podziałem na grupy | 14 |
| 5 | Podsumowanie – wnioski               | 19 |

## 1 Wstęp

Głównym celem naszego raportu jest przeanalizowanie bazy danych zawierającej informacje o klientach firmy telekomunikacyjnej w celu przewidzenia ich zachowań związanych z rezygnacją z usług firmy.

Baza danych `Telco-Customer-Churn`, na której będziemy pracować, została pobrana ze strony [Kaggle](#). Jest to fikcyjny zbiór danych zawierający informacje o klientach firmy telekomunikacyjnej świadczącej usługi telefonii stacjonarnej oraz inne usługi telekomunikacyjne w Kalifornii.

## 2 Opis danych

W analizowanej przez nas bazie danych jest zawartych 21 cech:

Tabela 1: Typy oraz opisy cech

|                  | Typ     | Opis                                         |
|------------------|---------|----------------------------------------------|
| customerID       | factor  | ID klienta                                   |
| gender           | factor  | płeć klienta                                 |
| SeniorCitizen    | integer | czy klient jest seniorem                     |
| Partner          | factor  | czy klient ma partnera                       |
| Dependents       | factor  | czy klient ma osoby na utrzymaniu            |
| tenure           | integer | liczba miesięcy w których klient był aktywny |
| PhoneService     | factor  | czy klient ma usługi telefoniczne            |
| MultipleLines    | factor  | czy klient ma wiele linii telefonicznych     |
| InternetService  | factor  | typ usługi internetowej                      |
| OnlineSecurity   | factor  | czy klient ma usługi bezpieczeństwa w sieci  |
| OnlineBackup     | factor  | czy klient ma usługę kopii zapasowej online  |
| DeviceProtection | factor  | czy klient ma usługę ochrony urządzeń        |
| TechSupport      | factor  | czy klient ma usługę wsparcia technicznego   |
| StreamingTV      | factor  | czy klient ma kablówkę                       |
| StreamingMovies  | factor  | czy klient ma usługę streamowania filmów     |
| Contract         | factor  | okres umowy                                  |
| PaperlessBilling | factor  | czy klient się rozlicza elektronicznie       |
| PaymentMethod    | factor  | metoda płatności                             |
| MonthlyCharges   | numeric | miesięczna kwota płatności                   |
| TotalCharges     | numeric | łączna kwota płatności                       |
| Churn            | factor  | czy klient zrezygnował                       |

Ich wartości dla 7043 przypadków zawartych w bazie prezentują się następująco:

Tabela 2: Podsumowanie danych

| customerID    | gender       | SeniorCitizen   | Partner   | Dependents |
|---------------|--------------|-----------------|-----------|------------|
| 0002-ORFBO: 1 | Female: 3488 | Min.: 0.0000    | No: 3641  | No: 4933   |
| 0003-MKNFE: 1 | Male: 3555   | 1st Qu.: 0.0000 | Yes: 3402 | Yes: 2110  |
| 0004-TLHLJ: 1 |              | Median: 0.0000  |           |            |
| 0011-IGKFF: 1 |              | Mean: 0.1621    |           |            |
| 0013-EXCHZ: 1 |              | 3rd Qu.: 0.0000 |           |            |
| 0013-MHZWF: 1 |              | Max.: 1.0000    |           |            |
| (Other): 7037 |              |                 |           |            |

| tenure         | PhoneService | MultipleLines         | InternetService   |
|----------------|--------------|-----------------------|-------------------|
| Min.: 0.00     | No: 682      | No: 3390              | DSL: 2421         |
| 1st Qu.: 9.00  | Yes: 6361    | No phone service: 682 | Fiber optic: 3096 |
| Median: 29.00  |              | Yes: 2971             | No: 1526          |
| Mean: 32.37    |              |                       |                   |
| 3rd Qu.: 55.00 |              |                       |                   |
| Max.: 72.00    |              |                       |                   |

| OnlineSecurity            | OnlineBackup              | DeviceProtection          |
|---------------------------|---------------------------|---------------------------|
| No: 3498                  | No: 3088                  | No: 3095                  |
| No internet service: 1526 | No internet service: 1526 | No internet service: 1526 |
| Yes: 2019                 | Yes: 2429                 | Yes: 2422                 |

| TechSupport               | StreamingTV               | StreamingMovies           |
|---------------------------|---------------------------|---------------------------|
| No: 3473                  | No: 2810                  | No: 2785                  |
| No internet service: 1526 | No internet service: 1526 | No internet service: 1526 |
| Yes: 2044                 | Yes: 2707                 | Yes: 2732                 |

| Contract             | PaperlessBilling | PaymentMethod                   |
|----------------------|------------------|---------------------------------|
| Month-to-month: 3875 | No: 2872         | Bank transfer (automatic): 1544 |
| One year: 1473       | Yes: 4171        | Credit card (automatic): 1522   |
| Two year: 1695       |                  | Electronic check: 2365          |
|                      |                  | Mailed check: 1612              |

| MonthlyCharges | TotalCharges    | Churn     |
|----------------|-----------------|-----------|
| Min.: 18.25    | Min.: 18.8      | No: 5174  |
| 1st Qu.: 35.50 | 1st Qu.: 401.4  | Yes: 1869 |
| Median: 70.35  | Median: 1397.5  |           |
| Mean: 64.76    | Mean: 2283.3    |           |
| 3rd Qu.: 89.85 | 3rd Qu.: 3794.7 |           |
| Max.: 118.75   | Max.: 8684.8    |           |
|                | NA's: 11        |           |

Powyższe tabele przedstawiają statystyki opisowe dla każdej z analizowanych cech, dzięki czemu możliwe jest wstępne zapoznanie się z danymi oraz identyfikacja podstawowych nieprawidłowości.

W danych występuje cecha `CustomerID`, która jednoznacznie identyfikuje klienta. Ze względów prywatności oraz ponieważ nie wnosi ona informacji istotnych dla analizy zachowań klientów, będziemy chcieli wykluczyć tę kolumnę z dalszej analizy.

Zmienna `SeniorCitizen` pierwotnie była zakodowana wartościami 0 i 1, gdzie 1 oznaczało klienta będącego seniorem. Dla lepszej czytelności i interpretowalności danych zmienimy kodowanie na wartości tekstowe: "No" – klient nie jest seniorem, "Yes" – klient jest seniorem.

Występują braki danych w kolumnie `TotalCharges`. Jest ich 11 i są kodowane za pomocą NA. Można jednak zauważyć, że brak danych w `TotalCharges` jest równoważny czasowi aktywności klienta równemu 0 miesięcy:

Tabela 3: Powiązanie `tenure=0` z `TotalCharges=NA`

| <code>tenure=0</code> | <code>tenure=0</code> oraz <code>TotalCharges=NA</code> | <code>TotalCharges=NA</code> |
|-----------------------|---------------------------------------------------------|------------------------------|
| 11                    | 11                                                      | 11                           |

Stąd możemy wywnioskować, że kiedy `TotalCharges=NA`, klient po prostu nie zdążył za nic zapłacić, więc łączna zapłacona kwota wynosi w rzeczywistości 0. Dlatego możemy bezpiecznie zamienić wszystkie NA w tej kolumnie na 0.

Niektóre zmienne są nazwane w inny sposób niż inne – większość nazw zmiennych zaczyna się od dużej litery, ale niektóre zaczynają się od małej litery. Zrobimy więc aby wszystkie zaczynały się od dużej. Zamienimy więc nazwy zmiennych `customerID`, `gender` oraz `tenure` na odpowiednio `CustomerID`, `Gender` i `Tenure`.

Dokonujemy wymienionych wyżej korekt w następujący sposób:

```
# Zmiana nazw zmiennych
names(dane) <- paste0(toupper(substr(names(dane), 1, 1)),
                      substring(names(dane), 2))

# Usunięcie kolumny customerID
dane$CustomerID <- NULL

# Zmiana typu zmiennej SeniorCitizen na jakościową (i zmiana wartości)
dane$SeniorCitizen <- factor(dane$SeniorCitizen,
                             levels = c(0, 1),
                             labels = c("No", "Yes"))

# Zmiana braków danych w TotalCharges na 0
dane$TotalCharges[is.na(dane$TotalCharges)] <- 0
```

Po korektach pozostaje nam 20 cech:

Tabela 4: Typy oraz opisy cech

|                  | Typ     | Opis                                         |
|------------------|---------|----------------------------------------------|
| Gender           | factor  | płeć klienta                                 |
| SeniorCitizen    | factor  | czy klient jest seniorem                     |
| Partner          | factor  | czy klient ma partnera                       |
| Dependents       | factor  | czy klient ma osoby na utrzymaniu            |
| Tenure           | integer | liczba miesięcy w których klient był aktywny |
| PhoneService     | factor  | czy klient ma usługi telefoniczne            |
| MultipleLines    | factor  | czy klient ma wiele linii telefonicznych     |
| InternetService  | factor  | typ usługi internetowej                      |
| OnlineSecurity   | factor  | czy klient ma usługi bezpieczeństwa w sieci  |
| OnlineBackup     | factor  | czy klient ma usługę kopii zapasowej online  |
| DeviceProtection | factor  | czy klient ma usługę ochrony urządzeń        |
| TechSupport      | factor  | czy klient ma usługę wsparcia technicznego   |
| StreamingTV      | factor  | czy klient ma kablówkę                       |
| StreamingMovies  | factor  | czy klient ma usługę streamowania filmów     |
| Contract         | factor  | okres umowy                                  |
| PaperlessBilling | factor  | czy klient się rozlicza elektronicznie       |
| PaymentMethod    | factor  | metoda płatności                             |
| MonthlyCharges   | numeric | miesięczna kwota płatności                   |
| TotalCharges     | numeric | łączna kwota płatności                       |
| Churn            | factor  | czy klient zrezygnował                       |

### 3 Analiza opisowa

Przeprowadzimy analizę opisową, dzięki której poznamy strukturę oraz charakterystykę zmiennych. W ramach tej analizy dokonamy przeglądu poszczególnych cech, analizując ich rozkłady, podstawowe statystyki opisowe oraz identyfikując ewentualne nieprawidłowości.


Tabela 5: Miary położenia i rozproszenia zmiennych ilościowych

|            | Tenure | MonthlyCharges | TotalCharges |
|------------|--------|----------------|--------------|
| Średnia    | 32.37  | 64.76          | 2279.73      |
| Mediana    | 29.00  | 70.35          | 1394.55      |
| Odchylenie | 24.56  | 30.09          | 2266.79      |
| Wariancja  | 603.17 | 905.41         | 5138357.17   |
| Min        | 0.00   | 18.25          | 0.00         |
| Q1         | 9.00   | 35.50          | 398.55       |
| Q3         | 55.00  | 89.85          | 3786.60      |
| Max        | 72.00  | 118.75         | 8684.80      |

Powyższa tabela przedstawia podstawowe statystyki opisowe dla zmiennych ilościowych ciągłych, takie jak średnia, wariancja, wartości minimalne i maksymalne oraz pierwszy i trzeci kwartyl.

Zakres wartości zmiennych ilościowych jest zróżnicowany. Zmienna **TotalCharges** przyjmuje wartości od 0 do 8684.80, co wskazuje na duże zróżnicowanie całkowitych opłat klientów. W przypadku **MonthlyCharges** wartości mieszczą się w przedziale od 18.25 do 118.75, natomiast **Tenure** przyjmuje wartości od 0 do 72 miesięcy, co odzwierciedla zarówno nowych, jak i długoletnich klientów.

Na podstawie wstępnej analizy danych możemy przypuszczać, że w zmiennej **TotalCharges** występują wartości odstające, na co wskazuje zauważalna różnica między średnią a medianą. Średnia jest statystyką wrażliwą na wartości odstające, różnica między średnią a medianą sugeruje, że niektóre płatności klientów są znacznie wyższe od typowych. W przypadku pozostałych zmiennych ich rozkłady wydają się być bardziej równomierne, bez wyraźnych oznak obecności wartości ekstremalnych.




Powyższe histogramy przedstawiają rozkład zmiennych **TotalCharges**, **MonthlyCharges** oraz **Tenure**.

Zmienna **MonthlyCharges** oznacza kwotę jaką klient zobowiązany jest zapłacić w danym miesiącu za świadczone usługi. Jej rozkład jest stosunkowo równomierny, z widoczną koncentracją wartości w średnich przedziałach cenowych.

Natomiast w przypadku zmiennej **TotalCharges** rozkład jest silnie prawoskośny, co oznacza że większość klientów zapłaciła stosunkowo niewielkie łączne kwoty, a mniejsza liczba klientów poniosła znacznie wyższe koszty.

Ostatni wykres przedstawia rozkład zmiennej **Tenure** określającej liczbę miesięcy przez które klient korzystał z usług firmy do tej pory. Średnia oraz mediana tej zmiennej wynoszą około 30 miesięcy (zob. tabela 5), co wskazuje, że przeciętny klient pozostaje w firmie przez około 2,5 roku. Rozkład zmiennej sugeruje obecność zarówno klientów o krótkim stażu – obejmujących osoby nowe oraz te, które szybko zrezygnowały z usług – jak i klientów o dłuższym okresie współpracy. Może mieć to istotne znaczenie w dalszej analizie rezygnacji z usług (churn).



Na powyższym wykresie zostały przedstawione rozkłady danych ciągłych na BoxPlotach. Gruba czarna kreska reprezentuje medianę, dolna i górna krawędź słupka odpowiednie kwartyle, a wąsy wartości najmniejsze i największe.


Zmienna **TotalCharges** wykazuje silną prawoskośność. Mediana znajduje się stosunkowo nisko, co sugeruje, że większość klientów wygenerowała dotychczas niewielki przychód skumulowany. Może to wynikać z dużej liczby nowych użytkowników lub klientów korzystających z najtańszych planów taryfowych. Zauważalny jest jednak górny „wąs” wykresu, który sięga poziomu 8000 jednostek, co wskazuje na obecność grupy lojalnych klientów o długim stażu, którzy przynieśli firmie znaczne przychody.

Rozkład zmiennej **MonthlyCharges** jest zbliżony do równomiernego. Pudełko obejmuje zakres od około 35 do 90 jednostek, co odzwierciedla szerokie różnicowanie oferty firmy. Wskazuje to, że baza klientów składa się w podobnym stopniu zarówno z osób wybierających tańsze pakiety podstawowe, jak i z klientów decydujących się na droższe opcje premium.

Wykres zmiennej **Tenure** również pokazuje rozkład równomierny i symetryczny. Oznacza to, że w zbiorze danych znajduje się zrównoważony miks klientów – zarówno nowi użytkownicy o niskim stażu, jak i osoby związane z firmą od wielu lat.

Największą zmiennością charakteryzuje się zmienna **TotalCharges**.





Następne zostały zbadane kształty rozkładu zmiennych ciągłych przy użyciu wykresów gęstości jądrowej, które znajdują się powyżej.

Na pierwszym wykresie (**TotalCharges**) obserwujemy silną prawoskośność, z najwyższym szczytem w okolicy zera. Wskazuje to, że większość klientów to nowi użytkownicy lub osoby generujące niskie rachunki.

Na wykresie **MonthlyCharges** widoczne są dwa szczyty (bimodalny rozkład) – pierwszy przy niskich wartościach (ok. 20 jednostek) reprezentuje klientów korzystających z najtańszych ofert, natomiast drugi, przy ok. 80 jednostek, obejmuje użytkowników wybierających droższe pakiety.

Wykres zmiennej **Tenure** ma również dwa szczyty, co świadczy o dużej liczbie klientów o bardzo krótkim stażu lub takich co szybko zrezygnowali z usług. Na drugim końcu są klienci bardzo lojalni, którzy są z firmą przez długi czas.

Duża ilość klientów płacących dużo miesięcznie sugeruje, że klienci przynoszący firmie największe przychody nie płacą znacząco więcej od innych klientów, lecz duża łączna zapłacona kwota wynika z długiego stażu.

Tabela 6: Liczności dla danych jakościowych (poza PaymentMethod)

|                  |                      |                           |                |
|------------------|----------------------|---------------------------|----------------|
| Gender           | Female: 3488         | Male: 3555                |                |
| SeniorCitizen    | No: 5901             | Yes: 1142                 |                |
| Partner          | No: 3641             | Yes: 3402                 |                |
| Dependents       | No: 4933             | Yes: 2110                 |                |
| PhoneService     | No: 682              | Yes: 6361                 |                |
| MultipleLines    | No: 3390             | No phone service: 682     | Yes: 2971      |
| InternetService  | DSL: 2421            | Fiber optic: 3096         | No: 1526       |
| OnlineSecurity   | No: 3498             | No internet service: 1526 | Yes: 2019      |
| OnlineBackup     | No: 3088             | No internet service: 1526 | Yes: 2429      |
| DeviceProtection | No: 3095             | No internet service: 1526 | Yes: 2422      |
| TechSupport      | No: 3473             | No internet service: 1526 | Yes: 2044      |
| StreamingTV      | No: 2810             | No internet service: 1526 | Yes: 2707      |
| StreamingMovies  | No: 2785             | No internet service: 1526 | Yes: 2732      |
| Contract         | Month-to-month: 3875 | One year: 1473            | Two year: 1695 |
| PaperlessBilling | No: 2872             | Yes: 4171                 |                |
| Churn            | No: 5174             | Yes: 1869                 |                |

Tabela 7: Liczności dla danych jakościowych (PaymentMethod)

| Metoda płatności          | Liczność |
|---------------------------|----------|
| Bank transfer (automatic) | 1544     |
| Credit card (automatic)   | 1522     |
| Electronic check          | 2365     |
| Mailed check              | 1612     |


Powyższe tabele przedstawiają iloczności dla zmiennych jakościowych. Na podstawie zestawień

liczności możemy scharakteryzować bazę klientów oraz wskazać dominujące trendy w poszczególnych segmentach. Struktura demograficzna klientów jest stosunkowo zrównoważona pod względem płci – liczba kobiet i mężczyzn jest niemal identyczna. Jednocześnie zdecydowaną większość stanowią osoby młode i w średnim wieku, podczas gdy seniorzy tworzą wyraźną mniejszość.

Analiza korzystania z usług telekomunikacyjnych pokazuje, że usługi podstawowe są powszechnie wykorzystywane – zdecydowana większość klientów posiada usługę telefoniczną, a znaczna część z nich korzysta również z więcej niż jednej linii. W przypadku internetu najpopularniejszą technologią jest światłowód, który wyprzedza łącza DSL, choć zauważalna jest także grupa klientów niekorzystających z internetu u badanego operatora.

Z perspektywy kontraktowej najczęściej wybieraną formą współpracy jest umowa krótkoterminowa (miesięczna), co wskazuje na dużą elastyczność, ale jednocześnie potencjalnie większe ryzyko rezygnacji. Umowy długoterminowe są wyraźnie mniej popularne.


Istotnym elementem analizy jest wskaźnik rezygnacji (**Churn**), który wynosi około 25%, co oznacza, że ponad jedna czwarta klientów zdecydowała się zakończyć współpracę z operatorem. Pozostała część bazy to klienci lojalni.



Na powyższych wykresach widzimy rozkład klientów względem wyboru umowy oraz metody płatności.

Najczęściej wybieraną formą umowy jest „miesiąc na miesiąc”, co daje klientom większą elastyczność i ułatwia rezygnację, a jednocześnie jest atrakcyjne dla nowych użytkowników, którzy nie chcą wiązać się długoterminowo.

Najczęstszą metodą płatności jest elektroniczny czek, co wskazuje na preferencje klientów względem tradycyjnych, ale wygodnych sposobów regulowania należności.



Na powyższych wykresach obserwujemy podział klientów pod względem posiadania usługi telefonicznej. Widać, że zdecydowana większość klientów decyduje się na tę opcję.


W analizowanym zbiorze danych wyróżniono dwa główne typy usług internetowych:

- DSL (Digital Subscriber Line) – jest to technologia wykorzystująca tradycyjne linie telefoniczne do przesyłu internetu. Charakteryzuje się niższą prędkością oraz zazwyczaj niższą ceną. Jest to rozwiązanie starsze, ale nadal popularne wśród klientów korzystających z podstawowych usług.
- Fiber optic (światłowód) – nowoczesna technologia oparta na światłowodach, umożliwiająca bardzo szybki i stabilny dostęp do internetu. Usługa ta oferuje znacznie wyższe prędkości, ale często wiąże się z wyższymi kosztami abonamentu.

Na wykresie dotyczącym usługi internetowej najczęściej klientów wybiera pakiet Fiber, natomiast nieco mniej osób korzysta z DSL. Istnieje także grupa klientów, którzy nie korzystają z internetu w ramach oferty firmy.


```
plot(dane$MonthlyCharges, dane$TotalCharges,
     main = "Wykres rozrzutu: MonthlyCharges vs TotalCharges",
     cex.main = 0.9,
     xlab = "MonthlyCharges",
     ylab = "TotalCharges",
     pch = 19,
     col = "cornflowerblue",
     cex = 0.7)
# Dodanie linii regresji liniowej
abline(lm(TotalCharges ~ MonthlyCharges, data = dane),
       col = "violetred",
       lwd = 2)
```

Wykres rozrzutu: MonthlyCharges vs TotalCharges




Na pierwszym wykresie można zauważyć liniową zależność między zmiennymi **MonthlyCharges** a **TotalCharges**. Fioletowo-czerwona linia przedstawia linię regresji liniowej, pokazującą ogólny trend wzrostu całkowitych opłat wraz ze wzrostem opłat miesięcznych.

Wykres rozrzutu: Tenure vs TotalCharges



Na drugim wykresie łatwo widoczna jest (oczywista) liniowa zależność między zmiennymi **Tenure**, a **TotalCharges** – miesięczne opłaty klientów są dodatnie, więc im dłużej klient je płaci, tym większa jest ich suma.

Wykres rozrzutu: Tenure vs MonthlyCharges



Na trzecim wykresie przedstawiono zależność między zmiennymi **Tenure**, a **MonthlyCharges**. Wykres nie ujawnia żadnej wyraźnej zależności – wartości **MonthlyCharges** są rozproszone w całym zakresie **Tenure**, co sugeruje, że wysokość miesięcznych opłat nie jest powiązana z długością stażu klienta.

## 4 Analiza opisowa z podziałem na grupy


W następującym etapie przeprowadzamy analizę opisową zmiennych z uwzględnieniem podziału klientów na dwie grupy: osoby, które zrezygnowały z usług (**Churn="Yes"**), oraz klientów lojalnych, kontynuujących korzystanie z oferty firmy (**Churn="No"**).

Na podstawie wskaźników opisowych można zauważyć istotne różnice między klientami, którzy zrezygnowali z usług, a tymi którzy pozostali. Klienci odchodzący charakteryzują się niższą średnią wartością **Tenure**, czyli krótszym stażem w firmie. Jednocześnie ich średnie wartości **TotalCharges** są niższe, co sugeruje mniejsze zaangażowanie finansowe. W przypadku **MonthlyCharges** można zaobserwować wyższe wartości w grupie klientów rezygnujących, co może wskazywać na większą wrażliwość cenową tej grupy.

Tabela 8: Wskaźniki opisowe zmiennych numerycznych wg ‘Churn’

| Zmienna               | Churn=No   | Churn=Yes  |
|-----------------------|------------|------------|
| Tenure_mean           | 37.56997   | 17.97913   |
| Tenure_median         | 38.00000   | 10.00000   |
| Tenure_min            | 0.00000    | 1.00000    |
| Tenure_max            | 72.00000   | 72.00000   |
| Tenure_sd             | 24.11378   | 19.53112   |
| MonthlyCharges_mean   | 61.26512   | 74.44133   |
| MonthlyCharges_median | 64.42500   | 79.65000   |
| MonthlyCharges_min    | 18.25000   | 18.85000   |
| MonthlyCharges_max    | 118.75000  | 118.35000  |
| MonthlyCharges_sd     | 31.09265   | 24.66605   |
| TotalCharges_mean     | 2549.91144 | 1531.79609 |
| TotalCharges_median   | 1679.52500 | 703.55000  |
| TotalCharges_min      | 0.00000    | 18.85000   |
| TotalCharges_max      | 8672.45000 | 8684.80000 |
| TotalCharges_sd       | 2329.95422 | 1890.82299 |


Poniżej znajduje się zestawienie histogramu oraz wykresu pudełkowego pozwalają na szczegółową analizę zależności między wysokością miesięcznego abonamentu (**MonthlyCharges**) a decyzją klienta o rezygnacji z usług (**Churn**).



Wykres pudełkowy wyraźnie wskazuje na różnice pomiędzy analizowanymi grupami. Mediana opłat miesięcznych dla klientów, którzy zrezygnowali z usług (**Churn=Yes**), jest wyższa (przy

około 80 jednostkach) niż w przypadku klientów lojalnych (**Churn=No**), gdzie wynosi około 65 jednostek. Sugeruje to, że wyższy koszt usługi może być istotnym czynnikiem wpływającym na decyzję o odejściu.

Histogram dodatkowo pokazuje, że rezygnacje rzadko występują wśród klientów korzystających z najtańszych pakietów (kosztujących około 20–30 jednostek). Największe zagęszczenie klientów odchodzących obserwuje się w przedziale 70–100 jednostek, co odpowiada najdroższym ofertom. Z kolei klienci pozostający w firmie (**Churn=No**) częściej występują w niższych przedziałach cenowych, co może wskazywać, że niższa cena stanowi istotny czynnik sprzyjający utrzymaniu klienta.




Analogicznie przeanalizowaliśmy zmienną **TotalCharges** w zależności od tego, czy klient zrezygnował z usług firmy (**Churn**).

Z analizy wynika, że całkowita kwota zapłacona przez klientów, którzy odeszli (**Churn=Yes**), jest wyraźnie niższa niż w przypadku klientów pozostających w firmie. Oznacza to, że większość rezygnacji następuje na wczesnym etapie korzystania z usług.

Wynik ten jest spójny z wcześniejszymi obserwacjami – mimo że klienci odchodzący często ponoszą wyższe miesięczne opłaty, korzystają z usług przez krótszy czas, co przekłada się na niższy poziom opłat całkowitych.

Dodatkowo, na wykresie pudełkowym dla grupy klientów rezygnujących widoczne są wartości odstające, oznaczone kolorem ceglistym. Wskazuje to, że wśród osób odchodzących znajdują się również tacy klienci, którzy korzystali z usług przez dłuższy czas i wygenerowali wyższe łączne opłaty, jednak ostatecznie zdecydowali się na rezygnację.






Na wykresach powyżej przedstawiono rozkład zmiennej **Tenure** z podziałem na osoby, które zrezygnowały z usług (**Churn=Yes**) oraz te, które pozostały w firmie (**Churn=No**).

Wśród klientów, którzy odeszli, dominują osoby o krótkim stażu – największa liczba rezygnacji występuje w pierwszych miesiącach korzystania z usług. Jednocześnie bardzo niewielki odsetek klientów odchodzi po dłuższym okresie współpracy.


Z kolei w grupie klientów lojalnych przeważają osoby o długim stażu, co wskazuje na stabilność tej grupy. Potwierdza to również wykres pudełkowy – mediana zmiennej **Tenure** dla klientów, którzy odeszli, jest wyraźnie niższa niż dla klientów pozostających w firmie.

Ilościowe zestawienie rodzaju umowy i Churn



Na powyższym wykresie widać, że odchodzący klienci najczęściej rozliczają się miesiąc do miesiąca, w porównaniu do nieodchodzących klientów u których przeważają kontrakty długoterminowe – roczne oraz dwuroczne.

Rodzaj usług internetowych w grupach Churn



Na wykresie widać, że u rezygnujących klientów dominuje internet światłowodowy.

Na podstawie przeprowadzonej analizy można stwierdzić, że największe zróżnicowanie między grupami klientów występuje zarówno dla zmiennych ilościowych, w szczególności **Tenure**, **MonthlyCharges**, ale także jakościowych takich jak **Contract** oraz **InternetService**.

Zmienna **Tenure** wyraźnie różnicuje klientów – osoby, które zrezygnowały z usług, charakteryzują się krótszym stażem w porównaniu do klientów lojalnych, co wskazuje, że ryzyko odejścia jest największe na początku współpracy.

W przypadku **MonthlyCharges** można zauważyć, że klienci odchodzący ponoszą przeciętnie wyższe miesięczne opłaty, co może świadczyć o większej wrażliwości tej grupy na ceny usług.

Istotne różnice obserwujemy również dla zmiennej **Contract**. Klienci korzystający z umów krótkoterminowych (month-to-month) znacznie częściej rezygnują z usług, niż osoby związane umowami długoterminowymi. Jest to powiązane oczywiście z krótszym stażem odchodzących klientów.

Zmienna **InternetService** także wykazuje zróżnicowanie między grupami – klienci korzystający z internetu światłowodowego częściej rezygnują z usług niż użytkownicy innych technologii, co może wynikać z wyższych kosztów lub oczekiwań względem jakości usługi.

Wymienione zmienne najlepiej pozwalają na rozróżnienie klientów, którzy odchodzą, od tych, którzy pozostają w firmie.

## 5 Podsumowanie – wnioski

Naszym zadaniem było przeanalizowanie bazy danych klientów firmy Telco i możliwego określenia powodów rezygancji z usług tej firmy.

Zauważyliśmy duży podział klientów firmy na krótkotrwałych klientów, będących z firmą krócej niż rok oraz długotrwałych klientów, będących z firmą nawet do trzech lat.

Dowiedzieliśmy się że wśród klientów odchodzących z firmy przeważają klienci z krótszym stażem. Dowiedzieliśmy się też, że wśród odchodzących klientów dominuje usługa internetu światłowodowego. Stąd wnioskujemy, że niezadowolenie z tej usługi może być głównym powodem rezygnacji z usług firmy.

Z analizy wynika także, że odchodzący klienci płacili miesięcznie więcej niż nieodchodzący, co może sugerować że cena mogła być znaczącym czynnikiem wpływającym na decyzję o odejściu.

Stąd można wywnioskować, aby przeciwdziałać odchodzeniu klientów, firma mogłaby obniżyć ceny usług światłowodowych, zachęcając klientów do pozostania i zniechęcając ich do zmiany dostawcy na konkurencyjną firmę.