

Sprawozdanie 1

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-02

Spis treści

1	Wstęp	1
2	Opis danych	2
3	Analiza opisowa	5
4	Analiza opisowa z podziałem na grupy	13
5	Podsumowanie – wnioski	15

1 Wstęp

Głównym celem naszego raportu jest przeanalizowanie bazy danych zawierającej informacje o klientach firmy telekomunikacyjnej w celu przewidzenia ich zachowań związanych z rezygnacją z usług firmy.

Baza danych `Telco-Customer-Churn`, na której będziemy pracować, została pobrana ze strony [Kaggle](#). Jest to fikcyjny zbiór danych zawierający informacje o klientach firmy telekomunikacyjnej świadczącej usługi telefonii stacjonarnej oraz inne usługi telekomunikacyjne w Kalifornii.

2 Opis danych

W analizowanej przez nas bazie danych jest zawartych 21 cech:

Tabela 1: Typy oraz opisy cech

	Typ	Opis
customerID	factor	ID klienta
gender	factor	płeć klienta
SeniorCitizen	integer	czy klient jest seniorem
Partner	factor	czy klient ma partnera
Dependents	factor	czy klient ma osoby na utrzymaniu
tenure	integer	liczba miesięcy w których klient był aktywny
PhoneService	factor	czy klient ma usługi telefoniczne
MultipleLines	factor	czy klient ma wiele linii telefonicznych
InternetService	factor	typ usługi internetowej
OnlineSecurity	factor	czy klient ma usługi bezpieczeństwa w sieci
OnlineBackup	factor	czy klient ma usługę kopii zapasowej online
DeviceProtection	factor	czy klient ma usługę ochrony urządzeń
TechSupport	factor	czy klient ma usługę wsparcia technicznego
StreamingTV	factor	czy klient ma kablówkę
StreamingMovies	factor	czy klient ma usługę streamowania filmów
Contract	factor	okres umowy
PaperlessBilling	factor	czy klient się rozlicza elektronicznie
PaymentMethod	factor	metoda płatności
MonthlyCharges	numeric	miesięczna kwota płatności
TotalCharges	numeric	łączna kwota płatności
Churn	factor	czy klient zrezygnował

Ich wartości dla 7043 przypadków zawartych w bazie prezentują się następująco:

Tabela 2: Podsumowanie danych (1/6)

customerID	gender	SeniorCitizen	Partner	Dependents
0002-ORFBO: 1	Female: 3488	Min.: 0.0000	No: 3641	No: 4933
0003-MKNFE: 1	Male: 3555	1st Qu.: 0.0000	Yes: 3402	Yes: 2110
0004-TLHLJ: 1		Median: 0.0000		
0011-IGKFF: 1		Mean: 0.1621		
0013-EXCHZ: 1		3rd Qu.: 0.0000		
0013-MHZWF: 1		Max.: 1.0000		
(Other): 7037				

Tabela 3: Podsumowanie danych (2/6)

tenure	PhoneService	MultipleLines	InternetService
Min.: 0.00	No: 682	No: 3390	DSL: 2421
1st Qu.: 9.00	Yes: 6361	No phone service: 682	Fiber optic: 3096
Median: 29.00		Yes: 2971	No: 1526
Mean: 32.37			
3rd Qu.: 55.00			
Max.: 72.00			

Tabela 4: Podsumowanie danych (3/6)

OnlineSecurity	OnlineBackup	DeviceProtection
No: 3498	No: 3088	No: 3095
No internet service: 1526	No internet service: 1526	No internet service: 1526
Yes: 2019	Yes: 2429	Yes: 2422

Tabela 5: Podsumowanie danych (4/6)

TechSupport	StreamingTV	StreamingMovies
No: 3473	No: 2810	No: 2785
No internet service: 1526	No internet service: 1526	No internet service: 1526
Yes: 2044	Yes: 2707	Yes: 2732

Tabela 6: Podsumowanie danych (5/6)

Contract	PaperlessBilling	PaymentMethod
Month-to-month: 3875	No: 2872	Bank transfer (automatic): 1544
One year: 1473	Yes: 4171	Credit card (automatic): 1522
Two year: 1695		Electronic check: 2365
		Mailed check: 1612

Tabela 7: Podsumowanie danych (6/6)

MonthlyCharges	TotalCharges	Churn
Min.: 18.25	Min.: 18.8	No: 5174
1st Qu.: 35.50	1st Qu.: 401.4	Yes: 1869
Median: 70.35	Median: 1397.5	

Mean: 64.76	Mean: 2283.3
3rd Qu.: 89.85	3rd Qu.: 3794.7
Max.: 118.75	Max.: 8684.8
	NA's: 11

Powyższe tabele przedstawiają statystyki opisowe dla każdej z analizowanych cech, dzięki czemu możliwe jest wstępne zapoznanie się z danymi oraz identyfikacja podstawowych nieprawidłowości.

W danych występuje cecha `CustomerID`, która jednoznacznie identyfikuje klienta. Ze względów prywatności oraz ponieważ nie wnosi ona informacji istotnych dla analizy zachowań klientów, będziemy chcieli wykluczyć tę kolumnę z dalszej analizy.

Zmienna `SeniorCitizen` pierwotnie była zakodowana wartościami 0 i 1, gdzie 1 oznaczało klienta będącego seniorem. Dla lepszej czytelności i interpretowalności danych zmienimy kodowanie na wartości tekstowe: "No" – klient nie jest seniorem, "Yes" – klient jest seniorem.

Występują braki danych w kolumnie `TotalCharges`. Jest ich 11 i są kodowane za pomocą NA. Można jednak zauważyć, że brak danych w `TotalCharges` jest równoważny czasowi aktywności klienta równemu 0 miesięcy:

```
## Warning in styling_latex_scale(out, table_info, "down"): Longtable cannot be
## resized.
```

Tabela 8: Powiązanie 'tenure=0' z 'TotalCharges=NA'

'tenure=0'	'tenure=0' oraz 'TotalCharges=NA'	'TotalCharges=NA'
11	11	11

Stąd możemy wywnioskować, że kiedy `TotalCharges=NA`, klient po prostu nie zdążył za nic zapłacić, więc łączna zapłacona kwota wynosi w rzeczywistości 0. Dlatego możemy bezpiecznie zamienić wszystkie NA w tej kolumnie na 0.

Z kwestii kosmetycznych, niektóre zmienne są nazwane w inny sposób niż inne – większość nazw zmiennych zaczyna się od dużej litery, ale niektóre zaczynają się od małej litery. Zrobimy więc aby wszystkie zaczynały się od dużej. Zamienimy więc nazwy zmiennych `customerID`, `gender` oraz `tenure` na odpowiednio `CustomerID`, `Gender` i `Tenure`.

Dokonujemy wymienionych wyżej korekt w następujący sposób:

```
# Zmiana nazw zmiennych
names(dane) <- paste0(toupper(substr(names(dane), 1, 1)),
                      substring(names(dane), 2))

# Usunięcie kolumny customerID
dane$CustomerID <- NULL
```

```
# Zmiana typu zmiennej SeniorCitizen na jakościową (i zmiana wartości)
dane$SeniorCitizen <- factor(dane$SeniorCitizen,
                             levels = c(0, 1),
                             labels = c("No", "Yes"))

# Zmiana braków danych w TotalCharges na 0
dane$TotalCharges[is.na(dane$TotalCharges)] <- 0
```

3 Analiza opisowa


Przeprowadzimy analizę opisową, dzięki której poznamy strukturę oraz charakterystykę zmiennych. W ramach tej analizy dokonamy przeglądu poszczególnych cech, analizując ich rozkłady, podstawowe statystyki opisowe oraz identyfikując ewentualne nieprawidłowości.

Tabela 9: Miary położenia i rozproszenia zmiennych ilościowych

	Tenure	MonthlyCharges	TotalCharges
Średnia	32.37	64.76	2279.73
Mediana	29.00	70.35	1394.55
Odchylenie	24.56	30.09	2266.79
Wariancja	603.17	905.41	5138357.17
Min	0.00	18.25	0.00
Q1	9.00	35.50	398.55
Q3	55.00	89.85	3786.60
Max	72.00	118.75	8684.80

Powyższa tabela przedstawia podstawowe statystyki opisowe dla zmiennych ilościowych ciągłych, takie jak średnia, wariancja, wartości minimalne i maksymalne oraz pierwszy i trzeci kwartył.

Na podstawie wstępnej analizy danych można przypuszczać, że w zmiennej **TotalCharges** występują wartości odstające, na co wskazuje zauważalna różnica między średnią a medianą. Ponieważ średnia jest statystyką wrażliwą na wartości odstające, różnica między średnią a medianą sugeruje, że niektóre płatności klientów są znacznie wyższe od typowych. W przypadku pozostałych zmiennych ich rozkłady wydają się być bardziej równomierne, bez wyraźnych oznak obecności wartości ekstremalnych.



Powyższe histogramy przedstawiają rozkład zmiennych **TotalCharges** oraz **MonthlyCharges**.


Zmienna **MonthlyCharges** oznacza kwotę jaką klient zobowiązany jest zapłacić w danym miesiącu za świadczone usługi. Jej rozkład jest stosunkowo równomierny, z widoczną koncentracją wartości w średnich przedziałach cenowych.

Natomiast w przypadku zmiennej **TotalCharges** rozkład jest silnie prawoskośny, co oznacza że większość klientów zapłaciła stosunkowo niewielkie łączne kwoty, a niewielka liczba klientów poniosła znacznie wyższe koszty. Może to sugerować występowanie wartości odstających.

Ostatni wykres przedstawia rozkład zmiennej **Tenure** określającej liczbę miesięcy przez które klient korzystał z usług firmy do tej pory.

Średnia oraz mediana tej zmiennej wynoszą około 30 miesięcy, co wskazuje, że przeciętny klient pozostaje w firmie przez około 2,5 roku. Rozkład zmiennej sugeruje obecność zarówno nowych klientów, jak i tych z dłuższym stażem, co może mieć istotne znaczenie w analizie rezygnacji z usług.

Na wykresie można zauważyć stosunkowo dużą liczbę nowych klientów. Klientów o dłuższym stażu jest natomiast mniej. Może to sugerować, że część klientów rezygnuje z usług firmy na wcześniejszym etapie współpracy, co wskazuje na potencjalnie wyższe ryzyko odejścia wśród nowych klientów.




Na powyższym wykresie zostały przedstawione rozkłady danych ciągłych na boxplotach (nigdzie nie piszemy co oznacza ten wykres może lepiej violin po prostu).

Zmienna **TotalCharges** wykazuje silną prawoskośność (asymetrię dodatnią). Mediana znajduje się stosunkowo nisko, co sugeruje, że większość klientów wygenerowała dotychczas niewielki przychód skumulowany. Może to wynikać z dużej liczby nowych użytkowników lub klientów korzystających z najtańszych planów taryfowych. Zauważalny jest jednak górny „wąs” wykresu, który sięga poziomu 8000 jednostek, co wskazuje na obecność grupy lojalnych klientów o długim stażu, którzy przynieśli firmie znaczne przychody.

Rozkład zmiennej **MonthlyCharges** jest zbliżony do równomiernego. Pudełko obejmuje zakres od około 35 do 90 jednostek, co odzwierciedla szerokie różnicowanie oferty firmy. Wskazuje to, że baza klientów składa się w podobnym stopniu zarówno z osób wybierających tańsze pakiety podstawowe, jak i z klientów decydujących się na droższe opcje premium.

Wykres zmiennej **Tenure** również pokazuje rozkład równomierny i symetryczny. Oznacza to, że w zbiorze danych znajduje się zrównoważony miks klientów: zarówno nowi użytkownicy o niskim stażu, jak i osoby związane z firmą od wielu lat.



Następnie zostały zbadane kształty rozkładu zmiennych ciągłych przy użyciu wykresów gęstości jądrowej.

Na pierwszym wykresie (**TotalCharges**) obserwujemy silną prawoskośność, z najwyższym szczytem w okolicy zera. Wskazuje to, że większość klientów to nowi użytkownicy lub osoby generujące niskie rachunki.

Na wykresie **MonthlyCharges** widoczne są dwa szczyty (bimodalny rozkład): pierwszy przy niskich wartościach (ok. 25 jednostek) reprezentuje klientów korzystających z najtańszych ofert, natomiast drugi, przy ok. 70 jednostek, obejmuje użytkowników wybierających droższe pakiety.

Wykres zmiennej **Tenure** ma również dwa szczyty, co świadczy o dużej liczbie klientów o bardzo krótkim stażu lub takich co szybko zrezygnowali z usług. Na drugim końcu są klienci bardzo lojalni, którzy są z firmą przez długi czas.

Tabela 10: Liczności dla danych jakościowych

Gender	Female:3488	Male :3555	
SeniorCitizen	No :5901	Yes:1142	
Partner	No :3641	Yes:3402	
Dependents	No :4933	Yes:2110	
PhoneService	No : 682	Yes:6361	
MultipleLines	No :3390	No phone service: 682	Yes :2971
InternetService	DSL :2421	Fiber optic:3096	No :1526
OnlineSecurity	No :3498	No internet service:1526	Yes :2019
OnlineBackup	No :3088	No internet service:1526	Yes :2429
DeviceProtection	No :3095	No internet service:1526	Yes :2422
TechSupport	No :3473	No internet service:1526	Yes :2044
StreamingTV	No :2810	No internet service:1526	Yes :2707
StreamingMovies	No :2785	No internet service:1526	Yes :2732
Contract	Month-to-month:3875	One year :1473	Two year :1695
PaperlessBilling	No :2872	Yes:4171	
Churn	No :5174	Yes:1869	

Tabela 11: Liczności dla metod płatności (PaymentMethod)

Metoda płatności	Liczność
Bank transfer (automatic)	1544
Credit card (automatic)	1522
Electronic check	2365
Mailed check	1612


Powyższa tabela przedstawia iloczności dla zmiennych jakościowych.



Na powyższych wykresach widzimy rozkład klientów względem wyboru umowy oraz metody płatności.

Najczęściej wybieraną formą umowy jest „miesiąc na miesiąc”, co daje klientom większą elastyczność i ułatwia rezygnację, a jednocześnie jest atrakcyjne dla nowych użytkowników, którzy nie chcą wiązać się długoterminowo.

Najczęstszą metodą płatności jest elektroniczny czek, co wskazuje na preferencje klientów względem tradycyjnych, ale wygodnych sposobów regulowania należności.



Na powyższych wykresach obserwujemy podział klientów pod względem posiadania usługi


telefonicznej. Widać, że zdecydowana większość klientów decyduje się na tę opcję.

Na wykresie dotyczącym usługi internetowej najczęściej klientów wybiera pakiet Fiber, natomiast nieco mniej osób korzysta z DSL. Istnieje także grupa klientów, którzy nie korzystają z internetu w ramach oferty firmy.

```
plot(dane$MonthlyCharges, dane$TotalCharges,
     main = "Wykres rozrzutu: MonthlyCharges vs TotalCharges",
     xlab = "MonthlyCharges",
     ylab = "TotalCharges",
     pch = 19, col = "blue")

# Dodanie linii regresji liniowej (opcjonalnie)
abline(lm(TotalCharges ~ MonthlyCharges, data = dane), col = "red", lwd = 2)
```


Wykres rozrzutu: MonthlyCharges vs TotalCharges



```
# cor(dane$MonthlyCharges, dane$TotalCharges, use = "complete.obs")
```


Na wykresie (odnośnik) można zauważyć liniową zależność między zmiennymi Monthly Charges a Total Charges. Czerwona linia przedstawia linię regresji liniowej, pokazującą ogólny trend wzrostu całkowitych opłat wraz ze wzrostem opłat miesięcznych.

im dłużej klient, tym większa suma opłat



Na wykresie (odnośnik) można zauważyć liniową zależność między zmiennymi Tenure (liczba miesięcy jako klient) a Total Charges. Czerwona linia przedstawia linię regresji liniowej, pokazującą ogólny trend wzrostu całkowitych opłat wraz ze wzrostem stażu klienta.


Czy starsi klienci p.ac. więcej/mniej miesięcznie?




Na wykresie (odnośnik) przedstawiono zależność między zmiennymi Tenure (liczba miesięcy jako klient) a Monthly Charges. Czerwona linia wskazuje linię regresji liniowej. Warto jednak zauważyć, że wykres nie ujawnia żadnej wyraźnej zależności – wartości Monthly Charges są rozproszone w całym zakresie Tenure, co sugeruje, że wysokość miesięcznych opłat nie zależy od długości stażu klienta.

4 Analiza opisowa z podziałem na grupy



Histogram MonthlyCharges wed.ug Churn





MonthlyCharges wed.ug gru



```
##
##           No      Yes
## Female 0.4926556 0.5024077
## Male   0.5073444 0.4975923
```





I opisać to wszystko podpunkt b z etapu 3

5 Podsumowanie – wnioski