

Sprawozdanie 1

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-01

Spis treści

0.1	Wstęp	1
0.2	Opis danych	1
0.3	Analiza opisowa	4
0.4	Analiza opisowa z podziałem na grupy	13
0.5	Podsumowanie - wnioski	15

0.1 Wstęp

Głównym celem naszego raportu jest przeanalizowanie bazy danych zawierającej informacje o klientach firmy telekomunikacyjnej w celu przewidzenia ich zachowań związanych z rezygnacją z usług firmy.

Baza danych „Telco Customer”, na której będziemy pracować, została pobrana ze strony Kaggle (tu należy wstawić link). Jest to fikcyjny zbiór danych zawierający informacje o klientach firmy telekomunikacyjnej świadczącej usługi telefonii stacjonarnej oraz inne usługi telekomunikacyjne w Kalifornii.

0.2 Opis danych

Tabela 1: Podsumowanie danych (kolumny 1-5)

gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService
Female:3488	No :5901	No :3641	No :4933	Min. : 0.00	No : 682
Male :3555	Yes:1142	Yes:3402	Yes:2110	1st Qu.: 9.00	Yes:6361
				Median :29.00	
				Mean :32.37	
				3rd Qu.:55.00	
				Max. :72.00	

Tabela 2: Podsumowanie danych (kolumny 6-10)

MultipleLines	InternetService	OnlineSecurity	OnlineBackup
No :3390	DSL :2421	No :3498	No :3088
No phone service: 682	Fiber optic:3096	No internet service:1526	No internet service:1526
Yes :2971	No :1526	Yes :2019	Yes :2429

Tabela 3: Podsumowanie danych (kolumny 11-15)

DeviceProtection	TechSupport	StreamingTV	StreamingMovies
No :3095	No :3473	No :2810	No :2785
No internet service:1526	No internet service:1526	No internet service:1526	No internet service:1526
Yes :2422	Yes :2044	Yes :2707	Yes :2732

Tabela 4: Podsumowanie danych (kolumny 16-21)

Contract	PaperlessBilling	PaymentMethod	MonthlyCharges
Month-to-month:3875	No :2872	Bank transfer (automatic):1544	Min. : 18.25
One year :1473	Yes:4171	Credit card (automatic) :1522	1st Qu.: 35.50
Two year :1695		Electronic check :2365	Median : 70.35
		Mailed check :1612	Mean : 64.76
			3rd Qu.: 89.85
			Max. :118.75

Tabela 5: Podsumowanie danych (kolumny 16-21)

TotalCharges	Churn
Min. : 18.8	No :5174
1st Qu.: 401.4	Yes:1869
Median :1397.5	
Mean :2283.3	
3rd Qu.:3794.7	
Max. :8684.8	
NA's :11	

Tabela 6: Typy oraz opisy zmiennych

	Typ	Opis
gender	factor	płeć (K/M)
SeniorCitizen	factor	Senior
Partner	factor	Posiadanie Partnera
Dependents	factor	Finansowa odpowiedzialność
tenure	integer	Licza miesięcy, w których osoba był aktywnym klientem
PhoneService	factor	Czy klient ma usługi telefoniczne
MultipleLines	factor	Czy klient ma wiele linii telefonicznych
InternetService	factor	Firma zapewniająca internet
OnlineSecurity	factor	Czy klient ma bezpieczeństwo w sieci
OnlineBackup	factor	czy ma kopię zapasową
DeviceProtection	factor	Czy ma ochronę urządzeń
TechSupport	factor	Czy ma wsparcie techniczne
StreamingTV	factor	Czy ma pakiet z serwisem stramingowym
StreamingMovies	factor	Czy ma platforme do strmigowania filmów
Contract	factor	Okres umowy
PaperlessBilling	factor	Nie papierowe billingi
PaymentMethod	factor	Metoda płatności
MonthlyCharges	numeric	Miesięczna kwota płatności
TotalCharges	numeric	Całkowita kwota płatności
Churn	factor	Czy jest aktywnym klientem

Analizowana przez nas baza danych zawiera 7043 przypadków oraz 20 cech.

Zmienna SeniorCitizen pierwotnie była zakodowana wartościami 0 i 1, gdzie 1 oznaczało klienta będącego seniorem. Dla lepszej czytelności i interpretowalności danych zmieniono kodowanie na wartości tekstowe: No – klient nie jest seniorem, Yes – klient jest seniorem.

W danych występuje cecha CustomerID, która jednoznacznie identyfikuje klienta. Ze względów prywatności oraz ponieważ nie wnosi ona informacji istotnych dla analizy zachowań klientów, kolumna ta została usunięta z dalszej analizy.

Występują braki danych w kolumnie TotalCharges jest ich 11 i są kodowane za pomocą Na. Na potrzeby analizy zdecydowano się zastąpić wartości NA zerami. Wynika to z charakterystyki zmiennej – TotalCharges oznacza łączną kwotę zapłaconą przez klienta. W przypadku nowych klientów brak tej wartości nie oznacza błędu danych, lecz fakt, że nie zdążyli oni jeszcze dokonać żadnej płatności. Potwierdza to obecność niezerowych wartości w kolumnie MonthlyCharges, która wskazuje bieżące opłaty abonamentowe – kwotę, jaką klient płaci miesięcznie za usługi firmy telekomunikacyjnej.

Dodatkowo uwzględniono zmienną tenure, określającą liczbę miesięcy, przez które klient pozostaje w firmie. Zaobserwowano, że obserwacje z brakującymi wartościami w TotalCharges mają wartość tenure równą 0, co sugeruje, że są to nowi klienci, którzy nie zakończyli jeszcze pierwszego pełnego miesiąca korzystania z usług.

W kolumnie **TotalCharges** mogą występować wartości odstające. Świadczy o tym fakt, że średnia wartość tej zmiennej jest znacznie wyższa od mediany, co wskazuje na możliwą obecność ekstremalnych obserwacji. Ponieważ średnia jest statystyką wrażliwą na wartości odstające, różnica między średnią a medianą sugeruje, że niektóre płatności klientów są znacznie wyższe od typowych.

0.3 Analiza opisowa


Tabela 7: Tabela liczości dla danych jakościowych

gender	Female:3488	Male :3555	
SeniorCitizen	No :5901	Yes:1142	
Partner	No :3641	Yes:3402	
Dependents	No :4933	Yes:2110	
PhoneService	No : 682	Yes:6361	
MultipleLines	No :3390	No phone service: 682	Yes :2971
InternetService	DSL :2421	Fiber optic:3096	No :1526
OnlineSecurity	No :3498	No internet service:1526	Yes :2019
OnlineBackup	No :3088	No internet service:1526	Yes :2429
DeviceProtection	No :3095	No internet service:1526	Yes :2422
TechSupport	No :3473	No internet service:1526	Yes :2044
StreamingTV	No :2810	No internet service:1526	Yes :2707
StreamingMovies	No :2785	No internet service:1526	Yes :2732
Contract	Month-to-month:3875	One year :1473	Two year :1695
PaperlessBilling	No :2872	Yes:4171	
PaymentMethod	Bank transfer (automatic):1544	Credit card (automatic) :1522	Electronic check :2
Churn	No :5174	Yes:1869	


Tabela 8: Miary położenia i rozproszenia zmiennych liczbowych

	tenure	MonthlyCharges	TotalCharges
Srednia	32.37	64.76	2283.30
Mediana	29.00	70.35	1397.47
Odchylenie	24.56	30.09	2266.77
Wariancja	603.17	905.41	5138252.41
Min	0.00	18.25	18.80
Q1	9.00	35.50	401.45
Q3	55.00	89.85	3794.74
Max	72.00	118.75	8684.80


Histogram TotalCharges



Histogram MonthlyCharges




Histogram liczby miesiecy




liczba miesiecy

Histogram TotalCharges




TotalCharges

Histogram MonthlyCharges




MonthlyCharges

Histogram tenure




tenure


Monthly Charges





Total Charges







Kernel Density Plot (ggplot2)







Struktura umów (%)



Internet




Metoda platnosci




Bank transfer (automatic) Electronic check

Wykres rozrzutu: MonthlyCharges vs TotalCharges




[1] 0.6511738


im dluzej klient, tym wieksza suma oplat



Czy starsi klienci placa wiecej/mniej miesiecznie?



Struktura umów (%)



```
##
## \begin{longtable}[t]{lrr}
## \caption{\label{tab:unnamed-chunk-20}Rozkład zmiennej Contract}\\
## \toprule
## Kategoria & Liczebność & Procent (\%)\\
## \midrule
## Month-to-month & 3875 & 55.02\\
## One year & 1473 & 20.91\\
## Two year & 1695 & 24.07\\
## \bottomrule
## \end{longtable}
##
## \begin{longtable}[t]{lrr}
## \caption{\label{tab:unnamed-chunk-20}Rozkład zmiennej gender}\\
## \toprule
## Kategoria & Liczebność & Procent (\%)\\
## \midrule
## Female & 3488 & 49.52\\
## Male & 3555 & 50.48\\
## \bottomrule
## \end{longtable}
##
## \begin{longtable}[t]{lrr}
## \caption{\label{tab:unnamed-chunk-20}Rozkład zmiennej InternetService}\\
## \toprule
## Kategoria & Liczebność & Procent (\%)\\
## \midrule
## DSL & 2421 & 34.37\\
## Fiber optic & 3096 & 43.96\\
```

```


## No & 1526 & 21.67\\
## \bottomrule
## \end{longtable}
##
## \begin{longtable}[t]{lrr}
## \caption{\label{tab:unnamed-chunk-20}Rozkład zmiennej PaymentMethod}\\
## \toprule
## Kategoria & Liczebność & Procent (\%)\\
## \midrule
## Bank transfer (automatic) & 1544 & 21.92\\
## Credit card (automatic) & 1522 & 21.61\\
## Electronic check & 2365 & 33.58\\
## Mailed check & 1612 & 22.89\\
## \bottomrule
## \end{longtable}

```


Dodac opisy tego wszystkiego to jest podpunkt d z etapu 2.

0.4 Analiza opisowa z podziałem na grupy

Histogram MonthlyCharges według Churn





MonthlyCharges według grup





```

##
##           No           Yes
## Female 0.4926556 0.5024077
## Male   0.5073444 0.4975923

```





I opisać to wszystko podpunkt b z etapu 3

0.5 Podsumowanie - wnioski