

Sprawozdanie 2

Eksploatacja danych

Emilia Porczyńska, Michał Szostak

2026-04-20

Spis treści

0.1	Część 1	1
0.2	Część 2	7
0.3	Część 3	11

0.1 Część 1





0.1.1 Wstęp





W pierwszej części raportu naszym celem będzie zdyskretyzować bazę danych zawierającą informacje o wynikach pomiarów dla trzech gatunków irysów. Dane zostały udostępnione przez Ronalda Fishera w 1936 roku.

Baza danych została pobrana z gotowych zbiorów danych w bibliotece datasets w R. Nasze dane pomiary kwiatów takie jak długości szerokości dwóch równych części kwiata, liczba kielicha oraz płatek .

Naszym zadaniem będzie przeanalizowanie cech i wybranie dwóch. Jednej która najlepiej podzieli dane i drugiej która robi to najgorzej. Następnie przeprowadzenie dyskretyzacji dla czterech metod dyskretyzacji nienadzorowanej, przyjmując że liczba klas wynosi 3. Do porównania wykorzystamy algorytmy: equal width, equal frequency, k-means clustering oraz dyskretyzacji na bazie przedziałów zadanych przez uniętnownika.

0.1.2 Opis danych





Najpelsza Petal width a najgorsza Sepal Length

zdania sa podzielone czat mowi ze leiej petal length a geminik ze width rozumeim czemu leght ale jestem za width.

```
## Warning: pakiet 'arules' został zbudowany w wersji R 4.5.3
## Ładowanie wymaganego pakietu: Matrix
##
## Dołączanie pakietu: 'arules'
## Następujące obiekty zostały zakryte z 'package:base':
##
```

```
##      abbreviate, write
```

Terat porownanie 1 metody

```
## podzial_11
```

```
## [4.3,5.5) [5.5,6.7) [6.7,7.9]
```



```
##      52      70      28
```

```
## podzial_12
```



```
## [0.1,0.9) [0.9,1.7) [1.7,2.5]
```

```
##      50      52      48
```

Metoda: interval discretization



Metoda: interval c





TEraz dla kolejnej metody frequency.



```
## podzial_21
## [4.3,5.4) [5.4,6.3) [6.3,7.9]
##          46          53          51

## podzial_22
## [0.1,0.867) [0.867,1.6) [1.6,2.5]
##          50          48          52
```

Metoda: interval discretization



Metoda: interval discretization




Teraz dla metody cluster.




```
## podzial_31
## [4.3,5.33) [5.33,6.27) [6.27,7.9]
```

```
##           46           53           51
## podzial_32
## [0.1,0.785) [0.785,1.69) [1.69,2.5]
##           50           52           48
```

Metoda: interval discretization



Metoda: interval discretization




Teraz dla wlasnego podzialu.




```
## podzial_41
## small medium large
##      52      63      35
## podzial_42
```

```
## small medium large
##      50      52      48
```

Metoda: interval discretization



Metoda: interval discretization



0.2 Część 2

0.2.1 Wstęp


0.2.2 Opis danych

0.2.3 Przygotowanie danych

```
## X UA_Name UA_Country UA_Continent Housing Cost.of.Living Startups
```

## 1 0	Aarhus	Denmark	Europe	6.1315	4.015	2.8270
## 2 1	Adelaide	Australia	Oceania	6.3095	4.692	3.1365
## 3 2	Albuquerque	New Mexico	North America	7.2620	6.059	3.7720
## 4 3	Almaty	Kazakhstan	Asia	9.2820	9.333	2.4585
## 5 4	Amsterdam	Netherlands	Europe	3.0530	3.824	7.9715
## 6 5	Anchorage	Alaska	North America	5.4335	3.141	2.7945
##	Venture.Capital	Travel.Connectivity	Commute	Business.Freedom	Safety	
## 1	2.512	3.5360	6.31175	9.940000	9.6165	
## 2	2.640	1.7765	5.33625	9.399667	7.9260	
## 3	1.493	1.4555	5.05575	8.671000	1.3435	
## 4	0.000	4.5920	5.87125	5.568000	7.3090	
## 5	6.107	8.3245	6.11850	8.836667	8.5035	
## 6	0.000	1.7380	4.71525	8.671000	3.4705	
##	Healthcare	Education	Environmental.Quality	Economy	Taxation	Internet.Access
## 1	8.704333	5.3665	7.63300	4.8865	5.0680	8.3730
## 2	7.936667	5.1420	8.33075	6.0695	4.5885	4.3410
## 3	6.430000	4.1520	7.31950	6.5145	4.3460	5.3960
## 4	4.545667	2.2830	3.85675	5.2690	8.5220	2.8860
## 5	7.907333	6.1800	7.59725	5.0530	4.9550	4.5230
## 6	6.060333	3.6245	9.27200	6.5145	4.7720	4.9645
##	Leisure...Culture	Tolerance	Outdoors			
## 1	3.1870	9.7385	4.1300			
## 2	4.3285	7.8220	5.5310			
## 3	4.8900	7.0285	3.5155			
## 4	2.9370	6.5395	5.5000			
## 5	8.8740	8.3680	5.3070			
## 6	3.2660	7.0930	5.3580			
##	Housing	Cost.of.Living	Startups	Venture.Capital	Travel.Connectivity	Commute
## 1	6.1315	4.015	2.8270	2.512	3.5360	6.31175
## 2	6.3095	4.692	3.1365	2.640	1.7765	5.33625
## 3	7.2620	6.059	3.7720	1.493	1.4555	5.05575
## 4	9.2820	9.333	2.4585	0.000	4.5920	5.87125
## 5	3.0530	3.824	7.9715	6.107	8.3245	6.11850
## 6	5.4335	3.141	2.7945	0.000	1.7380	4.71525
##	Business.Freedom	Safety	Healthcare	Education	Environmental.Quality	Economy
## 1	9.940000	9.6165	8.704333	5.3665	7.63300	4.8865
## 2	9.399667	7.9260	7.936667	5.1420	8.33075	6.0695
## 3	8.671000	1.3435	6.430000	4.1520	7.31950	6.5145
## 4	5.568000	7.3090	4.545667	2.2830	3.85675	5.2690
## 5	8.836667	8.5035	7.907333	6.1800	7.59725	5.0530
## 6	8.671000	3.4705	6.060333	3.6245	9.27200	6.5145
##	Taxation	Internet.Access	Leisure...Culture	Tolerance	Outdoors	
## 1	5.0680	8.3730	3.1870	9.7385	4.1300	
## 2	4.5885	4.3410	4.3285	7.8220	5.5310	

## 3	4.3460	5.3960	4.8900	7.0285	3.5155
## 4	8.5220	2.8860	2.9370	6.5395	5.5000
## 5	4.9550	4.5230	8.8740	8.3680	5.3070
## 6	4.7720	4.9645	3.2660	7.0930	5.3580



0.2.4 Wyznaczanie składowych głównych

##	PC1	PC2	PC3
## Housing	0.30782507	0.05335338	-0.313546491
## Cost.of.Living	0.25960906	-0.17578152	-0.330535177
## Startups	-0.18023854	-0.48344148	0.006099991
## Venture.Capital	-0.23659743	-0.42745094	0.014876825
## Travel.Connectivity	-0.20945432	-0.13530669	-0.339775966
## Commute	-0.11420445	0.02593103	-0.505735874
## Business.Freedom	-0.37728094	0.09821960	0.024104574
## Safety	-0.03893545	0.28710395	-0.333009986
## Healthcare	-0.28035896	0.24194822	-0.281024808
## Education	-0.40256205	-0.04907952	-0.073864482
## Environmental.Quality	-0.32622202	0.25253554	0.053571655
## Economy	-0.27317525	-0.07400327	0.308670514
## Taxation	0.02629917	0.10741513	-0.020184933
## Internet.Access	-0.27619221	0.02270564	0.028441569
## Leisure...Culture	-0.07444660	-0.36473241	-0.305054520
## Tolerance	-0.18974955	0.35509112	-0.102725071
## Outdoors	-0.09158656	-0.19338254	-0.148586789


Najwyższy wskaźnik dla PC1 ma Housing i Cost.of livig więc możemy interpretować tę zmienną jako koszty życia i poziom rozwoju. Następnie PC2 najwyższy wskaźnik dla safety i health care i environmental quality i tolerance więc możemy interpretować tę zmienną jako innowacyjność. Natomiast PC3 najwyższe wartości loading mają economy więc możemy interpretować tę zmienną jako infrastruktura i dostępność / mobilność.

PC1 reprezentuje ogólny poziom życia i koszty utrzymania, z największym wpływem zmiennych Housing i Cost.of.Living.

PC2 odzwierciedla jakość życia oraz poziom innowacyjności, związany ze zmiennymi takimi jak Startups, Venture Capital, Safety i Healthcare.


PC3 można interpretować jako komponent związany z infrastrukturą i mobilnością, ponieważ największe ładunki mają zmienne Commute oraz Travel Connectivity.

0.2.5 Zmienność odpowiadająca poszczególnym składowym




Do wyjaśnienia 80% składowych potrzebne jest 7 zmiennych, natomiast do wyjaśnienia 90% składowych potrzebne jest 10 zmiennych.

0.2.6 Wizualizacja danych wielowymiarowych



Warning: pakiet 'plot3D' został zbudowany w wersji R 4.5.3



0.2.7 Korelacja zmiennych

0.2.8 Końcowe wyniki

0.3 Część 3