

Sprawozdanie 2

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-27

Spis treści

1	Część 1 – dyskretyzacja cech ciągłych	2
1.1	Wstęp	2
1.2	Opis danych i wybór cech	2
1.3	Porównanie metod dyskretyzacji	3
2	Część 2 - Analiza składowych głównych	11
2.1	Wstęp	11
2.2	Opis danych	11
2.3	Przygotowanie danych	11
2.4	Wyznaczanie składowych głównych	14
2.5	Zmienność odpowiadająca poszczególnym składowym	15
2.6	Korelacja zmiennych	18
2.7	Końcowe wyniki	21
3	Część 3	21
3.1	Wstęp	21
3.2	Opis danych	21

1 Część 1 – dyskretyzacja cech ciągłych

1.1 Wstęp

Mamy zbiór danych zawierający wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*).



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

Zbiór danych został udostępniony przez Ronalda Fishera w 1936 roku. Pobieramy go z zestawu gotowych zbiorów dostępnych w pakiecie `datasets` w R.

Naszym pierwszym zadaniem będzie przeanalizowanie własności cech oraz wybranie jednej cechy, która najlepiej rozróżni gatunki kwiatu oraz jednej, która robi to najgorzej.

Następnym naszym zadaniem będzie przeprowadzenie dyskretyzacji wybranych cech na trzy klasy przy użyciu różnych metod dyskretyzacji nienadzorowanej oraz porównanie ich wyników. Będziemy porównywać metody *equal width*, *equal frequency*, *k-means clustering* oraz dyskretyzację na bazie przedziałów zadanych przez użytkownika (przez nas).

1.2 Opis danych i wybór cech

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatka (w cm)
Petal.Width	numeric	szerokość płatka (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)


Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

Wierzmy pomiarom i zakładamy że nie ma błędów. Braki danych nie występują.



Rysunek 2: Pomiary działki kielicha i płatka w zależności od gatunku. W celu polepszenia widoczności, punkty zostały odrobinę losowo rozrzucone.

Jako cechę najlepiej rozróżniającą gatunki wybieramy długość płatka (`Petal.Length`) – wartości dla *Iris setosa* są wyraźnie niższe niż dla pozostałych dwóch gatunków, a *Iris versicolor* i *Iris virginica* również są od siebie dobrze oddzielone. Jako cechę najgorzej rozróżniającą gatunki wybieramy szerokość działki kielicha (`Sepal.Width`) – rozkłady dla wszystkich trzech gatunków silnie się nakładają.

1.3 Porównanie metod dyskretyzacji

Do dokonania dyskretyzacji wykorzystujemy funkcję `discretize` z R-pakietu `arules`. Używamy jej w następujący sposób:

```
discretize(dane$CECHA, method = METODA, breaks = 3)
```

W miejsce **CECHA** wpisujemy identyfikator odpowiedniej cechy, a w miejsce **METODA** identyfikator metody:

- "interval" dla metody *equal width*,
- "frequency" dla metody *equal frequency*,
- "cluster" dla metody *k-means clustering* oraz
- "fixed" dla ręcznego podziału.

W przypadku ostatniej metody, zamiast `breaks = 3` piszemy wektor punktów rozdzielających, przykładowo:

```
discretize(
  dane$Sepal.Width,
  method = "fixed",
  breaks = c(2.0, 2.9, 3.2, 4.4)
)
```

1.3.1 Metoda equal width

Metoda *equal width* daje nam następujące przedziały:


Przedział	Liczność
[1,2.97)	50
[2.97,4.93)	54
[4.93,6.9]	46

Tabela 3: Przedziały dla naszej „dobrej” cechy – długości płatk


Przedział	Liczność
[2,2.8)	47
[2.8,3.6)	88
[3.6,4.4]	15

Tabela 4: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 3: Granice przedziałów dla metody *equal width* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 4: Rozkład gatunków w klasach dyskretyzacji (metoda *equal width*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.97)	[2.97,4.93)	[4.93,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	48	2
<i>virginica</i>	0	6	44

Tabela 5: Wynik podziału dla długości płatk

Gatunek	[2,2.8)	[2.8,3.6)	[3.6,4.4]
<i>setosa</i>	1	36	13
<i>versicolor</i>	27	23	0
<i>virginica</i>	19	29	2

Tabela 6: Wynik podziału dla szerokości działki kielicha

Dzieląc cechę długości płatk (`Petal.Length`) na równe przedziały z bardzo dobrą skutecznością rozdzielamy irysy gatunku *Iris setosa* od pozostałych. Wszystkie kwiaty tego gatunku wpadają w przedział najkrótszej długości oraz nie wpadają do tego przedziału żadne irysy innego gatunku.

W miarę skutecznie rozróżniamy też gatunki *Iris versicolor* i *Iris virginica*, które wpadają zazwyczaj odpowiednio w przedział o średniej długości i przedział o najdłuższej długości. W niektórych przypadkach *Iris versicolor* trafia jednak do przedziału o najdłuższej długości, a *Iris virginica* do przedziału o średniej długości. Więcej razy występuje ten pierwszy przypadek niż drugi.

Jeżeli podzielimy zamiast tego na równe przedziały cechę szerokości działki kielicha (`Sepal.Width`), nie otrzymamy żadnych zadowalających nas rezultatów.

1.3.2 Metoda *equal frequency*

Używając metody *equal frequency*, otrzymujemy przedziały:


Przedział	Liczność
[1,2.63)	50
[2.63,4.9)	49
[4.9,6.9]	51

Tabela 7: Przedziały dla naszej „dobrej” cechy – długości płatka


Przedział	Liczność
[2,2.9)	47
[2.9,3.2)	47
[3.2,4.4]	56

Tabela 8: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 5: Granice przedziałów dla metody *equal frequency* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 6: Rozkład gatunków w klasach dyskretyzacji (metoda *equal frequency*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.63)	[2.63,4.9)	[4.9,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	46	4
<i>virginica</i>	0	3	47

Tabela 9: Wynik podziału dla długości płatk

Gatunek	[2,2.9)	[2.9,3.2)	[3.2,4.4]
<i>setosa</i>	1	11	38
<i>versicolor</i>	27	18	5
<i>virginica</i>	19	18	13

Tabela 10: Wynik podziału dla szerokości działki kielicha

Przedziały dla długości płatk (*Petal.Length*) wychodzą niemal jednakowe jak w przypadku metody *equal width*, w związku z tym wyniki również wychodzą takie same. Skuteczność też się względem nich nie zmienia.

Zauważalną różnicą jest mniejsza różnica między liczbą przedstawicieli *Iris versicolor* trafiających jednak do przedziału o najdłuższej długości, a *Iris virginica* trafiających do przedziału o średniej długości. W pewien sposób można więc uznać te wyniki za lepsze.

Dzieląc szerokość działki kielicha (*Sepal.Width*) uzyskujemy inne przedziały, lecz równie (jak nie bardziej) niesatysfakcjonujące wyniki jak przy metodzie przedziałów równej długości.

1.3.3 Metoda k-means clustering

Metodą *k-means clustering* otrzymujemy takie przedziały:


Przedział	Liczność
[1,2.85)	50
[2.85,4.89)	49
[4.89,6.9]	51

Tabela 11: Przedziały dla naszej „dobrej” cechy – długości płatk


Przedział	Liczność
[2,2.75)	33
[2.75,3.29)	74
[3.29,4.4]	43

Tabela 12: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 7: Granice przedziałów dla metody *k-means clustering* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 8: Rozkład gatunków w klasach dyskretyzacji (metoda *k-means clustering*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.85)	[2.85,4.89)	[4.89,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	46	4
<i>virginica</i>	0	3	47

Tabela 13: Wynik podziału dla długości płatka

Gatunek	[2,2.75)	[2.75,3.29)	[3.29,4.4]
<i>setosa</i>	1	16	33
<i>versicolor</i>	21	27	2
<i>virginica</i>	11	31	8


Tabela 14: Wynik podziału dla szerokości działki kielicha

Dla długości płatka (*Petal.Length*) wyniki wychodzą dokładnie takie same jak w metodzie *equal frequency*.

W przypadku i tej metody, podział po szerokości działki kielicha (*Sepal.Width*) również nie daje zbyt wartościowych wyników.

1.3.4 Podział ręczny

Popatrzmy na rozkład wartości rozważanych cech dla każdego z gatunków:



Rysunek 9: Rozkład wartości cech w podziale na gatunki

Na oko wybieramy dla długości płatka (`Petal.Length`) przedziały $[1, 2.5)$, $[2.5, 4.8)$ oraz $[4.8, 6.9]$.

Dla szerokości działki kielicha (`Sepal.Width`) – choć to ciężkie – wybieramy przedziały $[2, 2.9)$, $[2.9, 3.2)$ i $[3.2, 4.4]$.

Wybrane przedziały dzielą nam zbiór danych na klasy o następującej liczności:


Przedział	Liczność
$[1, 2.5)$	50
$[2.5, 4.8)$	45
$[4.8, 6.9]$	55

Tabela 15: Przedziały dla naszej „dobrej” cechy – długości płatka


Przedział	Liczność
$[2, 2.9)$	47
$[2.9, 3.2)$	47
$[3.2, 4.4]$	56

Tabela 16: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki dyskretyzacji prezentują się tak:



Rysunek 10: Granice przedziałów dla podziału ręcznego naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 11: Rozkład gatunków w klasach dyskretyzacji (podział ręczny). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.5)	[2.5,4.8)	[4.8,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	44	6
<i>virginica</i>	0	1	49

Tabela 17: Wynik podziału dla długości płatków

Gatunek	[2,2.9)	[2.9,3.2)	[3.2,4.4]
<i>setosa</i>	1	11	38
<i>versicolor</i>	27	18	5
<i>virginica</i>	19	18	13

Tabela 18: Wynik podziału dla szerokości działki kielicha

W podziale długości płatków (*Petal.Length*) wybrane przez nas przedziały nie przewyższają skutecznością wcześniejszych metod. Liczba „pomyłek” jest mniej więcej taka sama.

W podziale szerokości działki kielicha (*Sepal.Width*) – w przeciwieństwie do poprzednich metod – udało nam się uzyskać jakikolwiek wartościowy efekt, a mianowicie udało nam się

rozdzielić *Iris setosa* od pozostałych gatunków – zdecydowana większość przedstawicieli tego gatunku trafia do trzeciego przedziału.

Pozostałe dwa gatunki zbyt się jednak pokrywają tą cechą aby można je było rozróżnić.

1.3.5 Podsumowanie

Cecha długości płatk (Petal.Length) na tyle dobrze rozróżnia rozważane gatunki kwiatów, że niezależnie od wyboru metody otrzymamy bardzo dobry wynik. Za pomocą większości metod jesteśmy w stanie z pełną skutecznością rozdzielić irysy gatunku *Iris setosa* od *Iris versicolor* i *Iris virginica*. Żadna metoda nie pozwala nam jednak na całkowite rozdzielanie dwóch ostatnich gatunków. Być może dyskretyzacja w oparciu na cechę będącą jakąś funkcją od bazowych cech pozwoliłaby na lepszy wynik.

Żadna metoda nie pozwoliła na rozróżnienie gatunków na podstawie cechy szerokości działki kielicha (Sepal.Width). Pokazuje to że ograniczając zbiór danych możemy stracić informacje których żadnym algorytmem nie będziemy w stanie odzyskać.

2 Część 2 - Analiza składowych głównych

2.1 Wstęp

W części drugiej będziemy pracować na zbiorze danych pobranych na stronie Kaagle (tu link). Baza danych W Kaggle została pobrana ze strony Teleport.org zawiera informacje o jakości życia najbardziej kreatywnych miast na całym świecie, co pozwala osobom znaleźć odpowiednie dla nich miasto do życia. Naszym celem będzie redukcja wymiaru cech ... (tu nwm co jeszcze)

2.2 Opis danych

Dane zawierają 21 zmiennych oraz 266 wystąpień. Zbiór danych zawiera wskaźniki opisujące jakość życia w wybranych miastach, w tym m.in. takie charakterystyki jak: warunki mieszkaniowe, koszty utrzymania, bezpieczeństwo, opieka zdrowotna, edukacja itp. Wszystkie cechy ilościowe przyjmują wartości w zakresie 0 - 10, im wyższa wartość tym lepszy wynik. Zbiór danych zawiera również zmienne jakościowe takie jak Nazwa miasta, kraju oraz kontynentu na jakim się znajdują posłużą nam do lepszej interpretacji wyników.

2.3 Przygotowanie danych

Zmienna Id została usunięta jako nie istotna do dalszej analizy również w celu wyznaczenia składowych głównych użyto tylko zmiennych ilościowych.

##	Housing	Cost.of.Living	Startups	Venture.Capital
##	Min. : 0.000	Min. : 0.000	Min. : 0.000	Min. : 0.000
##	1st Qu.: 5.149	1st Qu.: 4.795	1st Qu.: 3.098	1st Qu.: 0.000
##	Median : 6.726	Median : 5.630	Median : 4.214	Median : 2.317

```

## Mean      : 6.467      Mean      : 5.746      Mean      : 4.595      Mean      : 2.703
## 3rd Qu.: 8.313      3rd Qu.: 7.596      3rd Qu.: 5.790      3rd Qu.: 3.765
## Max.      :10.000      Max.      :10.000      Max.      :10.000      Max.      :10.000
## Travel.Connectivity      Commute      Business.Freedom      Safety
## Min.      : 0.500      Min.      :0.000      Min.      : 0.000      Min.      : 1.343
## 1st Qu.: 1.703      1st Qu.:4.400      1st Qu.: 5.771      1st Qu.: 5.972
## Median : 2.921      Median :5.064      Median : 8.404      Median : 7.189
## Mean      : 3.447      Mean      :4.632      Mean      : 7.331      Mean      : 6.972
## 3rd Qu.: 4.766      3rd Qu.:5.613      3rd Qu.: 8.837      3rd Qu.: 8.269
## Max.      :10.000      Max.      :6.729      Max.      :10.000      Max.      :10.000
## Healthcare      Education      Environmental.Quality      Economy
## Min.      :0.000      Min.      :0.000      Min.      :1.000      Min.      :0.000
## 1st Qu.:6.064      1st Qu.:2.184      1st Qu.:4.329      1st Qu.:4.103
## Median :6.780      Median :4.273      Median :6.481      Median :5.373
## Mean      :6.797      Mean      :3.835      Mean      :6.078      Mean      :5.058
## 3rd Qu.:8.055      3rd Qu.:5.294      3rd Qu.:7.888      3rd Qu.:6.514
## Max.      :9.321      Max.      :9.711      Max.      :9.953      Max.      :9.390
## Taxation      Internet.Access      Leisure...Culture      Tolerance
## Min.      : 0.500      Min.      :1.000      Min.      : 0.000      Min.      :1.406
## 1st Qu.: 3.921      1st Qu.:4.134      1st Qu.: 4.448      1st Qu.:5.780
## Median : 4.760      Median :5.379      Median : 5.707      Median :7.154
## Mean      : 4.953      Mean      :5.205      Mean      : 5.710      Mean      :6.793
## 3rd Qu.: 5.955      3rd Qu.:6.265      3rd Qu.: 7.062      3rd Qu.:8.052
## Max.      :10.000      Max.      :9.716      Max.      :10.000      Max.      :9.739
## Outdoors
## Min.      :0.500
## 1st Qu.:3.699
## Median :4.733
## Mean      :4.493
## 3rd Qu.:5.500
## Max.      :7.933

```

Powyższej tabeli znajdują się statystyki opisowe danych ilościowych (tu zastanawiam się czy dawać wszystkie czy tylko część) zbór danych nie zawiera żadnych braków danych po jest widoczne na poniższej tabeli.

```

## Housing      Cost.of.Living      Startups
##           0           0           0
## Venture.Capital      Travel.Connectivity      Commute
##           0           0           0
## Business.Freedom      Safety      Healthcare
##           0           0           0
## Education      Environmental.Quality      Economy
##           0           0           0
## Taxation      Internet.Access      Leisure...Culture
##           0           0           0

```


```
##          Tolerance          Outdoors
##          0          0

##          UA_Name          UA_Country          UA_Continent
## Birmingham : 2 United Kingdom: 13 Africa : 8
## Portland : 2 Canada : 11 Asia : 37
## Aarhus : 1 Germany : 11 Europe :111
## Adelaide : 1 France : 9 North America: 87
## Albuquerque: 1 Spain : 7 Oceania : 8
## Almaty : 1 Italy : 6 South America: 15
## (Other) :258 (Other) :209


## [1] 264
```

Następnie analizując dane jakościowe można ze mamy informacje o miastach znajdujących się na 6 kontynentach bez Antarktydy (gdzie m=nie ma miast (chyba)). Powyższa tabela wskazała nam że najwięcej miast mamy z Europy następnie z Ameryki Południowej. Łącznie mamy informacje o 264 miastach oraz o 135 Państwach co świadczy o dużej różnorodności.

Następnie w celu poprawnego wyznaczenia składowych głównych musimy sprawdzić zmienność poszczególnych cech tzn. czy wariancja naszych cech ilościowych jest podobna. Wartości wariancji znajduje się na wykresie poniżej.



Widzimy, że wariancja dla różnych cech jest inna, przez co konieczna jest standaryzacja. Wynik tego działania znajduje się na poniższym wykresie.



2.4 Wyznaczanie składowych głównych

Następnie wyznaczmy składowe główne naszych zmiennych, używając funkcji `prcomp()`.

tu z czatu definicja

Celem wyznaczenia składowych głównych (PCA, Principal Component Analysis) jest redukcja wymiarowości danych przy jednoczesnym zachowaniu jak największej części informacji zawartej w zmiennych pierwotnych. Metoda ta polega na przekształceniu oryginalnych, często skorelowanych zmiennych w nowy zestaw nieskorelowanych zmiennych (składowych głównych), które są liniowymi kombinacjami zmiennych wejściowych.

Pierwsza składowa główna wyjaśnia największą możliwą część wariancji danych, a każda kolejna maksymalizuje wyjaśnianą wariancję przy założeniu ortogonalności względem poprzednich. Dzięki temu możliwe jest uproszczenie struktury danych oraz identyfikacja głównych wzorców i zależności w zbiorze danych.

##	PC1	PC2	PC3
## Housing	0.30782507	0.05335338	-0.313546491
## Cost.of.Living	0.25960906	-0.17578152	-0.330535177
## Startups	-0.18023854	-0.48344148	0.006099991
## Venture.Capital	-0.23659743	-0.42745094	0.014876825
## Travel.Connectivity	-0.20945432	-0.13530669	-0.339775966
## Commute	-0.11420445	0.02593103	-0.505735874
## Business.Freedom	-0.37728094	0.09821960	0.024104574
## Safety	-0.03893545	0.28710395	-0.333009986
## Healthcare	-0.28035896	0.24194822	-0.281024808
## Education	-0.40256205	-0.04907952	-0.073864482
## Environmental.Quality	-0.32622202	0.25253554	0.053571655
## Economy	-0.27317525	-0.07400327	0.308670514
## Taxation	0.02629917	0.10741513	-0.020184933
## Internet.Access	-0.27619221	0.02270564	0.028441569
## Leisure...Culture	-0.07444660	-0.36473241	-0.305054520

## Tolerance	-0.18974955	0.35509112	-0.102725071
## Outdoors	-0.09158656	-0.19338254	-0.148586789

Najwyższy wskaźnik dla PC1 ma Housing i Cost.of livig wiec mmozemy interpretowac ta zmienna jako koszty zycia i poziom rozwoju. Nastepnie PC2 najwyzszy wskaźnik dla safety i health care i enviromental quality i tolerance wiec mozemy interpretowac ta zmienna jako innowacyjnosc . Natomiast PC3 najwyze wartosci loading maja ecomony wiec mozemy interpretowac ta zmienna jako frastruktura i dostępność / mobilność.

PC1 reprezentuje ogólny poziom rozwoju społeczno-gospodarczego oraz jakości życia, gdzie przeciwstawione są koszty życia (np. housing) i rozwój instytucjonalny (np. edukacja, środowisko, gospodarka).


PC2 odzwierciedla kontrast między innowacyjnością gospodarczą a jakością życia i czynnikami społecznymi (bezpieczeństwo, tolerancja, kultura).

PC3 można interpretować jako komponent związany z mobilnością, kosztami życia oraz dostępnością infrastruktury, z pewnym udziałem czynnika gospodarczego.


2.5 Zmienność odpowiadająca poszczególnym składowym

Następnie naszym celem będzie sprawdzenie jaki procent waraincji odpowiada poszczególnym składowym.

NA ponizszym wykresie znajduje sie wariancja poszczególnych składowych. Zgodnie z oczekiwaniami wariancje maleja wraz z dalchz składowa główna.



Skumulowana wariancja (w %)




Aby móc odpowiedzieć na pytanie, ile składowych głównych jest potrzebnych do wyjaśnienia 80% oraz 90% całkowitej zmienności. Wykonano wykres powyżej z zaznaczonymi poziomami odpowiednio 80 % i 90%. Na podstawie tego wykresu można wyznaczyć liczbę składowych potrzebnych do wyjaśnienia odpowiednich wartości procentowej wariancji.

Do wyjaśnienia 80% składowych potrzebne jest 7 zmiennych, natomiast do wyjaśnienia 90% składowych potrzebne jest 10 zmiennych.

2.5.1 Wizualizacja danych wielowymiarowych

PCA - kontynenty



Widzimy, że dane są szeroko rozpięte na osi poziomej, co sugeruje ogromne różnice w poziomie

rozwoju miast:

- **Europa (kolor zielony):** Miasta europejskie są rozproszone, ale znacząca ich część koncentruje się w lewej i centralnej części wykresu (wartości ujemne i bliskie zeru na PC1). Jeśli PC1 reprezentuje wysoki koszt życia skorelowany z wysokim rozwojem, to te miasta stanowią “główny nurt” rozwiniętych aglomeracji.
- **Afryka (kolor czerwony):** Są to najbardziej skrajne punkty po prawej stronie osi PC1 (wartości dodatnie). Oznacza to, że miasta afrykańskie znacząco odstają od reszty świata pod względem ogólnego poziomu rozwoju instytucjonalnego i gospodarczego ujętego w tym komponencie.

2.5.2 2. Zróżnicowanie wzdłuż osi PC2 (Innowacyjność vs. Bezpieczeństwo i Kultura)


Oś pionowa pokazuje kontrast między miastami stawiającymi na “twardą” gospodarkę a tymi, które oferują wyższą jakość życia społecznego:

- **Ameryka Północna (kolor jasnoniebieski):** Większość punktów znajduje się w dolnej części wykresu (wartości ujemne PC2). Sugeruje to, że miasta te charakteryzują się specyficznym profilem, gdzie czynniki społeczne (bezpieczeństwo, tolerancja) mogą wypadać relatywnie słabiej w stosunku do innowacyjności gospodarczej, lub odwrotnie – zależy to od dokładnego kierunku wektorów cech (loadings).
- **Europa (kolor zielony):** Wiele miast europejskich znajduje się w górnej części osi PC2. Może to świadczyć o ich wysokich wynikach w kategoriach bezpieczeństwa, kultury i tolerancji w porównaniu do miast z innych kontynentów o podobnym poziomie rozwoju gospodarczego.


2.5.3 3. Skupiska i “Outliery”

- **Azja (kolor żółty):** Wykazuje bardzo duży rozrzut na obu osiach. Oznacza to, że azjatyckie miasta są skrajnie niejednorodne – mamy tam zarówno potężne, rozwinięte centra, jak i miasta o znacznie niższym standardzie życia.
- **Oceania (kolor ciemnoniebieski):** Tworzy dość zwartą grupę w lewym górnym kwadrancie (niskie/średnie PC1, wysokie PC2), co sugeruje, że miasta te łączą stabilny rozwój gospodarczy z bardzo wysoką jakością życia i bezpieczeństwem.

PCA - Afryka vs reszta





CA 3D - Kontrasty regionalne: Europa i Afryka






2.6 Korelacja zmiennych

wykres korelacji tak o

```
variables <- get_pca_var(pca_dane)
corrplot(variables$cor)
```





2.7 Końcowe wyniki

3 Część 3

3.1 Wstęp

3.2 Opis danych