

Sprawozdanie 2

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-27

Spis treści

1	Część 1 – dyskretyzacja cech ciągłych	2
2	Część 2 - Analiza składowych głównych	2
2.1	Wstęp	2
2.2	Opis danych	2
2.3	Przygotowanie danych	2
2.4	Wyznaczanie składowych głównych	6
2.5	Zmienność odpowiadająca poszczególnym składowym	7
2.6	Korelacja zmiennych	11
2.7	Końcowe wyniki	14
3	Część 3	14
3.1	Wstęp	14
3.2	Opis danych	14

1 Część 1 – dyskretyzacja cech ciągłych

Tymczasowo w osobnym pliku żeby się szybciej kompilowało.

2 Część 2 - Analiza składowych głównych

2.1 Wstęp

W części drugiej będziemy pracować na zbiorze danych pobranych na stronie Kaagle (tu link). Baza danych W Kaggle została pobrana ze strony Teleport.org zawiera informacje o jakości życia najbardziej kreatywnych miast na całym świecie, co pozwala osobom znaleźć odpowiednie dla nich miasto do życia. Naszym celem będzie redukcja wymiaru cech ... (tu nwm co jeszcze)

2.2 Opis danych

Dane zawierają 21 zmiennych oraz 266 wystąpień. Zbiór danych zawiera wskaźniki opisujące jakość życia w wybranych miastach, w tym m.in. takie charakterystyki jak: warunki mieszkaniowe, koszty utrzymania, bezpieczeństwo, opieka zdrowotna, edukacja itp. Wszystkie cechy ilościowe przyjmują wartości w zakresie 0 - 10, im wyższa wartość tym lepszy wynik. Zbiór danych zawiera również zmienne jakościowe takie jak Nazwa miasta, kraju oraz kontynentu na jakim się znajdują posłużą nam do lepszej interpretacji wyników.

2.3 Przygotowanie danych

Zmienna Id została usunięta jako nie istotna do dalszej analizy również w celu wyznaczenia składowych głównych użyto tylko zmiennych ilościowych.

Housing	Cost.of.Living	Startups	Venture.Capital	Travel.Connectivity
Min.: 0.000	Min.: 0.000	Min.: 0.000	Min.: 0.000	Min.: 0.500
1st Qu.: 5.149	1st Qu.: 4.795	1st Qu.: 3.098	1st Qu.: 0.000	1st Qu.: 1.703
Median: 6.726	Median: 5.630	Median: 4.214	Median: 2.317	Median: 2.921
Mean: 6.467	Mean: 5.746	Mean: 4.595	Mean: 2.703	Mean: 3.447
3rd Qu.: 8.313	3rd Qu.: 7.596	3rd Qu.: 5.790	3rd Qu.: 3.765	3rd Qu.: 4.766
Max.: 10.000	Max.: 10.000	Max.: 10.000	Max.: 10.000	Max.: 10.000

Tabela 1: Podsumowanie cech ilościowych

Commute	Business.Freedom	Safety	Healthcare
Min.: 0.000	Min.: 0.000	Min.: 1.343	Min.: 0.000
1st Qu.: 4.400	1st Qu.: 5.771	1st Qu.: 5.972	1st Qu.: 6.064
Median: 5.064	Median: 8.404	Median: 7.189	Median: 6.780
Mean: 4.632	Mean: 7.331	Mean: 6.972	Mean: 6.797
3rd Qu.: 5.613	3rd Qu.: 8.837	3rd Qu.: 8.269	3rd Qu.: 8.055
Max.: 6.729	Max.: 10.000	Max.: 10.000	Max.: 9.321

Education	Environmental.Quality	Economy	Taxation
Min.: 0.000	Min.: 1.000	Min.: 0.000	Min.: 0.500
1st Qu.: 2.184	1st Qu.: 4.329	1st Qu.: 4.103	1st Qu.: 3.921
Median: 4.273	Median: 6.481	Median: 5.373	Median: 4.760
Mean: 3.835	Mean: 6.078	Mean: 5.058	Mean: 4.953
3rd Qu.: 5.294	3rd Qu.: 7.888	3rd Qu.: 6.514	3rd Qu.: 5.955
Max.: 9.711	Max.: 9.953	Max.: 9.390	Max.: 10.000

Internet.Access	Leisure...Culture	Tolerance	Outdoors
Min.: 1.000	Min.: 0.000	Min.: 1.406	Min.: 0.500
1st Qu.: 4.134	1st Qu.: 4.448	1st Qu.: 5.780	1st Qu.: 3.699
Median: 5.379	Median: 5.707	Median: 7.154	Median: 4.733
Mean: 5.205	Mean: 5.710	Mean: 6.793	Mean: 4.493
3rd Qu.: 6.265	3rd Qu.: 7.062	3rd Qu.: 8.052	3rd Qu.: 5.500
Max.: 9.716	Max.: 10.000	Max.: 9.739	Max.: 7.933

Powyzszj tabeli znajduj sie sattystyki opisowe danych ilocowych (tu zastanawiam sie czy dawac wszystkie czy tylko czesc) zbr danych nie zawiera adnych brakw danych po jest widoczne na poniszej tabeli.

Cecha	Liczba braków
Housing	0
Cost.of.Living	0
Startups	0
Venture.Capital	0
Travel.Connectivity	0
Commute	0
Business.Freedom	0
Safety	0
Healthcare	0
Education	0
Environmental.Quality	0
Economy	0
Taxation	0
Internet.Access	0
Leisure...Culture	0
Tolerance	0
Outdoors	0


Tabela 2: Liczba braków danych w cechach ilościowych

Kontynent	Liczba miast
Europe	111
North America	87
Asia	37
South America	15
Africa	8
Oceania	8

Tabela 3: Liczba miast w podziale na kontynenty


Następnie analizując dane jakościowe można że mamy informacje o miastach znajdujących się na 6 kontynentach bez Antarktydy (gdzie m=nie ma miast (chyba)). Powyższa tabela wskazała nam że najwięcej miast mamy z Eurpy następnie z Ameryki Połnocem. Łącznie mamy informacje o 264 miastach oraz o 135 Państwach co świadczy o dużej różnorodności.

Następnie w celu poprawnego wyznaczenia składowych głównych musimy sprawdzić zmienność poszczególnych cech tzn. czy wariancja naszych cech ilościowych jest podobna. Wartości wariancji znajduje się na wykresie poniżej.



Rysunek 1: Rozkład wartości poszczególnych cech ilościowych przed standaryzacją

Widzimy, że wariancja dla różnych cech jest inna, przez co konieczna jest standaryzacja. Wynik tego działania znajduje się na poniższym wykresie.



Rysunek 2: Rozkład wartości poszczególnych cech ilościowych po standaryzacji

2.4 Wyznaczanie składowych głównych

Następnie wyznaczmy składowe główne naszych zmiennych, używając funkcji `prcomp()`.

tu z czatu definicja

Celem wyznaczenia składowych głównych (PCA, Principal Component Analysis) jest redukcja wymiarowości danych przy jednoczesnym zachowaniu jak największej części informacji zawartej w zmiennych pierwotnych. Metoda ta polega na przekształceniu oryginalnych, często skorelowanych zmiennych w nowy zestaw nieskorelowanych zmiennych (składowych głównych), które są liniowymi kombinacjami zmiennych wejściowych.

Pierwsza składowa główna wyjaśnia największą możliwą część wariancji danych, a każda kolejna maksymalizuje wyjaśnianą wariancję przy założeniu ortogonalności względem poprzednich. Dzięki temu możliwe jest uproszczenie struktury danych oraz identyfikacja głównych wzorców i zależności w zbiorze danych.

	PC1	PC2	PC3
Housing	0.308	0.053	-0.314
Cost.of.Living	0.260	-0.176	-0.331
Startups	-0.180	-0.483	0.006
Venture.Capital	-0.237	-0.427	0.015
Travel.Connectivity	-0.209	-0.135	-0.340
Commute	-0.114	0.026	-0.506
Business.Freedom	-0.377	0.098	0.024
Safety	-0.039	0.287	-0.333
Healthcare	-0.280	0.242	-0.281
Education	-0.403	-0.049	-0.074
Environmental.Quality	-0.326	0.253	0.054
Economy	-0.273	-0.074	0.309
Taxation	0.026	0.107	-0.020
Internet.Access	-0.276	0.023	0.028
Leisure...Culture	-0.074	-0.365	-0.305
Tolerance	-0.190	0.355	-0.103
Outdoors	-0.092	-0.193	-0.149

Tabela 4: Współczynniki (loadings) trzech pierwszych składowych głównych

Najwyższy wskaźnik dla PC1 ma Housing i Cost.of livig więc możemy interpretować tę zmienną jako koszty życia i poziom rozwoju. Następnie PC2 najwyższy wskaźnik dla safety i health care i environmental quality i tolerance więc możemy interpretować tę zmienną jako innowacyjność. Natomiast PC3 najwyższe wartości loading mają economy więc możemy interpretować tę zmienną jako infrastruktura i dostępność / mobilność.

PC1 reprezentuje ogólny poziom rozwoju społeczno-gospodarczego oraz jakości życia, gdzie przeciwstawione są koszty życia (np. housing) i rozwój instytucjonalny (np. edukacja, środowisko, gospodarka).


PC2 odzwierciedla kontrast między innowacyjnością gospodarczą a jakością życia i czynnikami społecznymi (bezpieczeństwo, tolerancja, kultura).

PC3 można interpretować jako komponent związany z mobilnością, kosztami życia oraz dostępnością infrastruktury, z pewnym udziałem czynnika gospodarczego.


2.5 Zmienność odpowiadająca poszczególnym składowym

Następnie naszym celem będzie sprawdzenie jaki procent wariancji odpowiada poszczególnym składowym.

Na poniższym wykresie znajduje się wariancja poszczególnych składowych. Zgodnie z oczekiwaniami wariancje maleją wraz z dalszą składową główną.



Rysunek 3: Wariacje poszczególnych składowych głównych




Rysunek 4: Skumulowana wariancja (w %) wyjaśniana przez kolejne składowe główne

Aby móc odpowiedzieć na pytanie, ile składowych głównych jest potrzebnych do wyjaśnienia 80% oraz 90% całkowitej zmienności. Wykonano wykres powyżej z zaznaczonymi poziomami odpowiednio 80 % i 90%. Na podstawie tego wykresu można wyznaczyć liczbę składowych potrzebnych do wyjaśnienia odpowiednich wartości procentowej wariancji.

Do wyjaśnienia 80% składowych potrzebne jest 7 zmiennych, natomiast do wyjaśnienia 90% składowych potrzebne jest 10 zmiennych.

2.5.1 Wizualizacja danych wielowymiarowych



Rysunek 5: Rzut danych na dwie pierwsze składowe główne, kolory wg kontynentu

Widzimy, że dane są szeroko rozpięte na osi poziomej, co sugeruje ogromne różnice w poziomie rozwoju miast:

- **Europa (kolor zielony):** Miasta europejskie są rozproszone, ale znacząca ich część koncentruje się w lewej i centralnej części wykresu (wartości ujemne i bliskie zeru na PC1). Jeśli PC1 reprezentuje wysoki koszt życia skorelowany z wysokim rozwojem, to te miasta stanowią “główny nurt” rozwiniętych aglomeracji.
- **Afryka (kolor czerwony):** Są to najbardziej skrajne punkty po prawej stronie osi PC1 (wartości dodatnie). Oznacza to, że miasta afrykańskie znacząco odstają od reszty świata pod względem ogólnego poziomu rozwoju instytucjonalnego i gospodarczego ujętego w tym komponentcie.

2.5.2 2. Zróżnicowanie wzdłuż osi PC2 (Innowacyjność vs. Bezpieczeństwo i Kultura)


Oś pionowa pokazuje kontrast między miastami stawiającymi na “twardą” gospodarkę a tymi, które oferują wyższą jakość życia społecznego:

- **Ameryka Północna (kolor jasnoniebieski):** Większość punktów znajduje się w dolnej części wykresu (wartości ujemne PC2). Sugeruje to, że miasta te charakteryzują się specyficznym profilem, gdzie czynniki społeczne (bezpieczeństwo, tolerancja) mogą wypadać relatywnie słabiej w stosunku do innowacyjności gospodarczej, lub odwrotnie – zależy to od dokładnego kierunku wektorów cech (loadings).
- **Europa (kolor zielony):** Wiele miast europejskich znajduje się w górnej części osi PC2. Może to świadczyć o ich wysokich wynikach w kategoriach bezpieczeństwa, kultury i


tolerancji w porównaniu do miast z innych kontynentów o podobnym poziomie rozwoju gospodarczego.

2.5.3 3. Skupiska i “Outliery”

- **Azja (kolor żółty):** Wykazuje bardzo duży rozrzut na obu osiach. Oznacza to, że azjatyckie miasta są skrajnie niejednorodne – mamy tam zarówno potężne, rozwinięte centra, jak i miasta o znacznie niższym standardzie życia.
- **Oceania (kolor ciemnoniebieski):** Tworzy dość zwartą grupę w lewym górnym kwadrancie (niskie/średnie PC1, wysokie PC2), co sugeruje, że miasta te łączą stabilny rozwój gospodarczy z bardzo wysoką jakością życia i bezpieczeństwem.




Rysunek 6: Rzut danych na dwie pierwsze składowe główne – Afryka na tle pozostałych kontynentów




Rysunek 7: Rzut danych na trzy pierwsze składowe główne – wyróżnione: Europa i Ameryka Północna

2.6 Korelacja zmiennych


wykres korelacji tak o




Rysunek 8: Korelacje cech ze składowymi głównymi




Rysunek 9: Macierz korelacji cech ilościowych



Rysunek 10: Biplot PCA – 10 cech o największym wkładzie



Rysunek 11: Biplot PCA z podziałem obserwacji wg kontynentu



Rysunek 12: Biplot PCA z elipsami ufności (95%) dla kontynentów

2.7 Końcowe wyniki

3 Część 3

3.1 Wstęp

3.2 Opis danych