

Sprawozdanie 2

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-27

Spis treści

1	Część 1 – dyskretyzacja cech ciągłych	2
2	Część 2 - Analiza składowych głównych	2
3	Część 3 - Skalowanie wielowymiarowe (MDS)	2
3.1	Wstęp	2
3.2	Opis danych	2
3.3	Redukcja wymiaru na bazie MDS	4
3.4	Wizualizacja danych	4
3.5	Podsumowanie	4

1 Część 1 – dyskretyzacja cech ciągłych

Tymczasowo w osobnym pliku żeby się szybciej kompilowało.

2 Część 2 - Analiza składowych głównych

Tymczasowo w osobnym pliku żeby się szybciej kompilowało.

3 Część 3 - Skalowanie wielowymiarowe (MDS)

3.1 Wstęp

W ostatniej części raportu wykonaliśmy skalowanie wielowymiarowe na danych, które zawierają wybrane charakterystyki opisujące pasażerów Titanica.

tuatj opis tego czym jest to skalownaie mds

3.2 Opis danych

Zbiór danych zawiera informacje o pasażerach Titanica między innymi takie jak: wiek, płeć, miejsce rozpoczęcia podróży oraz klasa pasażerska. Ważna zmienna występująca w bazie danych jest zmienna Survived, która informuje nas czy dana osoba przeżyła katastrofę czy nie. Dane zawierają 891 informacji o różnych pasażerach oraz 12 cech które ich opisują.

Typy zmiennych które po wczytaniu danych były wczytane jako charact zmieniliśmy na factor są to zmienne takie jak Name, Sex, Ticket, Cabin oraz undefined. Zmienną Pclass zmieniono na zmienną porządkową.

	Typ	Opis
PassengerId	integer	ID pasażera
Survived	integer	Czy przeżył
Pclass	ordered, factor	Numer klasy
Name	factor	Imię pasażera
Sex	factor	Płeć
Age	numeric	Wiek
SibSp	integer	Liczba rodzeństwa oraz małżonków podróżujących z pasażerem
Parch	integer	Liczba rodziców oraz dzieci podróżujących z pasażerem
Ticket	factor	Numer biletu
Fare	numeric	Opłata za bilet
Cabin	factor	Numer kabiny
Embarked	factor	Port zaokrętowania pasażera

Tabela 1: Typy oraz opisy cech

Z danych zostały usunięte zmienne takie jak PassengerId, Name oraz Ticket, które nie wniosą nic do naszej analizy. Są to indywidualne dane każdego pasażera w celu ochrony danych zostaną one usunięte z dalszej analizy.

	Liczba_NA	Liczba_puste_pozycje
Survived	0	0
Pclass	0	0
Sex	0	0
Age	177	0
SibSp	0	0
Parch	0	0
Fare	0	0
Cabin	0	687
Embarked	0	2

Tabela 2: Braki danych w zbiorze

Zmienna cabin zawiera aż 687 braków w danych, więc nie będziemy jej uwzględniać w dalszej analizie, również z tego powodu że pełniła funkcję identyfikatora. Natomiast zmienna Age zawiera 177 braków w tym przypadku nie będziemy się decydować na usunięcie tej zmiennej tylko zastąpimy te braki medianą z pozostałych wartości Age, również nie decydujemy się na opcję usunięcia wierszy z tymi brakami, ponieważ stanowią one prawie 20% danych. Natomiast braki w zmiennej Embarked, która oznaczała port w którym wsiadł pasażer, błędy uzupełnimy najczęstszą opcją jak pojawia się w danych.

```
##      Survived      Pclass      Sex      Age      SibSp
##  Min.       :0.0000   1:216  female:314  Min.       : 0.42  Min.       :0.000
## 1st Qu.:0.0000   2:184   male  :577 1st Qu.:22.00 1st Qu.:0.000
## Median :0.0000   3:491                      Median :28.00 Median :0.000
## Mean   :0.3838                      Mean   :29.36 Mean   :0.523
## 3rd Qu.:1.0000                      3rd Qu.:35.00 3rd Qu.:1.000
## Max.    :1.0000                      Max.    :80.00 Max.    :8.000
##      Parch      Fare      Embarked
##  Min.       :0.0000  Min.       : 0.00      : 2
## 1st Qu.:0.0000 1st Qu.: 7.91 C:168
## Median :0.0000 Median :14.45 Q: 77
## Mean   :0.3816 Mean   :32.20 S:644
## 3rd Qu.:0.0000 3rd Qu.:31.00
## Max.    :6.0000 Max.    :512.33
```

W tabeli powyżej znajdują się statystyki opisowe zmiennych oraz liczności wystąpień poszczególnych kategorii w zmiennych jakościowych.

3.3 Redukcja wymiaru na bazie MDS

3.4 Wizualizacja danych

3.5 Podsumowanie