

Sprawozdanie 2

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-27

Spis treści

1	Część 1 – dyskretyzacja cech ciągłych	2
1.1	Wstęp	2
1.2	Opis danych i wybór cech	2
1.3	Porównanie metod dyskretyzacji	3
2	Część 2	8
2.1	Wstęp	8
2.2	Opis danych	8
2.3	Przygotowanie danych	8
2.4	Wyznaczanie składowych głównych	10
2.5	Zmienność odpowiadająca poszczególnym składowym	11
2.6	Korelacja zmiennych	12
2.7	Końcowe wyniki	14
3	Część 3	14
3.1	Wstęp	14
3.2	Opis danych	14

1 Część 1 – dyskretyzacja cech ciągłych

1.1 Wstęp

Mamy zbiór danych zawierający wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*).



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

Zbiór danych został udostępniony przez Ronalda Fishera w 1936 roku. Pobieramy go z zestawu gotowych zbiorów dostępnych w pakiecie `datasets` w R.

Naszym pierwszym zadaniem będzie przeanalizowanie własności cech oraz wybranie jednej cechy, która najlepiej rozróżni gatunki kwiatu oraz jednej, która robi to najgorzej.

Następnym naszym zadaniem będzie przeprowadzenie dyskretyzacji wybranych cech na trzy klasy przy użyciu różnych metod dyskretyzacji nienadzorowanej oraz porównanie ich wyników. Będziemy porównywać metody *equal width*, *equal frequency*, *k-means clustering* oraz dyskretyzację na bazie przedziałów zadanych przez użytkownika (przez nas).

1.2 Opis danych i wybór cech

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatka (w cm)
Petal.Width	numeric	szerokość płatka (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)


Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

Wierzmy pomiarom i zakładamy że nie ma błędów. Braki danych nie występują.



Rysunek 2: Pomiary działki kielicha i płatka w zależności od gatunku. W celu polepszenia widoczności, punkty zostały odrobinę losowo rozrzucone.

Jako cechę najlepiej rozróżniającą gatunki wybieramy długość płatka (`Petal.Length`) — wartości dla *setosa* są wyraźnie niższe niż dla pozostałych dwóch gatunków, a *versicolor* i *virginica* również są od siebie dobrze oddzielone. Jako cechę najgorzej rozróżniającą gatunki wybieramy szerokość działki kielicha (`Sepal.Width`) — rozkłady dla wszystkich trzech gatunków silnie się nakładają.

1.3 Porównanie metod dyskretyzacji

Do dokonania dyskretyzacji wykorzystujemy funkcję `discretize` z R-pakietu `arules`. Używamy jej w następujący sposób:

```
discretize(dane$CECHA, method = METODA, breaks = 3)
```

W miejsce `CECHA` wpisujemy identyfikator odpowiedniej cechy, a w miejsce `METODA` identyfikator metody — `"interval"` dla metody *equal width*, `"frequency"` dla metody *equal frequency*,

"cluster" dla metody *k-means clustering* oraz "fixed" dla ręcznego podziału.

W przypadku ostatniej metody, zamiast `breaks = 3` piszemy wpisujemy wektor punktów rozdzielających, oraz podajemy dodatkowo wektor ich etykiet w parametrze `labels`, na przykład:

```
discretize(
  dane$Sepal.Width,
  method = "fixed",
  breaks = c(-Inf, 2.9, 3.2, Inf),
  labels = c("wąska", "średna", "szeroka")
)
```

1.3.1 Metoda equal width


Metoda *equal width* daje nam następujące przedziały:

Przedział	Liczność
[2,2.8)	47
[2.8,3.6)	88
[3.6,4.4]	15

Tabela 3: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Przedział	Liczność
[1,2.97)	50
[2.97,4.93)	54
[4.93,6.9]	46

Tabela 4: Przedziały dla naszej „dobrej” cechy – długości płatk




Rysunek 3: Granice przedziałów dla metody equal width naniesione na wartości cech

TODO tekst: skomentować mosaic ploty – czy klasy dyskretyzacji pokrywają się z gatunkami. Dla `Petal.Length` powinno być prawie idealnie, dla `Sepal.Width` fatalnie.

1.3.2 Metoda equal frequency

INFO: równa liczność przedziałów. Granice wybiera się tak, żeby w każdej klasie była $\sim 1/3$ obserwacji (kwantyle). Plus: zawsze zbalansowane. Minus: granice mogą



Rysunek 4: Rozkład gatunków w klasach dyskretyzacji (metoda equal width)

wypaść w dziwnych miejscach względem rozkładu.


TODO tekst: porównać z equal width – tutaj licznosci mają być bliskie 50/50/50.

Przedział	Licznosc
[2,2.9)	47
[2.9,3.2)	47
[3.2,4.4]	56

Tabela 5: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Przedział	Licznosc
[1,2.63)	50
[2.63,4.9)	49
[4.9,6.9]	51


Tabela 6: Przedziały dla naszej „dobrej” cechy – długości płatków



Rysunek 5: Granice przedziałów dla metody equal frequency naniesione na wartości cech

1.3.3 Metoda k-means clustering

INFO: granice wyznacza algorytm k-means na 1D. Algorytm próbuje znaleźć skupiska w danych. Plus: granice idą tam gdzie są przerwy w danych. Minus: zależy od inicjalizacji, może dawać różne wyniki przy różnych uruchomieniach.



Rysunek 6: Rozkład gatunków w klasach dyskretyzacji (metoda equal frequency)


TODO tekst: skomentować, czy granice trafiły w naturalne przerwy między gatunkami (zwłaszcza dla Petal.Length, gdzie jest oczywista przerwa setosa vs reszta).

Przedział	Liczność
[2,2.85)	47
[2.85,3.44)	78
[3.44,4.4]	25

Tabela 7: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Przedział	Liczność
[1,2.95)	50
[2.95,5.13)	66
[5.13,6.9]	34


Tabela 8: Przedziały dla naszej „dobrej” cechy – długości płatków



Rysunek 7: Granice przedziałów dla metody k-means clustering naniesione na wartości cech

1.3.4 Podział ręczny

INFO: granice wybrane przez nas ręcznie: Sepal.Width: $c(-\text{Inf}, 2.9, 3.2, \text{Inf})$ — próba podziału na “wąskie/średnie/szerokie” działki. Petal.Length: $c(-\text{Inf}, 2.5, 5.0, \text{Inf})$ — granice tak dobrane, żeby możliwie oddzielić setosa | versicolor | virginica.



Rysunek 8: Rozkład gatunków w klasach dyskretyzacji (metoda k-means clustering)

Etykiety klas to “wąski/średni/szeroki” (Sepal.Width) i “krótki/średni/długi” (Petal.Length) zamiast nazw przedziałów.


TODO tekst: uzasadnić wybór granic, porównać efekt z metodami automatycznymi. Dla Petal.Length nasz podział pewnie wypadnie najlepiej (bo wybraliśmy go pod gatunki), dla Sepal.Width i tak słabo (cecha jest zła do rozróżniania).

Przedział	Liczność
wąska	47
średna	47
szeroka	56


Tabela 9: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Przedział	Liczność
krótka	50
średna	54
długa	46

Tabela 10: Przedziały dla naszej „dobrej” cechy – długości płatków



Rysunek 9: Granice przedziałów dla podziału ręcznego naniesione na wartości cech



Rysunek 10: Rozkład gatunków w klasach dyskretyzacji (podział ręczny)

1.3.5 Podsumowanie

TODO tekst: porównać 4 metody w 2-3 zdaniach. Spodziewamy się że dla Petal.Length wszystkie metody radzą sobie dobrze (cecha sama dobrze rozdziela gatunki), a dla Sepal.Width żadna nie pomoże (overlap rozkładów jest z natury duży). Można wskazać która metoda dała najbardziej zbalansowane klasy a która najlepsze pokrycie z gatunkami.

2 Część 2


2.1 Wstęp

2.2 Opis danych

2.3 Przygotowanie danych

```
## X      UA_Name  UA_Country UA_Continent Housing Cost.of.Living Startups
## 1 0      Aarhus    Denmark      Europe  6.1315          4.015    2.8270
## 2 1    Adelaide  Australia    Oceania  6.3095          4.692    3.1365
## 3 2 Albuquerque New Mexico North America  7.2620          6.059    3.7720
## 4 3      Almaty  Kazakhstan    Asia   9.2820          9.333    2.4585
## 5 4    Amsterdam Netherlands    Europe  3.0530          3.824    7.9715
## 6 5    Anchorage    Alaska North America  5.4335          3.141    2.7945
## Venture.Capital Travel.Connectivity Commute Business.Freedom Safety
## 1          2.512              3.5360 6.31175          9.940000 9.6165
## 2          2.640              1.7765 5.33625          9.399667 7.9260
## 3          1.493              1.4555 5.05575          8.671000 1.3435
## 4          0.000              4.5920 5.87125          5.568000 7.3090
## 5          6.107              8.3245 6.11850          8.836667 8.5035
## 6          0.000              1.7380 4.71525          8.671000 3.4705
## Healthcare Education Environmental.Quality Economy Taxation Internet.Access
```


## 1	8.704333	5.3665	7.63300	4.8865	5.0680	8.3730
## 2	7.936667	5.1420	8.33075	6.0695	4.5885	4.3410
## 3	6.430000	4.1520	7.31950	6.5145	4.3460	5.3960
## 4	4.545667	2.2830	3.85675	5.2690	8.5220	2.8860
## 5	7.907333	6.1800	7.59725	5.0530	4.9550	4.5230
## 6	6.060333	3.6245	9.27200	6.5145	4.7720	4.9645
##	Leisure...Culture Tolerance Outdoors					
## 1	3.1870	9.7385	4.1300			
## 2	4.3285	7.8220	5.5310			
## 3	4.8900	7.0285	3.5155			
## 4	2.9370	6.5395	5.5000			
## 5	8.8740	8.3680	5.3070			
## 6	3.2660	7.0930	5.3580			
##	Housing Cost.of.Living Startups Venture.Capital Travel.Connectivity Commute					
## 1	6.1315	4.015	2.8270	2.512	3.5360	6.31175
## 2	6.3095	4.692	3.1365	2.640	1.7765	5.33625
## 3	7.2620	6.059	3.7720	1.493	1.4555	5.05575
## 4	9.2820	9.333	2.4585	0.000	4.5920	5.87125
## 5	3.0530	3.824	7.9715	6.107	8.3245	6.11850
## 6	5.4335	3.141	2.7945	0.000	1.7380	4.71525
##	Business.Freedom Safety Healthcare Education Environmental.Quality Economy					
## 1	9.940000	9.6165	8.704333	5.3665	7.63300	4.8865
## 2	9.399667	7.9260	7.936667	5.1420	8.33075	6.0695
## 3	8.671000	1.3435	6.430000	4.1520	7.31950	6.5145
## 4	5.568000	7.3090	4.545667	2.2830	3.85675	5.2690
## 5	8.836667	8.5035	7.907333	6.1800	7.59725	5.0530
## 6	8.671000	3.4705	6.060333	3.6245	9.27200	6.5145
##	Taxation Internet.Access Leisure...Culture Tolerance Outdoors					
## 1	5.0680	8.3730	3.1870	9.7385	4.1300	
## 2	4.5885	4.3410	4.3285	7.8220	5.5310	
## 3	4.3460	5.3960	4.8900	7.0285	3.5155	
## 4	8.5220	2.8860	2.9370	6.5395	5.5000	
## 5	4.9550	4.5230	8.8740	8.3680	5.3070	
## 6	4.7720	4.9645	3.2660	7.0930	5.3580	



2.4 Wyznaczanie składowych głównych

##	PC1	PC2	PC3
## Housing	0.30782507	0.05335338	-0.313546491
## Cost.of.Living	0.25960906	-0.17578152	-0.330535177
## Startups	-0.18023854	-0.48344148	0.006099991
## Venture.Capital	-0.23659743	-0.42745094	0.014876825
## Travel.Connectivity	-0.20945432	-0.13530669	-0.339775966
## Commute	-0.11420445	0.02593103	-0.505735874
## Business.Freedom	-0.37728094	0.09821960	0.024104574
## Safety	-0.03893545	0.28710395	-0.333009986
## Healthcare	-0.28035896	0.24194822	-0.281024808
## Education	-0.40256205	-0.04907952	-0.073864482
## Environmental.Quality	-0.32622202	0.25253554	0.053571655
## Economy	-0.27317525	-0.07400327	0.308670514
## Taxation	0.02629917	0.10741513	-0.020184933
## Internet.Access	-0.27619221	0.02270564	0.028441569
## Leisure...Culture	-0.07444660	-0.36473241	-0.305054520
## Tolerance	-0.18974955	0.35509112	-0.102725071
## Outdoors	-0.09158656	-0.19338254	-0.148586789


Najwyższy wskaźnik dla PC1 ma Housing i Cost.of livig wiec mmozemy interpretowac ta zmienna jako koszty zycia i poziom rozwoju. Nastepnie PC2 najwyższy wskaźnik dla safety i health care i enviromental quality i tolerance wiec mozemy interpretowac ta zmienna jako innowacyjnosc . Natomiast PC3 najwyżze wartosci loading maja economy wiec mozemy interpretowac ta zmienna jako frastruktura i dostępność / mobilność.

PC1 reprezentuje ogólny poziom życia i koszty utrzymania, z największym wpływem zmiennych Housing i Cost.of.Living.

PC2 odzwierciedla jakość życia oraz poziom innowacyjności, związany ze zmiennymi takimi jak Startups, Venture Capital, Safety i Healthcare.


PC3 można interpretować jako komponent związany z infrastrukturą i mobilnością, ponieważ największe ładunki mają zmienne Commute oraz Travel Connectivity.


2.5 Zmienność odpowiadająca poszczególnym składowym



Do wyjaśnienia 80% składowych potrzebne jest 7 zmiennych, natomiast do wyjaśnienia 90% składowych potrzebne jest 10 zmiennych.

2.5.1 Wizualizacja danych wielowymiarowych







2.6 Korelacja zmiennych


wykres korelacji tak o

```
variables <- get_pca_var(pca_dane)
corrplot(variables$cor)
```







PCA - Biplot



PCA - Biplot





2.7 Końcowe wyniki

3 Część 3

3.1 Wstęp

3.2 Opis danych