

# Sprawozdanie 2

## Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-30


### Spis treści

|          |                                                           |           |
|----------|-----------------------------------------------------------|-----------|
| <b>1</b> | <b>Część 1 – dyskretyzacja cech ciągłych</b>              | <b>2</b>  |
| 1.1      | Wstęp . . . . .                                           | 2         |
| 1.2      | Opis danych i wybór cech . . . . .                        | 2         |
| 1.3      | Porównanie metod dyskretyzacji . . . . .                  | 3         |
| <b>2</b> | <b>Część 2 - Analiza składowych głównych</b>              | <b>11</b> |
| 2.1      | Wstęp . . . . .                                           | 11        |
| 2.2      | Przygotowanie danych . . . . .                            | 11        |
| 2.3      | Wyznaczanie składowych głównych . . . . .                 | 15        |
| 2.4      | Zmienność odpowiadająca poszczególnym składowym . . . . . | 17        |
| 2.5      | Korelacja zmiennych . . . . .                             | 21        |
| 2.6      | Końcowe wyniki . . . . .                                  | 23        |
| <b>3</b> | <b>Część 3 - Skalowanie wielowymiarowe (MDS)</b>          | <b>23</b> |
| 3.1      | Wstęp . . . . .                                           | 23        |
| 3.2      | Przygotowanie danych . . . . .                            | 24        |
| 3.3      | Redukcja wymiaru na bazie MDS . . . . .                   | 26        |
| 3.4      | Wizualizacja danych . . . . .                             | 28        |
| 3.5      | Podsumowanie . . . . .                                    | 30        |

# 1 Część 1 – dyskretyzacja cech ciągłych

## 1.1 Wstęp

Mamy zbiór danych zawierający wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*).



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

Zbiór danych został udostępniony przez Ronalda Fishera w 1936 roku. Pobieramy go z zestawu gotowych zbiorów dostępnych w pakiecie `datasets` w R.

Naszym pierwszym zadaniem będzie przeanalizowanie własności cech oraz wybranie jednej cechy, która najlepiej rozróżni gatunki kwiatu oraz jednej, która robi to najgorzej.

Następnym naszym zadaniem będzie przeprowadzenie dyskretyzacji wybranych cech na trzy klasy przy użyciu różnych metod dyskretyzacji nienadzorowanej oraz porównanie ich wyników. Będziemy porównywać metody *equal width*, *equal frequency*, *k-means clustering* oraz dyskretyzację na bazie przedziałów zadanych przez użytkownika (przez nas).

## 1.2 Opis danych i wybór cech

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

|              | Typ     | Opis                                                                   |
|--------------|---------|------------------------------------------------------------------------|
| Sepal.Length | numeric | długość działki kielicha (w cm)                                        |
| Sepal.Width  | numeric | szerokość działki kielicha (w cm)                                      |
| Petal.Length | numeric | długość płatka (w cm)                                                  |
| Petal.Width  | numeric | szerokość płatka (w cm)                                                |
| Species      | factor  | gatunek irysa ( <i>setosa</i> / <i>versicolor</i> / <i>virginica</i> ) |


Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

| Sepal.Length   | Sepal.Width    | Petal.Length   | Petal.Width    |
|----------------|----------------|----------------|----------------|
| Min.: 4.300    | Min.: 2.000    | Min.: 1.000    | Min.: 0.100    |
| 1st Qu.: 5.100 | 1st Qu.: 2.800 | 1st Qu.: 1.600 | 1st Qu.: 0.300 |
| Median: 5.800  | Median: 3.000  | Median: 4.350  | Median: 1.300  |
| Mean: 5.843    | Mean: 3.057    | Mean: 3.758    | Mean: 1.199    |
| 3rd Qu.: 6.400 | 3rd Qu.: 3.300 | 3rd Qu.: 5.100 | 3rd Qu.: 1.800 |
| Max.: 7.900    | Max.: 4.400    | Max.: 6.900    | Max.: 2.500    |

Tabela 2: Podsumowanie danych

Wierzmy pomiarom i zakładamy że nie ma błędów. Braki danych nie występują.



Rysunek 2: Pomiary działki kielicha i płatka w zależności od gatunku. W celu polepszenia widoczności, punkty zostały odrobinę losowo rozrzucone.

Jako cechę najlepiej rozróżniającą gatunki wybieramy długość płatka (`Petal.Length`) – wartości dla *Iris setosa* są wyraźnie niższe niż dla pozostałych dwóch gatunków, a *Iris versicolor* i *Iris virginica* również są od siebie dobrze oddzielone. Jako cechę najgorzej rozróżniającą gatunki wybieramy szerokość działki kielicha (`Sepal.Width`) – rozkłady dla wszystkich trzech gatunków silnie się nakładają.

### 1.3 Porównanie metod dyskretyzacji

Do dokonania dyskretyzacji wykorzystujemy funkcję `discretize` z R-pakietu `arules`. Używamy jej w następujący sposób:

```
discretize(dane$CECHA, method = METODA, breaks = 3)
```

W miejsce CECHA wpisujemy identyfikator odpowiedniej cechy, a w miejsce METODA identyfikator metody:

- "interval" dla metody *equal width*,
- "frequency" dla metody *equal frequency*,
- "cluster" dla metody *k-means clustering* oraz
- "fixed" dla ręcznego podziału.

W przypadku ostatniej metody, zamiast `breaks = 3` piszemy wektor punktów rozdzielających, przykładowo:

```
discretize(
  dane$Sepal.Width,
  method = "fixed",
  breaks = c(2.0, 2.9, 3.2, 4.4)
)
```

### 1.3.1 Metoda equal width

Metoda *equal width* daje nam następujące przedziały:


| Przedział   | Liczność |
|-------------|----------|
| [1,2.97)    | 50       |
| [2.97,4.93) | 54       |
| [4.93,6.9]  | 46       |

Tabela 3: Przedziały dla naszej „dobrej” cechy – długości płatk


| Przedział | Liczność |
|-----------|----------|
| [2,2.8)   | 47       |
| [2.8,3.6) | 88       |
| [3.6,4.4] | 15       |

Tabela 4: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 3: Granice przedziałów dla metody *equal width* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału  $[0, 1]$  w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 4: Rozkład gatunków w klasach dyskretyzacji (metoda *equal width*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

| Gatunek           | [1,2.97) | [2.97,4.93) | [4.93,6.9] |
|-------------------|----------|-------------|------------|
| <i>setosa</i>     | 50       | 0           | 0          |
| <i>versicolor</i> | 0        | 48          | 2          |
| <i>virginica</i>  | 0        | 6           | 44         |

Tabela 5: Wynik podziału dla długości płatk

| Gatunek           | [2,2.8) | [2.8,3.6) | [3.6,4.4] |
|-------------------|---------|-----------|-----------|
| <i>setosa</i>     | 1       | 36        | 13        |
| <i>versicolor</i> | 27      | 23        | 0         |
| <i>virginica</i>  | 19      | 29        | 2         |

Tabela 6: Wynik podziału dla szerokości działki kielicha

Dzieląc cechę długości płatk (`Petal.Length`) na równe przedziały z bardzo dobrą skutecznością rozdzielamy irysy gatunku *Iris setosa* od pozostałych. Wszystkie kwiaty tego gatunku wpadają w przedział najkrótszej długości oraz nie wpadają do tego przedziału żadne irysy innego gatunku.

W miarę skutecznie rozróżniamy też gatunki *Iris versicolor* i *Iris virginica*, które wpadają zazwyczaj odpowiednio w przedział o średniej długości i przedział o najdłuższej długości. W niektórych przypadkach *Iris versicolor* trafia jednak do przedziału o najdłuższej długości, a *Iris virginica* do przedziału o średniej długości. Więcej razy występuje ten pierwszy przypadek niż drugi.

Jeżeli podzielimy zamiast tego na równe przedziały cechę szerokości działki kielicha (`Sepal.Width`), nie otrzymamy żadnych zadowalających nas rezultatów.

### 1.3.2 Metoda *equal frequency*

Używając metody *equal frequency*, otrzymujemy przedziały:


| Przedział  | Liczność |
|------------|----------|
| [1,2.63)   | 50       |
| [2.63,4.9) | 49       |
| [4.9,6.9]  | 51       |

Tabela 7: Przedziały dla naszej „dobrej” cechy – długości płatka


| Przedział | Liczność |
|-----------|----------|
| [2,2.9)   | 47       |
| [2.9,3.2) | 47       |
| [3.2,4.4] | 56       |

Tabela 8: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 5: Granice przedziałów dla metody *equal frequency* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału  $[0, 1]$  w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 6: Rozkład gatunków w klasach dyskretyzacji (metoda *equal frequency*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

| Gatunek           | [1,2.63) | [2.63,4.9) | [4.9,6.9] |
|-------------------|----------|------------|-----------|
| <i>setosa</i>     | 50       | 0          | 0         |
| <i>versicolor</i> | 0        | 46         | 4         |
| <i>virginica</i>  | 0        | 3          | 47        |

Tabela 9: Wynik podziału dla długości płatk

| Gatunek           | [2,2.9) | [2.9,3.2) | [3.2,4.4] |
|-------------------|---------|-----------|-----------|
| <i>setosa</i>     | 1       | 11        | 38        |
| <i>versicolor</i> | 27      | 18        | 5         |
| <i>virginica</i>  | 19      | 18        | 13        |

Tabela 10: Wynik podziału dla szerokości działki kielicha

Przedziały dla długości płatk (**Petal.Length**) wychodzą niemal jednakowe jak w przypadku metody *equal width*, w związku z tym wyniki również wychodzą takie same. Skuteczność też się względem nich nie zmienia.

Zauważalną różnicą jest mniejsza różnica między liczbą przedstawicieli *Iris versicolor* trafiających jednak do przedziału o najdłuższej długości, a *Iris virginica* trafiających do przedziału o średniej długości. W pewien sposób można więc uznać te wyniki za lepsze.

Dzieląc szerokość działki kielicha (**Sepal.Width**) uzyskujemy inne przedziały, lecz równie (jak nie bardziej) niesatysfakcjonujące wyniki jak przy metodzie przedziałów równej długości.

### 1.3.3 Metoda k-means clustering

Metodą *k-means clustering* otrzymujemy takie przedziały:


| Przedział   | Liczność |
|-------------|----------|
| [1,2.95)    | 50       |
| [2.95,5.13) | 66       |
| [5.13,6.9]  | 34       |

Tabela 11: Przedziały dla naszej „dobrej” cechy – długości płatk


| Przedział   | Liczność |
|-------------|----------|
| [2,3.02)    | 83       |
| [3.02,3.55) | 48       |
| [3.55,4.4]  | 19       |

Tabela 12: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 7: Granice przedziałów dla metody *k-means clustering* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału  $[0, 1]$  w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 8: Rozkład gatunków w klasach dyskretyzacji (metoda *k-means clustering*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

| Gatunek           | [1,2.95) | [2.95,5.13) | [5.13,6.9] |
|-------------------|----------|-------------|------------|
| <i>setosa</i>     | 50       | 0           | 0          |
| <i>versicolor</i> | 0        | 50          | 0          |
| <i>virginica</i>  | 0        | 16          | 34         |

Tabela 13: Wynik podziału dla długości płatka

| Gatunek           | [2,3.02) | [3.02,3.55) | [3.55,4.4] |
|-------------------|----------|-------------|------------|
| <i>setosa</i>     | 8        | 26          | 16         |
| <i>versicolor</i> | 42       | 8           | 0          |
| <i>virginica</i>  | 33       | 14          | 3          |

Tabela 14: Wynik podziału dla szerokości działki kielicha


Dla długości płatka (`Petal.Length`) wyniki wychodzą dokładnie takie same jak w metodzie *equal frequency*.

W przypadku i tej metody, podział po szerokości działki kielicha (`Sepal.Width`) również nie daje zbyt wartościowych wyników.



### 1.3.4 Podział ręczny

Popatrzmy na rozkład wartości rozważanych cech dla każdego z gatunków:



Rysunek 9: Rozkład wartości cech w podziale na gatunki

Na oko wybieramy dla długości płatk (`Petal.Length`) przedziały  $[1, 2.5)$ ,  $[2.5, 4.8)$  oraz  $[4.8, 6.9]$ .

Dla szerokości działki kielicha (`Sepal.Width`) – choć to ciężkie – wybieramy przedziały  $[2, 2.9)$ ,  $[2.9, 3.2)$  i  $[3.2, 4.4]$ .

Wybrane przedziały dzielą nam zbiór danych na klasy o następującej liczności:


| Przedział    | Liczność |
|--------------|----------|
| $[1, 2.5)$   | 50       |
| $[2.5, 4.8)$ | 45       |
| $[4.8, 6.9]$ | 55       |

Tabela 15: Przedziały dla naszej „dobrej” cechy – długości płatk


| Przedział    | Liczność |
|--------------|----------|
| $[2, 2.9)$   | 47       |
| $[2.9, 3.2)$ | 47       |
| $[3.2, 4.4]$ | 56       |

Tabela 16: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki dyskretyzacji prezentują się tak:



Rysunek 10: Granice przedziałów dla podziału ręcznego naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału  $[0, 1]$  w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 11: Rozkład gatunków w klasach dyskretyzacji (podział ręczny). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

| Gatunek           | [1,2.5) | [2.5,4.8) | [4.8,6.9] |
|-------------------|---------|-----------|-----------|
| <i>setosa</i>     | 50      | 0         | 0         |
| <i>versicolor</i> | 0       | 44        | 6         |
| <i>virginica</i>  | 0       | 1         | 49        |

Tabela 17: Wynik podziału dla długości płata

| Gatunek           | [2,2.9) | [2.9,3.2) | [3.2,4.4] |
|-------------------|---------|-----------|-----------|
| <i>setosa</i>     | 1       | 11        | 38        |
| <i>versicolor</i> | 27      | 18        | 5         |
| <i>virginica</i>  | 19      | 18        | 13        |

Tabela 18: Wynik podziału dla szerokości działki kielicha

W podziale długości płata (*Petal.Length*) wybrane przez nas przedziały nie przewyższają skutecznością wcześniejszych metod. Liczba „pomyłek” jest mniej więcej taka sama.

W podziale szerokości działki kielicha (*Sepal.Width*) – w przeciwieństwie do poprzednich metod – udało nam się uzyskać jakikolwiek wartościowy efekt, a mianowicie udało nam się

rozdzielić *Iris setosa* od pozostałych gatunków – zdecydowana większość przedstawicieli tego gatunku trafia do trzeciego przedziału.

Pozostałe dwa gatunki zbyt się jednak pokrywają tą cechą aby można je było rozróżnić.

### 1.3.5 Podsumowanie

Cecha długości płatków (`Petal.Length`) na tyle dobrze rozróżnia rozważane gatunki kwiatów, że niezależnie od wyboru metody otrzymamy bardzo dobry wynik. Za pomocą większości metod jesteśmy w stanie z pełną skutecznością rozdzielić irysy gatunku *Iris setosa* od *Iris versicolor* i *Iris virginica*. Żadna metoda nie pozwala nam jednak na całkowite rozdzielanie dwóch ostatnich gatunków. Być może dyskretyzacja w oparciu na cechę będącą jakąś funkcją od bazowych cech pozwoliłaby na lepszy wynik.

Żadna metoda nie pozwoliła na rozróżnienie gatunków na podstawie cechy szerokości działki kielicha (`Sepal.Width`). Pokazuje to że ograniczając zbiór danych możemy stracić informacje których żadnym algorytmem nie będziemy w stanie odzyskać.

## 2 Część 2 - Analiza składowych głównych

### 2.1 Wstęp

W części drugiej będziemy pracować na zbiorze danych pobranych ze strony [Kaggle](#), pochodzącym oryginalnie z nieistniejącej już (przynajmniej pod tą domeną) strony Teleport.org. Zbiór zawiera wskaźniki opisujące jakość życia z wybranej grupy „najbardziej kreatywnych” miast z całego świata, zebrane po to, aby pomóc znaleźć odpowiednie miasto do życia według preferencji.

Wskaźniki dotyczą między innymi charakterystyk takich jak: warunki mieszkaniowe, koszty utrzymania, bezpieczeństwo, opieka zdrowotna, edukacja itp. Wszystkie wskaźniki są w skali od 0 do 10, gdzie większa wartość oznacza lepszy wynik.

Naszym celem będzie przeprowadzenie analizy składowych głównych (PCA, ang. *Principal Component Analysis*) wskaźników zawartych w zbiorze.

### 2.2 Przygotowanie danych

Dane zawierają informacje o 266 miastach. Dla każdego z nich mamy 21 cech.

|                       | Typ     | Opis                                                                |
|-----------------------|---------|---------------------------------------------------------------------|
| X                     | integer | identyfikator obserwacji                                            |
| UA_Name               | factor  | nazwa obszaru miejskiego (UA – ang. <i>urban area</i> )             |
| UA_Country            | factor  | kraj                                                                |
| UA_Continent          | factor  | kontynent                                                           |
| Housing               | numeric | warunki mieszkaniowe                                                |
| Cost.of.Living        | numeric | koszty utrzymania                                                   |
| Startups              | numeric | ekosystem startupów                                                 |
| Venture.Capital       | numeric | dostępność kapitału inwestycyjnego                                  |
| Travel.Connectivity   | numeric | połączenia komunikacyjne (transport międzykrajowy i międzynarodowy) |
| Commute               | numeric | codzienne dojazdy                                                   |
| Business.Freedom      | numeric | swoboda prowadzenia biznesu                                         |
| Safety                | numeric | bezpieczeństwo                                                      |
| Healthcare            | numeric | opieka zdrowotna                                                    |
| Education             | numeric | edukacja                                                            |
| Environmental.Quality | numeric | jakość środowiska                                                   |
| Economy               | numeric | kondycja gospodarki                                                 |
| Taxation              | numeric | podatki                                                             |
| Internet.Access       | numeric | dostęp do internetu                                                 |
| Leisure...Culture     | numeric | oferta rozrywkowa i kulturalna                                      |
| Tolerance             | numeric | tolerancja społeczna                                                |
| Outdoors              | numeric | możliwości spędzania czasu na świeżym powietrzu                     |

Tabela 19: Typy oraz opisy cech

Identyfikator **X** na pewno nie będzie nas interesował, więc go usuwamy.

Aby ujednolicić konwencję nazw, nazwy cech **UA\_Name**, **UA\_Country** oraz **UA\_Continent** zamieniamy odpowiednio na **UrbanArea**, **Country** i **Continent**. Pozostałe nazwy cech, w których spacje zostały zamienione przez wbudowany w R czytnik CSV na kropki również ujednolicamy do tej konwencji. W nazwie cechy **Leisure...Culture**, w której na kropkę został zamieniony także symbol „&”, powstały trójkropek zamieniamy na „And”.

Zmienione nazwy zmiennych możemy zobaczyć w poniższej tabeli – będącej częścią dalszych działań dążących do oczyszczenia danych – podsumowującej wartości nieusuniętych zmiennych:

| UrbanArea      | Country            | Continent         | Housing        | CostOfLiving   |
|----------------|--------------------|-------------------|----------------|----------------|
| Birmingham: 2  | United Kingdom: 13 | Africa: 8         | Min.: 0.000    | Min.: 0.000    |
| Portland: 2    | Canada: 11         | Asia: 37          | 1st Qu.: 5.149 | 1st Qu.: 4.795 |
| Aarhus: 1      | Germany: 11        | Europe: 111       | Median: 6.726  | Median: 5.630  |
| Adelaide: 1    | France: 9          | North America: 87 | Mean: 6.467    | Mean: 5.746    |
| Albuquerque: 1 | Spain: 7           | Oceania: 8        | 3rd Qu.: 8.313 | 3rd Qu.: 7.596 |
| Almaty: 1      | Italy: 6           | South America: 15 | Max.: 10.000   | Max.: 10.000   |
| (Inne): 258    | (Inne): 209        |                   |                |                |

| Startups       | VentureCapital | TravelConnectivity | Commute        | BusinessFreedom |
|----------------|----------------|--------------------|----------------|-----------------|
| Min.: 0.000    | Min.: 0.000    | Min.: 0.500        | Min.: 0.000    | Min.: 0.000     |
| 1st Qu.: 3.098 | 1st Qu.: 0.000 | 1st Qu.: 1.703     | 1st Qu.: 4.400 | 1st Qu.: 5.771  |
| Median: 4.214  | Median: 2.317  | Median: 2.921      | Median: 5.064  | Median: 8.404   |
| Mean: 4.595    | Mean: 2.703    | Mean: 3.447        | Mean: 4.632    | Mean: 7.331     |
| 3rd Qu.: 5.790 | 3rd Qu.: 3.765 | 3rd Qu.: 4.766     | 3rd Qu.: 5.613 | 3rd Qu.: 8.837  |
| Max.: 10.000   | Max.: 10.000   | Max.: 10.000       | Max.: 6.729    | Max.: 10.000    |

| Safety         | Healthcare     | Education      | EnvironmentalQuality | Economy        |
|----------------|----------------|----------------|----------------------|----------------|
| Min.: 1.343    | Min.: 0.000    | Min.: 0.000    | Min.: 1.000          | Min.: 0.000    |
| 1st Qu.: 5.972 | 1st Qu.: 6.064 | 1st Qu.: 2.184 | 1st Qu.: 4.329       | 1st Qu.: 4.103 |
| Median: 7.189  | Median: 6.780  | Median: 4.273  | Median: 6.481        | Median: 5.373  |
| Mean: 6.972    | Mean: 6.797    | Mean: 3.835    | Mean: 6.078          | Mean: 5.058    |
| 3rd Qu.: 8.269 | 3rd Qu.: 8.055 | 3rd Qu.: 5.294 | 3rd Qu.: 7.888       | 3rd Qu.: 6.514 |
| Max.: 10.000   | Max.: 9.321    | Max.: 9.711    | Max.: 9.953          | Max.: 9.390    |

| Taxation       | InternetAccess | LeisureAndCulture | Tolerance      | Outdoors       |
|----------------|----------------|-------------------|----------------|----------------|
| Min.: 0.500    | Min.: 1.000    | Min.: 0.000       | Min.: 1.406    | Min.: 0.500    |
| 1st Qu.: 3.921 | 1st Qu.: 4.134 | 1st Qu.: 4.448    | 1st Qu.: 5.780 | 1st Qu.: 3.699 |
| Median: 4.760  | Median: 5.379  | Median: 5.707     | Median: 7.154  | Median: 4.733  |
| Mean: 4.953    | Mean: 5.205    | Mean: 5.710       | Mean: 6.793    | Mean: 4.493    |
| 3rd Qu.: 5.955 | 3rd Qu.: 6.265 | 3rd Qu.: 7.062    | 3rd Qu.: 8.052 | 3rd Qu.: 5.500 |
| Max.: 10.000   | Max.: 9.716    | Max.: 10.000      | Max.: 9.739    | Max.: 7.933    |

Tabela 20: Podsumowanie danych


Jak widać, wszystkie zmienne zawierają wartości zgodne z naszymi oczekiwaniami. Nie występują też żadne braki danych.

Mamy 3 cechy jakościowe reprezentujące nazwę miasta, kraju i kontynentu oraz 17 cech ilościowych zawierających wartości wskaźników jakości życia.

W podsumowaniu danych jakościowych widzimy, że mamy informacje o miastach znajdujących się na 6 kontynentach (niestety bez [Antarktydy](#)). Powyższa tabela wskazuje nam, że najwięcej miast mamy z [Europy](#) (111), następnie z [Ameryki Północnej](#) (87). Łącznie mamy informacje o 264 miastach z 135 państw, co świadczy o dużej różnorodności.


W tabeli widzimy też, że nie wszystkie cechy ilościowe przyjmują wartości skrajne – 0 oraz 10. Może to sugerować, że ich rozkłady się znacząco różnią.

W celu najlepszego wyznaczenia składowych głównych, zmienne powinny mieć podobną wariancję.



Rysunek 12: Rozkład wartości cech ilościowych

Widzimy, że zakres wartości zmiennych takich jak `Commute` i `Outdoors` jest dużo węższy niż przykładowo `VentureCapital`, `EnvironmentalQuality`, czy `Education`. Wskazuje to na różnice w wariancji. Z tego powodu dokonujemy standaryzacji za pomocą wbudowanej w R funkcji `scale()`. Wynik tego działania znajduje się na poniższym wykresie.



Rysunek 13: Rozkład wartości cech ilościowych po standaryzacji

Musimy jednak pamiętać, że wartości zmiennych po standaryzacji nie są już w skali 0–10.

## 2.3 Wyznaczanie składowych głównych

Kolejnym naszym krokiem będzie wyznaczenie składowych głównych naszych zmiennych. Użyjemy do tego funkcji `prcomp()`.

W celu interpretacji otrzymanych składowych, analizujemy ich wektory ładunków (ang. *loadings*). Reprezentują one wkład każdej ze zmiennych na wartości składowych.

|                      | PC1    | PC2    | PC3    |
|----------------------|--------|--------|--------|
| Housing              | 0.308  | 0.053  | -0.314 |
| CostOfLiving         | 0.260  | -0.176 | -0.331 |
| Startups             | -0.180 | -0.483 | 0.006  |
| VentureCapital       | -0.237 | -0.427 | 0.015  |
| TravelConnectivity   | -0.209 | -0.135 | -0.340 |
| Commute              | -0.114 | 0.026  | -0.506 |
| BusinessFreedom      | -0.377 | 0.098  | 0.024  |
| Safety               | -0.039 | 0.287  | -0.333 |
| Healthcare           | -0.280 | 0.242  | -0.281 |
| Education            | -0.403 | -0.049 | -0.074 |
| EnvironmentalQuality | -0.326 | 0.253  | 0.054  |
| Economy              | -0.273 | -0.074 | 0.309  |
| Taxation             | 0.026  | 0.107  | -0.020 |
| InternetAccess       | -0.276 | 0.023  | 0.028  |
| LeisureAndCulture    | -0.074 | -0.365 | -0.305 |
| Tolerance            | -0.190 | 0.355  | -0.103 |
| Outdoors             | -0.092 | -0.193 | -0.149 |

Tabela 21: Wartości wektorów ładunków trzech pierwszych składowych głównych

Największy wpływ na interpretację składowych głównych mają zmienne o najwyższych wartościach bezwzględnych ładunków.

Najwyższe dodatnie wartości dla pierwszej składowej głównej (PC1) osiągają zmienne **Housing** oraz **CostOfLiving**, czyli wskaźniki dostępności mieszkań i przystępności kosztów utrzymania. Z kolei najniższe (ujemne) wartości przyjmują zmienne **Education**, **BusinessFreedom** oraz **EnvironmentalQuality**. Oznacza to, że PC1 można interpretować jako wymiar kontrastu pomiędzy przystępnością życia a poziomem rozwoju społeczno-gospodarczego.

W przypadku drugiej składowej głównej (PC2) najwyższe dodatnie wartości osiągają zmienne **Safety**, **Healthcare**, **EnvironmentalQuality** oraz **Tolerance**, które opisują szeroko rozumianą jakość życia. Najniższe wartości przyjmują natomiast zmienne **Startups**, **VentureCapital** oraz **LeisureAndCulture**, związane z aktywnością innowacyjną i gospodarczą. W związku z tym PC2 można interpretować jako wymiar przeciwstawiający wysoką jakość życia dynamice innowacyjno-gospodarczej.


Dla trzeciej składowej głównej (PC3) najwyższą dodatnią wartość przyjmuje zmienna **Economy**, natomiast niskie (ujemne) wartości obserwujemy m.in. dla zmiennych **Commute**, **TravelConnectivity**, **CostOfLiving** oraz **Safety**. Oznacza to, że PC3 można interpretować jako wymiar odzwierciedlający sytuację gospodarczą w zestawieniu z wybranymi aspektami komfortu życia. Wyższe wartości tej składowej mogą wskazywać na lepsze warunki ekonomiczne, ale jednocześnie mniej korzystne warunki codziennego funkcjonowania.




## 2.4 Zmienność odpowiadająca poszczególnym składowym

W kolejnym etapie analizy zbadaliśmy, jaki procent całkowitej zmienności (wariancji) danych jest wyjaśniany przez poszczególne składowe główne.

Na pierwszym wykresie przedstawiono wariancję poszczególnych składowych. Zgodnie z założeniami metody PCA, wartości wariancji maleją wraz z kolejnymi składowymi, co potwierdza, że pierwsze z nich zawierają najistotniejszą informację o strukturze zbioru danych.



Rysunek 14: Wariancje poszczególnych składowych głównych




Rysunek 15: Skumulowana wariancja (w %) wyjaśniana przez kolejne składowe główne

Aby móc odpowiedzieć na pytanie, ile składowych głównych jest potrzebnych do wyjaśnienia 80% oraz 90% całkowitej zmienności, na powyższym wykresie zaznaczamy odpowiednio

poziomy 80% i 90%. Na podstawie tego wykresu możemy wyznaczyć liczbę składowych potrzebnych do wyjaśnienia odpowiednich wartości procentowych wariancji.

Do wyjaśnienia 80% wariancji potrzebnych jest 7 składowych głównych, natomiast do wyjaśnienia 90% wariancji potrzebnych jest 10 składowych głównych.

#### 2.4.1 Wizualizacja danych wielowymiarowych



Rysunek 16: Rzut danych na dwie pierwsze składowe główne, kolory wg kontynentu

Na powyższym wykresie przedstawiono rozkład miast w przestrzeni dwóch pierwszych składowych głównych, które można interpretować odpowiednio jako przystępność życia (PC1) oraz jakość życia (PC2).


Punkty na wykresie są pogrupowane według kontynentów, co pozwala na analizę zróżnicowania geograficznego.

Miasta europejskie koncentrują się głównie w lewej górnej części wykresu. Oznacza to, że wiele z nich charakteryzuje się relatywnie wysokimi kosztami życia (ujemne wartości PC1) przy jednocześnie wysokim poziomie jakości życia (wysokie wartości PC2), obejmującej m.in. bezpieczeństwo, opiekę zdrowotną oraz jakość środowiska.

Miasta Ameryki Północnej wykazują większe zróżnicowanie i są bardziej rozproszone na wykresie, z widoczną tendencją do niższych wartości PC2. Może to sugerować, że część tych miast w większym stopniu charakteryzuje się dynamiką innowacyjną oraz aktywnością gospodarczą (np. rozwój startupów), kosztem niektórych aspektów jakości życia.

Miasta azjatyckie cechują się największym rozproszeniem na wykresie, co odzwierciedla dużą różnorodność gospodarczą i społeczną tego kontynentu. Obejmuje ona zarówno wysoko rozwinięte metropolie (np. Singapur czy Tokio), jak i miasta o niższym poziomie rozwoju, co przekłada się na szeroki zakres wartości obu składowych.


Miasta afrykańskie koncentrują się częściej w obszarach o wyższych wartościach PC1, czyli tam, gdzie koszty utrzymania są niższe a mieszkania bardziej dostępne. Idzie to jednak w parze z niższymi wartościami wskaźników rozwoju społeczno-gospodarczego oraz jakości życia.



Rysunek 17: Biplot PCA z elipsami ufności (95%) dla kontynentów

Na wykresie biplot przedstawiono podział miast według kontynentów wraz z naniesionymi wektorami zmiennych opisujących ich charakterystyki. Strzałki reprezentują kierunek i siłę wpływu poszczególnych zmiennych na składowe główne, co umożliwia jednoczesną analizę zależności między miastami oraz badanymi cechami.


Miasta Europy oraz Ameryki Północnej znajdują się po stronie ujemnych wartości Dim1, gdzie wskaźniki rozwoju społeczno-gospodarczego (*Education*, *BusinessFreedom*, *EnvironmentalQuality*) przyjmują wyższe wartości. Miasta z Afryki, Ameryki Południowej oraz części Azji sytuują się po przeciwnej stronie osi Dim1 – tam, gdzie dominują wektory *Housing* i *CostOfLiving*, czyli niższe koszty utrzymania, ale też niższe wskaźniki rozwoju. Widoczna separacja regionów pokazuje, że PCA dobrze odzwierciedla różnice w profilach miast między tymi grupami.



Rysunek 18: Rzut danych na dwie pierwsze składowe główne – wyróżnione cztery miasta najbardziej oddalone od środka przestrzeni PCA

Na wykresie PCA widzimy, że miasta zlokalizowane w lewym dolnym rogu przestrzeni (niskie wartości PC1 i PC2) tworzą grupę o szczególnych cechach strukturalnych. Są to głównie metropolie z Europy i Ameryki Północnej (Nowy Jork, Londyn, San Francisco Bay Area), które charakteryzują się wysokimi kosztami życia oraz ograniczoną dostępnością mieszkań. Ich niskie wartości PC2 oznaczają silną dynamikę innowacyjno-gospodarczą i bogatą ofertę kulturalną, kosztem niższych wskaźników bezpieczeństwa, opieki zdrowotnej i jakości środowiska.

Lagos, położone w Nigerii (Afryka Zachodnia), znajduje się na przeciwnym biegunie osi PC1 względem tych miast zachodnich, co czyni je jednym z najbardziej oddalonych punktów w tym wymiarze. Miasto to reprezentuje dynamicznie rozwijającą się metropolię Globalnego Południa, zmagającą się z wyzwaniami gwałtownej urbanizacji, presją demograficzną oraz ograniczeniami infrastrukturalnymi. Jego wysoka wartość PC1 wynika z niskich kosztów utrzymania, a niska wartość PC2 wskazuje na ograniczoną dostępność usług publicznych (edukacja, opieka zdrowotna) i niższą jakość środowiska, co wyraźnie odróżnia je od metropolii Europy i Ameryki Północnej.




Rysunek 19: Rzut danych na trzy pierwsze składowe główne – wyróżnione: Europa i Ameryka Północna

Na trójwymiarowym wykresie PCA przedstawiono rozmieszczenie miast względem trzech głównych składowych: PC1, PC2 oraz PC3, ograniczając analizę do miast Europy i Ameryki Północnej. Każda z osi reprezentuje odmienny wymiar jakości życia i rozwoju społeczno-gospodarczego.


Analiza rozmieszczenia miast w tej przestrzeni pokazuje wyraźne różnice regionalne. Miasta Ameryki Północnej częściej lokują się w obszarach wyższych wartości PC3, co sugeruje relatywnie silniejszą sytuację gospodarczą w porównaniu do miast europejskich. Jednocześnie miasta europejskie częściej osiągają wyższe wartości w wymiarach jakości życia (PC2), co wskazuje na większy nacisk na bezpieczeństwo, ochronę zdrowia i jakość środowiska. W rezultacie obie grupy miast różnią się profilem rozwoju: Ameryka Północna jest bardziej zorientowana na dynamikę gospodarczą, natomiast Europa na zrównoważoną jakość życia.

## 2.5 Korelacja zmiennych

Następnie, w celu porównania zależności między zmiennymi opisanymi przez składowe PCA, zrobiliśmy zestawienie obejmujące macierz korelacji oraz biplot PCA.



Rysunek 20: Korelacje cech ze składowymi głównymi



Rysunek 21: Biplot PCA – 10 cech o największym wkładzie

Analiza macierzy korelacji wykazała istotne zależności pomiędzy zmiennymi. W szczególności

zaobserwowano silną dodatnią korelację między `Housing` a `CostOfLiving` – w tańszych miastach mieszkania są przeciętnie łatwiej dostępne. Ujemne zależności występują między tymi zmiennymi a wskaźnikami jakości środowiska oraz rozwoju społeczno-gospodarczego, co oznacza, że miasta o lepiej rozwiniętej edukacji, biznesie i jakości środowiska są zwykle droższe.

Wykres biplot PCA potwierdza te zależności w ujęciu geometrycznym. Zmienne silnie dodatnio skorelowane są reprezentowane przez wektory skierowane w podobnym kierunku, natomiast zmienne o korelacji ujemnej znajdują się po przeciwnych stronach wykresu względem siebie. Dodatkowo biplot umożliwia analizę zależności pomiędzy samymi zmiennymi – małe kąty między wektorami (np. `Housing` i `CostOfLiving`) wskazują na silną korelację dodatnią, natomiast przeciwne kierunki wektorów (np. `Housing` i `Education`) świadczą o korelacji ujemnej.

Wnioski uzyskane z obu metod są spójne i wzajemnie się uzupełniają. Macierz korelacji dostarcza precyzyjnych wartości liczbowych opisujących siłę zależności, natomiast biplot PCA pozwala na ich intuicyjną interpretację geometryczną, umożliwiając jednoczesną analizę relacji między zmiennymi oraz ich projekcji w przestrzeni składowych głównych.

## 2.6 Końcowe wyniki

W przeprowadzonych analizach PCA udało się zaobserwować wyraźną strukturę danych, w której pierwsze dwie składowe główne opisują najważniejsze wymiary zróżnicowania miast: przystępność życia kontra poziom rozwoju społeczno-gospodarczego (PC1) oraz jakość życia (PC2). Dodatkowo trzecia składowa (PC3) wnosi informację o sytuacji gospodarczej, jednak jej znaczenie jest mniejsze niż dwóch pierwszych komponentów.

Z analizy wynika, że już dwie składowe główne są wystarczające do uzyskania dobrej, czytelnej reprezentacji danych, ponieważ wyjaśniają one znaczną część całkowitej wariancji i pozwalają na wyraźne rozróżnienie grup miast. Dodanie trzeciej składowej poprawia szczegółowość interpretacji, ale nie jest kluczowe dla ogólnego obrazu struktury danych.

Standaryzacja danych miała istotny wpływ na wyniki analizy. Dzięki niej wszystkie zmienne zostały sprowadzone do porównywalnej skali, co zapobiegło dominacji cech o dużych wartościach liczbowych (np. kosztów życia). W efekcie PCA lepiej odzwierciedla rzeczywiste relacje między zmiennymi, a uzyskane składowe są bardziej zrównoważone.

# 3 Część 3 - Skalowanie wielowymiarowe (MDS)

## 3.1 Wstęp

W ostatniej części raportu mamy zbiór danych zawierających charakterystyki opisujące pasażerów Titanica, wraz z informacją czy dana osoba przeżyła. Zbiór pobieramy z R-pakietu `titanic`, ale jest też on dostępny na [Kaggle](#).

Naszym zadaniem będzie dokonanie skalowania wielowymiarowego (MDS, ang. *multi-dimensional scaling*).

## 3.2 Przygotowanie danych

Zbiór danych zawiera informacje o pasażerach Titanica. Między innymi takie jak: wiek, płeć, miejsce rozpoczęcia podróży oraz klasa pasażerska. Ważną zmienną występującą w bazie danych jest cecha **Survived**, która informuje nas czy dana osoba przeżyła katastrofę, czy nie. Dane zawierają 891 informacji o różnych pasażerach oraz 12 cech, które ich opisują.

|             | Typ       | Opis                                                    |
|-------------|-----------|---------------------------------------------------------|
| PassengerId | integer   | ID pasażera                                             |
| Survived    | integer   | Czy przeżył                                             |
| Pclass      | integer   | Numer klasy                                             |
| Name        | character | Imię pasażera                                           |
| Sex         | character | Płeć                                                    |
| Age         | numeric   | Wiek                                                    |
| SibSp       | integer   | Liczba rodzeństwa + małżonków podróżujących z pasażerem |
| Parch       | integer   | Liczba rodziców + dzieci podróżujących z pasażerem      |
| Ticket      | character | Numer biletu                                            |
| Fare        | numeric   | Opłata za bilet                                         |
| Cabin       | character | Numer kabiny                                            |
| Embarked    | character | Port zaokrętowania pasażera                             |

Tabela 22: Typy oraz opisy cech

Z danych na pewno usuwamy zmienne takie jak **PassengerId**, **Name**, **Ticket** oraz **Cabin**, które nie wniosą nic do naszej analizy. Są to indywidualne dane każdego pasażera, w celu ochrony danych zostaną one usunięte z dalszej analizy.

Dodatkowo, typy zmiennych które po wczytaniu danych były wczytane jako typ **character** zmieniamy na typ **factor**. Są to zmienne takie jak płeć oraz port zaokrętowania, które możemy traktować jako zmienne jakościowe. Zmienną **Pclass** reprezentującą numer klasy zmieniamy na zmienną porządkową.

Sprawdzamy czy mamy jakieś braki danych:



|          | Liczba_NA | Liczba_puste_pozycje |
|----------|-----------|----------------------|
| Survived | 0         | 0                    |
| Pclass   | 0         | 0                    |
| Sex      | 0         | 0                    |
| Age      | 177       | 0                    |
| SibSp    | 0         | 0                    |
| Parch    | 0         | 0                    |
| Fare     | 0         | 0                    |
| Cabin    | 0         | 687                  |
| Embarked | 0         | 2                    |

Tabela 23: Braki danych w zbiorze

Zmienna **Age** zawiera 177 braków. W tym przypadku nie usuwamy tej zmiennej, tylko zastępujemy te braki medianą z pozostałych wartości **Age**. Nie usuwamy też wierszy z tymi brakami, ponieważ stanowią one prawie 20% danych. Natomiast braki w zmiennej **Embarked**, która oznacza port w którym wsiadł pasażer, uzupełniamy najczęstszą wartością jaka pojawia się w danych.

W tabeli poniżej znajdują się statystyki opisowe zmiennych oraz licznosci wystąpień poszczególnych kategorii w nieusuniętych zmiennych jakościowych.

| Survived        | Pclass | Sex         | Age            |
|-----------------|--------|-------------|----------------|
| Min.: 0.0000    | 1: 216 | female: 314 | Min.: 0.42     |
| 1st Qu.: 0.0000 | 2: 184 | male: 577   | 1st Qu.: 22.00 |
| Median: 0.0000  | 3: 491 |             | Median: 28.00  |
| Mean: 0.3838    |        |             | Mean: 29.36    |
| 3rd Qu.: 1.0000 |        |             | 3rd Qu.: 35.00 |
| Max.: 1.0000    |        |             | Max.: 80.00    |


| SibSp          | Parch           | Fare           | Cabin          |
|----------------|-----------------|----------------|----------------|
| Min.: 0.000    | Min.: 0.0000    | Min.: 0.00     | : 687          |
| 1st Qu.: 0.000 | 1st Qu.: 0.0000 | 1st Qu.: 7.91  | B96 B98: 4     |
| Median: 0.000  | Median: 0.0000  | Median: 14.45  | C23 C25 C27: 4 |
| Mean: 0.523    | Mean: 0.3816    | Mean: 32.20    | G6: 4          |
| 3rd Qu.: 1.000 | 3rd Qu.: 0.0000 | 3rd Qu.: 31.00 | C22 C26: 3     |
| Max.: 8.000    | Max.: 6.0000    | Max.: 512.33   | D: 3           |
|                |                 |                | (Inne): 186    |

Tabela 24: Podsumowanie danych po uzupełnieniu braków

### 3.3 Redukcja wymiaru na bazie MDS

Następnie w celu poprawnej redukcji wymiaru dzielimy nasz zbiór na zmienną **Survived** i resztę zmiennych. Macierz odmienności wyznaczamy za pomocą metryki Gowera, ponieważ w naszych danych znajdują się zarówno dane ilościowe, jak i jakościowe. Do zmiennych ilościowych stosujemy również standaryzację w celu poprawnego wyliczenia odległości.

Otrzymaną macierz wizualizujemy poniżej w postaci heatmapy z naniesionym dendrogramem, który pozwala dostrzec hierarchiczną strukturę podobieństwa pomiędzy obserwacjami.




Rysunek 22: Heatmapa macierzy odmienności (Gower) – jaśniejsze pola oznaczają większe podobieństwo, ciemniejsze mniejszą

Na podstawie heatmapy możemy zauważyć, że pasażerowie na statku Titanic byli bardzo podzieleni na różne grupy. Wzdłuż przekątnej zauważamy jasne pola, które świadczą o bardzo dużym podobieństwie osób wśród tych samych grup.

Na samej górze i po lewej stronie znajdują się drzewa – widzimy wyraźny podział na dwie części. Dendrogram sugeruje, że różnice między tymi dwiema grupami są bardziej znaczące niż jakiegokolwiek inne cechy indywidualne.

Ciemne elementy na heatmapie są to wartości odstające, na przykład pasażerowie, którzy mimo bycia w 3. klasie mieli drogi bilet.

Następnie stosujemy algorytm MDS w wariacie metrycznym (funkcja `cmdscale`) dla wymiaru  $k = 3$  z metryką euklidesową (na początku spróbowaliśmy dla  $k = 2$  i stress wyszedł jako 0.26, co sugerowało, że należy zwiększyć wymiar). Wybieramy wariant metryczny, ponieważ macierz odmienności Gowera daje nam realne wartości odległości, a nie tylko ich kolejność – nie ma więc powodu, żeby rezygnować z tej informacji. Aby ocenić jakość tej redukcji, rysujemy diagram Sheparda.




Rysunek 23: Diagram Sheparda dla MDS ( $k=3$ )

Analizując wykres Sheparda możemy zauważyć, że punkty układają się wzdłuż linii  $y = x$  – świadczy to o poprawności relacji podobieństwa. Na wykresie widzimy też schody, które świadczą o występowaniu grup wśród osób o podobnych cechach oraz granic między grupami – co jest spójne z tym, co widzieliśmy na heatmapie.

Nie występują wartości znacząco odstające od linii  $y = x$ , co spójne jest z niską wartością funkcji *stress*, która wyniosła 0.17 – potwierdza to poprawność użytego wymiaru.

### 3.4 Wizualizacja danych

Wyniki MDS oglądamy na wykresach 2D, kolorując punkty według różnych zmiennych. Najpierw kolorujemy je według tego, czy pasażer przeżył.




Rysunek 24: Wizualizacja MDS (rzut 2D z przestrzeni 3D), kolory według **Survived**

Na wykresie możemy zauważyć bardzo wyraźny podział na grupy. Każde skupisko to grupa pasażerów podobnych do siebie ze względu na zestaw cech. Duża odległość między dwoma głównymi skupiskami świadczy o znaczącej różnicy między tymi grupami pasażerów.

Co istotne, górne skupiska punktów to w większości osoby ocalałe (czyli np. kobiety i dzieci z 1. klasy), a dolne to w większości ofiary – mimo że zmienna **Survived** nie była używana do redukcji. Cechy które przyjęliśmy (klasa, płeć, wiek) są więc silnie związane z przeżyciem. Ciekawym zjawiskiem są wartości odstające, np. osoby które zginęły mimo wysokiego statusu społeczno-ekonomicznego.


Następnie kolorujemy punkty według płci pasażera.



Rysunek 25: Wizualizacja MDS (rzut 2D), kolory według płci

Na powyższym wykresie widzimy podział ze względu na płeć osób – możemy stwierdzić, że płeć w naszym zbiorze danych jest bardzo ważną cechą i jest podstawą w szukaniu podobieństw między pasażerami. Porównując z wykresem przeżyć widzimy, że wśród osób które przeżyły katastrofę są głównie kobiety. Jest też grupa kobiet, która zginęła (wykres wyżej) – są to prawdopodobnie kobiety z najniższej klasy, które nie miały szansy na łódź ratunkową.

Na koniec kolorujemy punkty według klasy pasażerskiej.



Rysunek 26: Wizualizacja MDS (rzut 2D), kolory według klasy pasażerskiej

W obu skupiskach widać też podział na klasy, ale dużo słabszy niż ten na płci.

Tak jak zakładaliśmy wcześniej, kobiety które zginęły w katastrofie to kobiety z 3. klasy. Natomiast w dolnym skupisku (mężczyźni) niezależnie od klasy w każdej grupie znajdowały się jednostki, którym udało się przeżyć.

### 3.5 Podsumowanie

Analizując heatmapę i dendrogram zauważyliśmy, że istnieją dwie główne grupy różniące się między sobą, co potwierdziło się w dalszej analizie. Dzięki diagramowi Sheparda możemy mieć pewność, że redukcja do 3 wymiarów jest wiarygodna – większość punktów leży wzdłuż linii  $y = x$ , co świadczy o rzetelności naszych wniosków. Dodatkowo potwierdza to niska wartość funkcji stress (0.17).

Wykresy MDS pokazały, że pasażerowie naturalnie grupują się w skupiska, co świadczy o silnych zależnościach między ich cechami. Największe różnice występują między kobietami i mężczyznami oraz pasażerami 1. i 3. klasy. Osoby ocalałe wyraźnie grupują się w przestrzeni MDS, mimo że zmienna **Survived** nie była używana do redukcji – cechy które przyjęliśmy są więc silnie związane z przeżyciem.