

Sprawozdanie 2

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-27

Spis treści

1	Część 1 – dyskretyzacja cech ciągłych	2
1.1	Wstęp	2
1.2	Opis danych i wybór cech	2
1.3	Porównanie metod dyskretyzacji	3
2	Część 2	11
2.1	Wstęp	11
2.2	Opis danych	11
2.3	Przygotowanie danych	11
2.4	Wyznaczanie składowych głównych	13
2.5	Zmienność odpowiadająca poszczególnym składowym	14
2.6	Korelacja zmiennych	15
2.7	Końcowe wyniki	17
3	Część 3	17
3.1	Wstęp	17
3.2	Opis danych	17

1 Część 1 – dyskretyzacja cech ciągłych

1.1 Wstęp

Mamy zbiór danych zawierający wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*).



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

Zbiór danych został udostępniony przez Ronalda Fishera w 1936 roku. Pobieramy go z zestawu gotowych zbiorów dostępnych w pakiecie `datasets` w R.

Naszym pierwszym zadaniem będzie przeanalizowanie własności cech oraz wybranie jednej cechy, która najlepiej rozróżni gatunki kwiatu oraz jednej, która robi to najgorzej.

Następnym naszym zadaniem będzie przeprowadzenie dyskretyzacji wybranych cech na trzy klasy przy użyciu różnych metod dyskretyzacji nienadzorowanej oraz porównanie ich wyników. Będziemy porównywać metody *equal width*, *equal frequency*, *k-means clustering* oraz dyskretyzację na bazie przedziałów zadanych przez użytkownika (przez nas).

1.2 Opis danych i wybór cech

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatka (w cm)
Petal.Width	numeric	szerokość płatka (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)


Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

Wierzmy pomiarom i zakładamy że nie ma błędów. Braki danych nie występują.



Rysunek 2: Pomiary działki kielicha i płatka w zależności od gatunku. W celu polepszenia widoczności, punkty zostały odrobinę losowo rozrzucone.

Jako cechę najlepiej rozróżniającą gatunki wybieramy długość płatka (`Petal.Length`) – wartości dla *Iris setosa* są wyraźnie niższe niż dla pozostałych dwóch gatunków, a *Iris versicolor* i *Iris virginica* również są od siebie dobrze oddzielone. Jako cechę najgorzej rozróżniającą gatunki wybieramy szerokość działki kielicha (`Sepal.Width`) – rozkłady dla wszystkich trzech gatunków silnie się nakładają.

1.3 Porównanie metod dyskretyzacji

Do dokonania dyskretyzacji wykorzystujemy funkcję `discretize` z R-pakietu `arules`. Używamy jej w następujący sposób:

```
discretize(dane$CECHA, method = METODA, breaks = 3)
```

W miejsce **CECHA** wpisujemy identyfikator odpowiedniej cechy, a w miejsce **METODA** identyfikator metody:

- "interval" dla metody *equal width*,
- "frequency" dla metody *equal frequency*,
- "cluster" dla metody *k-means clustering* oraz
- "fixed" dla ręcznego podziału.

W przypadku ostatniej metody, zamiast `breaks = 3` piszemy wektor punktów rozdzielających, przykładowo:

```
discretize(
  dane$Sepal.Width,
  method = "fixed",
  breaks = c(2.0, 2.9, 3.2, 4.4)
)
```

1.3.1 Metoda equal width

Metoda *equal width* daje nam następujące przedziały:


Przedział	Liczność
[1,2.97)	50
[2.97,4.93)	54
[4.93,6.9]	46

Tabela 3: Przedziały dla naszej „dobrej” cechy – długości płatk


Przedział	Liczność
[2,2.8)	47
[2.8,3.6)	88
[3.6,4.4]	15

Tabela 4: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 3: Granice przedziałów dla metody *equal width* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 4: Rozkład gatunków w klasach dyskretyzacji (metoda *equal width*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.97)	[2.97,4.93)	[4.93,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	48	2
<i>virginica</i>	0	6	44

Tabela 5: Wynik podziału dla długości płatk

Gatunek	[2,2.8)	[2.8,3.6)	[3.6,4.4]
<i>setosa</i>	1	36	13
<i>versicolor</i>	27	23	0
<i>virginica</i>	19	29	2

Tabela 6: Wynik podziału dla szerokości działki kielicha

Dzieląc cechę długości płatk (`Petal.Length`) na równe przedziały z bardzo dobrą skutecznością rozdzielamy irysy gatunku *Iris setosa* od pozostałych. Wszystkie kwiaty tego gatunku wpadają w przedział najkrótszej długości oraz nie wpadają do tego przedziału żadne irysy innego gatunku.

W miarę skutecznie rozróżniamy też gatunki *Iris versicolor* i *Iris virginica*, które wpadają zazwyczaj odpowiednio w przedział o średniej długości i przedział o najdłuższej długości. W niektórych przypadkach *Iris versicolor* trafia jednak do przedziału o najdłuższej długości, a *Iris virginica* do przedziału o średniej długości. Więcej razy występuje ten pierwszy przypadek niż drugi.

Jeżeli podzielimy zamiast tego na równe przedziały cechę szerokości działki kielicha (`Sepal.Width`), nie otrzymamy żadnych zadowalających nas rezultatów.

1.3.2 Metoda *equal frequency*

Używając metody *equal frequency*, otrzymujemy przedziały:


Przedział	Liczność
[1,2.63)	50
[2.63,4.9)	49
[4.9,6.9]	51

Tabela 7: Przedziały dla naszej „dobrej” cechy – długości płatka


Przedział	Liczność
[2,2.9)	47
[2.9,3.2)	47
[3.2,4.4]	56

Tabela 8: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 5: Granice przedziałów dla metody *equal frequency* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 6: Rozkład gatunków w klasach dyskretyzacji (metoda *equal frequency*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.63)	[2.63,4.9)	[4.9,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	46	4
<i>virginica</i>	0	3	47

Tabela 9: Wynik podziału dla długości płatk

Gatunek	[2,2.9)	[2.9,3.2)	[3.2,4.4]
<i>setosa</i>	1	11	38
<i>versicolor</i>	27	18	5
<i>virginica</i>	19	18	13

Tabela 10: Wynik podziału dla szerokości działki kielicha

Przedziały dla długości płatk (`Petal.Length`) wychodzą niemal jednakowe jak w przypadku metody *equal width*, w związku z tym wyniki również wychodzą takie same. Skuteczność też się względem nich nie zmienia.

Zauważalną różnicą jest mniejsza różnica między liczbą przedstawicieli *Iris versicolor* trafiających jednak do przedziału o najdłuższej długości, a *Iris virginica* trafiających do przedziału o średniej długości. W pewien sposób można więc uznać te wyniki za lepsze.

Dzieląc szerokość działki kielicha (`Sepal.Width`) uzyskujemy inne przedziały, lecz równie (jak nie bardziej) niesatysfakcjonujące wyniki jak przy metodzie przedziałów równej długości.

1.3.3 Metoda k-means clustering

Metodą *k-means clustering* otrzymujemy takie przedziały:


Przedział	Liczność
[1,2.95)	50
[2.95,5.13)	66
[5.13,6.9]	34

Tabela 11: Przedziały dla naszej „dobrej” cechy – długości płatk


Przedział	Liczność
[2,2.85)	47
[2.85,3.44)	78
[3.44,4.4]	25

Tabela 12: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 7: Granice przedziałów dla metody *k-means clustering* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 8: Rozkład gatunków w klasach dyskretyzacji (metoda *k-means clustering*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.95)	[2.95,5.13)	[5.13,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	50	0
<i>virginica</i>	0	16	34

Tabela 13: Wynik podziału dla długości płatka

Gatunek	[2,2.85)	[2.85,3.44)	[3.44,4.4]
<i>setosa</i>	1	27	22
<i>versicolor</i>	27	23	0
<i>virginica</i>	19	28	3


Tabela 14: Wynik podziału dla szerokości działki kielicha

Dla długości płatka (*Petal.Length*) wyniki wychodzą dokładnie takie same jak w metodzie *equal frequency*.

W przypadku i tej metody, podział po szerokości działki kielicha (*Sepal.Width*) również nie daje zbyt wartościowych wyników.

1.3.4 Podział ręczny

Popatrzmy na rozkład wartości rozważanych cech dla każdego z gatunków:



Rysunek 9: Rozkład wartości cech w podziale na gatunki

Na oko wybieramy dla długości płatk (`Petal.Length`) przedziały $[1, 2.5)$, $[2.5, 4.8)$ oraz $[4.8, 6.9]$.

Dla szerokości działki kielicha (`Sepal.Width`) – choć to ciężkie – wybieramy przedziały $[2, 2.9)$, $[2.9, 3.2)$ i $[3.2, 4.4]$.

Wybrane przedziały dzielą nam zbiór danych na klasy o następującej liczności:


Przedział	Liczność
$[1, 2.5)$	50
$[2.5, 4.8)$	45
$[4.8, 6.9]$	55

Tabela 15: Przedziały dla naszej „dobrej” cechy – długości płatk


Przedział	Liczność
$[2, 2.9)$	47
$[2.9, 3.2)$	47
$[3.2, 4.4]$	56

Tabela 16: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki dyskretyzacji prezentują się tak:



Rysunek 10: Granice przedziałów dla podziału ręcznego naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 11: Rozkład gatunków w klasach dyskretyzacji (podział ręczny). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.5)	[2.5,4.8)	[4.8,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	44	6
<i>virginica</i>	0	1	49

Tabela 17: Wynik podziału dla długości płatka

Gatunek	[2,2.9)	[2.9,3.2)	[3.2,4.4]
<i>setosa</i>	1	11	38
<i>versicolor</i>	27	18	5
<i>virginica</i>	19	18	13

Tabela 18: Wynik podziału dla szerokości działki kielicha

W podziale długości płatka (*Petal.Length*) wybrane przez nas przedziały nie przewyższają skutecznością wcześniejszych metod. Liczba „pomyłek” jest mniej więcej taka sama.

W podziale szerokości działki kielicha (*Sepal.Width*) – w przeciwieństwie do poprzednich metod – udało nam się uzyskać jakikolwiek wartościowy efekt, a mianowicie udało nam się

rozdzielić *Iris setosa* od pozostałych gatunków – zdecydowana większość przedstawicieli tego gatunku trafia do trzeciego przedziału.

Pozostałe dwa gatunki zbyt się jednak pokrywają tą cechą aby można je było rozróżnić.

1.3.5 Podsumowanie

Cecha długości płatków (*Petal.Length*) na tyle dobrze rozróżnia rozważane gatunki kwiatów, że niezależnie od wyboru metody otrzymamy bardzo dobry wynik. Za pomocą większości metod jesteśmy w stanie z pełną skutecznością rozdzielić irysy gatunku *Iris setosa* od *Iris versicolor* i *Iris virginica*. Żadna metoda nie pozwala nam jednak na całkowite rozdzielanie dwóch ostatnich gatunków. Być może dyskretyzacja w oparciu na cechę będącą jakąś funkcją od bazowych cech pozwoliłaby na lepszy wynik.

Żadna metoda nie pozwoliła na rozróżnienie gatunków na podstawie cechy szerokości działki kielicha (*Sepal.Width*). Pokazuje to że ograniczając zbiór danych możemy stracić informacje których żadnym algorytmem nie będziemy w stanie odzyskać.

2 Część 2


2.1 Wstęp

2.2 Opis danych

2.3 Przygotowanie danych

##	X	UA_Name	UA_Country	UA_Continent	Housing	Cost.of.Living	Startups
## 1	0	Aarhus	Denmark	Europe	6.1315	4.015	2.8270
## 2	1	Adelaide	Australia	Oceania	6.3095	4.692	3.1365
## 3	2	Albuquerque	New Mexico	North America	7.2620	6.059	3.7720
## 4	3	Almaty	Kazakhstan	Asia	9.2820	9.333	2.4585
## 5	4	Amsterdam	Netherlands	Europe	3.0530	3.824	7.9715
## 6	5	Anchorage	Alaska	North America	5.4335	3.141	2.7945
##	Venture.Capital	Travel.Connectivity	Commute	Business.Freedom	Safety		
## 1	2.512		3.5360	6.31175	9.940000	9.6165	
## 2	2.640		1.7765	5.33625	9.399667	7.9260	
## 3	1.493		1.4555	5.05575	8.671000	1.3435	
## 4	0.000		4.5920	5.87125	5.568000	7.3090	
## 5	6.107		8.3245	6.11850	8.836667	8.5035	
## 6	0.000		1.7380	4.71525	8.671000	3.4705	
##	Healthcare	Education	Environmental.Quality	Economy	Taxation	Internet.Access	
## 1	8.704333	5.3665		7.63300	4.8865	5.0680	8.3730
## 2	7.936667	5.1420		8.33075	6.0695	4.5885	4.3410
## 3	6.430000	4.1520		7.31950	6.5145	4.3460	5.3960
## 4	4.545667	2.2830		3.85675	5.2690	8.5220	2.8860
## 5	7.907333	6.1800		7.59725	5.0530	4.9550	4.5230

## 6	6.060333	3.6245		9.27200	6.5145	4.7720	4.9645
##	Leisure...	Culture	Tolerance	Outdoors			
## 1		3.1870	9.7385	4.1300			
## 2		4.3285	7.8220	5.5310			
## 3		4.8900	7.0285	3.5155			
## 4		2.9370	6.5395	5.5000			
## 5		8.8740	8.3680	5.3070			
## 6		3.2660	7.0930	5.3580			
##	Housing	Cost.of.Living	Startups	Venture.Capital	Travel.Connectivity	Commute	
## 1	6.1315	4.015	2.8270	2.512		3.5360	6.31175
## 2	6.3095	4.692	3.1365	2.640		1.7765	5.33625
## 3	7.2620	6.059	3.7720	1.493		1.4555	5.05575
## 4	9.2820	9.333	2.4585	0.000		4.5920	5.87125
## 5	3.0530	3.824	7.9715	6.107		8.3245	6.11850
## 6	5.4335	3.141	2.7945	0.000		1.7380	4.71525
##	Business.Freedom	Safety	Healthcare	Education	Environmental.Quality	Economy	
## 1	9.940000	9.6165	8.704333	5.3665	7.63300	4.8865	
## 2	9.399667	7.9260	7.936667	5.1420	8.33075	6.0695	
## 3	8.671000	1.3435	6.430000	4.1520	7.31950	6.5145	
## 4	5.568000	7.3090	4.545667	2.2830	3.85675	5.2690	
## 5	8.836667	8.5035	7.907333	6.1800	7.59725	5.0530	
## 6	8.671000	3.4705	6.060333	3.6245	9.27200	6.5145	
##	Taxation	Internet.Access	Leisure...Culture	Tolerance	Outdoors		
## 1	5.0680	8.3730	3.1870	9.7385	4.1300		
## 2	4.5885	4.3410	4.3285	7.8220	5.5310		
## 3	4.3460	5.3960	4.8900	7.0285	3.5155		
## 4	8.5220	2.8860	2.9370	6.5395	5.5000		
## 5	4.9550	4.5230	8.8740	8.3680	5.3070		
## 6	4.7720	4.9645	3.2660	7.0930	5.3580		



2.4 Wyznaczanie składowych głównych

##	PC1	PC2	PC3
## Housing	0.30782507	0.05335338	-0.313546491
## Cost.of.Living	0.25960906	-0.17578152	-0.330535177
## Startups	-0.18023854	-0.48344148	0.006099991
## Venture.Capital	-0.23659743	-0.42745094	0.014876825
## Travel.Connectivity	-0.20945432	-0.13530669	-0.339775966
## Commute	-0.11420445	0.02593103	-0.505735874
## Business.Freedom	-0.37728094	0.09821960	0.024104574
## Safety	-0.03893545	0.28710395	-0.333009986
## Healthcare	-0.28035896	0.24194822	-0.281024808
## Education	-0.40256205	-0.04907952	-0.073864482
## Environmental.Quality	-0.32622202	0.25253554	0.053571655
## Economy	-0.27317525	-0.07400327	0.308670514
## Taxation	0.02629917	0.10741513	-0.020184933
## Internet.Access	-0.27619221	0.02270564	0.028441569
## Leisure...Culture	-0.07444660	-0.36473241	-0.305054520
## Tolerance	-0.18974955	0.35509112	-0.102725071
## Outdoors	-0.09158656	-0.19338254	-0.148586789


Najwyższy wskaźnik dla PC1 ma Housing i Cost.of living więc możemy interpretować tę zmienną jako koszty życia i poziom rozwoju. Następnie PC2 najwyższy wskaźnik dla safety i health care i environmental quality i tolerance więc możemy interpretować tę zmienną jako innowacyjność. Natomiast PC3 najwyższe wartości loadings mają economy więc możemy interpretować tę zmienną jako infrastruktura i dostępność / mobilność.

PC1 reprezentuje ogólny poziom życia i koszty utrzymania, z największym wpływem zmiennych Housing i Cost.of.Living.

PC2 odzwierciedla jakość życia oraz poziom innowacyjności, związany ze zmiennymi takimi jak Startups, Venture Capital, Safety i Healthcare.


PC3 można interpretować jako komponent związany z infrastrukturą i mobilnością, ponieważ największe ładunki mają zmienne Commute oraz Travel Connectivity.


2.5 Zmienność odpowiadająca poszczególnym składowym



Do wyjaśnienia 80% składowych potrzebne jest 7 zmiennych, natomiast do wyjaśnienia 90% składowych potrzebne jest 10 zmiennych.

2.5.1 Wizualizacja danych wielowymiarowych







2.6 Korelacja zmiennych


wykres korelacji tak o

```
variables <- get_pca_var(pca_dane)
corrplot(variables$cor)
```







PCA - Biplot



PCA - Biplot





2.7 Końcowe wyniki

3 Część 3

3.1 Wstęp

3.2 Opis danych