

Sprawozdanie 2

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-30

Spis treści

1	Część 1 – dyskretyzacja cech ciągłych	2
1.1	Wstęp	2
1.2	Opis danych i wybór cech	2
1.3	Porównanie metod dyskretyzacji	3
2	Część 2 - Analiza składowych głównych	11
2.1	Wstęp	11
2.2	Przygotowanie danych	11
2.3	Wyznaczanie składowych głównych	15
2.4	Zmienność odpowiadająca poszczególnym składowym	17
2.5	Korelacja zmiennych	21
2.6	Końcowe wyniki	23
3	Część 3 - Skalowanie wielowymiarowe (MDS)	23
3.1	Wstęp	23
3.2	Przygotowanie danych	24
3.3	Redukcja wymiaru na bazie MDS	26
3.4	Wizualizacja danych	28
3.5	Podsumowanie	30

1 Część 1 – dyskretyzacja cech ciągłych

1.1 Wstęp

Mamy zbiór danych zawierający wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*).



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

Zbiór danych został udostępniony przez Ronalda Fishera w 1936 roku. Pobieramy go z zestawu gotowych zbiorów dostępnych w pakiecie `datasets` w R.

Naszym pierwszym zadaniem będzie przeanalizowanie własności cech oraz wybranie jednej cechy, która najlepiej rozróżni gatunki kwiatu oraz jednej, która robi to najgorzej.

Następnym naszym zadaniem będzie przeprowadzenie dyskretyzacji wybranych cech na trzy klasy przy użyciu różnych metod dyskretyzacji nienadzorowanej oraz porównanie ich wyników. Będziemy porównywać metody *equal width*, *equal frequency*, *k-means clustering* oraz dyskretyzację na bazie przedziałów zadanych przez użytkownika (przez nas).

1.2 Opis danych i wybór cech

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatka (w cm)
Petal.Width	numeric	szerokość płatka (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)


Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

Wierzmy pomiarom i zakładamy że nie ma błędów. Braki danych nie występują.



Rysunek 2: Pomiary działki kielicha i płatka w zależności od gatunku. W celu polepszenia widoczności, punkty zostały odrobinę losowo rozrzucone.

Jako cechę najlepiej rozróżniającą gatunki wybieramy długość płatka (`Petal.Length`) – wartości dla *Iris setosa* są wyraźnie niższe niż dla pozostałych dwóch gatunków, a *Iris versicolor* i *Iris virginica* również są od siebie dobrze oddzielone. Jako cechę najgorzej rozróżniającą gatunki wybieramy szerokość działki kielicha (`Sepal.Width`) – rozkłady dla wszystkich trzech gatunków silnie się nakładają.

1.3 Porównanie metod dyskretyzacji

Do dokonania dyskretyzacji wykorzystujemy funkcję `discretize` z R-pakietu `arules`. Używamy jej w następujący sposób:

```
discretize(dane$CECHA, method = METODA, breaks = 3)
```

W miejsce CECHA wpisujemy identyfikator odpowiedniej cechy, a w miejsce METODA identyfikator metody:

- "interval" dla metody *equal width*,
- "frequency" dla metody *equal frequency*,
- "cluster" dla metody *k-means clustering* oraz
- "fixed" dla ręcznego podziału.

W przypadku ostatniej metody, zamiast `breaks = 3` piszemy wektor punktów rozdzielających, przykładowo:

```
discretize(
  dane$Sepal.Width,
  method = "fixed",
  breaks = c(2.0, 2.9, 3.2, 4.4)
)
```

1.3.1 Metoda equal width

Metoda *equal width* daje nam następujące przedziały:


Przedział	Liczność
[1,2.97)	50
[2.97,4.93)	54
[4.93,6.9]	46

Tabela 3: Przedziały dla naszej „dobrej” cechy – długości płatk


Przedział	Liczność
[2,2.8)	47
[2.8,3.6)	88
[3.6,4.4]	15

Tabela 4: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 3: Granice przedziałów dla metody *equal width* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 4: Rozkład gatunków w klasach dyskretyzacji (metoda *equal width*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.97)	[2.97,4.93)	[4.93,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	48	2
<i>virginica</i>	0	6	44

Tabela 5: Wynik podziału dla długości płatk

Gatunek	[2,2.8)	[2.8,3.6)	[3.6,4.4]
<i>setosa</i>	1	36	13
<i>versicolor</i>	27	23	0
<i>virginica</i>	19	29	2

Tabela 6: Wynik podziału dla szerokości działki kielicha

Dzieląc cechę długości płatk (`Petal.Length`) na równe przedziały z bardzo dobrą skutecznością rozdzielamy irysy gatunku *Iris setosa* od pozostałych. Wszystkie kwiaty tego gatunku wpadają w przedział najkrótszej długości oraz nie wpadają do tego przedziału żadne irysy innego gatunku.

W miarę skutecznie rozróżniamy też gatunki *Iris versicolor* i *Iris virginica*, które wpadają zazwyczaj odpowiednio w przedział o średniej długości i przedział o najdłuższej długości. W niektórych przypadkach *Iris versicolor* trafia jednak do przedziału o najdłuższej długości, a *Iris virginica* do przedziału o średniej długości. Więcej razy występuje ten pierwszy przypadek niż drugi.

Jeżeli podzielimy zamiast tego na równe przedziały cechę szerokości działki kielicha (`Sepal.Width`), nie otrzymamy żadnych zadowalających nas rezultatów.

1.3.2 Metoda *equal frequency*

Używając metody *equal frequency*, otrzymujemy przedziały:


Przedział	Liczność
[1,2.63)	50
[2.63,4.9)	49
[4.9,6.9]	51

Tabela 7: Przedziały dla naszej „dobrej” cechy – długości płatka


Przedział	Liczność
[2,2.9)	47
[2.9,3.2)	47
[3.2,4.4]	56

Tabela 8: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 5: Granice przedziałów dla metody *equal frequency* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 6: Rozkład gatunków w klasach dyskretyzacji (metoda *equal frequency*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.63)	[2.63,4.9)	[4.9,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	46	4
<i>virginica</i>	0	3	47

Tabela 9: Wynik podziału dla długości płatk

Gatunek	[2,2.9)	[2.9,3.2)	[3.2,4.4]
<i>setosa</i>	1	11	38
<i>versicolor</i>	27	18	5
<i>virginica</i>	19	18	13

Tabela 10: Wynik podziału dla szerokości działki kielicha

Przedziały dla długości płatk (`Petal.Length`) wychodzą niemal jednakowe jak w przypadku metody *equal width*, w związku z tym wyniki również wychodzą takie same. Skuteczność też się względem nich nie zmienia.

Zauważalną różnicą jest mniejsza różnica między liczbą przedstawicieli *Iris versicolor* trafiających jednak do przedziału o najdłuższej długości, a *Iris virginica* trafiających do przedziału o średniej długości. W pewien sposób można więc uznać te wyniki za lepsze.

Dzieląc szerokość działki kielicha (`Sepal.Width`) uzyskujemy inne przedziały, lecz równie (jak nie bardziej) niesatysfakcjonujące wyniki jak przy metodzie przedziałów równej długości.

1.3.3 Metoda k-means clustering

Metodą *k-means clustering* otrzymujemy takie przedziały:


Przedział	Liczność
[1,2.95)	50
[2.95,5.13)	66
[5.13,6.9]	34

Tabela 11: Przedziały dla naszej „dobrej” cechy – długości płatk


Przedział	Liczność
[2,2.78)	33
[2.78,3.41)	92
[3.41,4.4]	25

Tabela 12: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 7: Granice przedziałów dla metody *k-means clustering* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 8: Rozkład gatunków w klasach dyskretyzacji (metoda *k-means clustering*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.95)	[2.95,5.13)	[5.13,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	50	0
<i>virginica</i>	0	16	34

Tabela 13: Wynik podziału dla długości płatka

Gatunek	[2,2.78)	[2.78,3.41)	[3.41,4.4]
<i>setosa</i>	1	27	22
<i>versicolor</i>	21	29	0
<i>virginica</i>	11	36	3


Tabela 14: Wynik podziału dla szerokości działki kielicha

Dla długości płatka (*Petal.Length*) wyniki wychodzą dokładnie takie same jak w metodzie *equal frequency*.

W przypadku i tej metody, podział po szerokości działki kielicha (*Sepal.Width*) również nie daje zbyt wartościowych wyników.

1.3.4 Podział ręczny

Popatrzmy na rozkład wartości rozważanych cech dla każdego z gatunków:



Rysunek 9: Rozkład wartości cech w podziale na gatunki

Na oko wybieramy dla długości płatka (`Petal.Length`) przedziały $[1, 2.5)$, $[2.5, 4.8)$ oraz $[4.8, 6.9]$.

Dla szerokości działki kielicha (`Sepal.Width`) – choć to ciężkie – wybieramy przedziały $[2, 2.9)$, $[2.9, 3.2)$ i $[3.2, 4.4]$.

Wybrane przedziały dzielą nam zbiór danych na klasy o następującej liczności:


Przedział	Liczność
$[1, 2.5)$	50
$[2.5, 4.8)$	45
$[4.8, 6.9]$	55

Tabela 15: Przedziały dla naszej „dobrej” cechy – długości płatka


Przedział	Liczność
$[2, 2.9)$	47
$[2.9, 3.2)$	47
$[3.2, 4.4]$	56

Tabela 16: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki dyskretyzacji prezentują się tak:



Rysunek 10: Granice przedziałów dla podziału ręcznego naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 11: Rozkład gatunków w klasach dyskretyzacji (podział ręczny). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.5)	[2.5,4.8)	[4.8,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	44	6
<i>virginica</i>	0	1	49

Tabela 17: Wynik podziału dla długości płata

Gatunek	[2,2.9)	[2.9,3.2)	[3.2,4.4]
<i>setosa</i>	1	11	38
<i>versicolor</i>	27	18	5
<i>virginica</i>	19	18	13

Tabela 18: Wynik podziału dla szerokości działki kielicha

W podziale długości płata (*Petal.Length*) wybrane przez nas przedziały nie przewyższają skutecznością wcześniejszych metod. Liczba „pomyłek” jest mniej więcej taka sama.

W podziale szerokości działki kielicha (*Sepal.Width*) – w przeciwieństwie do poprzednich metod – udało nam się uzyskać jakikolwiek wartościowy efekt, a mianowicie udało nam się

rozdzielić *Iris setosa* od pozostałych gatunków – zdecydowana większość przedstawicieli tego gatunku trafia do trzeciego przedziału.

Pozostałe dwa gatunki zbyt się jednak pokrywają tą cechą aby można je było rozróżnić.

1.3.5 Podsumowanie

Cecha długości płatków (`Petal.Length`) na tyle dobrze rozróżnia rozważane gatunki kwiatów, że niezależnie od wyboru metody otrzymamy bardzo dobry wynik. Za pomocą większości metod jesteśmy w stanie z pełną skutecznością rozdzielić irysy gatunku *Iris setosa* od *Iris versicolor* i *Iris virginica*. Żadna metoda nie pozwala nam jednak na całkowite rozdzielanie dwóch ostatnich gatunków. Być może dyskretyzacja w oparciu na cechę będącą jakąś funkcją od bazowych cech pozwoliłaby na lepszy wynik.

Żadna metoda nie pozwoliła na rozróżnienie gatunków na podstawie cechy szerokości działki kielicha (`Sepal.Width`). Pokazuje to że ograniczając zbiór danych możemy stracić informacje których żadnym algorytmem nie będziemy w stanie odzyskać.

2 Część 2 - Analiza składowych głównych

2.1 Wstęp

W części drugiej będziemy pracować na zbiorze danych pobranych ze strony [Kaggle](#), pochodzącym oryginalnie z nieistniejącej już (przynajmniej pod tą domeną) strony Teleport.org. Zbiór zawiera wskaźniki opisujące jakość życia z wybranej grupy „najbardziej kreatywnych” miast z całego świata, zebrane po to, aby pomóc znaleźć odpowiednie miasto do życia według preferencji.

Wskaźniki dotyczą między innymi charakterystyk takich jak: warunki mieszkaniowe, koszty utrzymania, bezpieczeństwo, opieka zdrowotna, edukacja itp. Wszystkie wskaźniki są w skali od 0 do 10, gdzie większa wartość oznacza lepszy wynik.

Naszym celem będzie przeprowadzenie analizy składowych głównych (PCA, ang. *Principal Component Analysis*) wskaźników zawartych w zbiorze.

2.2 Przygotowanie danych

Dane zawierają informacje o 266 miastach. Dla każdego z nich mamy 21 cech.

	Typ	Opis
X	integer	identyfikator obserwacji
UA_Name	factor	nazwa obszaru miejskiego (UA – ang. <i>urban area</i>)
UA_Country	factor	kraj
UA_Continent	factor	kontynent
Housing	numeric	warunki mieszkaniowe
Cost.of.Living	numeric	koszty utrzymania
Startups	numeric	ekosystem startupów
Venture.Capital	numeric	dostępność kapitału inwestycyjnego
Travel.Connectivity	numeric	połączenia komunikacyjne (transport międzymiastowy i międzynarodowy)
Commute	numeric	codzienne dojazdy
Business.Freedom	numeric	swoboda prowadzenia biznesu
Safety	numeric	bezpieczeństwo
Healthcare	numeric	opieka zdrowotna
Education	numeric	edukacja
Environmental.Quality	numeric	jakość środowiska
Economy	numeric	kondycja gospodarki
Taxation	numeric	podatki
Internet.Access	numeric	dostęp do internetu
Leisure...Culture	numeric	oferta rozrywkowa i kulturalna
Tolerance	numeric	tolerancja społeczna
Outdoors	numeric	możliwości spędzania czasu na świeżym powietrzu

Tabela 19: Typy oraz opisy cech

Identyfikator **X** na pewno nie będzie nas interesował, więc go usuwamy.

Aby ujednolicić konwencję nazw, nazwy cech **UA_Name**, **UA_Country** oraz **UA_Continent** zamieniamy odpowiednio na **UrbanArea**, **Country** i **Continent**. Pozostałe nazwy cech, w których spacje zostały zamienione przez wbudowany w R czytnik CSV na kropki również ujednolicamy do tej konwencji. W nazwie cechy **Leisure...Culture**, w której na kropkę został zamieniony także symbol „&”, powstały trójkropek zamieniamy na „And”.

Zmienione nazwy zmiennych możemy zobaczyć w poniższej tabeli – będącej częścią dalszych działań dążących do oczyszczenia danych – podsumowującej wartości nieusuniętych zmiennych:

UrbanArea	Country	Continent	Housing	CostOfLiving
Birmingham: 2	United Kingdom: 13	Africa: 8	Min.: 0.000	Min.: 0.000
Portland: 2	Canada: 11	Asia: 37	1st Qu.: 5.149	1st Qu.: 4.795
Aarhus: 1	Germany: 11	Europe: 111	Median: 6.726	Median: 5.630
Adelaide: 1	France: 9	North America: 87	Mean: 6.467	Mean: 5.746
Albuquerque: 1	Spain: 7	Oceania: 8	3rd Qu.: 8.313	3rd Qu.: 7.596
Almaty: 1	Italy: 6	South America: 15	Max.: 10.000	Max.: 10.000
(Inne): 258	(Inne): 209			

Startups	VentureCapital	TravelConnectivity	Commute	BusinessFreedom
Min.: 0.000	Min.: 0.000	Min.: 0.500	Min.: 0.000	Min.: 0.000
1st Qu.: 3.098	1st Qu.: 0.000	1st Qu.: 1.703	1st Qu.: 4.400	1st Qu.: 5.771
Median: 4.214	Median: 2.317	Median: 2.921	Median: 5.064	Median: 8.404
Mean: 4.595	Mean: 2.703	Mean: 3.447	Mean: 4.632	Mean: 7.331
3rd Qu.: 5.790	3rd Qu.: 3.765	3rd Qu.: 4.766	3rd Qu.: 5.613	3rd Qu.: 8.837
Max.: 10.000	Max.: 10.000	Max.: 10.000	Max.: 6.729	Max.: 10.000

Safety	Healthcare	Education	EnvironmentalQuality	Economy
Min.: 1.343	Min.: 0.000	Min.: 0.000	Min.: 1.000	Min.: 0.000
1st Qu.: 5.972	1st Qu.: 6.064	1st Qu.: 2.184	1st Qu.: 4.329	1st Qu.: 4.103
Median: 7.189	Median: 6.780	Median: 4.273	Median: 6.481	Median: 5.373
Mean: 6.972	Mean: 6.797	Mean: 3.835	Mean: 6.078	Mean: 5.058
3rd Qu.: 8.269	3rd Qu.: 8.055	3rd Qu.: 5.294	3rd Qu.: 7.888	3rd Qu.: 6.514
Max.: 10.000	Max.: 9.321	Max.: 9.711	Max.: 9.953	Max.: 9.390

Taxation	InternetAccess	LeisureAndCulture	Tolerance	Outdoors
Min.: 0.500	Min.: 1.000	Min.: 0.000	Min.: 1.406	Min.: 0.500
1st Qu.: 3.921	1st Qu.: 4.134	1st Qu.: 4.448	1st Qu.: 5.780	1st Qu.: 3.699
Median: 4.760	Median: 5.379	Median: 5.707	Median: 7.154	Median: 4.733
Mean: 4.953	Mean: 5.205	Mean: 5.710	Mean: 6.793	Mean: 4.493
3rd Qu.: 5.955	3rd Qu.: 6.265	3rd Qu.: 7.062	3rd Qu.: 8.052	3rd Qu.: 5.500
Max.: 10.000	Max.: 9.716	Max.: 10.000	Max.: 9.739	Max.: 7.933

Tabela 20: Podsumowanie danych


Jak widać, wszystkie zmienne zawierają wartości zgodne z naszymi oczekiwaniami. Nie występują też żadne braki danych.

Mamy 3 cechy jakościowe reprezentujące nazwę miasta, kraju i kontynentu oraz 17 cech ilościowych zawierających wartości wskaźników jakości życia.

W podsumowaniu danych jakościowych widzimy, że mamy informacje o miastach znajdujących się na 6 kontynentach (niestety bez [Antarktydy](#)). Powyższa tabela wskazuje nam, że najwięcej miast mamy z [Europy](#) (111), następnie z [Ameryki Północnej](#) (87). Łącznie mamy informacje o 264 miastach z 135 państw, co świadczy o dużej różnorodności.


W tabeli widzimy też, że nie wszystkie cechy ilościowe przyjmują wartości skrajne – 0 oraz 10. Może to sugerować, że ich rozkłady się znacząco różnią.

W celu najlepszego wyznaczenia składowych głównych, zmienne powinny mieć podobną wariancję.



Rysunek 12: Rozkład wartości cech ilościowych

Widzimy, że zakres wartości zmiennych takich jak `Commute` i `Outdoors` jest dużo węższy niż przykładowo `VentureCapital`, `EnvironmentalQuality`, czy `Education`. Wskazuje to na różnice w wariancji. Z tego powodu dokonujemy standaryzacji za pomocą wbudowanej w R funkcji `scale()`. Wynik tego działania znajduje się na poniższym wykresie.



Rysunek 13: Rozkład wartości cech ilościowych po standaryzacji

Musimy jednak pamiętać, że wartości zmiennych po standaryzacji nie są już w skali 0–10.

2.3 Wyznaczanie składowych głównych

Kolejnym naszym krokiem będzie wyznaczenie składowych głównych naszych zmiennych. Użyjemy do tego funkcji `prcomp()`.

W celu interpretacji otrzymanych składowych, analizujemy ich wektory ładunków (ang. *loadings*). Reprezentują one wkład każdej ze zmiennych na wartości składowych.

	PC1	PC2	PC3
Housing	0.308	0.053	-0.314
CostOfLiving	0.260	-0.176	-0.331
Startups	-0.180	-0.483	0.006
VentureCapital	-0.237	-0.427	0.015
TravelConnectivity	-0.209	-0.135	-0.340
Commute	-0.114	0.026	-0.506
BusinessFreedom	-0.377	0.098	0.024
Safety	-0.039	0.287	-0.333
Healthcare	-0.280	0.242	-0.281
Education	-0.403	-0.049	-0.074
EnvironmentalQuality	-0.326	0.253	0.054
Economy	-0.273	-0.074	0.309
Taxation	0.026	0.107	-0.020
InternetAccess	-0.276	0.023	0.028
LeisureAndCulture	-0.074	-0.365	-0.305
Tolerance	-0.190	0.355	-0.103
Outdoors	-0.092	-0.193	-0.149

Tabela 21: Wartości wektorów ładunków trzech pierwszych składowych głównych

Największy wpływ na interpretację składowych głównych mają zmienne o najwyższych wartościach bezwzględnych ładunków.

Najwyższe dodatnie wartości dla pierwszej składowej głównej (PC1) osiągają zmienne **Housing** oraz **CostOfLiving**, czyli wskaźniki dostępności mieszkań i przystępności kosztów utrzymania. Z kolei najniższe (ujemne) wartości przyjmują zmienne **Education**, **BusinessFreedom** oraz **EnvironmentalQuality**. Oznacza to, że PC1 można interpretować jako wymiar kontrastu pomiędzy przystępnością życia a poziomem rozwoju społeczno-gospodarczego.


W przypadku drugiej składowej głównej (PC2) najwyższe dodatnie wartości osiągają zmienne **Safety**, **Healthcare**, **EnvironmentalQuality** oraz **Tolerance**, które opisują szeroko rozumianą jakość życia. Najniższe wartości przyjmują natomiast zmienne **Startups**, **VentureCapital** oraz **LeisureAndCulture**, związane z aktywnością innowacyjną i gospodarczą. W związku z tym PC2 można interpretować jako wymiar przeciwstawiający wysoką jakość życia dynamice innowacyjno-gospodarczej.

Dla trzeciej składowej głównej (PC3) najwyższą dodatnią wartość przyjmuje zmienna **Economy**, natomiast niskie (ujemne) wartości obserwujemy m.in. dla zmiennych **Commute**, **TravelConnectivity**, **CostOfLiving** oraz **Safety**. Oznacza to, że PC3 można interpretować jako wymiar odzwierciedlający sytuację gospodarczą w zestawieniu z wybranymi aspektami komfortu życia. Wyższe wartości tej składowej mogą wskazywać na lepsze warunki ekonomiczne, ale jednocześnie mniej korzystne warunki codziennego funkcjonowania.


2.4 Zmienność odpowiadająca poszczególnym składowym

W kolejnym etapie analizy zbadaliśmy, jaki procent całkowitej zmienności (wariancji) danych jest wyjaśniany przez poszczególne składowe główne.

Na pierwszym wykresie przedstawiono wariancję poszczególnych składowych. Zgodnie z założeniami metody PCA, wartości wariancji maleją wraz z kolejnymi składowymi, co potwierdza, że pierwsze z nich zawierają najistotniejszą informację o strukturze zbioru danych.



Rysunek 14: Wariancje poszczególnych składowych głównych




Rysunek 15: Skumulowana wariancja (w %) wyjaśniana przez kolejne składowe główne

Aby móc odpowiedzieć na pytanie, ile składowych głównych jest potrzebnych do wyjaśnienia 80% oraz 90% całkowitej zmienności, na powyższym wykresie zaznaczamy odpowiednio

poziomy 80% i 90%. Na podstawie tego wykresu możemy wyznaczyć liczbę składowych potrzebnych do wyjaśnienia odpowiednich wartości procentowych wariancji.

Do wyjaśnienia 80% wariancji potrzebnych jest 7 składowych głównych, natomiast do wyjaśnienia 90% wariancji potrzebnych jest 10 składowych głównych.

2.4.1 Wizualizacja danych wielowymiarowych



Rysunek 16: Rzut danych na dwie pierwsze składowe główne, kolory wg kontynentu

Na powyższym wykresie przedstawiono rozkład miast w przestrzeni dwóch pierwszych składowych głównych, które można interpretować odpowiednio jako przystępność życia (PC1) oraz jakość życia (PC2).


Punkty na wykresie są pogrupowane według kontynentów, co pozwala na analizę zróżnicowania geograficznego.

Miasta europejskie koncentrują się głównie w lewej górnej części wykresu. Oznacza to, że wiele z nich charakteryzuje się relatywnie wysokimi kosztami życia (ujemne wartości PC1) przy jednocześnie wysokim poziomie jakości życia (wysokie wartości PC2), obejmującej m.in. bezpieczeństwo, opiekę zdrowotną oraz jakość środowiska.

Miasta Ameryki Północnej wykazują większe zróżnicowanie i są bardziej rozproszone na wykresie, z widoczną tendencją do niższych wartości PC2. Może to sugerować, że część tych miast w większym stopniu charakteryzuje się dynamiką innowacyjną oraz aktywnością gospodarczą (np. rozwój startupów), kosztem niektórych aspektów jakości życia.

Miasta azjatyckie cechują się największym rozproszeniem na wykresie, co odzwierciedla dużą różnorodność gospodarczą i społeczną tego kontynentu. Obejmuje ona zarówno wysoko rozwinięte metropolie (np. Singapur czy Tokio), jak i miasta o niższym poziomie rozwoju, co przekłada się na szeroki zakres wartości obu składowych.


Miasta afrykańskie koncentrują się częściej w obszarach o wyższych wartościach PC1, czyli tam, gdzie koszty utrzymania są niższe a mieszkania bardziej dostępne. Idzie to jednak w parze z niższymi wartościami wskaźników rozwoju społeczno-gospodarczego oraz jakości życia.



Rysunek 17: Biplot PCA z elipsami ufności (95%) dla kontynentów

Na wykresie biplot przedstawiono podział miast według kontynentów wraz z naniesionymi wektorami zmiennych opisujących ich charakterystyki. Strzałki reprezentują kierunek i siłę wpływu poszczególnych zmiennych na składowe główne, co umożliwia jednoczesną analizę zależności między miastami oraz badanymi cechami.


Miasta Europy oraz Ameryki Północnej znajdują się po stronie ujemnych wartości Dim1, gdzie wskaźniki rozwoju społeczno-gospodarczego (*Education*, *BusinessFreedom*, *EnvironmentalQuality*) przyjmują wyższe wartości. Miasta z Afryki, Ameryki Południowej oraz części Azji sytuują się po przeciwnej stronie osi Dim1 – tam, gdzie dominują wektory *Housing* i *CostOfLiving*, czyli niższe koszty utrzymania, ale też niższe wskaźniki rozwoju. Widoczna separacja regionów pokazuje, że PCA dobrze odzwierciedla różnice w profilach miast między tymi grupami.



Rysunek 18: Rzut danych na dwie pierwsze składowe główne – wyróżnione cztery miasta najbardziej oddalone od środka przestrzeni PCA

Na wykresie PCA widzimy, że miasta zlokalizowane w lewym dolnym rogu (niskie wartości PC1 i PC2) tworzą grupę o szczególnych cechach strukturalnych. Są to głównie metropolie z Europy i Ameryki Północnej (Nowy Jork, Londyn, San Francisco Bay Area), które charakteryzują się wysokimi kosztami życia oraz ograniczoną dostępnością mieszkań. Ich niskie wartości PC2 oznaczają silną dynamikę innowacyjno-gospodarczą i bogatą ofertę kulturalną, kosztem niższych wskaźników bezpieczeństwa, opieki zdrowotnej i jakości środowiska.

Lagos, położone w Nigerii (Afryka Zachodnia), znajduje się na przeciwnym biegunie osi PC1 względem tych miast zachodnich, co czyni je jednym z najbardziej oddalonych punktów w tym wymiarze. Miasto to reprezentuje dynamicznie rozwijającą się metropolię Globalnego Południa, zmagającą się z wyzwaniami gwałtownej urbanizacji, presją demograficzną oraz ograniczeniami infrastrukturalnymi. Jego wysoka wartość PC1 wynika z niskich kosztów utrzymania, a niska wartość PC2 wskazuje na ograniczoną dostępność usług publicznych (edukacja, opieka zdrowotna) i niższą jakość środowiska, co wyraźnie odróżnia je od metropolii Europy i Ameryki Północnej.




Rysunek 19: Rzut danych na trzy pierwsze składowe główne – wyróżnione: Europa i Ameryka Północna

Na trójwymiarowym wykresie PCA przedstawiono rozmieszczenie miast względem trzech głównych składowych: PC1, PC2 oraz PC3, ograniczając analizę do miast Europy i Ameryki Północnej. Każda z osi reprezentuje odmienny wymiar jakości życia i rozwoju społeczno-gospodarczego.


Analiza rozmieszczenia miast w tej przestrzeni pokazuje wyraźne różnice regionalne. Miasta Ameryki Północnej częściej lokują się w obszarach wyższych wartości PC3, co sugeruje relatywnie silniejszą sytuację gospodarczą w porównaniu do miast europejskich. Jednocześnie miasta europejskie częściej osiągają wyższe wartości w wymiarach jakości życia (PC2), co wskazuje na większy nacisk na bezpieczeństwo, ochronę zdrowia i jakość środowiska. W rezultacie obie grupy miast różnią się profilem rozwoju: Ameryka Północna jest bardziej zorientowana na dynamikę gospodarczą, natomiast Europa na zrównoważoną jakość życia.

2.5 Korelacja zmiennych

Następnie, w celu porównania zależności między zmiennymi opisanymi przez składowe PCA, zrobiliśmy zestawienie obejmujące macierz korelacji oraz biplot PCA.



Rysunek 20: Korelacje cech ze składowymi głównymi



Rysunek 21: Biplot PCA – 10 cech o największym wkładzie

Analiza macierzy korelacji wykazała istotne zależności pomiędzy zmiennymi. W szczególności

zaobserwowano silną dodatnią korelację między `Housing` a `CostOfLiving` – w tańszych miastach mieszkania są przeciętnie łatwiej dostępne. Ujemne zależności występują między tymi zmiennymi a wskaźnikami jakości środowiska oraz rozwoju społeczno-gospodarczego, co oznacza, że miasta o lepiej rozwiniętej edukacji, biznesie i jakości środowiska są zwykle droższe.

Wykres biplot PCA potwierdza te zależności w ujęciu geometrycznym. Zmienne silnie dodatnio skorelowane są reprezentowane przez wektory skierowane w podobnym kierunku, natomiast zmienne o korelacji ujemnej znajdują się po przeciwnych stronach wykresu względem siebie. Dodatkowo biplot umożliwia analizę zależności pomiędzy samymi zmiennymi – małe kąty między wektorami (np. `Housing` i `CostOfLiving`) wskazują na silną korelację dodatnią, natomiast przeciwne kierunki wektorów (np. `Housing` i `Education`) świadczą o korelacji ujemnej.

Wnioski uzyskane z obu metod są spójne i wzajemnie się uzupełniają. Macierz korelacji dostarcza precyzyjnych wartości liczbowych opisujących siłę zależności, natomiast biplot PCA pozwala na ich intuicyjną interpretację geometryczną, umożliwiając jednoczesną analizę relacji między zmiennymi oraz ich projekcji w przestrzeni składowych głównych.

2.6 Końcowe wyniki

W przeprowadzonych analizach PCA udało się zaobserwować wyraźną strukturę danych, w której pierwsze dwie składowe główne opisują najważniejsze wymiary zróżnicowania miast: przystępność życia kontra poziom rozwoju społeczno-gospodarczego (PC1) oraz jakość życia (PC2). Dodatkowo trzecia składowa (PC3) wnosi informację o sytuacji gospodarczej, jednak jej znaczenie jest mniejsze niż dwóch pierwszych komponentów.

Z analizy wynika, że dwie pierwsze składowe główne wyjaśniają łącznie około 45% wariancji, co oznacza umiarkowanie dobrą reprezentację danych. Pozwala to na uchwycenie głównych trendów oraz wyraźne rozróżnienie grup miast, jednak część informacji zawarta jest również w kolejnych składowych. Dodanie trzeciej składowej zwiększa szczegółowość analizy, ale nie zmienia istotnie ogólnej struktury danych.

Standaryzacja danych miała istotny wpływ na wyniki analizy. Dzięki niej wszystkie zmienne zostały sprowadzone do porównywalnej skali, co zapobiegło dominacji cech o dużych wartościach liczbowych (np. kosztów życia). W efekcie PCA lepiej odzwierciedla rzeczywiste relacje między zmiennymi, a uzyskane składowe są bardziej zrównoważone.

3 Część 3 - Skalowanie wielowymiarowe (MDS)

3.1 Wstęp

W ostatniej części raportu mamy zbiór danych zawierających charakterystyki opisujące pasażerów Titanica, wraz z informacją czy dana osoba przeżyła. Zbiór pobieramy z R-pakietu `titanic`, ale jest też on dostępny na [Kaggle](#).

Naszym zadaniem będzie dokonanie skalowania wielowymiarowego (MDS, ang. *multi-dimensional scaling*).

3.2 Przygotowanie danych

Zbiór danych zawiera informacje o pasażerach Titanica. Między innymi takie jak: wiek, płeć, miejsce rozpoczęcia podróży oraz klasa pasażerska. Ważną zmienną występującą w bazie danych jest cecha **Survived**, która informuje nas czy dana osoba przeżyła katastrofę, czy nie. Dane zawierają 891 informacji o różnych pasażerach oraz 12 cech, które ich opisują.

	Typ	Opis
PassengerId	integer	ID pasażera
Survived	integer	Czy przeżył
Pclass	integer	Numer klasy
Name	character	Imię pasażera
Sex	character	Płeć
Age	numeric	Wiek
SibSp	integer	Liczba rodzeństwa + małżonków podróżujących z pasażerem
Parch	integer	Liczba rodziców + dzieci podróżujących z pasażerem
Ticket	character	Numer biletu
Fare	numeric	Opłata za bilet
Cabin	character	Numer kabiny
Embarked	character	Port zaokrętowania pasażera

Tabela 22: Typy oraz opisy cech

Z danych na pewno usuwamy zmienne takie jak **PassengerId**, **Name**, **Ticket** oraz **Cabin**, które nie wniosą nic do naszej analizy. Są to indywidualne dane każdego pasażera, w celu ochrony danych zostaną one usunięte z dalszej analizy.

Dodatkowo, typy zmiennych które po wczytaniu danych były wczytane jako typ **character** zmieniamy na typ **factor**. Są to zmienne takie jak płeć oraz port zaokrętowania, które możemy traktować jako zmienne jakościowe. Zmienną **Pclass** reprezentującą numer klasy zmieniamy na zmienną porządkową.

Sprawdzamy czy mamy jakieś braki danych:

	Liczba_NA	Liczba_puste_pozycje
Survived	0	0
Pclass	0	0
Sex	0	0
Age	177	0
SibSp	0	0
Parch	0	0
Fare	0	0
Embarked	0	2

Tabela 23: Braki danych w zbiorze

Zmienna **Age** zawiera 177 braków. W tym przypadku nie usuwamy tej zmiennej, tylko zastępujemy te braki medianą z pozostałych wartości **Age**. Nie usuwamy też wierszy z tymi brakami, ponieważ stanowią one prawie 20% danych. Natomiast braki w zmiennej **Embarked**, która oznacza port w którym wsiadł pasażer, uzupełniamy najczęstszą wartością jaka pojawia się w danych.

W tabeli poniżej znajdują się statystyki opisowe zmiennych oraz liczości wystąpień poszczególnych kategorii w nieusuniętych zmiennych jakościowych.

Survived	Pclass	Sex	Age
Min.: 0.0000	1: 216	female: 314	Min.: 0.42
1st Qu.: 0.0000	2: 184	male: 577	1st Qu.: 22.00
Median: 0.0000	3: 491		Median: 28.00
Mean: 0.3838			Mean: 29.36
3rd Qu.: 1.0000			3rd Qu.: 35.00
Max.: 1.0000			Max.: 80.00

SibSp	Parch	Fare	Embarked
Min.: 0.000	Min.: 0.0000	Min.: 0.00	C: 168
1st Qu.: 0.000	1st Qu.: 0.0000	1st Qu.: 7.91	Q: 77
Median: 0.000	Median: 0.0000	Median: 14.45	S: 646
Mean: 0.523	Mean: 0.3816	Mean: 32.20	
3rd Qu.: 1.000	3rd Qu.: 0.0000	3rd Qu.: 31.00	
Max.: 8.000	Max.: 6.0000	Max.: 512.33	


Tabela 24: Podsumowanie danych po uzupełnieniu braków

3.3 Redukcja wymiaru na bazie MDS

Następnie w celu poprawnej redukcji wymiaru dzielimy nasz zbiór na zmienną **Survived** i resztę zmiennych. Macierz odmienności wyznaczamy za pomocą metryki Gowera, ponieważ w naszych danych znajdują się zarówno dane ilościowe, jak i jakościowe. Do zmiennych ilościowych stosujemy również standaryzację w celu poprawnego wyliczenia odległości.

Otrzymaną macierz wizualizujemy poniżej w postaci heatmapy z naniesionym dendrogramem, który pozwala dostrzec hierarchiczną strukturę podobieństwa pomiędzy obserwacjami.

```
## Warning: pakiet 'cluster' został zbudowany w wersji R 4.5.3
```



Rysunek 22: Heatmapa macierzy odmienności (Gower) – jaśniejsze pola oznaczają większe podobieństwo, ciemniejsze mniejszą


Na podstawie heatmapy możemy zauważyć, że pasażerowie na statku Titanic byli bardzo podzieleni na różne grupy. Wzdłuż przekątnej zauważamy jasne pola, które świadczą o bardzo dużym podobieństwie osób wśród tych samych grup.

Na samej górze i po lewej stronie znajdują się drzewa – widzimy wyraźny podział na dwie części. Dendrogram sugeruje, że różnice między tymi dwiema grupami są bardziej znaczące niż jakiegokolwiek inne cechy indywidualne.

Ciemne elementy na heatmapie są to wartości odstające, na przykład pasażerowie, którzy

mimo bycia w 3. klasie mieli drogi bilet.

Następnie stosujemy algorytm MDS w wariancie metrycznym (funkcja `cmdscale`) dla wymiaru $k = 3$ z metryką euklidesową (na początku spróbowaliśmy dla $k = 2$ i stress wyszedł jako 0.26, co sugerowało, że należy zwiększyć wymiar). Wybieramy wariant metryczny, ponieważ macierz odmienności Gowera daje nam realne wartości odległości, a nie tylko ich kolejność – nie ma więc powodu, żeby rezygnować z tej informacji. Aby ocenić jakość tej redukcji, rysujemy diagram Sheparda.




Rysunek 23: Diagram Sheparda dla MDS ($k=3$)

Analizując wykres Sheparda możemy zauważyć, że punkty układają się wzdłuż linii $y = x$ – świadczy to o poprawności relacji podobieństwa. Na wykresie widzimy też schody, które świadczą o występowaniu grup wśród osób o podobnych cechach oraz granic między grupami – co jest spójne z tym, co widzieliśmy na heatmapie.

Nie występują wartości znacząco odstające od linii $y = x$, co spójne jest z niską wartością funkcji *stress*, która wyniosła 0.17 – potwierdza to poprawność użytego wymiaru.

3.4 Wizualizacja danych

Wyniki MDS oglądamy na wykresach 2D, kolorując punkty według różnych zmiennych. Najpierw kolorujemy je według tego, czy pasażer przeżył.




Rysunek 24: Wizualizacja MDS (rzut 2D z przestrzeni 3D), kolory według **Survived**

Na wykresie możemy zauważyć bardzo wyraźny podział na grupy. Każde skupisko to grupa pasażerów podobnych do siebie ze względu na zestaw cech. Duża odległość między dwoma głównymi skupiskami świadczy o znaczącej różnicy między tymi grupami pasażerów.

Co istotne, górne skupiska punktów to w większości osoby ocalałe (czyli np. kobiety i dzieci z 1. klasy), a dolne to w większości ofiary – mimo że zmienna **Survived** nie była używana do redukcji. Cechy które przyjęliśmy (klasa, płeć, wiek) są więc silnie związane z przeżyciem. Ciekawym zjawiskiem są wartości odstające, np. osoby które zginęły mimo wysokiego statusu społeczno-ekonomicznego.


Następnie kolorujemy punkty według płci pasażera.



Rysunek 25: Wizualizacja MDS (rzut 2D), kolory według płci

Na powyższym wykresie widzimy podział ze względu na płeć osób – możemy stwierdzić, że płeć w naszym zbiorze danych jest bardzo ważną cechą i jest podstawą w szukaniu podobieństw między pasażerami. Porównując z wykresem przeżyć widzimy, że wśród osób które przeżyły katastrofę są głównie kobiety. Jest też grupa kobiet, która zginęła (wykres wyżej) – są to prawdopodobnie kobiety z najniższej klasy, które nie miały szansy na łódź ratunkową.

Na koniec kolorujemy punkty według klasy pasażerskiej.



Rysunek 26: Wizualizacja MDS (rzut 2D), kolory według klasy pasażerskiej

W obu skupiskach widać też podział na klasy, ale dużo słabszy niż ten na płci.

Tak jak zakładaliśmy wcześniej, kobiety które zginęły w katastrofie to kobiety z 3. klasy. Natomiast w dolnym skupisku (mężczyźni) niezależnie od klasy w każdej grupie znajdowały się jednostki, którym udało się przeżyć.

3.5 Podsumowanie

Analizując heatmapę i dendrogram zauważyliśmy, że istnieją dwie główne grupy różniące się między sobą, co potwierdziło się w dalszej analizie. Dzięki diagramowi Sheparda możemy mieć pewność, że redukcja do 3 wymiarów jest wiarygodna – większość punktów leży wzdłuż linii $y = x$, co świadczy o rzetelności naszych wniosków. Dodatkowo potwierdza to niska wartość funkcji stress (0.17).

Wykresy MDS pokazały, że pasażerowie naturalnie grupują się w skupiska, co świadczy o silnych zależnościach między ich cechami. Największe różnice występują między kobietami i mężczyznami oraz pasażerami 1. i 3. klasy. Osoby ocalałe wyraźnie grupują się w przestrzeni MDS, mimo że zmienna **Survived** nie była używana do redukcji – cechy które przyjęliśmy są więc silnie związane z przeżyciem.