

Sprawozdanie 2

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-27

Spis treści

1	Część 1 – dyskretyzacja cech ciągłych	2
1.1	Wstęp	2
1.2	Opis danych i wybór cech	2
1.3	Porównanie metod dyskretyzacji	3
2	Część 2 - Analiza składowych głównych	8
2.1	Wstęp	8
2.2	Opis danych	8
2.3	Przygotowanie danych	8
2.4	Wyznaczanie składowych głównych	12
2.5	Zmienność odpowiadająca poszczególnym składowym	13
2.6	Korelacja zmiennych	17
2.7	Końcowe wyniki	19
3	Część 3	19
3.1	Wstęp	19
3.2	Opis danych	19

1 Część 1 – dyskretyzacja cech ciągłych

1.1 Wstęp

Mamy zbiór danych zawierający wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*).



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

Zbiór danych został udostępniony przez Ronalda Fishera w 1936 roku. Pobieramy go z zestawu gotowych zbiorów dostępnych w pakiecie `datasets` w R.

Naszym pierwszym zadaniem będzie przeanalizowanie własności cech oraz wybranie jednej cechy, która najlepiej rozróżni gatunki kwiatu oraz jednej, która robi to najgorzej.

Następnym naszym zadaniem będzie przeprowadzenie dyskretyzacji wybranych cech na trzy klasy przy użyciu różnych metod dyskretyzacji nienadzorowanej oraz porównanie ich wyników. Będziemy porównywać metody *equal width*, *equal frequency*, *k-means clustering* oraz dyskretyzację na bazie przedziałów zadanych przez użytkownika (przez nas).

1.2 Opis danych i wybór cech

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatka (w cm)
Petal.Width	numeric	szerokość płatka (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)


Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

Wierzmy pomiarom i zakładamy że nie ma błędów. Braki danych nie występują.



Rysunek 2: Pomiary działki kielicha i płatka w zależności od gatunku. W celu polepszenia widoczności, punkty zostały odrobinę losowo rozrzucone.

Jako cechę najlepiej rozróżniającą gatunki wybieramy długość płatka (`Petal.Length`) — wartości dla *setosa* są wyraźnie niższe niż dla pozostałych dwóch gatunków, a *versicolor* i *virginica* również są od siebie dobrze oddzielone. Jako cechę najgorzej rozróżniającą gatunki wybieramy szerokość działki kielicha (`Sepal.Width`) — rozkłady dla wszystkich trzech gatunków silnie się nakładają.

1.3 Porównanie metod dyskretyzacji

Do dokonania dyskretyzacji wykorzystujemy funkcję `discretize` z R-pakietu `arules`. Używamy jej w następujący sposób:

```
discretize(dane$CECHA, method = METODA, breaks = 3)
```

W miejsce `CECHA` wpisujemy identyfikator odpowiedniej cechy, a w miejsce `METODA` identyfikator metody — `"interval"` dla metody *equal width*, `"frequency"` dla metody *equal frequency*,

"cluster" dla metody *k-means clustering* oraz "fixed" dla ręcznego podziału.

W przypadku ostatniej metody, zamiast `breaks = 3` piszemy wpisujemy wektor punktów rozdzielających, oraz podajemy dodatkowo wektor ich etykiet w parametrze `labels`, na przykład:

```
discretize(
  dane$Sepal.Width,
  method = "fixed",
  breaks = c(-Inf, 2.9, 3.2, Inf),
  labels = c("wąska", "średna", "szeroka")
)
```

1.3.1 Metoda equal width


Metoda *equal width* daje nam następujące przedziały:

Przedział	Liczność
[1,2.97)	50
[2.97,4.93)	54
[4.93,6.9]	46

Tabela 3: Przedziały dla naszej „dobrej” cechy – długości płatka

Przedział	Liczność
[2,2.8)	47
[2.8,3.6)	88
[3.6,4.4]	15

Tabela 4: Przedziały dla naszej „złej” cechy – szerokości działki kielicha




Rysunek 3: Granice przedziałów dla metody equal width naniesione na wartości cech

TODO tekst: skomentować mosaic ploty – czy klasy dyskretyzacji pokrywają się z gatunkami. Dla `Petal.Length` powinno być prawie idealnie, dla `Sepal.Width` fatalnie.

1.3.2 Metoda equal frequency

INFO: równa liczność przedziałów. Granice wybiera się tak, żeby w każdej klasie była $\sim 1/3$ obserwacji (kwantyle). Plus: zawsze zbalansowane. Minus: granice mogą



Rysunek 4: Rozkład gatunków w klasach dyskretyzacji (metoda equal width)

wypaść w dziwnych miejscach względem rozkładu.


TODO tekst: porównać z equal width – tutaj licznosci mają być bliskie 50/50/50.

Przedział	Licznosc
[1,2.63)	50
[2.63,4.9)	49
[4.9,6.9]	51

Tabela 5: Przedziały dla naszej „dobrej” cechy – długości płatków

Przedział	Licznosc
[2,2.9)	47
[2.9,3.2)	47
[3.2,4.4]	56


Tabela 6: Przedziały dla naszej „złej” cechy – szerokości działki kielicha



Rysunek 5: Granice przedziałów dla metody equal frequency naniesione na wartości cech

1.3.3 Metoda k-means clustering

INFO: granice wyznacza algorytm k-means na 1D. Algorytm próbuje znaleźć skupiska w danych. Plus: granice idą tam gdzie są przerwy w danych. Minus: zależy od inicjalizacji, może dawać różne wyniki przy różnych uruchomieniach.



Rysunek 6: Rozkład gatunków w klasach dyskretyzacji (metoda equal frequency)


TODO tekst: skomentować, czy granice trafiły w naturalne przerwy między gatunkami (zwłaszcza dla Petal.Length, gdzie jest oczywista przerwa setosa vs reszta).

Przedział	Liczność
[1,2.85)	50
[2.85,4.89)	49
[4.89,6.9]	51

Tabela 7: Przedziały dla naszej „dobrej” cechy – długości płatków

Przedział	Liczność
[2,2.69)	24
[2.69,3.28)	83
[3.28,4.4]	43


Tabela 8: Przedziały dla naszej „złej” cechy – szerokości działki kielicha



Rysunek 7: Granice przedziałów dla metody k-means clustering naniesione na wartości cech

1.3.4 Podział ręczny

INFO: granice wybrane przez nas ręcznie: Sepal.Width: $c(-\text{Inf}, 2.9, 3.2, \text{Inf})$ — próba podziału na „wąskie/średnie/szerokie” działki. Petal.Length: $c(-\text{Inf}, 2.5, 5.0, \text{Inf})$ — granice tak dobrane, żeby możliwie oddzielić setosa | versicolor | virginica.



Rysunek 8: Rozkład gatunków w klasach dyskretyzacji (metoda k-means clustering)

Etykiety klas to “wąski/średni/szeroki” (Sepal.Width) i “krótki/średni/długi” (Petal.Length) zamiast nazw przedziałów.


TODO tekst: uzasadnić wybór granic, porównać efekt z metodami automatycznymi. Dla Petal.Length nasz podział pewnie wypadnie najlepiej (bo wybraliśmy go pod gatunki), dla Sepal.Width i tak słabo (cecha jest zła do rozróżniania).

Przedział	Liczność
krótka	50
średna	54
długa	46


Tabela 9: Przedziały dla naszej „dobrej” cechy – długości płatka

Przedział	Liczność
wąska	47
średna	47
szeroka	56

Tabela 10: Przedziały dla naszej „złej” cechy – szerokości działki kielicha



Rysunek 9: Granice przedziałów dla podziału ręcznego naniesione na wartości cech



Rysunek 10: Rozkład gatunków w klasach dyskretyzacji (podział ręczny)

1.3.5 Podsumowanie

TODO tekst: porównać 4 metody w 2-3 zdaniach. Spodziewamy się że dla Petal.Length wszystkie metody radzą sobie dobrze (cecha sama dobrze rozdziela gatunki), a dla Sepal.Width żadna nie pomoże (overlap rozkładów jest z natury duży). Można wskazać która metoda dała najbardziej zbalansowane klasy a która najlepsze pokrycie z gatunkami.

2 Część 2 - Analiza składowych głównych

2.1 Wstęp

W części drugiej będziemy pracować na zbiorze danych pobranych na stronie Kaagle (tu link). Baza danych W Kaggle została pobrana ze strony Teleport.org zawiera informacje o jakości życia najbardziej kreatywnych miast na całym świecie, co pozwala osobom znaleźć odpowiednie dla nich miasto do życia. Naszym celem będzie redukcja wymiaru cech ... (tu nwm co jeszcze)

2.2 Opis danych

Dane zawierają 21 zmiennych oraz 266 wystąpień. Zbiór danych zawiera wskaźniki opisujące jakość życia w wybranych miastach, w tym m.in. takie charakterystyki jak: warunki mieszkaniowe, koszty utrzymania, bezpieczeństwo, opieka zdrowotna, edukacja itp. Wszystkie cechy ilościowe przyjmują wartości w zakresie 0 - 10, im wyższa wartość tym lepszy wynik. Zbiór danych zawiera również zmienne jakościowe takie jak Nazwa miasta, kraju oraz kontynentu na jakim się znajdują posłużą nam do lepszej interpretacji wyników.

2.3 Przygotowanie danych

Zmienna Id została usunięta jako nie istotna do dalszej analizy również w celu wyznaczenia składowych głównych użyto tylko zmiennych ilościowych.

##	Housing	Cost.of.Living	Startups	Venture.Capital
##	Min. : 0.000	Min. : 0.000	Min. : 0.000	Min. : 0.000
##	1st Qu.: 5.149	1st Qu.: 4.795	1st Qu.: 3.098	1st Qu.: 0.000
##	Median : 6.726	Median : 5.630	Median : 4.214	Median : 2.317
##	Mean : 6.467	Mean : 5.746	Mean : 4.595	Mean : 2.703
##	3rd Qu.: 8.313	3rd Qu.: 7.596	3rd Qu.: 5.790	3rd Qu.: 3.765
##	Max. :10.000	Max. :10.000	Max. :10.000	Max. :10.000
##	Travel.Connectivity	Commute	Business.Freedom	Safety
##	Min. : 0.500	Min. :0.000	Min. : 0.000	Min. : 1.343
##	1st Qu.: 1.703	1st Qu.:4.400	1st Qu.: 5.771	1st Qu.: 5.972
##	Median : 2.921	Median :5.064	Median : 8.404	Median : 7.189
##	Mean : 3.447	Mean :4.632	Mean : 7.331	Mean : 6.972
##	3rd Qu.: 4.766	3rd Qu.:5.613	3rd Qu.: 8.837	3rd Qu.: 8.269
##	Max. :10.000	Max. :6.729	Max. :10.000	Max. :10.000
##	Healthcare	Education	Environmental.Quality	Economy
##	Min. :0.000	Min. :0.000	Min. :1.000	Min. :0.000
##	1st Qu.:6.064	1st Qu.:2.184	1st Qu.:4.329	1st Qu.:4.103
##	Median :6.780	Median :4.273	Median :6.481	Median :5.373
##	Mean :6.797	Mean :3.835	Mean :6.078	Mean :5.058
##	3rd Qu.:8.055	3rd Qu.:5.294	3rd Qu.:7.888	3rd Qu.:6.514
##	Max. :9.321	Max. :9.711	Max. :9.953	Max. :9.390
##	Taxation	Internet.Access	Leisure...Culture	Tolerance
##	Min. : 0.500	Min. :1.000	Min. : 0.000	Min. :1.406
##	1st Qu.: 3.921	1st Qu.:4.134	1st Qu.: 4.448	1st Qu.:5.780
##	Median : 4.760	Median :5.379	Median : 5.707	Median :7.154
##	Mean : 4.953	Mean :5.205	Mean : 5.710	Mean :6.793
##	3rd Qu.: 5.955	3rd Qu.:6.265	3rd Qu.: 7.062	3rd Qu.:8.052
##	Max. :10.000	Max. :9.716	Max. :10.000	Max. :9.739
##	Outdoors			
##	Min. :0.500			
##	1st Qu.:3.699			
##	Median :4.733			
##	Mean :4.493			
##	3rd Qu.:5.500			
##	Max. :7.933			

Powyższej tabeli znajdują się statystyki opisowe danych ilościowych (tu zastanawiam się czy dawać wszystkie czy tylko część) zbiór danych nie zawiera żadnych braków danych po jest widoczne na poniższej tabeli.

##	Housing	Cost.of.Living	Startups
##	0	0	0
##	Venture.Capital	Travel.Connectivity	Commute
##	0	0	0
##	Business.Freedom	Safety	Healthcare
##	0	0	0

```

##          Education Environmental.Quality          Economy
##              0              0              0
##          Taxation      Internet.Access      Leisure...Culture
##              0              0              0
##          Tolerance              Outdoors
##              0              0


##          UA_Name          UA_Country          UA_Continent
## Birmingham : 2      United Kingdom: 13      Africa          : 8
## Portland   : 2      Canada          : 11      Asia            : 37
## Aarhus     : 1      Germany         : 11      Europe             :111
## Adelaide   : 1      France          : 9       North America: 87
## Albuquerque: 1      Spain           : 7       Oceania            : 8
## Almaty     : 1      Italy           : 6       South America: 15
## (Other)    :258     (Other)         :209

## [1] 264


```

Następnie analizując dane jakościowe można że mamy informacje o miastach znajdujących się na 6 kontynentach bez Antarktydy (gdzie m=nie ma miast (chyba)). Powyższa tabela wskazała nam że najwięcej miast mamy z Eurpoy następnie z Ameryki Połnocem. Łącznie mamy informacje o 264 miastach oraz o 135 Panstwach co świadczy o dużej różnos=rodnosci .

Następnie w celu poprawnego wznaczenia składowych głwonych musimy sprawdzić zmienność poszczególnych cech tzn. czy wariancja naszych cech ilościowych jest podobna. Warotsci wariancji znajduje się na wykresie poniżej.



Widzimy, że wariancja dla różnych cech jest inna, przez co konieczna jest standaryzacja. Wynik tego działania znajduje się na poniższym wykresie.



2.4 Wyznaczanie składowych głównych

Następnie wyznaczmy składowe główne naszych zmiennych, używając funkcji `prcomp()`.

tu z czatu definicja

Celem wyznaczenia składowych głównych (PCA, Principal Component Analysis) jest redukcja wymiarowości danych przy jednoczesnym zachowaniu jak największej części informacji zawartej w zmiennych pierwotnych. Metoda ta polega na przekształceniu oryginalnych, często skorelowanych zmiennych w nowy zestaw nieskorelowanych zmiennych (składowych głównych), które są liniowymi kombinacjami zmiennych wejściowych.

Pierwsza składowa główna wyjaśnia największą możliwą część wariancji danych, a każda kolejna maksymalizuje wyjaśnianą wariancję przy założeniu ortogonalności względem poprzednich. Dzięki temu możliwe jest uproszczenie struktury danych oraz identyfikacja głównych wzorców i zależności w zbiorze danych.

##	PC1	PC2	PC3
## Housing	0.30782507	0.05335338	-0.313546491
## Cost.of.Living	0.25960906	-0.17578152	-0.330535177
## Startups	-0.18023854	-0.48344148	0.006099991
## Venture.Capital	-0.23659743	-0.42745094	0.014876825
## Travel.Connectivity	-0.20945432	-0.13530669	-0.339775966
## Commute	-0.11420445	0.02593103	-0.505735874
## Business.Freedom	-0.37728094	0.09821960	0.024104574
## Safety	-0.03893545	0.28710395	-0.333009986
## Healthcare	-0.28035896	0.24194822	-0.281024808
## Education	-0.40256205	-0.04907952	-0.073864482
## Environmental.Quality	-0.32622202	0.25253554	0.053571655
## Economy	-0.27317525	-0.07400327	0.308670514
## Taxation	0.02629917	0.10741513	-0.020184933
## Internet.Access	-0.27619221	0.02270564	0.028441569
## Leisure...Culture	-0.07444660	-0.36473241	-0.305054520
## Tolerance	-0.18974955	0.35509112	-0.102725071
## Outdoors	-0.09158656	-0.19338254	-0.148586789

Najwyższy wskaźnik dla PC1 ma Housing i Cost.of livig wiec mmozemy interpretowac ta zmienna jako koszty zycia i poziom rozwoju. Nastepnie PC2 najwyzszy wskaźnik dla safety i health care i enviromental quality i tolerance wiec mozemy interpretowac ta zmienna jako innowacyjnosc . Natomiast PC3 najwyze wartosci loading maja ecomony wiec mozemy interpretowac ta zmienna jako frastruktura i dostępność / mobilność.

PC1 reprezentuje ogólny poziom rozwoju społeczno-gospodarczego oraz jakości życia, gdzie przeciwstawione są koszty życia (np. housing) i rozwój instytucjonalny (np. edukacja, środowisko, gospodarka).


PC2 odzwierciedla kontrast między innowacyjnością gospodarczą a jakością życia i czynnikami społecznymi (bezpieczeństwo, tolerancja, kultura).


PC3 można interpretować jako komponent związany z mobilnością, kosztami życia oraz dostępnością infrastruktury, z pewnym udziałem czynnika gospodarczego.

2.5 Zmienność odpowiadająca poszczególnym składowym

Następnie naszym celem będzie sprawdzenie jaki procent wariancji odpowiada poszczególnym składowym.

Na poniższym wykresie znajduje się wariancja poszczególnych składowych. Zgodnie z oczekiwaniami wariancje maleją wraz z dalszą składową główną.






Aby móc odpowiedzieć na pytanie, ile składowych głównych jest potrzebnych do wyjaśnienia 80% oraz 90% całkowitej zmienności. Wykonano wykres powyżej z zaznaczonymi poziomami odpowiednio 80 % i 90%. Na podstawie tego wykresu można wyznaczyć liczbę składowych potrzebnych do wyjaśnienia odpowiednich wartości procentowej wariancji.

Do wyjaśnienia 80% składowych potrzebne jest 7 zmiennych, natomiast do wyjaśnienia 90% składowych potrzebne jest 10 zmiennych.

2.5.1 Wizualizacja danych wielowymiarowych



Widzimy, że dane są szeroko rozpięte na osi poziomej, co sugeruje ogromne różnice w poziomie rozwoju miast:

- **Europa (kolor zielony):** Miasta europejskie są rozproszone, ale znacząca ich część koncentruje się w lewej i centralnej części wykresu (wartości ujemne i bliskie zeru na PC1). Jeśli PC1 reprezentuje wysoki koszt życia skorelowany z wysokim rozwojem, to te miasta stanowią “główny nurt” rozwiniętych aglomeracji.
- **Afryka (kolor czerwony):** Są to najbardziej skrajne punkty po prawej stronie osi PC1 (wartości dodatnie). Oznacza to, że miasta afrykańskie znacząco odstają od reszty świata pod względem ogólnego poziomu rozwoju instytucjonalnego i gospodarczego ujętego w tym komponentcie.

2.5.2 2. Zróżnicowanie wzdłuż osi PC2 (Innowacyjność vs. Bezpieczeństwo i Kultura)

Oś pionowa pokazuje kontrast między miastami stawiającymi na “twardą” gospodarkę a tymi, które oferują wyższą jakość życia społecznego:


- **Ameryka Północna (kolor jasnoniebieski):** Większość punktów znajduje się w dolnej części wykresu (wartości ujemne PC2). Sugeruje to, że miasta te charakteryzują się specyficznym profilem, gdzie czynniki społeczne (bezpieczeństwo, tolerancja) mogą wypadać relatywnie słabiej w stosunku do innowacyjności gospodarczej, lub odwrotnie – zależy to od dokładnego kierunku wektorów cech (loadings).

- **Europa (kolor zielony):** Wiele miast europejskich znajduje się w górnej części osi PC2. Może to świadczyć o ich wysokich wynikach w kategoriach bezpieczeństwa, kultury i tolerancji w porównaniu do miast z innych kontynentów o podobnym poziomie rozwoju gospodarczego.


2.5.3 3. Skupiska i “Outliery”

- **Azja (kolor żółty):** Wykazuje bardzo duży rozrzut na obu osiach. Oznacza to, że azjatyckie miasta są skrajnie niejednorodne – mamy tam zarówno potężne, rozwinięte centra, jak i miasta o znacznie niższym standardzie życia.
- **Oceania (kolor ciemnoniebieski):** Tworzy dość zwartą grupę w lewym górnym kwadrancie (niskie/średnie PC1, wysokie PC2), co sugeruje, że miasta te łączą stabilny rozwój gospodarczy z bardzo wysoką jakością życia i bezpieczeństwem.

PCA - Afryka vs reszta




CA 3D - Kontrasty regionalne: Europa i Afryka




2.6 Korelacja zmiennych


wykres korelacji tak o

```
variables <- get_pca_var(pca_dane)
corrplot(variables$cor)
```







PCA - Biplot



PCA - Biplot





2.7 Końcowe wyniki

3 Część 3

3.1 Wstęp

3.2 Opis danych