

Sprawozdanie 2

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-28

Spis treści

1	Część 1 – dyskretyzacja cech ciągłych	2
2	Część 2 - Analiza składowych głównych	2
3	Część 3 - Skalowanie wielowymiarowe (MDS)	2
3.1	Wstęp	2
3.2	Opis danych	2
3.3	Redukcja wymiaru na bazie MDS	4
3.4	Wizualizacja danych	6
3.5	Podsumowanie	8

1 Część 1 – dyskretyzacja cech ciągłych

Tymczasowo w osobnym pliku żeby się szybciej kompilowało.

2 Część 2 - Analiza składowych głównych

Tymczasowo w osobnym pliku żeby się szybciej kompilowało.

3 Część 3 - Skalowanie wielowymiarowe (MDS)

3.1 Wstep

W ostatniej części raportu wykonaliśmy skalowanie wielowymiarowe na danych, które zawierają wybrane charakterystyki opisujące pasażerów Titanica.

tuatj opis tego czym jest to skalownaie mds

3.2 Opis danych

Zbiór danych zawiera informacje o pasażerach Titanica między innymi takie jak: wiek, płeć, miejsce rozpoczęcia podróży oraz klasa pasażerska. Ważna zmienna występująca w bazie danych jest checha Survived, która informuje nas czy dana osoba przeżyła katastrofę czy nie. Dane zawierają 891 informacji o różnych pasażerach oraz 12 cech które ich opisują.

Typy zmiennych które po wczytaniu danych były wczytane jako characet zmieniliśmy na factor są to zmienne takie jak Name , Sex , Ticket, Cabin oraz undefined . Zmienną Pclass zmieniono na zmienną porządkową.

Typ.PassengerId	Typ.Survived	Typ.Pclass	Typ.Name	Typ.Sex	Typ.Age	Typ.SibSp	Typ.Parch	Typ.Ticket	Typ.Fare	Typ.Cabin	Typ.Embarked	Opis
integer	integer	ordered	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	ID pasażera
integer	integer	factor	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Czy przeżył
integer	integer	ordered	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Numer klasy
integer	integer	factor	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Imię pasażera
integer	integer	ordered	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Płeć
integer	integer	factor	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Wiek
integer	integer	ordered	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Liczba rodzeństwa oraz małżonków podróżujących z pasażerem
integer	integer	factor	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Liczba rodziców oraz dzieci podróżujących z pasażerem
integer	integer	ordered	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Numer biletu
integer	integer	factor	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Oплата za bilet
integer	integer	ordered	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Numer kabiny
integer	integer	factor	factor	factor	numeric	integer	integer	factor	numeric	factor	factor	Port zaokrętownia pasażera

Tabela 1: Typy oraz opisy cech

Z danych zostały usunięte zmienne takie jak PassengerId , Name oraz Ticket, które nie wniosą nic do naszej analizy są to indywidualne dane każdego pasażera w celu ochrony danych zostaną one usunięte z dalszej analizy.

	Liczba_NA	Liczba_puste_pozycje
Survived	0	0
Pclass	0	0
Sex	0	0
Age	177	0
SibSp	0	0
Parch	0	0
Fare	0	0
Cabin	0	687
Embarked	0	2

Tabela 2: Braki danych w zbiorze

Zmienna cabin zawiera aż 687 braków w danych, więc nie będziemy jej uwzględniać w dalszej analizie, również z tego powodu że pełniła funkcję identyfikatora. Natomiast zmienna Age zawiera 177 braków w tym przypadku nie będziemy się decydować na usunięcie tej zmiennej tylko zastąpimy te braki medianą z pozostałych wartości Age, również nie decydujemy się na opcję usunięcia wierszy z tymi brakami, ponieważ stanowią one prawie 20% danych. Natomiast braki w zmiennej Embarked, która oznaczała port w którym wsiadł pasażer, błędy uzupełnimy najczęstszą opcją jak pojawia się w danych.

Survived	Pclass	Sex	Age
Min.: 0.0000	1: 216	female: 314	Min.: 0.42
1st Qu.: 0.0000	2: 184	male: 577	1st Qu.: 22.00
Median: 0.0000	3: 491		Median: 28.00
Mean: 0.3838			Mean: 29.36
3rd Qu.: 1.0000			3rd Qu.: 35.00
Max.: 1.0000			Max.: 80.00


Tabela 3: Podsumowanie danych po uzupełnieniu braków

SibSp	Parch	Fare	Embarked
Min.: 0.000	Min.: 0.0000	Min.: 0.00	C: 168
1st Qu.: 0.000	1st Qu.: 0.0000	1st Qu.: 7.91	Q: 77
Median: 0.000	Median: 0.0000	Median: 14.45	S: 646
Mean: 0.523	Mean: 0.3816	Mean: 32.20	
3rd Qu.: 1.000	3rd Qu.: 0.0000	3rd Qu.: 31.00	
Max.: 8.000	Max.: 6.0000	Max.: 512.33	

W tabeli powyżej znajdują się statystyki opisowe zmiennych oraz liczności wystąpień poszczególnych kategorii w zmiennych jakościowych.


3.3 Redukcja wymiaru na bazie MDS

Następnie w celu poprawnej redukcji wymiaru na początku podzielimy naszą zbior na zmienne `survived` i resztę zmiennych. Macierz odmienności została wyznaczona za pomocą metryki Gowera, ponieważ w naszych danych znajdują się zarówno dane ilościowe jak i jakościowe. Zastosowano również standaryzację do zmiennych ilościowych w celu poprawnego wyliczenia odległości.



Rysunek 1: Heatmapa macierzy odmienności (Gower)

po wyżej znajduje się heatmapa, która przedstawia macierz odmienności obliczoną przy pomocy matryki gowera. Również do heatmapy dodano dendrogram, dzięki któremu możemy zobaczyć hierarchiczną strukturę podobieństwa pomiędzy obserwacjami. Na podstawie heatmapy możemy zauważyć, że pasażerowie na statku Titanic byli bardzo podzieleni na różne grupy społeczne. Wzdłuż przekątnej zauważamy jasne pola, które świadczą o bardzo dużym podobieństwie osób wśród tych samych grup społecznych np. klasa 3 i klasa 1. Na samej górze i po lewej stronie znajdują się drzewa, widzimy wyraźny podział na dwie części, co może świadczyć o podziale pasażerów na mężczyzn klasy 3 i kobiety z dziećmi klasy 1. Dendrogram sugeruje, że różnice między tymi dwoma klasami są bardziej znaczące niż jakiejkolwiek inne cechy indywidualne. Czerwone elementy na heatmapie są to wartości odstające np. pasażerowie, którzy mimo bycia w 1 klasie mieli drogi bilet.




Rysunek 2: Diagram Sheparda dla MDS ($k=3$)

Następnie zastosowano algorytm mds dla wymiaru 3 (tu można dodać na początku zrobiłam dla $k=2$ i ten stress wyszedł jako 0.26 co sugerowało, że należy zwiększyć wymiar) z metryką euklidesową. Analizując wykres Sheparda, możemy zauważyć, że punkty układają się wzdłuż linii $y=x$, świadczy to o poprawności relacji podobieństwa. Mamy potwierdzenie z heatmapy, na wykresie powyżej widzimy schody, które świadczą o występowaniu grup wśród osób o podobnych cechach oraz granic między grupami. Nie występują wartości odstające, co świadczy o niskiej wartości funkcji stress, która wyniosła 0.16, co potwierdza poprawność użytego wymiaru.


3.4 Wizualizacja danych

pojechało mi się i tu jest ta wizualizacja, ja ją dałam wyżej ... aaaaaaa ale to nie jest SUPER




Rysunek 3: Wizualizacja MDS (rzut 2D z przestrzeni 3D), kolory wg Survived

W celu wizualizacji wyników działania algorytmu mds utworzono wykres 2d. Na wykresie możemy zauważyć bardzo wyraźny podział na grupy, każde skupisko punktów to podział pasażerów ze względu na konkretne cechy. Odległość między dwoma dużymi skupiskami, może świadczyć o dużej różnicy między grupami dla pasażerów klasy 1 i 3. Działanie algorytmu jest poprawne, ponieważ górne skupiska punktów są to w większości ocalałe, czyli np. kobiety i dzieci z klasy 1, nasz algorytm dobrze poradził sobie z klasyfikacją, czy ktoś przyszył czy zginął, tylko na podstawie informacji o klasie, płci czy wieku. Ciekawym zjawiskiem są wartości odstające, czy np. osoby, które zginęły mimo wysokiego statusu społecznego, ekonomicznego czy coś tam.



Rysunek 4: Wizualizacja MDS (rzut 2D), kolory wg Sex

Na nateonym wykrsie widzmy podziła ze wzgledu na płec osob mozemy stwrrdzic płec w naszym zbiorze danych jest bardzo wazna cecha ona jest podastwa w szukaniu poobienstw meidzy pasazerami, porównując w ykresm przezyc widzimy ze wsrod osobe ktroe przezyly katasfotre sa głównie kobiety. jest grupa kkobiet ktora zginęła wykres wyzej sa to prawdopodobnie koeity z najnizeszej klasy ktor nie miały sznsy na łodz ratnkow (szalupa nwm jak to było) .



Rysunek 5: Wizualizacja MDS (rzut 2D), kolory wg Pclass

Ostani wykres przedstawia podzila pasazerów po mds ze wzgledu na klasy. tak jak zakladalismy wczesniej kobiety ktore zginely w atostdoriwe sa to kobiety z klasy 3. natomiast dolne skupiska mezczyzni nie zaleznie od klasy w kazdej grupie znalazaly sie jednoski ktorym udalo sie przezyc.

3.5 Podsumowanie

Analizujas heatmapę i dendrogram zalozyalism ze beda istniec dwie glowne grupy rozniaca sie miedzy soba co ponieszej analizie okazalo sie poprawnym zalozeniem. Dzieki mapie shepreda mozemy miec pewnosc ze mapa 2d jest wirygodna, wikszość punktów lezy wzdluz linii $y=x$, co swiadczy o rzetelnosci naszych wnioskow. Co dodatkow potwierdza niska wartosc funkcji stress, zapenia nas o poprawnoscu wynikow dla pasazerów titanic. Wykresy Mds pokazaly, ze pasazerowi naturalnie grupuja sie w skupiska, co swiadczy o silnych zaleznosciach co do przynaleznosci do danej grupy. najwieksze roznice wystepuja miedzy kobietami i mezczyznami i pasazerami klasy 1 i 3. Algorytm mds bardzo dobrze wykryl osoby ktore przezyly mimo ze nie mial dostepu do tej zmiennej.