

Sprawozdanie 2

Eksploatacja danych

Emilia Porczyńska, Michał Szostak

2026-04-30

Spis treści

1	Część 1 – dyskretyzacja cech ciągłych	2
1.1	Wstęp	2
1.2	Opis danych i wybór cech	2
1.3	Porównanie metod dyskretyzacji	3
2	Część 2 - Analiza składowych głównych	11
3	Część 3 - Skalowanie wielowymiarowe (MDS)	11
3.1	Wstęp	11
3.2	Przygotowanie danych	11
3.3	Redukcja wymiaru na bazie MDS	13
3.4	Wizualizacja danych	15
3.5	Podsumowanie	18

1 Część 1 – dyskretyzacja cech ciągłych

1.1 Wstęp

Mamy zbiór danych zawierający wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*).



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

Zbiór danych został udostępniony przez Ronalda Fishera w 1936 roku. Pobieramy go z zestawu gotowych zbiorów dostępnych w pakiecie `datasets` w R.

Naszym pierwszym zadaniem będzie przeanalizowanie własności cech oraz wybranie jednej cechy, która najlepiej rozróżni gatunki kwiatu oraz jednej, która robi to najgorzej.

Następnym naszym zadaniem będzie przeprowadzenie dyskretyzacji wybranych cech na trzy klasy przy użyciu różnych metod dyskretyzacji nienadzorowanej oraz porównanie ich wyników. Będziemy porównywać metody *equal width*, *equal frequency*, *k-means clustering* oraz dyskretyzację na bazie przedziałów zadanych przez użytkownika (przez nas).

1.2 Opis danych i wybór cech

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatka (w cm)
Petal.Width	numeric	szerokość płatka (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)


Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

Wierzmy pomiarom i zakładamy że nie ma błędów. Braki danych nie występują.



Rysunek 2: Pomiary działki kielicha i płatka w zależności od gatunku. W celu polepszenia widoczności, punkty zostały odrobinę losowo rozrzucone.

Jako cechę najlepiej rozróżniającą gatunki wybieramy długość płatka (`Petal.Length`) – wartości dla *Iris setosa* są wyraźnie niższe niż dla pozostałych dwóch gatunków, a *Iris versicolor* i *Iris virginica* również są od siebie dobrze oddzielone. Jako cechę najgorzej rozróżniającą gatunki wybieramy szerokość działki kielicha (`Sepal.Width`) – rozkłady dla wszystkich trzech gatunków silnie się nakładają.

1.3 Porównanie metod dyskretyzacji

Do dokonania dyskretyzacji wykorzystujemy funkcję `discretize` z R-pakietu `arules`. Używamy jej w następujący sposób:

```
discretize(dane$CECHA, method = METODA, breaks = 3)
```

W miejsce CECHA wpisujemy identyfikator odpowiedniej cechy, a w miejsce METODA identyfikator metody:

- "interval" dla metody *equal width*,
- "frequency" dla metody *equal frequency*,
- "cluster" dla metody *k-means clustering* oraz
- "fixed" dla ręcznego podziału.

W przypadku ostatniej metody, zamiast `breaks = 3` piszemy wektor punktów rozdzielających, przykładowo:

```
discretize(
  dane$Sepal.Width,
  method = "fixed",
  breaks = c(2.0, 2.9, 3.2, 4.4)
)
```

1.3.1 Metoda equal width

Metoda *equal width* daje nam następujące przedziały:


Przedział	Liczność
[1,2.97)	50
[2.97,4.93)	54
[4.93,6.9]	46

Tabela 3: Przedziały dla naszej „dobrej” cechy – długości płatk


Przedział	Liczność
[2,2.8)	47
[2.8,3.6)	88
[3.6,4.4]	15

Tabela 4: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 3: Granice przedziałów dla metody *equal width* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 4: Rozkład gatunków w klasach dyskretyzacji (metoda *equal width*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.97)	[2.97,4.93)	[4.93,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	48	2
<i>virginica</i>	0	6	44

Tabela 5: Wynik podziału dla długości płatk

Gatunek	[2,2.8)	[2.8,3.6)	[3.6,4.4]
<i>setosa</i>	1	36	13
<i>versicolor</i>	27	23	0
<i>virginica</i>	19	29	2

Tabela 6: Wynik podziału dla szerokości działki kielicha

Dzieląc cechę długości płatk (`Petal.Length`) na równe przedziały z bardzo dobrą skutecznością rozdzielamy irysy gatunku *Iris setosa* od pozostałych. Wszystkie kwiaty tego gatunku wpadają w przedział najkrótszej długości oraz nie wpadają do tego przedziału żadne irysy innego gatunku.

W miarę skutecznie rozróżniamy też gatunki *Iris versicolor* i *Iris virginica*, które wpadają zazwyczaj odpowiednio w przedział o średniej długości i przedział o najdłuższej długości. W niektórych przypadkach *Iris versicolor* trafia jednak do przedziału o najdłuższej długości, a *Iris virginica* do przedziału o średniej długości. Więcej razy występuje ten pierwszy przypadek niż drugi.

Jeżeli podzielimy zamiast tego na równe przedziały cechę szerokości działki kielicha (`Sepal.Width`), nie otrzymamy żadnych zadowalających nas rezultatów.

1.3.2 Metoda *equal frequency*

Używając metody *equal frequency*, otrzymujemy przedziały:


Przedział	Liczność
[1,2.63)	50
[2.63,4.9)	49
[4.9,6.9]	51

Tabela 7: Przedziały dla naszej „dobrej” cechy – długości płatka


Przedział	Liczność
[2,2.9)	47
[2.9,3.2)	47
[3.2,4.4]	56

Tabela 8: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 5: Granice przedziałów dla metody *equal frequency* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 6: Rozkład gatunków w klasach dyskretyzacji (metoda *equal frequency*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.63)	[2.63,4.9)	[4.9,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	46	4
<i>virginica</i>	0	3	47

Tabela 9: Wynik podziału dla długości płatk

Gatunek	[2,2.9)	[2.9,3.2)	[3.2,4.4]
<i>setosa</i>	1	11	38
<i>versicolor</i>	27	18	5
<i>virginica</i>	19	18	13

Tabela 10: Wynik podziału dla szerokości działki kielicha

Przedziały dla długości płatk (`Petal.Length`) wychodzą niemal jednakowe jak w przypadku metody *equal width*, w związku z tym wyniki również wychodzą takie same. Skuteczność też się względem nich nie zmienia.

Zauważalną różnicą jest mniejsza różnica między liczbą przedstawicieli *Iris versicolor* trafiających jednak do przedziału o najdłuższej długości, a *Iris virginica* trafiających do przedziału o średniej długości. W pewien sposób można więc uznać te wyniki za lepsze.

Dzieląc szerokość działki kielicha (`Sepal.Width`) uzyskujemy inne przedziały, lecz równie (jak nie bardziej) niesatysfakcjonujące wyniki jak przy metodzie przedziałów równej długości.

1.3.3 Metoda k-means clustering

Metodą *k-means clustering* otrzymujemy takie przedziały:


Przedział	Liczność
[1,2.95)	50
[2.95,5.13)	66
[5.13,6.9]	34

Tabela 11: Przedziały dla naszej „dobrej” cechy – długości płatk


Przedział	Liczność
[2,3.02)	83
[3.02,3.55)	48
[3.55,4.4]	19

Tabela 12: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki naszej dyskretyzacji prezentują się tak:



Rysunek 7: Granice przedziałów dla metody *k-means clustering* naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 8: Rozkład gatunków w klasach dyskretyzacji (metoda *k-means clustering*). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.95)	[2.95,5.13)	[5.13,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	50	0
<i>virginica</i>	0	16	34

Tabela 13: Wynik podziału dla długości płatka

Gatunek	[2,3.02)	[3.02,3.55)	[3.55,4.4]
<i>setosa</i>	8	26	16
<i>versicolor</i>	42	8	0
<i>virginica</i>	33	14	3


Tabela 14: Wynik podziału dla szerokości działki kielicha

Dla długości płatka (`Petal.Length`) wyniki wychodzą dokładnie takie same jak w metodzie *equal frequency*.

W przypadku i tej metody, podział po szerokości działki kielicha (`Sepal.Width`) również nie daje zbyt wartościowych wyników.

1.3.4 Podział ręczny

Popatrzmy na rozkład wartości rozważanych cech dla każdego z gatunków:



Rysunek 9: Rozkład wartości cech w podziale na gatunki

Na oko wybieramy dla długości płatk (`Petal.Length`) przedziały $[1, 2.5)$, $[2.5, 4.8)$ oraz $[4.8, 6.9]$.

Dla szerokości działki kielicha (`Sepal.Width`) – choć to ciężkie – wybieramy przedziały $[2, 2.9)$, $[2.9, 3.2)$ i $[3.2, 4.4]$.

Wybrane przedziały dzielą nam zbiór danych na klasy o następującej liczności:


Przedział	Liczność
$[1, 2.5)$	50
$[2.5, 4.8)$	45
$[4.8, 6.9]$	55

Tabela 15: Przedziały dla naszej „dobrej” cechy – długości płatk


Przedział	Liczność
$[2, 2.9)$	47
$[2.9, 3.2)$	47
$[3.2, 4.4]$	56

Tabela 16: Przedziały dla naszej „złej” cechy – szerokości działki kielicha

Wyniki dyskretyzacji prezentują się tak:



Rysunek 10: Granice przedziałów dla podziału ręcznego naniesione na wartości cech. Oś pionowa przedstawia losowe wartości z przedziału $[0, 1]$ w celu rozróżnienia punktów o tej samej wartości cechy



Rysunek 11: Rozkład gatunków w klasach dyskretyzacji (podział ręczny). Szerokość słupków na wykresach jest proporcjonalna do liczby elementów w przedziałach

Gatunek	[1,2.5)	[2.5,4.8)	[4.8,6.9]
<i>setosa</i>	50	0	0
<i>versicolor</i>	0	44	6
<i>virginica</i>	0	1	49

Tabela 17: Wynik podziału dla długości płatków

Gatunek	[2,2.9)	[2.9,3.2)	[3.2,4.4]
<i>setosa</i>	1	11	38
<i>versicolor</i>	27	18	5
<i>virginica</i>	19	18	13

Tabela 18: Wynik podziału dla szerokości działki kielicha

W podziale długości płatków (*Petal.Length*) wybrane przez nas przedziały nie przewyższają skutecznością wcześniejszych metod. Liczba „pomyłek” jest mniej więcej taka sama.

W podziale szerokości działki kielicha (*Sepal.Width*) – w przeciwieństwie do poprzednich metod – udało nam się uzyskać jakikolwiek wartościowy efekt, a mianowicie udało nam się

rozdzielić *Iris setosa* od pozostałych gatunków – zdecydowana większość przedstawicieli tego gatunku trafia do trzeciego przedziału.

Pozostałe dwa gatunki zbyt się jednak pokrywają tą cechą aby można je było rozróżnić.

1.3.5 Podsumowanie

Cecha długości płatków (`Petal.Length`) na tyle dobrze rozróżnia rozważane gatunki kwiatów, że niezależnie od wyboru metody otrzymamy bardzo dobry wynik. Za pomocą większości metod jesteśmy w stanie z pełną skutecznością rozdzielić irysy gatunku *Iris setosa* od *Iris versicolor* i *Iris virginica*. Żadna metoda nie pozwala nam jednak na całkowite rozdzielanie dwóch ostatnich gatunków. Być może dyskretyzacja w oparciu na cechę będącą jakąś funkcją od bazowych cech pozwoliłaby na lepszy wynik.

Żadna metoda nie pozwoliła na rozróżnienie gatunków na podstawie cechy szerokości działki kielicha (`Sepal.Width`). Pokazuje to że ograniczając zbiór danych możemy stracić informacje których żadnym algorytmem nie będziemy w stanie odzyskać.

2 Część 2 - Analiza składowych głównych

Tymczasowo w osobnym pliku żeby się szybciej kompilowało.

3 Część 3 - Skalowanie wielowymiarowe (MDS)

3.1 Wstęp

W ostatniej części raportu mamy zbiór danych zawierających charakterystyki opisujące pasażerów Titanica, wraz z informacją czy dana osoba przeżyła. Zbiór pobieramy z R-pakietu `titanic`, ale jest też on dostępny na [Kaggle](#).

Naszym zadaniem będzie dokonanie skalowania wielowymiarowego (MDS, ang. *multi-dimensional scaling*).

3.2 Przygotowanie danych

Zbiór danych zawiera informacje o pasażerach Titanica. Między innymi takie jak: wiek, płeć, miejsce rozpoczęcia podróży oraz klasa pasażerska. Ważną zmienną występującą w bazie danych jest cecha `Survived`, która informuje nas czy dana osoba przeżyła katastrofę, czy nie. Dane zawierają 891 informacji o różnych pasażerach oraz 12 cech, które ich opisują.

	Typ	Opis
PassengerId	integer	ID pasażera
Survived	integer	Czy przeżył
Pclass	integer	Numer klasy
Name	character	Imię pasażera
Sex	character	Płeć
Age	numeric	Wiek
SibSp	integer	Liczba rodzeństwa + małżonków podróżujących z pasażerem
Parch	integer	Liczba rodziców + dzieci podróżujących z pasażerem
Ticket	character	Numer biletu
Fare	numeric	Opłata za bilet
Cabin	character	Numer kabiny
Embarked	character	Port zaokrętowania pasażera

Tabela 19: Typy oraz opisy cech

Z danych na pewno usuwamy zmienne takie jak `PassengerId`, `Name`, `Ticket` oraz `Cabin`, które nie wniosą nic do naszej analizy. Są to indywidualne dane każdego pasażera, w celu ochrony danych zostaną one usunięte z dalszej analizy.

Dodatkowo, typy zmiennych które po wczytaniu danych były wczytane jako typ `character` zmieniamy na typ `factor`. Są to zmienne takie jak płeć oraz port zaokrętowania, które możemy traktować jako zmienne jakościowe. Zmienną `Pclass` reprezentującą numer klasy zmieniamy na zmienną porządkową.

Sprawdzamy czy mamy jakieś braki danych:

	Liczba_NA	Liczba_puste_pozycje
Survived	0	0
Pclass	0	0
Sex	0	0
Age	177	0
SibSp	0	0
Parch	0	0
Fare	0	0
Cabin	0	687
Embarked	0	2

Tabela 20: Braki danych w zbiorze

Zmienna `Age` zawiera 177 braków. W tym przypadku nie usuwamy tej zmiennej, tylko zastępujemy te braki medianą z pozostałych wartości `Age`. Nie usuwamy też wierszy z tymi

brakami, ponieważ stanowią one prawie 20% danych. Natomiast braki w zmiennej **Embarked**, która oznacza port w którym wsiadł pasażer, uzupełniamy najczęstszą wartością jaka pojawia się w danych.

W tabeli poniżej znajdują się statystyki opisowe zmiennych oraz liczności wystąpień poszczególnych kategorii w nieusuniętych zmiennych jakościowych.

Survived	Pclass	Sex	Age
Min.: 0.0000	1: 216	female: 314	Min.: 0.42
1st Qu.: 0.0000	2: 184	male: 577	1st Qu.: 22.00
Median: 0.0000	3: 491		Median: 28.00
Mean: 0.3838			Mean: 29.36
3rd Qu.: 1.0000			3rd Qu.: 35.00
Max.: 1.0000			Max.: 80.00


SibSp	Parch	Fare	Cabin
Min.: 0.000	Min.: 0.0000	Min.: 0.00	: 687
1st Qu.: 0.000	1st Qu.: 0.0000	1st Qu.: 7.91	B96 B98: 4
Median: 0.000	Median: 0.0000	Median: 14.45	C23 C25 C27: 4
Mean: 0.523	Mean: 0.3816	Mean: 32.20	G6: 4
3rd Qu.: 1.000	3rd Qu.: 0.0000	3rd Qu.: 31.00	C22 C26: 3
Max.: 8.000	Max.: 6.0000	Max.: 512.33	D: 3
			(Inne): 186

Tabela 21: Podsumowanie danych po uzupełnieniu braków

3.3 Redukcja wymiaru na bazie MDS

Następnie w celu poprawnej redukcji wymiaru dzielimy nasz zbiór na zmienną **Survived** i resztę zmiennych. Macierz odmienności wyznaczamy za pomocą metryki Gowera, ponieważ w naszych danych znajdują się zarówno dane ilościowe, jak i jakościowe. Do zmiennych ilościowych stosujemy również standaryzację w celu poprawnego wyliczenia odległości.

Otrzymaną macierz wizualizujemy poniżej w postaci heatmapy z naniesionym dendrogramem, który pozwala dostrzec hierarchiczną strukturę podobieństwa pomiędzy obserwacjami.



Rysunek 12: Heatmapa macierzy odmienności (Gower) – jaśniejsze pola oznaczają większe podobieństwo, ciemniejsze mniejszą


Na podstawie heatmapy możemy zauważyć, że pasażerowie na statku Titanic byli bardzo podzieleni na różne grupy. Wzdłuż przekątnej zauważamy jasne pola, które świadczą o bardzo dużym podobieństwie osób wśród tych samych grup.

Na samej górze i po lewej stronie znajdują się drzewa – widzimy wyraźny podział na dwie części. Dendrogram sugeruje, że różnice między tymi dwiema grupami są bardziej znaczące niż jakiekolwiek inne cechy indywidualne.

Ciemne elementy na heatmapie są to wartości odstające, na przykład pasażerowie, którzy

mimo bycia w 3. klasie mieli drogi bilet.

Następnie stosujemy algorytm MDS w wariancie metrycznym (funkcja `cmdscale`) dla wymiaru $k = 3$ z metryką euklidesową (na początku spróbowaliśmy dla $k = 2$ i stress wyszedł jako 0.26, co sugerowało, że należy zwiększyć wymiar). Wybieramy wariant metryczny, ponieważ macierz odmienności Gowera daje nam realne wartości odległości, a nie tylko ich kolejność – nie ma więc powodu, żeby rezygnować z tej informacji. Aby ocenić jakość tej redukcji, rysujemy diagram Sheparda.




Rysunek 13: Diagram Sheparda dla MDS ($k=3$)

Analizując wykres Sheparda możemy zauważyć, że punkty układają się wzdłuż linii $y = x$ – świadczy to o poprawności relacji podobieństwa. Na wykresie widzimy też schody, które świadczą o występowaniu grup wśród osób o podobnych cechach oraz granic między grupami – co jest spójne z tym, co widzieliśmy na heatmapie.

Nie występują wartości znacząco odstające od linii $y = x$, co spójne jest z niską wartością funkcji *stress*, która wyniosła 0.17 – potwierdza to poprawność użytego wymiaru.

3.4 Wizualizacja danych

Wyniki MDS oglądamy na wykresach 2D, kolorując punkty według różnych zmiennych. Najpierw kolorujemy je według tego, czy pasażer przeżył.




Rysunek 14: Wizualizacja MDS (rzut 2D z przestrzeni 3D), kolory według **Survived**

Na wykresie możemy zauważyć bardzo wyraźny podział na grupy. Każde skupisko to grupa pasażerów podobnych do siebie ze względu na zestaw cech. Duża odległość między dwoma głównymi skupiskami świadczy o znaczącej różnicy między tymi grupami pasażerów.

Co istotne, górne skupiska punktów to w większości osoby ocalałe (czyli np. kobiety i dzieci z 1. klasy), a dolne to w większości ofiary – mimo że zmienna **Survived** nie była używana do redukcji. Cechy które przyjęliśmy (klasa, płeć, wiek) są więc silnie związane z przeżyciem. Ciekawym zjawiskiem są wartości odstające, np. osoby które zginęły mimo wysokiego statusu społeczno-ekonomicznego.


Następnie kolorujemy punkty według płci pasażera.



Rysunek 15: Wizualizacja MDS (rzut 2D), kolory według płci

Na powyższym wykresie widzimy podział ze względu na płeć osób – możemy stwierdzić, że płeć w naszym zbiorze danych jest bardzo ważną cechą i jest podstawą w szukaniu podobieństw między pasażerami. Porównując z wykresem przeżyć widzimy, że wśród osób które przeżyły katastrofę są głównie kobiety. Jest też grupa kobiet, która zginęła (wykres wyżej) – są to prawdopodobnie kobiety z najniższej klasy, które nie miały szansy na łódź ratunkową.

Na koniec kolorujemy punkty według klasy pasażerskiej.



Rysunek 16: Wizualizacja MDS (rzut 2D), kolory według klasy pasażerskiej

W obu skupiskach widać też podział na klasy, ale dużo słabszy niż ten na płci.

Tak jak zakładaliśmy wcześniej, kobiety które zginęły w katastrofie to kobiety z 3. klasy. Natomiast w dolnym skupisku (mężczyźni) niezależnie od klasy w każdej grupie znajdowały się jednostki, którym udało się przeżyć.

3.5 Podsumowanie

Analizując heatmapę i dendrogram zauważyliśmy, że istnieją dwie główne grupy różniące się między sobą, co potwierdziło się w dalszej analizie. Dzięki diagramowi Sheparda możemy mieć pewność, że redukcja do 3 wymiarów jest wiarygodna – większość punktów leży wzdłuż linii $y = x$, co świadczy o rzetelności naszych wniosków. Dodatkowo potwierdza to niska wartość funkcji stress (0.17).

Wykresy MDS pokazały, że pasażerowie naturalnie grupują się w skupiska, co świadczy o silnych zależnościach między ich cechami. Największe różnice występują między kobietami i mężczyznami oraz pasażerami 1. i 3. klasy. Osoby ocalałe wyraźnie grupują się w przestrzeni MDS, mimo że zmienna **Survived** nie była używana do redukcji – cechy które przyjęliśmy są więc silnie związane z przeżyciem.