

Sprawozdanie 2

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-26

Spis treści

1	Część 1 – dyskretyzacja cech ciągłych	2
1.1	Wstęp	2
1.2	Opis danych	3
2	Część 2	8
2.1	Wstęp	8
2.2	Opis danych	8
2.3	Przygotowanie danych	8
2.4	Wyznaczanie składowych głównych	10
2.5	Zmienność odpowiadająca poszczególnym składowym	11
2.6	Korelacja zmiennych	12
2.7	Końcowe wyniki	15
3	Część 3	15
3.1	Wstęp	15
3.2	Opis danych	15

1 Część 1 – dyskretyzacja cech ciągłych

1.1 Wstęp

Mamy zbiór danych zawierający wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatków (ang. *petal*).







Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)





Zbiór danych został udostępniony przez Ronalda Fishera w 1936 roku. Pobieramy go z zestawu gotowych zbiorów dostępnych w pakiecie `datasets` w R.

Naszym pierwszym zadaniem będzie przeanalizowanie własności cech oraz wybranie jednej cechy, która najlepiej rozróżni gatunki kwiatu oraz jednej, która robi to najgorzej.

Następnym naszym zadaniem będzie przeprowadzenie dyskretyzacji wybranych cech na trzy klasy przy użyciu różnych metod dyskretyzacji nienadzorowanej oraz porównanie ich wyników. Będziemy porównywać metody *equal width*, *equal frequency*, *k-means clustering* oraz dyskretyzację na bazie przedziałów zadanych przez użytkownika (przez nas).

1.2 Opis danych





Najpelsza Petal width a najgorsza Sepal Length

zdania sa podzielone czat mowi ze leiej petal length a geminik ze width rozumeim czemu leght ale jestem za width.

Terat porownanie 1 metody

```
## podzial_11
## [4.3,5.5) [5.5,6.7) [6.7,7.9)
##          52          70          28

## podzial_12
## [0.1,0.9) [0.9,1.7) [1.7,2.5]
```


##

50




52

48

Metoda: interval discretization



Metoda: interval c



TEraz dla kolejnej metody frequency.

podzial_21

[4.3,5.4) [5.4,6.3) [6.3,7.9]


46 53 51

podzial_22


[0.1,0.867) [0.867,1.6) [1.6,2.5]

50 48 52

Metoda: interval discretization




dane\$Sepal.Length




podzial_21

Metoda: interval c



dane\$Petal.Length





podzial_22

Teraz dla metody cluster.



```
## podzial_31
## [4.3,5.37) [5.37,6.36) [6.36,7.9]
##          46          62          42

## podzial_32
## [0.1,0.792) [0.792,1.71) [1.71,2.5]
##          50          54          46
```

Metoda: interval discretization



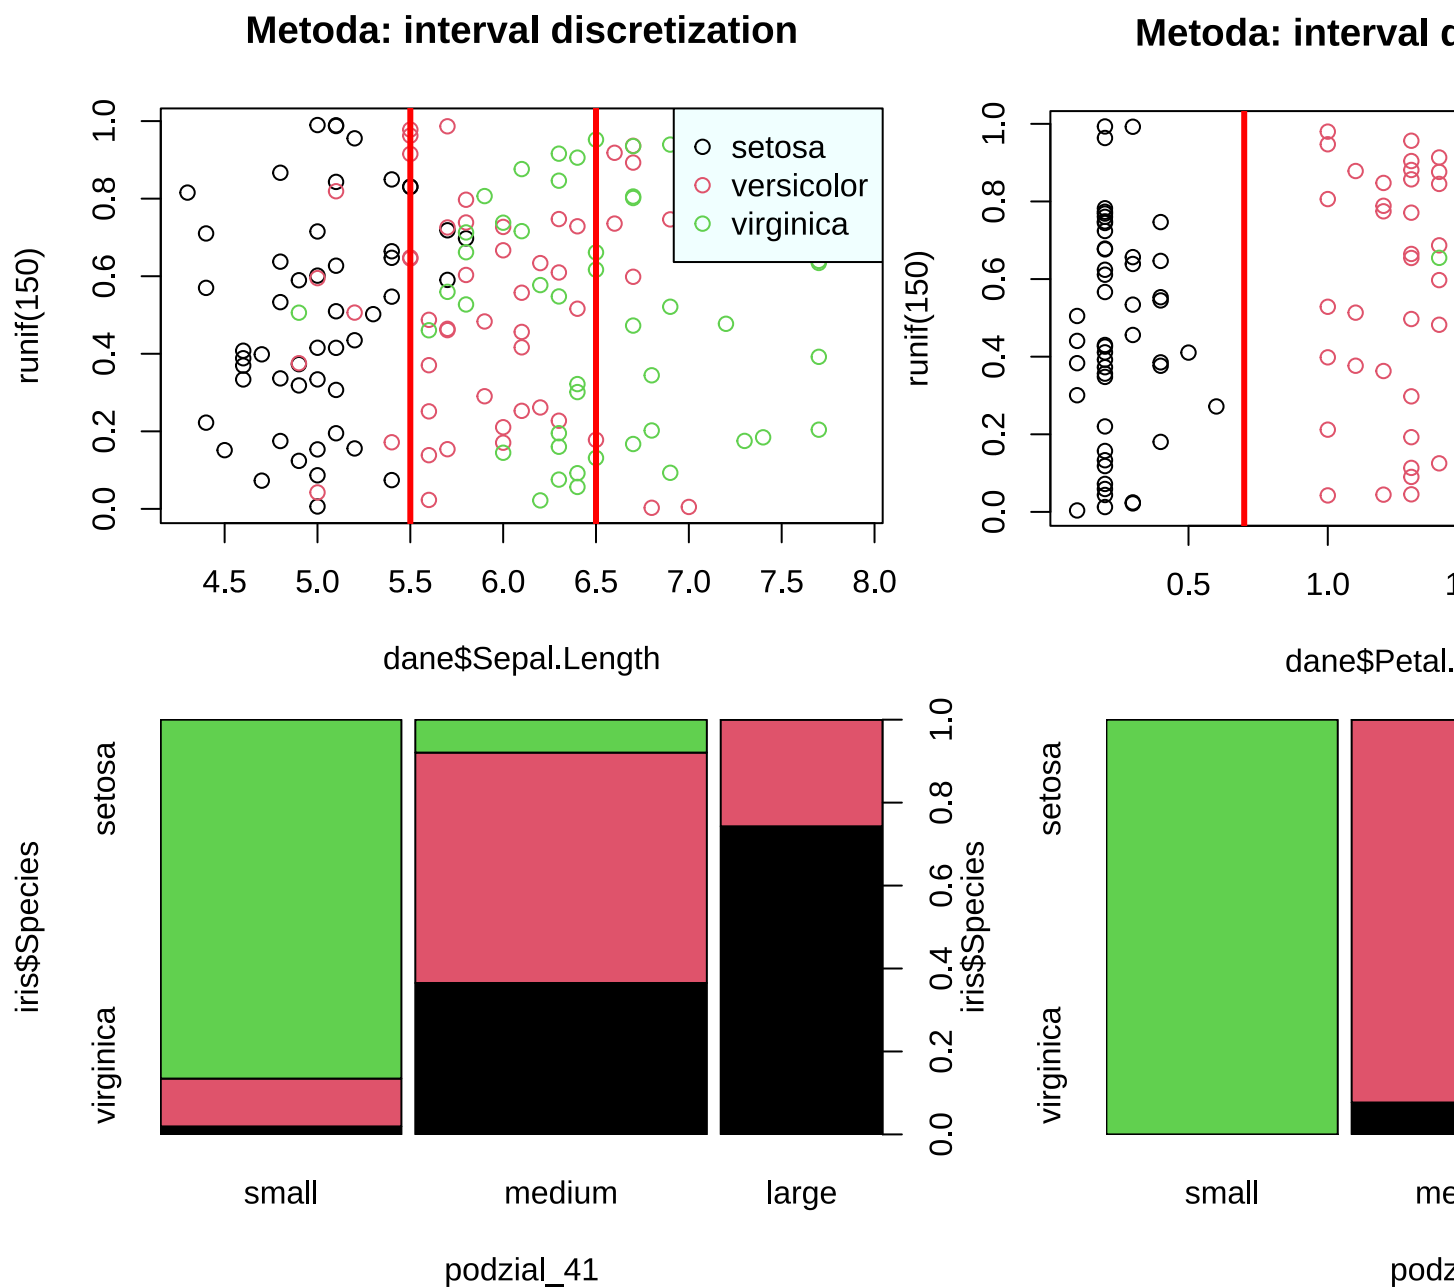
Metoda: interval c



Teraz dla wlasnego podzialu.

```
## podzial_41
##  small medium  large
##    52    63    35

## podzial_42
##  small medium  large
##    50    52    48
```



2 Część 2

2.1 Wstęp


2.2 Opis danych

2.3 Przygotowanie danych

```
## X UA_Name UA_Country UA_Continent Housing Cost.of.Living Startups
## 1 0 Aarhus Denmark Europe 6.1315 4.015 2.8270
```


## 2 1	Adelaide	Australia	Oceania	6.3095	4.692	3.1365
## 3 2	Albuquerque	New Mexico	North America	7.2620	6.059	3.7720
## 4 3	Almaty	Kazakhstan	Asia	9.2820	9.333	2.4585
## 5 4	Amsterdam	Netherlands	Europe	3.0530	3.824	7.9715
## 6 5	Anchorage	Alaska	North America	5.4335	3.141	2.7945
##	Venture.Capital	Travel.Connectivity	Commute	Business.Freedom	Safety	
## 1	2.512	3.5360	6.31175	9.940000	9.6165	
## 2	2.640	1.7765	5.33625	9.399667	7.9260	
## 3	1.493	1.4555	5.05575	8.671000	1.3435	
## 4	0.000	4.5920	5.87125	5.568000	7.3090	
## 5	6.107	8.3245	6.11850	8.836667	8.5035	
## 6	0.000	1.7380	4.71525	8.671000	3.4705	
##	Healthcare	Education	Environmental.Quality	Economy	Taxation	Internet.Access
## 1	8.704333	5.3665	7.63300	4.8865	5.0680	8.3730
## 2	7.936667	5.1420	8.33075	6.0695	4.5885	4.3410
## 3	6.430000	4.1520	7.31950	6.5145	4.3460	5.3960
## 4	4.545667	2.2830	3.85675	5.2690	8.5220	2.8860
## 5	7.907333	6.1800	7.59725	5.0530	4.9550	4.5230
## 6	6.060333	3.6245	9.27200	6.5145	4.7720	4.9645
##	Leisure...Culture	Tolerance	Outdoors			
## 1	3.1870	9.7385	4.1300			
## 2	4.3285	7.8220	5.5310			
## 3	4.8900	7.0285	3.5155			
## 4	2.9370	6.5395	5.5000			
## 5	8.8740	8.3680	5.3070			
## 6	3.2660	7.0930	5.3580			
##	Housing	Cost.of.Living	Startups	Venture.Capital	Travel.Connectivity	Commute
## 1	6.1315	4.015	2.8270	2.512	3.5360	6.31175
## 2	6.3095	4.692	3.1365	2.640	1.7765	5.33625
## 3	7.2620	6.059	3.7720	1.493	1.4555	5.05575
## 4	9.2820	9.333	2.4585	0.000	4.5920	5.87125
## 5	3.0530	3.824	7.9715	6.107	8.3245	6.11850
## 6	5.4335	3.141	2.7945	0.000	1.7380	4.71525
##	Business.Freedom	Safety	Healthcare	Education	Environmental.Quality	Economy
## 1	9.940000	9.6165	8.704333	5.3665	7.63300	4.8865
## 2	9.399667	7.9260	7.936667	5.1420	8.33075	6.0695
## 3	8.671000	1.3435	6.430000	4.1520	7.31950	6.5145
## 4	5.568000	7.3090	4.545667	2.2830	3.85675	5.2690
## 5	8.836667	8.5035	7.907333	6.1800	7.59725	5.0530
## 6	8.671000	3.4705	6.060333	3.6245	9.27200	6.5145
##	Taxation	Internet.Access	Leisure...Culture	Tolerance	Outdoors	
## 1	5.0680	8.3730	3.1870	9.7385	4.1300	
## 2	4.5885	4.3410	4.3285	7.8220	5.5310	
## 3	4.3460	5.3960	4.8900	7.0285	3.5155	

## 4	8.5220	2.8860	2.9370	6.5395	5.5000
## 5	4.9550	4.5230	8.8740	8.3680	5.3070
## 6	4.7720	4.9645	3.2660	7.0930	5.3580



2.4 Wyznaczanie składowych głównych

##	PC1	PC2	PC3
## Housing	0.30782507	0.05335338	-0.313546491
## Cost.of.Living	0.25960906	-0.17578152	-0.330535177
## Startups	-0.18023854	-0.48344148	0.006099991
## Venture.Capital	-0.23659743	-0.42745094	0.014876825
## Travel.Connectivity	-0.20945432	-0.13530669	-0.339775966
## Commute	-0.11420445	0.02593103	-0.505735874
## Business.Freedom	-0.37728094	0.09821960	0.024104574
## Safety	-0.03893545	0.28710395	-0.333009986
## Healthcare	-0.28035896	0.24194822	-0.281024808
## Education	-0.40256205	-0.04907952	-0.073864482
## Environmental.Quality	-0.32622202	0.25253554	0.053571655
## Economy	-0.27317525	-0.07400327	0.308670514
## Taxation	0.02629917	0.10741513	-0.020184933
## Internet.Access	-0.27619221	0.02270564	0.028441569
## Leisure...Culture	-0.07444660	-0.36473241	-0.305054520
## Tolerance	-0.18974955	0.35509112	-0.102725071
## Outdoors	-0.09158656	-0.19338254	-0.148586789

Najwyższy wskaźnik dla PC1 ma Housing i Cost.of livig więc możemy interpretować tę zmienną jako koszty życia i poziom rozwoju. Następnie PC2 najwyższy wskaźnik dla safety i health care i enviromental quality i tolerance więc możemy interpretować tę zmienną jako innowacyjność. Natomiast PC3 najwyższe wartości loading mają economy więc możemy interpretować tę zmienną jako infrastruktura i dostępność / mobilność.


PC1 reprezentuje ogólny poziom życia i koszty utrzymania, z największym wpływem zmien-

nych Housing i Cost.of.Living.

PC2 odzwierciedla jakość życia oraz poziom innowacyjności, związany ze zmiennymi takimi jak Startups, Venture Capital, Safety i Healthcare.


PC3 można interpretować jako komponent związany z infrastrukturą i mobilnością, ponieważ największe ładunki mają zmienne Commute oraz Travel Connectivity.

2.5 Zmienność odpowiadająca poszczególnym składowym



Do wyjaśnienia 80% skal=owych potrzebne jest 7 zmiennych, natomiast do wyjaśnienia 90% składowych potrzebne jest 10 zmiennych.



2.5.1 Wizualizacja danych wielowymiarowych






2.6 Korelacja zmiennych

wykres korelacji tak o

```
variables <- get_pca_var(pca_dane)
corrplot(variables$cor)
```





2.7 Końcowe wyniki

3 Część 3

3.1 Wstęp

3.2 Opis danych