

Sprawozdanie 2 – Część 2 (tymczasowe)

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-30

Spis treści

1	Część 2 - Analiza składowych głównych	1
1.1	Wstęp	1
1.2	Przygotowanie danych	1
1.3	Wyznaczanie składowych głównych	5
1.4	Zmienność odpowiadająca poszczególnym składowym	6
1.5	Korelacja zmiennych	9
1.6	Końcowe wyniki	12

1 Część 2 - Analiza składowych głównych

1.1 Wstęp

W części drugiej będziemy pracować na zbiorze danych pobranych ze strony [Kaggle](#), pochodzącym oryginalnie z nieistniejącej już (przynajmniej pod tą domeną) strony [Teleport.org](#). Zbiór zawiera wskaźniki opisujące jakość życia z wybranej grupy „najbardziej kreatywnych” miast z całego świata zebranych w celu pozwolenia osobom znaleźć odpowiedniego miasta do życia według ich preferencji.

Wskaźniki dotyczą między innymi charakterystyk takich jak: warunki mieszkaniowe, koszty utrzymania, bezpieczeństwo, opieka zdrowotna, edukacja itp. Wszystkie wskaźniki są w skali od 0 do 10, gdzie większa wartość oznacza lepszy wynik.

Naszym celem będzie przeprowadzenie analizy składowych głównych (PCA, ang. *Principal Component Analysis*) wskaźników zawartych w zbiorze.

1.2 Przygotowanie danych

Dane zawierają informacje o 266 miastach. Dla każdego z nich mamy 21 cech.

	Typ	Opis
X	integer	identyfikator obserwacji
UA_Name	factor	nazwa obszaru miejskiego (UA – ang. <i>urban area</i>)
UA_Country	factor	kraj
UA_Continent	factor	kontynent
Housing	numeric	warunki mieszkaniowe
Cost.of.Living	numeric	koszty utrzymania
Startups	numeric	ekosystem startupów
Venture.Capital	numeric	dostępność kapitału inwestycyjnego
Travel.Connectivity	numeric	połączenia komunikacyjne (transport międzymiastowy i międzynarodowy)
Commute	numeric	codzienne dojazdy
Business.Freedom	numeric	swoboda prowadzenia biznesu
Safety	numeric	bezpieczeństwo
Healthcare	numeric	opieka zdrowotna
Education	numeric	edukacja
Environmental.Quality	numeric	jakość środowiska
Economy	numeric	kondycja gospodarki
Taxation	numeric	podatki
Internet.Access	numeric	dostęp do internetu
Leisure...Culture	numeric	oferta rozrywkowa i kulturalna
Tolerance	numeric	tolerancja społeczna
Outdoors	numeric	możliwości spędzania czasu na świeżym powietrzu

Tabela 1: Typy oraz opisy cech

Identyfikator **X** na pewno nie będzie nas interesował, więc go usuwamy.

Aby ujednolicić konwencję nazw, nazwy cech `UA_Name`, `UA_Country` oraz `UA_Continent` zamieniamy odpowiednio na `UrbanArea`, `Country` i `Continent`. Pozostałe nazwy cech, w których spacje zostały zamienione przez wbudowany w R czytnik CSV na kropki również ujednolicamy do tej konwencji. W nazwie cechy `Leisure...Culture`, w której na kropkę został zamieniony także symbol „&”, powstały trzykropek zamieniamy na „And”.

Zmienione nazwy zmiennych możemy zobaczyć w poniższej tabeli – będącej częścią dalszych działań dążących do oczyszczenia danych – podsumowującej wartości nieusuniętych zmiennych:

UrbanArea	Country	Continent	Housing	CostOfLiving
Birmingham: 2	United Kingdom: 13	Africa: 8	Min.: 0.000	Min.: 0.000
Portland: 2	Canada: 11	Asia: 37	1st Qu.: 5.149	1st Qu.: 4.795
Aarhus: 1	Germany: 11	Europe: 111	Median: 6.726	Median: 5.630
Adelaide: 1	France: 9	North America: 87	Mean: 6.467	Mean: 5.746
Albuquerque: 1	Spain: 7	Oceania: 8	3rd Qu.: 8.313	3rd Qu.: 7.596
Almaty: 1	Italy: 6	South America: 15	Max.: 10.000	Max.: 10.000
(Inne): 258	(Inne): 209			

Startups	VentureCapital	TravelConnectivity	Commute	BusinessFreedom
Min.: 0.000	Min.: 0.000	Min.: 0.500	Min.: 0.000	Min.: 0.000
1st Qu.: 3.098	1st Qu.: 0.000	1st Qu.: 1.703	1st Qu.: 4.400	1st Qu.: 5.771
Median: 4.214	Median: 2.317	Median: 2.921	Median: 5.064	Median: 8.404
Mean: 4.595	Mean: 2.703	Mean: 3.447	Mean: 4.632	Mean: 7.331
3rd Qu.: 5.790	3rd Qu.: 3.765	3rd Qu.: 4.766	3rd Qu.: 5.613	3rd Qu.: 8.837
Max.: 10.000	Max.: 10.000	Max.: 10.000	Max.: 6.729	Max.: 10.000

Safety	Healthcare	Education	EnvironmentalQuality	Economy
Min.: 1.343	Min.: 0.000	Min.: 0.000	Min.: 1.000	Min.: 0.000
1st Qu.: 5.972	1st Qu.: 6.064	1st Qu.: 2.184	1st Qu.: 4.329	1st Qu.: 4.103
Median: 7.189	Median: 6.780	Median: 4.273	Median: 6.481	Median: 5.373
Mean: 6.972	Mean: 6.797	Mean: 3.835	Mean: 6.078	Mean: 5.058
3rd Qu.: 8.269	3rd Qu.: 8.055	3rd Qu.: 5.294	3rd Qu.: 7.888	3rd Qu.: 6.514
Max.: 10.000	Max.: 9.321	Max.: 9.711	Max.: 9.953	Max.: 9.390

Taxation	InternetAccess	LeisureAndCulture	Tolerance	Outdoors
Min.: 0.500	Min.: 1.000	Min.: 0.000	Min.: 1.406	Min.: 0.500
1st Qu.: 3.921	1st Qu.: 4.134	1st Qu.: 4.448	1st Qu.: 5.780	1st Qu.: 3.699
Median: 4.760	Median: 5.379	Median: 5.707	Median: 7.154	Median: 4.733
Mean: 4.953	Mean: 5.205	Mean: 5.710	Mean: 6.793	Mean: 4.493
3rd Qu.: 5.955	3rd Qu.: 6.265	3rd Qu.: 7.062	3rd Qu.: 8.052	3rd Qu.: 5.500
Max.: 10.000	Max.: 9.716	Max.: 10.000	Max.: 9.739	Max.: 7.933

Tabela 2: Podsumowanie danych


Jak widać, wszystkie zmienne zawierają wartości zgodne z naszymi oczekiwaniami. Nie występują też żadne braki danych.

Mamy 3 cechy jakościowe reprezentujące nazwę miasta, kraju i kontynentu oraz 17 cech ilościowych zawierających wartości wskaźników jakości życia.

W podsumowaniu danych jakościowych widzimy że mamy informacje o miastach znajdujących się na 6 kontynentach (niestety bez [Antarktydy](#)). Powyższa tabela wskazuje nam że najwięcej miast mamy z [Europy](#) (111), następnie z [Ameryki Północnej](#) (87). Łącznie mamy informacje o 264 miastach z 135 państw, co świadczy o dużej różnorodności.


W tabeli widzimy też, że nie wszystkie cechy ilościowe przyjmują wartości skrajne – 0 oraz 10. Może to sugerować, że ich rozkłady się znacząco różnią.

W celu najlepszego wyznaczenia składowych głównych, zmienne powinny mieć podobną wariancję.



Rysunek 1: Rozkład wartości cech ilościowych

Widzimy, że zakres wartości zmiennych takich jak `Commute` i `Outdoors` jest dużo węższy niż przykładowo `VentureCapital`, `EnvironmentQuality`, czy `Education`. Wskazuje to na różnice w wariancji. Z tego powodu dokonujemy standaryzacji za pomocą wbudowanej w R funkcji `scale()`. Wynik tego działania znajduje się na poniższym wykresie.



Rysunek 2: Rozkład wartości cech ilościowych po standaryzacji

Musimy jednak pamiętać że wartości zmiennych po standaryzacji nie są już w skali 0–10.

1.3 Wyznaczanie składowych głównych

Kolejnym naszym krokiem będzie wyznaczenie składowych głównych naszych zmiennych. Użyjemy do tego funkcji `prcomp()`.

W celu interpretacji otrzymanych składowych, analizujemy ich wektory ładunków (ang. *loadings*). Reprezentują one wkład każdej ze zmiennych na wartości składowych.

	PC1	PC2	PC3
Housing	0.308	0.053	-0.314
CostOfLiving	0.260	-0.176	-0.331
Startups	-0.180	-0.483	0.006
VentureCapital	-0.237	-0.427	0.015
TravelConnectivity	-0.209	-0.135	-0.340
Commute	-0.114	0.026	-0.506
BusinessFreedom	-0.377	0.098	0.024
Safety	-0.039	0.287	-0.333
Healthcare	-0.280	0.242	-0.281
Education	-0.403	-0.049	-0.074
EnvironmentalQuality	-0.326	0.253	0.054
Economy	-0.273	-0.074	0.309
Taxation	0.026	0.107	-0.020
InternetAccess	-0.276	0.023	0.028
LeisureAndCulture	-0.074	-0.365	-0.305
Tolerance	-0.190	0.355	-0.103
Outdoors	-0.092	-0.193	-0.149

Tabela 3: Wartości wektorów ładunków trzech pierwszych składowych głównych

Najwyższy wskaźnik dla PC1 ma **Housing** i **CostOfLiving**. Dostępność mieszkań jest powiązana z kosztami życia, więc możemy interpretować tę zmienną po prostu jako koszty życia.

Następnie, dla PC2 najwyższy wskaźnik ma **Safety**, **Healthcare**, **EnvironmentalQuality** i **Tolerance**. Możemy więc interpretować tę zmienną jako poziom rozwoju.


Dla PC3, najwyższą wartość mają **Economy**, więc możemy interpretować tę zmienną jako sytuację gospodarczą.

1.4 Zmienność odpowiadająca poszczególnym składowym


Następnie naszym celem będzie sprawdzenie jaki procent wariancji odpowiada poszczególnym składowym głównym.

Na poniższym wykresie znajduje się wariancja poszczególnych składowych.

— dotąd zrobiłem bla bla bla bla :000 POWODZENIA !!!!



Rysunek 3: Wariancje poszczególnych składowych głównych




Rysunek 4: Skumulowana wariancja (w %) wyjaśniana przez kolejne składowe główne

Zgodnie z oczekiwaniami, wariancje maleją wraz z dalszą składową główną.

Aby móc odpowiedzieć na pytanie, ile składowych głównych jest potrzebnych do wyjaśnienia 80% oraz 90% całkowitej zmienności, na powyższym wykresie zaznaczamy odpowiednio poziomy 80% i 90%. Na podstawie tego wykresu możemy wyznaczyć liczbę składowych potrzebnych do wyjaśnienia odpowiednich wartości procentowych wariancji.

Do wyjaśnienia 80% wariancji potrzebnych jest 7 składowych głównych, natomiast do wyjaśnienia 90% wariancji potrzebnych jest 10 składowych głównych.

1.4.1 Wizualizacja danych wielowymiarowych



Rysunek 5: Rzut danych na dwie pierwsze składowe główne, kolory wg kontynentu

to z czatu do wyjebania :((to był geminik

Na powyższym wykresie widzimy rozkład obserwacji rozmieszczonych w zależności kosztów życia od poziomu rozwoju.


Miasta są grupowane na wykresie względem kontynentów.

Widzimy, że dane są szeroko rozpięte na osi poziomej, co sugeruje ogromne różnice w poziomie rozwoju miast. Możemy wywnioskować, że miasta znajdujące się w Europie są dość rozproszone na wykresie, lecz ich główna koncentracja znajduje się w przywyszy poziomu $pc2$ co świadczy o wysokim poziomie rozwoju tych miast. Znajdują się w obszarze ujemnych wartościach $pc1$ jak i 0 co oznacza koszty życia niższe koszty życia wraz z co może oznaczać tańsze bardziej dostępne mieszkania.

Miasta znajdujące się w Ameryce Północnej są rozłożone na całej długości $pc2$ oraz występują głównie na ujemnych wartościach $pc1$. Co świadczy o dużym rozróżnieniu co do poziomu rozwoju tych miast i dość niskich kosztów życia.

Natomiast miasta w Azji są mocno rozproszone po całym wykresie czego mogliśmy się spodziewać po wielkości i jak ogromnym zróżnicowaniem cechuje się ten kontynent. np. od rozwiniętej Japonii po ubogą Indie czy jakis Bangladesz i tnm.

Z kolei miasta Afryki znajdują się przy ujemnych wartościach $pc2$ oraz dodatnich wartościach $pc1$, co świadczy o niskim poziomie rozwoju tych państw oraz niskich kosztach życia. Co jest spodziewanym wynikiem.




Rysunek 6: Rzut danych na trzy pierwsze składowe główne – wyróżnione: Europa i Ameryka Północna


Na powyższym wykresie 3d widzimy rozkład miast względem 3 zmiennych pc1 koszty życia, pc2 poziom rozwoju oraz pc3 jako sytuacja gospodarcza na wykresie znajdują się miasta Europy oraz amerykańki Północnej. teraz możemy dodać do poprzedniej analizy zmienna odpowiadająca za sytuację gospodarczą. Możemy zauważyć że miasta amerykańki północnej cechują się lepszą sytuacją gospodarczą niż miasta Europy.

1.5 Korelacja zmiennych

następnie w celu sprawdzenia korelacji występującej w zmiennych pc stworzyliśmy dwuwymiarowy wykres.




Rysunek 7: Korelacje cech ze składowymi głównymi




Rysunek 8: Korelacje cech ze składowymi głównymi

Na pierwszym wykresie widzimy korelacje nowych zmiennych ze starymi (?) widzimy ze pc1


jest mocno skorelowana z kosztami życia oraz dostępnością życia co potwierdza nasze wcześniejsze przypuszczenia odnośnie znaczenia tej zmiennej. Następnie zmienna pc2 występuje dodatnia korelacja między zmiennymi bezpieczeństwo, opieki zdrowotnej oraz tolerancji co dobrze wynisokowaliśmy ze zmienna ta odpowiada za poziom rozwoju.



Rysunek 9: Biplot PCA – 10 cech o największym wkładzie



Rysunek 10: Biplot PCA z podziałem obserwacji wg kontynentu



Rysunek 11: Biplot PCA z elipsami ufności (95%) dla kontynentów

1.6 Końcowe wyniki