

Sprawozdanie 2 – Część 2 (tymczasowe)

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-30

Spis treści

1	Część 2 - Analiza składowych głównych	1
1.1	Wstęp	1
1.2	Przygotowanie danych	1
1.3	Wyznaczanie składowych głównych	5
1.4	Zmienność odpowiadająca poszczególnym składowym	7
1.5	Korelacja zmiennych	11
1.6	Końcowe wyniki	13

1 Część 2 - Analiza składowych głównych

1.1 Wstęp

W części drugiej będziemy pracować na zbiorze danych pobranych ze strony [Kaggle](#), pochodzącym oryginalnie z nieistniejącej już (przynajmniej pod tą domeną) strony [Teleport.org](#). Zbiór zawiera wskaźniki opisujące jakość życia z wybranej grupy „najbardziej kreatywnych” miast z całego świata zebranych w celu pozwolenia osobom znaleźć odpowiedniego miasta do życia według ich preferencji.

Wskaźniki dotyczą między innymi charakterystyk takich jak: warunki mieszkaniowe, koszty utrzymania, bezpieczeństwo, opieka zdrowotna, edukacja itp. Wszystkie wskaźniki są w skali od 0 do 10, gdzie większa wartość oznacza lepszy wynik.

Naszym celem będzie przeprowadzenie analizy składowych głównych (PCA, ang. *Principal Component Analysis*) wskaźników zawartych w zbiorze.

1.2 Przygotowanie danych

Dane zawierają informacje o 266 miastach. Dla każdego z nich mamy 21 cech.

	Typ	Opis
X	integer	identyfikator obserwacji
UA_Name	factor	nazwa obszaru miejskiego (UA – ang. <i>urban area</i>)
UA_Country	factor	kraj
UA_Continent	factor	kontynent
Housing	numeric	warunki mieszkaniowe
Cost.of.Living	numeric	koszty utrzymania
Startups	numeric	ekosystem startupów
Venture.Capital	numeric	dostępność kapitału inwestycyjnego
Travel.Connectivity	numeric	połączenia komunikacyjne (transport międzymiastowy i międzynarodowy)
Commute	numeric	codzienne dojazdy
Business.Freedom	numeric	swoboda prowadzenia biznesu
Safety	numeric	bezpieczeństwo
Healthcare	numeric	opieka zdrowotna
Education	numeric	edukacja
Environmental.Quality	numeric	jakość środowiska
Economy	numeric	kondycja gospodarki
Taxation	numeric	podatki
Internet.Access	numeric	dostęp do internetu
Leisure...Culture	numeric	oferta rozrywkowa i kulturalna
Tolerance	numeric	tolerancja społeczna
Outdoors	numeric	możliwości spędzania czasu na świeżym powietrzu

Tabela 1: Typy oraz opisy cech

Identyfikator **X** na pewno nie będzie nas interesował, więc go usuwamy.

Aby ujednolicić konwencję nazw, nazwy cech **UA_Name**, **UA_Country** oraz **UA_Continent** zamieniamy odpowiednio na **UrbanArea**, **Country** i **Continent**. Pozostałe nazwy cech, w których spacje zostały zamienione przez wbudowany w R czytnik CSV na kropki również ujednolicamy do tej konwencji. W nazwie cechy **Leisure...Culture**, w której na kropkę został zamieniony także symbol „&”, powstały trzykropek zamieniamy na „And”.

Zmienione nazwy zmiennych możemy zobaczyć w poniższej tabeli – będącej częścią dalszych działań dążących do oczyszczenia danych – podsumowującej wartości nieusuniętych zmiennych:

UrbanArea	Country	Continent	Housing	CostOfLiving
Birmingham: 2	United Kingdom: 13	Africa: 8	Min.: 0.000	Min.: 0.000
Portland: 2	Canada: 11	Asia: 37	1st Qu.: 5.149	1st Qu.: 4.795
Aarhus: 1	Germany: 11	Europe: 111	Median: 6.726	Median: 5.630
Adelaide: 1	France: 9	North America: 87	Mean: 6.467	Mean: 5.746
Albuquerque: 1	Spain: 7	Oceania: 8	3rd Qu.: 8.313	3rd Qu.: 7.596
Almaty: 1	Italy: 6	South America: 15	Max.: 10.000	Max.: 10.000
(Inne): 258	(Inne): 209			

Startups	VentureCapital	TravelConnectivity	Commute	BusinessFreedom
Min.: 0.000	Min.: 0.000	Min.: 0.500	Min.: 0.000	Min.: 0.000
1st Qu.: 3.098	1st Qu.: 0.000	1st Qu.: 1.703	1st Qu.: 4.400	1st Qu.: 5.771
Median: 4.214	Median: 2.317	Median: 2.921	Median: 5.064	Median: 8.404
Mean: 4.595	Mean: 2.703	Mean: 3.447	Mean: 4.632	Mean: 7.331
3rd Qu.: 5.790	3rd Qu.: 3.765	3rd Qu.: 4.766	3rd Qu.: 5.613	3rd Qu.: 8.837
Max.: 10.000	Max.: 10.000	Max.: 10.000	Max.: 6.729	Max.: 10.000

Safety	Healthcare	Education	EnvironmentalQuality	Economy
Min.: 1.343	Min.: 0.000	Min.: 0.000	Min.: 1.000	Min.: 0.000
1st Qu.: 5.972	1st Qu.: 6.064	1st Qu.: 2.184	1st Qu.: 4.329	1st Qu.: 4.103
Median: 7.189	Median: 6.780	Median: 4.273	Median: 6.481	Median: 5.373
Mean: 6.972	Mean: 6.797	Mean: 3.835	Mean: 6.078	Mean: 5.058
3rd Qu.: 8.269	3rd Qu.: 8.055	3rd Qu.: 5.294	3rd Qu.: 7.888	3rd Qu.: 6.514
Max.: 10.000	Max.: 9.321	Max.: 9.711	Max.: 9.953	Max.: 9.390

Taxation	InternetAccess	LeisureAndCulture	Tolerance	Outdoors
Min.: 0.500	Min.: 1.000	Min.: 0.000	Min.: 1.406	Min.: 0.500
1st Qu.: 3.921	1st Qu.: 4.134	1st Qu.: 4.448	1st Qu.: 5.780	1st Qu.: 3.699
Median: 4.760	Median: 5.379	Median: 5.707	Median: 7.154	Median: 4.733
Mean: 4.953	Mean: 5.205	Mean: 5.710	Mean: 6.793	Mean: 4.493
3rd Qu.: 5.955	3rd Qu.: 6.265	3rd Qu.: 7.062	3rd Qu.: 8.052	3rd Qu.: 5.500
Max.: 10.000	Max.: 9.716	Max.: 10.000	Max.: 9.739	Max.: 7.933

Tabela 2: Podsumowanie danych


Jak widać, wszystkie zmienne zawierają wartości zgodne z naszymi oczekiwaniami. Nie występują też żadne braki danych.

Mamy 3 cechy jakościowe reprezentujące nazwę miasta, kraju i kontynentu oraz 17 cech ilościowych zawierających wartości wskaźników jakości życia.

W podsumowaniu danych jakościowych widzimy że mamy informacje o miastach znajdujących się na 6 kontynentach (niestety bez [Antarktydy](#)). Powyższa tabela wskazuje nam że najwięcej miast mamy z [Europy](#) (111), następnie z [Ameryki Północnej](#) (87). Łącznie mamy informacje o 264 miastach z 135 państw, co świadczy o dużej różnorodności.


W tabeli widzimy też, że nie wszystkie cechy ilościowe przyjmują wartości skrajne – 0 oraz 10. Może to sugerować, że ich rozkłady się znacząco różnią.

W celu najlepszego wyznaczenia składowych głównych, zmienne powinny mieć podobną wariancję.



Rysunek 1: Rozkład wartości cech ilościowych

Widzimy, że zakres wartości zmiennych takich jak `Commute` i `Outdoors` jest dużo węższy niż przykładowo `VentureCapital`, `EnvironmentQuality`, czy `Education`. Wskazuje to na różnice w wariancji. Z tego powodu dokonujemy standaryzacji za pomocą wbudowanej w R funkcji `scale()`. Wynik tego działania znajduje się na poniższym wykresie.



Rysunek 2: Rozkład wartości cech ilościowych po standaryzacji

Musimy jednak pamiętać że wartości zmiennych po standaryzacji nie są już w skali 0–10.

1.3 Wyznaczanie składowych głównych

Kolejnym naszym krokiem będzie wyznaczenie składowych głównych naszych zmiennych. Użyjemy do tego funkcji `prcomp()`.

W celu interpretacji otrzymanych składowych, analizujemy ich wektory ładunków (ang. *loadings*). Reprezentują one wkład każdej ze zmiennych na wartości składowych.

	PC1	PC2	PC3
Housing	0.308	0.053	-0.314
CostOfLiving	0.260	-0.176	-0.331
Startups	-0.180	-0.483	0.006
VentureCapital	-0.237	-0.427	0.015
TravelConnectivity	-0.209	-0.135	-0.340
Commute	-0.114	0.026	-0.506
BusinessFreedom	-0.377	0.098	0.024
Safety	-0.039	0.287	-0.333
Healthcare	-0.280	0.242	-0.281
Education	-0.403	-0.049	-0.074
EnvironmentalQuality	-0.326	0.253	0.054
Economy	-0.273	-0.074	0.309
Taxation	0.026	0.107	-0.020
InternetAccess	-0.276	0.023	0.028
LeisureAndCulture	-0.074	-0.365	-0.305
Tolerance	-0.190	0.355	-0.103
Outdoors	-0.092	-0.193	-0.149

Tabela 3: Wartości wektorów ładunków trzech pierwszych składowych głównych

Największy wpływ na interpretację składowych głównych mają zmienne o najwyższych wartościach bezwzględnych ładunków.

Najwyższe dodatnie wartości dla pierwszej składowej głównej (PC1) osiągają zmienne Housing oraz CostOfLiving, co wskazuje na silny związek tej składowej z kosztami życia i dostępnością mieszkań. Z kolei najniższe (ujemne) wartości przyjmują zmienne Education, BusinessFreedom oraz EnvironmentalQuality. Oznacza to, że PC1 można interpretować jako wymiar kontrastu pomiędzy wysokimi kosztami życia a poziomem rozwoju społeczno-gospodarczego.


W przypadku drugiej składowej głównej (PC2) najwyższe dodatnie wartości osiągają zmienne Safety, Healthcare, EnvironmentalQuality oraz Tolerance, które opisują szeroko rozumianą jakość życia. Najniższe wartości przyjmują natomiast zmienne Startups, VentureCapital oraz LeisureAndCulture, związane z aktywnością innowacyjną i gospodarczą. W związku z tym PC2 można interpretować jako wymiar przeciwstawiający wysoką jakość życia dynamice innowacyjno-gospodarczej.

Dla trzeciej składowej głównej (PC3) najwyższą dodatnią wartość przyjmuje zmienna Economy, natomiast niskie (ujemne) wartości obserwujemy m.in. dla zmiennych Commute, TravelConnectivity, CostOfLiving oraz Safety. Oznacza to, że PC3 można interpretować jako wymiar odzwierciedlający sytuację gospodarczą w zestawieniu z wybranymi aspektami komfortu życia. Wyższe wartości tej składowej mogą wskazywać na lepsze warunki ekonomiczne, ale jednocześnie mniej korzystne warunki codziennego funkcjonowania.


1.4 Zmienność odpowiadająca poszczególnym składowym

W kolejnym etapie analizy zbadaliśmy, jaki procent całkowitej zmienności (wariancji) danych jest wyjaśniany przez poszczególne składowe główne.

Na pierwszym wykresie przedstawiono wariancję poszczególnych składowych. Zgodnie z założeniami metody PCA, wartości wariancji maleją wraz z kolejnymi składowymi, co potwierdza, że pierwsze z nich zawierają najistotniejszą informację o strukturze zbioru danych.



Rysunek 3: Wariancje poszczególnych składowych głównych




Rysunek 4: Skumulowana wariancja (w %) wyjaśniana przez kolejne składowe główne

Aby móc odpowiedzieć na pytanie, ile składowych głównych jest potrzebnych do wyjaśnienia 80% oraz 90% całkowitej zmienności, na powyższym wykresie zaznaczamy odpowiednio

poziomy 80% i 90%. Na podstawie tego wykresu możemy wyznaczyć liczbę składowych potrzebnych do wyjaśnienia odpowiednich wartości procentowych wariancji.

Do wyjaśnienia 80% wariancji potrzebnych jest 7 składowych głównych, natomiast do wyjaśnienia 90% wariancji potrzebnych jest 10 składowych głównych.

1.4.1 Wizualizacja danych wielowymiarowych



Rysunek 5: Rzut danych na dwie pierwsze składowe główne, kolory wg kontynentu

Na powyższym wykresie przedstawiono rozkład miast w przestrzeni dwóch pierwszych składowych głównych, które można interpretować odpowiednio jako koszty życia (PC1) oraz poziom rozwoju i jakość życia (PC2).


Punkty na wykresie są pogrupowane według kontynentów, co pozwala na analizę zróżnicowania geograficznego.

Miasta europejskie koncentrują się głównie w lewej górnej części wykresu. Oznacza to, że wiele z nich charakteryzuje się relatywnie niższymi kosztami życia (ujemne wartości PC1) przy jednocześnie wysokim poziomie rozwoju oraz jakości życia (wysokie wartości PC2), obejmującej m.in. bezpieczeństwo, opiekę zdrowotną oraz jakość środowiska.

Miasta Ameryki Północnej wykazują większe zróżnicowanie i są bardziej rozproszone na wykresie, z widoczną tendencją do niższych wartości PC2. Może to sugerować, że część tych miast w większym stopniu charakteryzuje się dynamiką innowacyjną oraz aktywnością gospodarczą (np. rozwój startupów), kosztem niektórych aspektów jakości życia.

Miasta azjatyckie cechują się największym rozproszeniem na wykresie, co odzwierciedla dużą różnorodność gospodarczą i społeczną tego kontynentu. Obejmuje ona zarówno wysoko rozwinięte metropolie (np. Singapur czy Tokio), jak i miasta o niższym poziomie rozwoju, co przekłada się na szeroki zakres wartości obu składowych.

Miasta afrykańskie w analizowanej próbie koncentrują się częściej w obszarach o wyższych wartościach PC1. W kontekście przyjętej interpretacji oznacza to, że czynniki związane z kosztami życia i dostępnością mieszkań odgrywają w ich przypadku istotniejszą rolę, przy jednocześnie niższych wartościach wskaźników związanych z jakością życia.




Rysunek 6: Biplot PCA z elipsami ufności (95%) dla kontynentów

Na wykresie biplot przedstawiono podział miast według kontynentów wraz z naniesionymi wektorami zmiennych opisujących ich charakterystyki. Strzałki reprezentują kierunek i siłę wpływu poszczególnych zmiennych na składowe główne, co umożliwia jednoczesną analizę zależności między miastami oraz badanymi cechami.

Miasta Europy oraz Ameryki Północnej znajdują się po stronie odpowiadającej wyższym wartościom zmiennych związanych z poziomem rozwoju społeczno-gospodarczego. Z kolei miasta z Afryki, Ameryki Południowej oraz części Azji sytuują się po przeciwnej stronie osi Dim1, co sugeruje niższe wartości tych wskaźników w analizowanym zbiorze danych. Widoczna separacja regionów potwierdza, że PCA skutecznie identyfikuje globalne różnice w poziomie rozwoju miast.


PCA – miasta skrajne



Rysunek 7: Rzut danych na dwie pierwsze składowe główne – Afryka na tle pozostałych kontynentów

Na wykresie PCA widzimy, że miasta zlokalizowane w lewym dolnym rogu przestrzeni (niskie wartości PC1 i PC2) tworzą grupę o szczególnych cechach strukturalnych. Są to głównie metropolie z Europy i Ameryki Północnej, które charakteryzują się wysokimi kosztami życia oraz rozwiniętym rynkiem nieruchomości. Jednocześnie ich relatywnie niskie wartości PC2 sugerują, że mimo wysokiego poziomu bezpieczeństwa i jakości usług publicznych, mogą one cechować się mniejszą dynamiką innowacyjno-gospodarczą lub ograniczoną dostępnością pewnych aspektów życia miejskiego, takich jak przystępność kultury czy elastyczność rynku.

Lagos, położone w Nigerii (Afryka Zachodnia), znajduje się na przeciwnym biegunie osi PC1 względem wielu miast zachodnich, co czyni je jednym z najbardziej oddalonych punktów w tym wymiarze. Miasto to reprezentuje dynamicznie rozwijającą się metropolię Globalnego Południa, zmagającą się z wyzwaniami gwałtownej urbanizacji, presją demograficzną oraz ograniczeniami infrastrukturalnymi. Jego pozycja w przestrzeni PCA sugeruje, że czynniki takie jak nierówności społeczne, ograniczona dostępność usług publicznych (edukacja, opieka zdrowotna) oraz jakość środowiska w istotny sposób odróżniają je od metropolii Europy i Ameryki Północnej.




Rysunek 8: Rzut danych na trzy pierwsze składowe główne – wyróżnione: Europa i Ameryka Północna

Na trójwymiarowym wykresie PCA przedstawiono rozmieszczenie miast względem trzech głównych składowych: PC1, PC2 oraz PC3, ograniczając analizę do miast Europy i Ameryki Północnej. Każda z osi reprezentuje odmienny wymiar jakości życia i rozwoju społeczno-gospodarczego.


Analiza rozmieszczenia miast w tej przestrzeni pokazuje wyraźne różnice regionalne. Miasta Ameryki Północnej częściej lokują się w obszarach wyższych wartości PC3, co sugeruje relatywnie silniejszą sytuację gospodarczą w porównaniu do miast europejskich. Jednocześnie miasta europejskie częściej osiągają wyższe wartości w wymiarach jakości życia (PC2), co wskazuje na większy nacisk na bezpieczeństwo, ochronę zdrowia i jakość środowiska. W rezultacie obie grupy miast różnią się profilem rozwoju: Ameryka Północna jest bardziej zorientowana na dynamikę gospodarczą, natomiast Europa na zrównoważoną jakość życia.

1.5 Korelacja zmiennych

Następnie, w celu porównania zależności między zmiennymi opisanymi przez składowe PCA, zrobiliśmy dwuwymiarowy wykres obejmujący macierz korelacji oraz biplot PCA.



Rysunek 9: Korelacje cech ze składowymi głównymi



Rysunek 10: Biplot PCA – 10 cech o największym wkładzie

Analiza macierzy korelacji wykazała istotne zależności pomiędzy zmiennymi. W szczególności

zaobserwowano silną dodatnią korelację między kosztami życia a dostępnością mieszkań, natomiast ujemne zależności występują między kosztami życia a wskaźnikami jakości środowiska oraz poziomu rozwoju społeczno-gospodarczego.

Wykres biplot PCA potwierdza te zależności w ujęciu geometrycznym. Zmienne silnie dodatnio skorelowane są reprezentowane przez wektory skierowane w podobnym kierunku, natomiast zmienne o korelacji ujemnej znajdują się po przeciwnych stronach wykresu względem siebie. Dodatkowo biplot umożliwia analizę zależności pomiędzy samymi zmiennymi — małe kąty między wektorami (np. Housing i CostOfLiving) wskazują na silną korelację dodatnią, natomiast przeciwne kierunki wektorów (np. Housing i Education) świadczą o korelacji ujemnej.

Wnioski uzyskane z obu metod są spójne i wzajemnie się uzupełniają. Macierz korelacji dostarcza precyzyjnych wartości liczbowych opisujących siłę zależności, natomiast biplot PCA pozwala na ich intuicyjną interpretację geometryczną, umożliwiając jednoczesną analizę relacji między zmiennymi oraz ich projekcji w przestrzeni składowych głównych.

1.6 Końcowe wyniki

W przeprowadzonych analizach PCA udało się zaobserwować wyraźną strukturę danych, w której pierwsze dwie składowe główne opisują najważniejsze wymiary zróżnicowania miast: poziom kosztów życia (PC1) oraz jakość życia i rozwój społeczno-gospodarczy (PC2). Dodatkowo trzecia składowa (PC3) wnosi informację o sytuacji gospodarczej, jednak jej znaczenie jest mniejsze niż dwóch pierwszych komponentów.

Z analizy wynika, że już dwie składowe główne są wystarczające do uzyskania dobrej, czytelnej reprezentacji danych, ponieważ wyjaśniają one znaczną część całkowitej wariancji i pozwalają na wyraźne rozróżnienie grup miast. Dodanie trzeciej składowej poprawia szczegółowość interpretacji, ale nie jest kluczowe dla ogólnego obrazu struktury danych.

Standaryzacja danych miała istotny wpływ na wyniki analizy. Dzięki niej wszystkie zmienne zostały sprowadzone do porównywalnej skali, co zapobiegło dominacji cech o dużych wartościach liczbowych (np. kosztów życia). W efekcie PCA lepiej odzwierciedla rzeczywiste relacje między zmiennymi, a uzyskane składowe są bardziej zrównoważone.