

Sprawozdanie 2 – Część 2 (tymczasowe)

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-04-28

Spis treści

1	Część 2 - Analiza składowych głównych	2
1.1	Wstęp	2
1.2	Przygotowanie danych	2
1.3	Wyznaczanie składowych głównych	7
1.4	Zmienność odpowiadająca poszczególnym składowym	8
1.5	Korelacja zmiennych	12
1.6	Końcowe wyniki	15

1 Część 2 - Analiza składowych głównych

1.1 Wstęp

W części drugiej będziemy pracować na zbiorze danych pobranych ze strony [Kaggle](#), pochodzącym oryginalnie z nieistniejącej już (przynajmniej pod tą domeną) strony [Teleport.org](#). Zbiór zawiera wskaźniki dotyczące jakości życia z 266 „najbardziej kreatywnych” miast na całym świecie zebranych w celu pozwolenia osobom znaleźć odpowiedniego miasta do życia według ich preferencji. Naszym celem będzie przeprowadzenie analizy składowych głównych (PCA, ang. *Principal Component Analysis*) wskaźników zawartych w zbiorze.

1.2 Przygotowanie danych

Dane zawierają informacje o 266 miastach. Dla każdego z nich mamy 21 cech.

	Typ	Opis
X	integer	identyfikator obserwacji
UA_Name	factor	nazwa obszaru miejskiego (UA – ang. <i>urban area</i>)
UA_Country	factor	kraj
UA_Continent	factor	kontynent
Housing	numeric	warunki mieszkaniowe
Cost.of.Living	numeric	koszty utrzymania
Startups	numeric	ekosystem startupów
Venture.Capital	numeric	dostępność kapitału inwestycyjnego
Travel.Connectivity	numeric	połączenia komunikacyjne (transport międzymiastowy i międzynarodowy)
Commute	numeric	codzienne dojazdy
Business.Freedom	numeric	swoboda prowadzenia biznesu
Safety	numeric	bezpieczeństwo
Healthcare	numeric	opieka zdrowotna
Education	numeric	edukacja
Environmental.Quality	numeric	jakość środowiska
Economy	numeric	kondycja gospodarki
Taxation	numeric	obciążenia podatkowe
Internet.Access	numeric	dostęp do internetu
Leisure...Culture	numeric	oferta rozrywkowa i kulturalna
Tolerance	numeric	tolerancja społeczna
Outdoors	numeric	możliwości spędzania czasu na świeżym powietrzu

Tabela 1: Typy oraz opisy cech

X	UA_Name	UA_Country	UA_Continent	Housing
Min.: 0.00	Birmingham: 2	United Kingdom: 13	Africa: 8	Min.: 0.000
1st Qu.: 66.25	Portland: 2	Canada: 11	Asia: 37	1st Qu.: 5.149
Median: 132.50	Aarhus: 1	Germany: 11	Europe: 111	Median: 6.726
Mean: 132.50	Adelaide: 1	France: 9	North America: 87	Mean: 6.467
3rd Qu.: 198.75	Albuquerque: 1	Spain: 7	Oceania: 8	3rd Qu.: 8.313
Max.: 265.00	Almaty: 1	Italy: 6	South America: 15	Max.: 10.000
	(Inne): 258	(Inne): 209		

Cost.of.Living	Startups	Venture.Capital	Travel.Connectivity	Commute
Min.: 0.000	Min.: 0.000	Min.: 0.000	Min.: 0.500	Min.: 0.000
1st Qu.: 4.795	1st Qu.: 3.098	1st Qu.: 0.000	1st Qu.: 1.703	1st Qu.: 4.400
Median: 5.630	Median: 4.214	Median: 2.317	Median: 2.921	Median: 5.064
Mean: 5.746	Mean: 4.595	Mean: 2.703	Mean: 3.447	Mean: 4.632
3rd Qu.: 7.596	3rd Qu.: 5.790	3rd Qu.: 3.765	3rd Qu.: 4.766	3rd Qu.: 5.613
Max.: 10.000	Max.: 10.000	Max.: 10.000	Max.: 10.000	Max.: 6.729

Business.Freedom	Safety	Healthcare	Education	Environmental.Quality
Min.: 0.000	Min.: 1.343	Min.: 0.000	Min.: 0.000	Min.: 1.000
1st Qu.: 5.771	1st Qu.: 5.972	1st Qu.: 6.064	1st Qu.: 2.184	1st Qu.: 4.329
Median: 8.404	Median: 7.189	Median: 6.780	Median: 4.273	Median: 6.481
Mean: 7.331	Mean: 6.972	Mean: 6.797	Mean: 3.835	Mean: 6.078
3rd Qu.: 8.837	3rd Qu.: 8.269	3rd Qu.: 8.055	3rd Qu.: 5.294	3rd Qu.: 7.888
Max.: 10.000	Max.: 10.000	Max.: 9.321	Max.: 9.711	Max.: 9.953

Economy	Taxation	Internet.Access	Leisure...Culture	Tolerance
Min.: 0.000	Min.: 0.500	Min.: 1.000	Min.: 0.000	Min.: 1.406
1st Qu.: 4.103	1st Qu.: 3.921	1st Qu.: 4.134	1st Qu.: 4.448	1st Qu.: 5.780
Median: 5.373	Median: 4.760	Median: 5.379	Median: 5.707	Median: 7.154
Mean: 5.058	Mean: 4.953	Mean: 5.205	Mean: 5.710	Mean: 6.793
3rd Qu.: 6.514	3rd Qu.: 5.955	3rd Qu.: 6.265	3rd Qu.: 7.062	3rd Qu.: 8.052
Max.: 9.390	Max.: 10.000	Max.: 9.716	Max.: 10.000	Max.: 9.739

Outdoors
Min.: 0.500
1st Qu.: 3.699
Median: 4.733
Mean: 4.493
3rd Qu.: 5.500
Max.: 7.933

Tabela 2: Podsumowanie danych

zawiera wartości wskaźników opisujących jakość życia w wybranych miastach, w tym m.in. takie charakterystyki jak: warunki mieszkaniowe, koszty utrzymania, bezpieczeństwo, opieka zdrowotna, edukacja itp. Wszystkie cechy ilościowe przyjmują wartości w zakresie 0 - 10, im wyższa wartość tym lepszy wynik. Zbiór danych zawiera również zmienne jakościowe takie jak Nazwa miasta, kraju oraz kontynentu na jakim się znajdują posłużą nam do lepszej interpretacji wyników.

Powyższej tabeli znajdują się statystyki opisowe danych ilościowych (tu zastanawiam się czy dawać wszystkie czy tylko część) zbiór danych nie zawiera żadnych braków danych po jest widoczne na poniższej tabeli.

Zmienna Id została usunięta jako nie istotna do dalszej analizy również w celu wyznaczenia składników głównych użyto tylko zmiennych ilościowych.

Cecha	Liczba braków
Housing	0
Cost of Living	0
Startups	0
Venture Capital	0
Travel Connectivity	0
Commute	0
Business Freedom	0
Safety	0
Healthcare	0
Education	0
Environmental Quality	0
Economy	0
Taxation	0
Internet Access	0
Leisure & Culture	0
Tolerance	0
Outdoors	0


Tabela 3: Liczba braków danych w cechach ilościowych

Kontynent	Liczba miast
Europe	111
North America	87
Asia	37
South America	15
Africa	8
Oceania	8

Tabela 4: Liczba miast w podziale na kontynenty


Następnie analizując dane jakościowe można że mamy informacje o miastach znajdujących się na 6 kontynentach bez Antarktydy (gdzie m=nie ma miast (chyba)). Powyższa tabela wskazała nam że najwięcej miast mamy z [Europy](#) następnie z [Ameryki Północnej](#). Łącznie mamy informacje o 264 miastach oraz o 135 Państwach co świadczy o dużej różnorodności.

Następnie w celu poprawnego wyznaczenia składowych głównych musimy sprawdzić zmienność poszczególnych cech tzn. czy wariancja naszych cech ilościowych jest podobna. Wartości wariancji znajduje się na wykresie poniżej.



Rysunek 1: Rozkład wartości poszczególnych cech ilościowych przed standaryzacją

Widzimy, że wariancja dla różnych cech jest inna, przez co konieczna jest standaryzacja. Wynik tego działania znajduje się na poniższym wykresie.



Rysunek 2: Rozkład wartości poszczególnych cech ilościowych po standaryzacji

1.3 Wyznaczanie składowych głównych

Następnie wyznaczmy składowe główne naszych zmiennych, używając funkcji `prcomp()`.

tu z czatu definicja

Celem wyznaczenia składowych głównych (PCA, *Principal Component Analysis*) jest redukcja wymiarowości danych przy jednoczesnym zachowaniu jak największej części informacji zawartej w zmiennych pierwotnych. Metoda ta polega na przekształceniu oryginalnych, często skorelowanych zmiennych w nowy zestaw nieskorelowanych zmiennych (składowych głównych), które są liniowymi kombinacjami zmiennych wejściowych.

Pierwsza składowa główna wyjaśnia największą możliwą część wariancji danych, a każda kolejna maksymalizuje wyjaśnianą wariancję przy założeniu ortogonalności względem poprzednich. Dzięki temu możliwe jest uproszczenie struktury danych oraz identyfikacja głównych wzorców i zależności w zbiorze danych.

	PC1	PC2	PC3
Housing	0.308	0.053	-0.314
Cost of Living	0.260	-0.176	-0.331
Startups	-0.180	-0.483	0.006
Venture Capital	-0.237	-0.427	0.015
Travel Connectivity	-0.209	-0.135	-0.340
Commute	-0.114	0.026	-0.506
Business Freedom	-0.377	0.098	0.024
Safety	-0.039	0.287	-0.333
Healthcare	-0.280	0.242	-0.281
Education	-0.403	-0.049	-0.074
Environmental Quality	-0.326	0.253	0.054
Economy	-0.273	-0.074	0.309
Taxation	0.026	0.107	-0.020
Internet Access	-0.276	0.023	0.028
Leisure & Culture	-0.074	-0.365	-0.305
Tolerance	-0.190	0.355	-0.103
Outdoors	-0.092	-0.193	-0.149

Tabela 5: Współczynniki (loadings) trzech pierwszych składowych głównych

Najwyższy wskaźnik dla PC1 ma **Housing** i **Cost of Living** więc możemy interpretować tę zmienną jako koszty życia i poziom rozwoju. Następnie PC2 najwyższy wskaźnik dla **Safety** i **Healthcare** i **Environmental Quality** i **Tolerance** więc możemy interpretować tę zmienną jako innowacyjność. Natomiast PC3 najwyższe wartości *loading* mają **Economy** więc możemy interpretować tę zmienną jako infrastruktura i dostępność / mobilność.

PC1 reprezentuje ogólny poziom rozwoju społeczno-gospodarczego oraz jakości życia, gdzie przeciwstawione są koszty życia (np. **Housing**) i rozwój instytucjonalny (np. edukacja, środowisko, gospodarka).


PC2 odzwierciedla kontrast między innowacyjnością gospodarczą a jakością życia i czynnikami społecznymi (bezpieczeństwo, tolerancja, kultura).

PC3 można interpretować jako komponent związany z mobilnością, kosztami życia oraz dostępnością infrastruktury, z pewnym udziałem czynnika gospodarczego.


1.4 Zmienność odpowiadająca poszczególnym składowym

Następnie naszym celem będzie sprawdzenie, jaki procent wariancji odpowiada poszczególnym składowym.

Na poniższym wykresie znajduje się wariancja poszczególnych składowych. Zgodnie z oczekiwaniami wariancje maleją wraz z dalszą składową główną.



Rysunek 3: Wariacje poszczególnych składowych głównych




Rysunek 4: Skumulowana wariancja (w %) wyjaśniana przez kolejne składowe główne

Aby móc odpowiedzieć na pytanie, ile składowych głównych jest potrzebnych do wyjaśnienia 80% oraz 90% całkowitej zmienności. Wykonano wykres powyżej z zaznaczonymi poziomami odpowiednio 80 % i 90%. Na podstawie tego wykresu można wyznaczyć liczbę składowych potrzebnych do wyjaśnienia odpowiednich wartości procentowej wariancji.

Do wyjaśnienia 80% składowych potrzebne jest 7 zmiennych, natomiast do wyjaśnienia 90% składowych potrzebne jest 10 zmiennych.

1.4.1 Wizualizacja danych wielowymiarowych



Rysunek 5: Rzut danych na dwie pierwsze składowe główne, kolory wg kontynentu

Widzimy, że dane są szeroko rozpięte na osi poziomej, co sugeruje ogromne różnice w poziomie rozwoju miast:

- **Europa (kolor zielony):** Miasta europejskie są rozproszone, ale znacząca ich część koncentruje się w lewej i centralnej części wykresu (wartości ujemne i bliskie zeru na PC1). Jeśli PC1 reprezentuje wysoki koszt życia skorelowany z wysokim rozwojem, to te miasta stanowią “główny nurt” rozwiniętych aglomeracji.
- **Afryka (kolor czerwony):** Są to najbardziej skrajne punkty po prawej stronie osi PC1 (wartości dodatnie). Oznacza to, że miasta afrykańskie znacząco odstają od reszty świata pod względem ogólnego poziomu rozwoju instytucjonalnego i gospodarczego ujętego w tym komponencie.

1.4.2 2. Zróźnicowanie wzdłuż osi PC2 (Innowacyjność vs. Bezpieczeństwo i Kultura)


Oś pionowa pokazuje kontrast między miastami stawiającymi na “twardą” gospodarkę a tymi, które oferują wyższą jakość życia społecznego:

- **Ameryka Północna (kolor jasnoniebieski):** Większość punktów znajduje się w dolnej części wykresu (wartości ujemne PC2). Sugeruje to, że miasta te charakteryzują się specyficznym profilem, gdzie czynniki społeczne (bezpieczeństwo, tolerancja) mogą wypadać relatywnie słabiej w stosunku do innowacyjności gospodarczej, lub odwrotnie – zależy to od dokładnego kierunku wektorów cech (*loadings*).
- **Europa (kolor zielony):** Wiele miast europejskich znajduje się w górnej części osi PC2. Może to świadczyć o ich wysokich wynikach w kategoriach bezpieczeństwa, kultury i


tolerancji w porównaniu do miast z innych kontynentów o podobnym poziomie rozwoju gospodarczego.

1.4.3 3. Skupiska i “Outliery”

- **Azja (kolor żółty):** Wykazuje bardzo duży rozrzut na obu osiach. Oznacza to, że azjatyckie miasta są skrajnie niejednorodne – mamy tam zarówno potężne, rozwinięte centra, jak i miasta o znacznie niższym standardzie życia.
- **Oceania (kolor ciemnoniebieski):** Tworzy dość zwartą grupę w lewym górnym kwadrancie (niskie/średnie PC1, wysokie PC2), co sugeruje, że miasta te łączą stabilny rozwój gospodarczy z bardzo wysoką jakością życia i bezpieczeństwem.




Rysunek 6: Rzut danych na dwie pierwsze składowe główne – Afryka na tle pozostałych kontynentów




Rysunek 7: Rzut danych na trzy pierwsze składowe główne – wyróżnione: Europa i Ameryka Północna

1.5 Korelacja zmiennych


wykres korelacji tak o




Rysunek 8: Korelacje cech ze składowymi głównymi




Rysunek 9: Macierz korelacji cech ilościowych



Rysunek 10: Biplot PCA – 10 cech o największym wkładzie



Rysunek 11: Biplot PCA z podziałem obserwacji wg kontynentu



Rysunek 12: Biplot PCA z elipsami ufności (95%) dla kontynentów

1.6 Końcowe wyniki