

Sprawozdanie 3

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-06-03


Spis treści

1	Część 1 – klasyfikacja	2
1.1	Wstęp	2
1.2	Przypomnienie struktury danych	2
1.3	Podział danych na zbiór uczący i testowy	3
1.4	Konstrukcja klasyfikatora i wyznaczanie prognoz	3
1.5	Ocena klasyfikacji	4
1.6	Model liniowy dla rozszerzonej przestrzeni klas	6
2	Część 2 - porównanie metod klasyfikacji	7
2.1	Wstęp	7
2.2	Opis i wstępna analiza danych	8
2.3	Ocena dokładności klasyfikacji i porównanie metod	12
2.4	Różne parametry i podzbiory cech	17
2.5	Podsumowanie	17

1 Część 1 – klasyfikacja

1.1 Wstęp

Pracujemy na tym samym zbiorze danych co w poprzednim sprawozdaniu. Zbiór zawiera wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*). W przeciągu ostatniego miesiąca wygląd kwiatów się nie zmienił i nadal wyglądają one tak:



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

1.2 Przypomnienie struktury danych

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatka (w cm)
Petal.Width	numeric	szerokość płatka (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)

Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

1.3 Podział danych na zbiór uczący i testowy

W celu oceny jakości działania klasyfikatora dzielimy zbiór danych na zbiór uczący `train_set` i zbiór testowy `test_set` w proporcjach 1 do 2:

```
set.seed(67) # ustawiamy seed losowania

n <- nrow(dane) # liczba obserwacji

# losujemy które obserwacje będą w zbiorze uczącym a które w testowym
train_index <- sample(1:n, size = round(2/3 * n))

# tworzymy osobne ramki danych dla obu zbiorów
train_set <- dane[train_index, ]
test_set <- dane[-train_index, ]
```

Zbiór uczący zawiera 100 obserwacji, a zbiór testowy 50.

1.4 Konstrukcja klasyfikatora i wyznaczanie prognoz

Będziemy konstruować klasyfikator oparty na regresji liniowej. W tym celu na podstawie zbioru uczącego (`train_set`) będziemy estymować parametry modelu.

Aby to zrobić, musimy najpierw zakodować klasy przy użyciu zmiennych binarnych (indykatory klas):

```
etykietki.klas <- train_set$Species

K <- length(unique(etykietki.klas)) # liczba klas (gatunków)
n.train <- nrow(train_set)          # liczba obserwacji uczących

# tworzymy macierz wskaźników klas i przypisujemy jej odpowiednie wartości
Y.train <- matrix(0, nrow = n.train, ncol = K)
etykietki.num <- as.numeric(etykietki.klas)
```

```
for(k in 1:K)
  Y.train[etykietki.num == k, k] <- 1
```

Następnie estymujemy parametry modelu za pomocą zbioru uczącego:

```
# macierz cech z dodatkową kolumną jedynek (wyraz wolny)
X.train <- as.matrix(cbind(1, train_set[,1:4]))

# estymacja współczynników metodą najmniejszych kwadratów:  $B=(X'X)^{-1} X'Y$ 
B.hat <- solve(t(X.train) %*% X.train) %*%
          t(X.train) %*% Y.train
```

Dla każdej obserwacji – zarówno ze zbioru uczącego i testowego – liczymy estymowane indykatory klas:

```
# dopasowane wskaźniki klas dla zbioru uczącego
Y.hat.train <- X.train %*% B.hat
pred.train <- apply(Y.hat.train, 1, which.max) # klasa = kolumna z największą wartością

# to samo dla zbioru testowego (kolumna jedynek jak w zbiorze uczącym)
X.test <- cbind(1, test_set[,1:4])
X.test <- as.matrix(X.test)

Y.hat.test <- X.test %*% B.hat
pred.test <- apply(Y.hat.test, 1, which.max)
```

1.5 Ocena klasyfikacji

W celu oceny klasyfikacji wyliczamy macierz pomyłek (ang. *confusion matrix*) oraz błąd klasyfikacji na zbiorze uczącym oraz testowym.

	<i>setosa</i>	<i>versicolor</i>	<i>virginica</i>
<i>setosa</i>	28	0	0
<i>versicolor</i>	0	28	9
<i>virginica</i>	0	6	29

Tabela 3: Macierz pomyłek dla zbioru uczącego (model liniowy). Wiersz oznacza faktyczny gatunek, a kolumna estymowany.


Na powyższej tabeli widzimy wyniki dopasowania gatunków do kwiatów. Błąd klasyfikacji (proporcja źle sklasyfikowanych obserwacji do wszystkich obserwacji) wynosi 15%. Taka wysoka wartość wynika z mylenia przez model gatunków *versicolor* oraz *virginica* – jak na to że jest to zbiór uczący, sugeruje to że ciężko jest te gatunki rozdzielić.

Zjawisko maskowania klas nie występuje – gdyby występowało, któraś z klas byłaby przewidywana znacząco rzadziej niż występuje. W naszym przypadku tak nie jest. Pomaga nam to, że liczba $p = 4$ zmiennych objaśniających jest większa od liczby $K = 3$ klas, dzięki czemu „wymiarowość” gra trochę na naszą korzyść.

	<i>setosa</i>	<i>versicolor</i>	<i>virginica</i>
<i>setosa</i>	22	0	0
<i>versicolor</i>	0	11	2
<i>virginica</i>	0	5	10

Tabela 4: Macierz pomyłek dla zbioru testowego (model liniowy). Wiersz oznacza faktyczny gatunek, a kolumna estymowany.

Dla zbioru testowego błąd klasyfikacji wynosi 14%; zbliżona wartość błędów dla zbioru uczącego i testowego świadczy, że model nie jest przetrenowany i dobrze klasyfikuje dane.



Rysunek 2: Wartości wskaźników klas $\hat{Y}$ (estymatorów indykatorów) dla modelu liniowego (zbiór uczący). Oś x nic nie oznacza i ma na celu tylko rozdzielenie gatunków. Od lewej: *setosa*, *versicolor*, *virginica*.

Na wykresie widać, że najlepszą separowalność uzyskano dla kwiatów z gatunku *setosa*, o czym świadczą wysokie wartości wskaźników dla ich własnej klasy i niskie dla pozostałych.

W przypadku *versicolor* i *virginica*, wartości wskaźników właściwych klas są niższe niż w przypadku *setosa*, niewiele większe od wartości wskaźników o drugich najwyższych wartościach – wskaźników *virginica* w przypadku *versicolor* oraz vice versa. Powoduje to trudność w

rozdzieleniu przez model kwiatów tych dwóch gatunków, co zostało zauważone już przy macierzy pomyłek.

1.6 Model liniowy dla rozszerzonej przestrzeni klas

Teraz przeprowadzimy klasyfikację gatunków irysów na rozszerzonej przestrzeni cech. W tym celu zbudujemy nowy model liniowy dla tych cech. Nasza nowa przestrzeń cech zawiera oryginalne zmienne PL, PW, SL i SW oraz składniki wielomianowe stopnia 2: $PL^2, PW^2, SL^2, SW^2, PL \cdot PW, PL \cdot SL, PL \cdot SW, PW \cdot SL, PW \cdot SW$ oraz $SL \cdot SW$.

Model konstruujemy analogicznie jak poprzednio z uprzednim dodaniem nowych cech.

W celu porównania dokładności klasyfikacji modelu z poprzednim, przeanalizujemy wyniki klasyfikacji w podobny sposób jak wcześniejsze, zaczynając od analizy macierzy pomyłek oraz błędów klasyfikacji.

	setosa	versicolor	virginica
setosa	28	0	0
versicolor	0	36	1
virginica	0	1	34

Tabela 5: Macierz pomyłek dla zbioru uczącego (model wielomianowy)


Od razu widzimy lepszą separowalność gatunków dla samego zbioru uczącego niż w przypadku poprzedniego modelu – błąd klasyfikacji wynosi jedynie 2% w porównaniu do wcześniejszych 15%. Sugeruje to, że zależności gatunków między irysami nie są liniowe, ponieważ wprowadzenie dodatkowych cech pozwoliło na lepsze odseparowanie klas.

Ponownie nie występuje zjawisko maskowania klas.

	setosa	versicolor	virginica
setosa	22	0	0
versicolor	0	13	0
virginica	0	3	12

Tabela 6: Macierz pomyłek dla zbioru testowego (model wielomianowy)

Na zbiorze testowym błąd klasyfikacji wynosi 6%. Jest to gorszy wynik niż w zbiorze uczącym. Może to sugerować drobne przeuczenie modelu, lecz może równie dobrze być to błąd statystyczny wynikający z małej liczebności próby. Wynik ten wciąż jest lepszy od wyniku w poprzednim modelu (14%).



Rysunek 3: Wartości wskaźników klas $\hat{Y}$ (estymatorów indyktorów) dla modelu wielomianowego (zbiór uczący). Oś x nie oznacza i ma na celu tylko rozdzielenie gatunków. Od lewej: *setosa*, *versicolor*, *virginica*.

W nowym modelu wykres wskaźników klas wygląda dużo przyjemniej. Dla wszystkich gatunków wartości właściwych wskaźników są prawie wszystkie w okolicy 1, a niewłaściwych w okolicy 0.

Wciąż jest odrobinę lepiej w przypadku *setosa*, niż w przypadku *versicolor* i *virginica*, lecz dwa ostatnie gatunki są o wiele lepiej traktowane niż w poprzednim modelu i tylko czasami są mylone.

Ogółem, model rozszerzony o składniki wielomianowe stopnia 2 radzi sobie lepiej z klasyfikacją niż model bez tych składników, co pozwala nam na lepszą klasyfikację gatunków naszych kwiatów i sprawia że jesteśmy szczęśliwsi.

2 Część 2 - porównanie metod klasyfikacji

2.1 Wstęp

W tej części raportu będziemy pracować na zbiorze danych Wine z R-pakietu `HDclassif`. Zbiór danych zawiera informacje o wynikach analizy chemicznej win uprawianych w tych samych regionach Włoch, lecz będących trzech różnych odmian.

W naszym zbiorze danych, ani na jego stronie nie ma informacji o tym jakie to są odmiany, jednak w *innym wariancie zbioru* są podane ich nazwy: *Barolo*, *Grignolino* oraz *Barbera*.

Naszym zadaniem będzie zastosowanie i porównanie algorytmów klasyfikacji k-najbliższych

sasiadów, drzewa klasyfikacyjnego oraz naiwnego klasyfikatora Bayesowskiego na tym zbiorze danych.

Cechą według której będziemy klasyfikować wina jest zmienna informująca o przynależności do odmiany wina.

2.2 Opis i wstępna analiza danych

Dane zawierają informacje o 178 winach. Dla każdego z nich mamy informacje o 14 cechach:

	Typ	Opis
class	integer	przynależność do klasy wina
V1	numeric	zawartość alkoholu
V2	numeric	kwas jabłkowy
V3	numeric	zawartość popiołu
V4	numeric	alkaliczność popiołu
V5	integer	zawartość magnezu
V6	numeric	łączna zawartość fenoli
V7	numeric	flawonoidy
V8	numeric	fenole nieflawonoidowe
V9	numeric	proantocyjaniny
V10	numeric	intensywność barwy
V11	numeric	odcień koloru
V12	numeric	OD280/OD315 rozcieńczonych win
V13	integer	zawartość proliny

Tabela 7: Typy oraz opisy cech zbioru wine

Cecha `class` będzie nas informować o przynależności do klasy, natomiast do klasyfikacji posłuży nam 13 pozostałych cech dotyczących różnych parametrów wina. Zmienna `class` zawiera informacje o przynależności do jednej z 3 klas, czyli odmian wina.

Porównując nasz zbiór ze wspomnianym wariantem można się dowiedzieć, że klasa zakodowana u nas jako 1 to odmiana *Barolo*, klasa zakodowana jako 2 to *Grignolino*, a klasa zakodowana jako 3 to *Barbera*.

Zmieniamy odpowiednio etykiety w naszym zbiorze:

```
dane2$class <- factor(
  dane2$class,
  labels = c("Barolo", "Grignolino", "Barbera")
)
```

Alternatywny zbiór zawiera także opisowe nazwy zmiennych, jednak zachowujemy nazwy numeryczne aby nie utrudniać pracy na danych.

Zmienne V5 (zawartość magnezu) oraz V13 (zawartość proliny) zostały wczytane jako `integer`. Wynika to z tego, że w danych występują jedynie wartości całkowite, prawdopodobnie z powodu zaokrąglenia. Wartości tych cech jak najbardziej mogłyby być niecałkowite, więc zmieniamy ich typ na `numeric`.

W poniższej tabeli znajdują się statystyki opisowe zmiennych, dzięki którym możliwe będzie wstępne zapoznanie się z danymi oraz identyfikacja podstawowych nieprawidłowości.

class	V1	V2	V3	V4
Barolo :59	Min. :11.03	Min. :0.740	Min. :1.360	Min. :10.60
Grignolino:71	1st Qu.:12.36	1st Qu.:1.603	1st Qu.:2.210	1st Qu.:17.20
Barbera :48	Median :13.05	Median :1.865	Median :2.360	Median :19.50
	Mean :13.00	Mean :2.336	Mean :2.367	Mean :19.49
	3rd Qu.:13.68	3rd Qu.:3.083	3rd Qu.:2.558	3rd Qu.:21.50
	Max. :14.83	Max. :5.800	Max. :3.230	Max. :30.00


V5	V6	V7	V8	V9
Min. : 70.00	Min. :0.980	Min. :0.340	Min. :0.1300	Min. :0.410
1st Qu.: 88.00	1st Qu.:1.742	1st Qu.:1.205	1st Qu.:0.2700	1st Qu.:1.250
Median : 98.00	Median :2.355	Median :2.135	Median :0.3400	Median :1.555
Mean : 99.74	Mean :2.295	Mean :2.029	Mean :0.3619	Mean :1.591
3rd Qu.:107.00	3rd Qu.:2.800	3rd Qu.:2.875	3rd Qu.:0.4375	3rd Qu.:1.950
Max. :162.00	Max. :3.880	Max. :5.080	Max. :0.6600	Max. :3.580

V10	V11	V12	V13
Min. : 1.280	Min. :0.4800	Min. :1.270	Min. : 278.0
1st Qu.: 3.220	1st Qu.:0.7825	1st Qu.:1.938	1st Qu.: 500.5
Median : 4.690	Median :0.9650	Median :2.780	Median : 673.5
Mean : 5.058	Mean :0.9574	Mean :2.612	Mean : 746.9
3rd Qu.: 6.200	3rd Qu.:1.1200	3rd Qu.:3.170	3rd Qu.: 985.0
Max. :13.000	Max. :1.7100	Max. :4.000	Max. :1680.0

Tabela 8: Podsumowanie danych zbioru wine

W danych nie występują wartości NA. Braki zakodowane w inny sposób raczej nie występują – na pewno nie występują braki zapisane jako 0, ponieważ wartości 0 nie występują wcale.

W podsumowaniu możemy zauważyć także znacząco różną zmienność w przypadku zmiennej V13 (zawartość proliny) niż w przypadku pozostałych zmiennych. Może to wskazywać na ewentualną potrzebę standaryzacji przy niektórych metodach.




Rysunek 4: Rozkład licznosci odmian w zbiorze `wine`. Kolory słupków odpowiadają odmianom: *Barolo*, *Grignolino*, *Barbera*.

Na powyższym wykresie widzimy rozkład licznosci odmian. Możemy zauważyć, że najwięcej obserwacji należy do odmiany *Grignolino*, natomiast najmniej do odmiany *Barbera*. Różnice nie są jednak znaczące, licznosci klas są w miarę zbalansowane.

Klasyfikator przypisujący wszystkie obserwacje do najczęściej występującej klasy miałby błąd klasyfikacji na poziomie 60%, czyli częściej by się mylił niż zgadywał dobrze.


Na poniższym wykresie znajdują się rozkłady wariancji dla wszystkich cech ilościowych:



Rysunek 5: Wykresy pudełkowe cech ilościowych przed standaryzacją.

Jak już zauważyliśmy wcześniej, zmienna V13 (zawartość proliny) cechuje się znacznie wyższą zmiennością. W związku z tym konieczne jest zastosowanie standaryzacji aby algorytmy

klasyfikujące działały poprawnie.



Rysunek 6: Wykresy pudełkowe cech ilościowych po standaryzacji.

Widzimy, że po standaryzacji zmienne mają zbliżone wariancje, co pozytywnie wpłynie na działanie algorytmów.

CO TO JEST TO LDAAAAAAAAAAAA

[LDA – sekcja zostaje. DECYZJA WDROŻONA: `lda` liczymy na danych ustandaryzowanych. Powód: standaryzacja nie zmienia ani klasyfikacji (błąd resubstytucji = 0), ani udziałów LD1/LD2 (68.75%/31.25%) – zmienia tylko wielkości współczynników `model$scaling`, czyli ranking cech, czyniąc go interpretowalnym i niezależnym od skali. Ranking na danych std (V7, V13, V12, V1, V10) pokrywa się z niezależnym rankingiem opisowym (η^2 z jednoczynnikowej ANOVA), podczas gdy surowe `lda` wypychało do topu cechy słabo separujące (V3, V8) – artefakt jednostek pomiaru. Podzbiór V7, V13, V12, V1, V10 wdrożony w całej Części 2; wariant „bez standaryzacji” odrzucony.]

W celu wskazania zmiennych o najlepszych zdolnościach dyskryminacyjnych zastosowano model liniowej analizy dyskryminacyjnej (LDA) na danych ustandaryzowanych. Model przekształca pierwotną przestrzeń cech w przestrzeń o niższej wymiarowości ($K - 1$, gdzie K to liczba klas). Ponieważ cechy wcześniej ustandaryzowano, wartości bezwzględne współczynników funkcji dyskryminacyjnych odzwierciedlają realną siłę dyskryminacyjną cech, a nie ich skalę (na surowych danych ranking byłby zaburzony jednostkami pomiaru).

	LD1	LD2
V1	-0.327	0.708
V2	0.185	0.341
V3	-0.101	0.644
V4	0.517	-0.489
V5	-0.031	-0.007
V6	0.387	-0.020
V7	-1.659	-0.491
V8	-0.186	-0.203
V9	0.077	-0.176
V10	0.823	0.587
V11	-0.187	-0.346
V12	-0.822	0.036
V13	-0.847	0.898

Tabela 9: Współczynniki funkcji dyskryminacyjnych LDA (LD1, LD2)

Największy wkład w separację klas mają zmienne V7 (flawonoidy), V13 (zawartość proliny), V12 (OD280/OD315 rozcieńczonych win), V1 (zawartość alkoholu) oraz V10 (intensywność barwy) – to one najlepiej różnicują obserwacje należące do różnych odmian. Pierwsza funkcja dyskryminacyjna (LD1) wyjaśnia 68.75% zmienności między klasami, a druga (LD2) 31.25%, co oznacza, że większość informacji separacyjnej zawarta jest w LD1. Ten zestaw pięciu cech wykorzystamy dalej do porównania metod klasyfikacji na zmniejszonej liczbie zmiennych.

2.3 Ocena dokładności klasyfikacji i porównanie metod

W dalszej części raportu porównamy działanie algorytmów klasyfikujących takich jak naive, tree, i knn na naszym zbiorze wine. Na początku podzielimy zbiór na dwa podzbiory pierwszy treningowy następny uczący. Zbiór uczący będzie zawierał 70% danych. Do podziału została użyta biblioteka caret zachowująca proporcje w danych.

od czajnika trochę madre

[OPIS POJEDYNCZEGO PODZIAŁU (część wymogu 2d): zarys JEST już w akapicie wyżej (70%, `createDataPartition`, `caret`, proporcje klas), ale w błędach i z placeholderem „od czajnika trochę madre” do usunięcia. Pełniejsza, poprawna wersja siedzi PONIŻEJ w komentarzu HTML (`<!-- ... -->`) i NIE renderuje się w PDF. CO ZROBIĆ: scalić to w jeden poprawny akapit (po polsku, bez błędów), a duplikaty – placeholder i komentarze HTML – skasować. Treść: podział 70/30 `createDataPartition` z zachowaniem proporcji klas; standaryzacja cech (k-NN działa na odległościach); dla każdej metody macierz pomyłek + błąd na zbiorze uczącym i testowym, a różnica między nimi mówi o przeuczeniu; k-NN liczymy dla $k = 5$.]

	<i>Barolo</i>	<i>Grignolino</i>	<i>Barbera</i>
<i>Barolo</i>	42	0	0
<i>Grignolino</i>	3	47	0
<i>Barbera</i>	0	0	34

Tabela 10: Macierz pomyłek – k-NN, zbiór uczący

	<i>Barolo</i>	<i>Grignolino</i>	<i>Barbera</i>
<i>Barolo</i>	17	0	0
<i>Grignolino</i>	1	18	2
<i>Barbera</i>	0	0	14

Tabela 11: Macierz pomyłek – k-NN, zbiór testowy

Powyższa tabela zawiera wyniki działania klasyfikatora knn dla 5 sąsiedów dla widzimy że macierz pomyłek dla train i test nie zawiera maskowania danych na przekatnych znajduje się większość informacji oraz błąd klasyfikacji dla train wynosi 2.4% a dla testu 5.8% wartości są relatywnie zbliżone do siebie co świadczy że model nie jest przetrenowany. (tu się zastanawiam czy czegoś częściej nie odczytać z tych wyników)

	<i>Barolo</i>	<i>Grignolino</i>	<i>Barbera</i>
<i>Barolo</i>	42	0	0
<i>Grignolino</i>	0	50	0
<i>Barbera</i>	0	0	34

Tabela 12: Macierz pomyłek – drzewo, zbiór uczący

	<i>Barolo</i>	<i>Grignolino</i>	<i>Barbera</i>
<i>Barolo</i>	17	0	0
<i>Grignolino</i>	0	21	0
<i>Barbera</i>	0	0	14

Tabela 13: Macierz pomyłek – drzewo, zbiór testowy

Otrzymane wyniki świadczą o bezbłędnej klasyfikacji zarówno na zbiorze uczącym jak i testowym, co świadczy o bardzo dobrych właściwościach klasyfikacyjnych algorytmu drzew decyzyjnych. Z uwagi na fakt podział danych na zbiór uczący i testowy zostały wykonane porównanie a wynik 100% występuje również na danych testowych, możemy wykluczyć przetrenowanie modelu. - tego nie jestem pewna

	<i>Barolo</i>	<i>Grignolino</i>	<i>Barbera</i>
<i>Barolo</i>	42	0	0
<i>Grignolino</i>	0	50	0
<i>Barbera</i>	0	0	34

Tabela 14: Macierz pomyłek – naive Bayes, zbiór uczący

	<i>Barolo</i>	<i>Grignolino</i>	<i>Barbera</i>
<i>Barolo</i>	16	1	0
<i>Grignolino</i>	0	21	0
<i>Barbera</i>	0	0	14

Tabela 15: Macierz pomyłek – naive Bayes, zbiór testowy

Wyniki kalsyfikacji dla modelu naive bayes dla zbioru uczącego wykazują 100% dokładności model bezlednie dopasował dane, natomiast wynik błędu dla zbioru testowego wynosi 1.92% co świadczy o bardzo dobrym działaniu modelu i braku przetrenowania go. Również nie występuje zjawisko maskowania klas na przekątnej macierzy znajduje się zdecydowanie większość danych.

Następnie w celu porównania działań algorytmów przeprowadzimy kalsyfikację lecz zastosujemy bardziej zaawansowany schemat oceny dokładności. Użyliśmy metody cross validation.

k	Accuracy
5	0.976
7	0.944
9	0.976
11	0.967
13	0.967

Tabela 16: Wyniki 10-krotnej walidacji krzyżowej – k-NN (wg parametru k)

tu tabelę na innym podzbiórze do porównania

k	Accuracy
5	0.968
7	0.985
9	0.976
11	0.968
13	0.976

Tabela 17: Wyniki CV – k-NN na podzbiorze cech V7 (flawonoidy), V13 (zawartość proliny), V12 (OD280/OD315 rozcieńczonych win), V1 (zawartość alkoholu), V10 (intensywność barwy)

Wyniki uzyskane metodą cross-validation odnoszą się do zbioru treningowego, który został wielokrotnie dzielony na części uczące i walidacyjne. W związku z tym stanowią one bardziej stabilną ocenę modelu niż pojedynczy wynik na zbiorze treningowym, ale nadal nie są to wyniki na niezależnym zbiorze testowym.

W przypadku pojedynczego podziału k-NN dla $k = 5$ uzyskano dokładność klasyfikacji na zbiorze testowym na poziomie 94.2%. Wynik ten może być jednak obciążony dużą zmiennością, ponieważ zależy od konkretnego losowego podziału danych.

Zastosowanie 10-krotnej walidacji krzyżowej dało zbliżoną, równie wysoką ocenę skuteczności – najlepszy wynik uzyskano dla $k = 5$, ze średnią dokładnością na poziomie 97.6%.

Zbieżność obu ocen świadczy o tym, że wysoka skuteczność k-NN nie jest artefaktem jednego korzystnego podziału. Walidacja krzyżowa pozostaje przy tym oceną bardziej wiarygodną, ponieważ uśrednia wynik po wielu podziałach danych.

Najlepszą dokładność osiągnięto dla niewielkiej liczby sąsiadów ($k = 5$); dokładność nie rośnie monotonicznie wraz z k – zbyt duże k nadmiernie wygładza granice decyzyjne i pogarsza klasyfikację.

Następnie w tabeli przedstawiono wyniki k-NN dla różnych wartości parametru k na podzbiorze pięciu cech wybranych przez LDA – V7 (flawonoidy), V13 (zawartość proliny), V12 (OD280/OD315 rozcieńczonych win), V1 (zawartość alkoholu) oraz V10 (intensywność barwy). Najwyższą dokładność uzyskano dla $k = 7$, a jej poziom (98.5%) jest zbliżony do wyniku na pełnym zestawie cech (97.6%). Oznacza to, że te pięć cech niesie niemal całą informację różnicującą klasy, więc redukcja wymiaru praktycznie nie pogarsza jakości klasyfikacji.

cp	Accuracy
0.079	0.914
0.447	0.830
0.461	0.501

Tabela 18: Wyniki 10-krotnej walidacji krzyżowej – drzewo (wg parametru cp)

cp	Accuracy
0.079	0.929
0.447	0.815
0.461	0.476

Tabela 19: Wyniki CV – drzewo na podzbiorze cech V7 (flawonoidy), V13 (zawartość proliny), V12 (OD280/OD315 rozcieńczonych win), V1 (zawartość alkoholu), V10 (intensywność barwy)

W pojedynczym podziale accuracy wyniosło 100% dla test set. Wynik ten wskazuje na bardzo wysoką skuteczność modelu drzewa decyzyjnego, jednak należy interpretować go ostrożnie, ponieważ może on wynikać z korzystnego podziału danych, niewielkiej liczby obserwacji w zbiorze testowym lub łatwej separowalności klas.

W celu oceny skuteczności drzewa decyzyjnego zastosowano metodę 10-krotnej walidacji krzyżowej (10-fold cross-validation). Model CART testował różne wartości parametru `cp` (complexity parameter), który kontroluje stopień przycinania drzewa i jego złożoność.

Najlepszy wynik uzyskano dla `cp = 0.0789`, dla którego model osiągnął dokładność klasyfikacji na poziomie około 91.4% oraz współczynnik Kappa równy 0.871. Oznacza to bardzo dobrą zgodność klasyfikacji oraz wysoką zdolność modelu do poprawnego rozróżniania klas.

Wraz ze wzrostem wartości parametru `cp` obserwowano spadek skuteczności modelu, co wskazuje, że zbyt silne przycinanie drzewa prowadzi do utraty informacji i pogorszenia jakości klasyfikacji.

Use kernel	Accuracy
FALSE	0.969
TRUE	0.961

Tabela 20: Wyniki 10-krotnej walidacji krzyżowej – Naive Bayes

Use kernel	Accuracy
FALSE	0.954
TRUE	0.962

Tabela 21: Wyniki CV – Naive Bayes na podzbiorze cech V7 (flawonoidy), V13 (zawartość proliny), V12 (OD280/OD315 rozcieńczonych win), V1 (zawartość alkoholu), V10 (intensywność barwy)

[CO TU NAPISAĆ: wynik naive Bayes w CV — który wariant lepszy (z czy bez estymacji jądrowej, `usekernel`), jaka dokładność i Kappa (są już inline R — zostawić), oraz interpretacja: wysoka skuteczność oznacza, że przy założeniu niezależności cech klasy są dobrze separowalne. Dobrze też porównać z wynikiem naive Bayes na pojedynczym podziale.]

W celu oceny skuteczności klasyfikatora Naive Bayes zastosowano 10-krotną walidację krzyżową. Model testował dwa warianty: z estymacją jądrową (`usekernel = TRUE`) oraz bez niej (`usekernel = FALSE`).

Najlepszy wynik uzyskano dla modelu bez estymacji jądrowej, który osiągnął dokładność klasyfikacji na poziomie około 96.9% oraz współczynnik Kappa równy 0.952. Oznacza to bardzo wysoką skuteczność klasyfikatora oraz bardzo dobrą zgodność przewidywań z rzeczywistymi klasami.

Wyniki wskazują, że klasy w analizowanym zbiorze danych są dobrze separowalne przy założeniu niezależności zmiennych, co sprzyja wysokiej skuteczności modelu Naive Bayes.

2.4 Różne parametry i podzbiory cech

one przeniesione wyżej lepiej porównywać

[DO NAPISANIA – komentarz do tabel na podzbiorze cech: porównać dokładność modeli na pełnym zestawie cech vs na podzbiorze V7, V13, V12, V1, V10 dla każdej z metod (k-NN, drzewo, naive Bayes); napisać, czy ograniczenie cech pomogło, zaszkodziło, czy nie zmieniło wyników. (Sprawdzone w CV dla NOWEGO podzbioru 5 najlepszych cech wg LDA: ograniczenie cech prawie nie zmienia wyników – k-NN ok. 97% → ok. 98%, naive Bayes ok. 98% → ok. 97%, drzewo ok. 88% → ok. 89%. Wniosek: te 5 cech niesie niemal całą informację różnicującą, więc redukcja wymiaru praktycznie nic nie kosztuje – inaczej niż przy starym podzbiorze, który wyraźnie psuł k-NN i NB.)]

2.5 Podsumowanie

[DO NAPISANIA – końcowe wnioski (Zadanie 2f), wymagane w treści listy. Odpowiedzieć na trzy pytania: (1) dla jakiego podzbioru cech i jakich parametrów (np. `k` w k-NN, `cp` w drzewie, `usekernel` w naive Bayes) wyniki są najlepsze; (2) która metoda klasyfikacji wypada najlepiej, a która najgorzej na zbiorze wine; (3) czy wybór schematu oceny (pojedynczy podział vs walidacja krzyżowa) wpłynął na wnioski o skuteczności metod. Można podeprzeć się tabelami wyżej. (Sprawdzone w R, CV pełny zestaw cech: naive Bayes ok. 97.6% (najlepszy), k-NN ok. 96.9%, drzewo ok. 88.1% (najsłabsze); najlepsze parametry: k-NN `k=5`, drzewo `cp` ok. 0.079, naive Bayes `usekernel=FALSE`; po standaryzacji LDA podzbiór 5 najlepszych cech (V7, V13, V12, V1, V10) daje wyniki zbliżone do pełnego zestawu dla wszystkich metod (k-NN i NB praktycznie bez straty, drzewo bez zmian); po dodaniu standaryzacji do CV oba schematy dają spójny ranking – wybór schematu NIE zmienia wniosków, jedynie pojedynczy podział był zbyt optymistyczny dla drzewa (100% vs 88% w CV).)]