

Sprawozdanie 3

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-06-03


Spis treści

1	Część 1 – klasyfikacja	2
1.1	Wstęp	2
1.2	Przypomnienie struktury danych	2
1.3	Podział danych na zbiór uczący i testowy	3
1.4	Konstrukcja klasyfikatora i wyznaczanie prognoz	3
1.5	Ocena klasyfikacji	4
1.6	Model liniowy dla rozszerzonej przestrzeni klas	6
2	Część 2 - porównanie metod klasyfikacji	7
2.1	Wstęp	7
2.2	Opis i wstępna analiza danych	8
2.3	Ocena dokładności klasyfikacji i porównanie metod	13
2.4	Różne parametry i podzbiory cech	18
2.5	Podsumowanie	18

1 Część 1 – klasyfikacja

1.1 Wstęp

Pracujemy na tym samym zbiorze danych danych co w poprzednim sprawozdaniu. Zbiór zawiera wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*). W przeciągu ostatniego miesiąca wygląd kwiatów się nie zmienił i nadal wyglądają one tak:



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

1.2 Przypomnienie struktury danych

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatka (w cm)
Petal.Width	numeric	szerokość płatka (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)

Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

1.3 Podział danych na zbiór uczący i testowy

W celu oceny jakości działania klasyfikatora dzielimy zbiór danych na zbiór uczący `train_set` i zbiór testowy `test_set` w proporcjach 1 do 2:

```
set.seed(67) # ustawiamy seed losowania

n <- nrow(dane) # liczba obserwacji

# losujemy które obserwacje będą w zbiorze uczącym a które w testowym
train_index <- sample(1:n, size = round(2/3 * n))

# tworzymy osobne ramki danych dla obu zbiorów
train_set <- dane[train_index, ]
test_set <- dane[-train_index, ]
```

Zbiór uczący zawiera 100 obserwacji, a zbiór testowy 50.

1.4 Konstrukcja klasyfikatora i wyznaczanie prognoz

Będziemy konstruować klasyfikator oparty na regresji liniowej. W tym celu na podstawie zbioru uczącego (`train_set`) będziemy estymować parametry modelu.

Aby to zrobić, musimy najpierw zakodować klasy przy użyciu zmiennych binarnych (indykatory klas):

```
etykietki.klas <- train_set$Species

K <- length(unique(etykietki.klas)) # liczba klas (gatunków)
n.train <- nrow(train_set)           # liczba obserwacji uczących

# tworzymy macierz wskaźników klas i przypisujemy jej odpowiednie wartości
Y.train <- matrix(0, nrow = n.train, ncol = K)
etykietki.num <- as.numeric(etykietki.klas)
```

```
for(k in 1:K)
  Y.train[etykietki.num == k, k] <- 1
```

Następnie estymujemy parametry modelu za pomocą zbioru uczącego:

```
# macierz cech z dodatkową kolumną jedynek (wyraz wolny)
X.train <- as.matrix(cbind(1, train_set[,1:4]))

# estymacja współczynników metodą najmniejszych kwadratów:  $B=(X'X)^{-1} X'Y$ 
B.hat <- solve(t(X.train) %*% X.train) %*%
          t(X.train) %*% Y.train
```

Dla każdej obserwacji – zarówno ze zbioru uczącego i testowego – liczymy estymowane indykatory klas:

```
# dopasowane wskaźniki klas dla zbioru uczącego
Y.hat.train <- X.train %*% B.hat
pred.train <- apply(Y.hat.train, 1, which.max) # klasa = kolumna z największą wartością

# to samo dla zbioru testowego (kolumna jedynek jak w zbiorze uczącym)
X.test <- cbind(1, test_set[,1:4])
X.test <- as.matrix(X.test)

Y.hat.test <- X.test %*% B.hat
pred.test <- apply(Y.hat.test, 1, which.max)
```

1.5 Ocena klasyfikacji

W celu oceny klasyfikacji wyliczamy macierz pomyłek (ang. *confusion matrix*) oraz błąd klasyfikacji na zbiorze uczącym oraz testowym.

	<i>setosa</i>	<i>versicolor</i>	<i>virginica</i>
<i>setosa</i>	28	0	0
<i>versicolor</i>	0	28	9
<i>virginica</i>	0	6	29

Tabela 3: Macierz pomyłek dla zbioru uczącego (model liniowy). Wiersz oznacza faktyczny gatunek, a kolumna estymowany.


Na powyższej tabeli widzimy wyniki dopasowania gatunków do kwiatów. Błąd klasyfikacji (proporcja źle sklasyfikowanych obserwacji do wszystkich obserwacji) wynosi 15%. Taka wysoka wartość wynika z mylenia przez model gatunków *versicolor* oraz *virginica* – jak na to że jest to zbiór uczący, sugeruje to że ciężko jest te gatunki rozdzielić.

Zjawisko maskowania klas nie występuje – gdyby występowało, któraś z klas byłaby przewidywana znacząco rzadziej niż występuje. W naszym przypadku tak nie jest. Pomaga nam to, że liczba $p = 4$ zmiennych objaśniających jest większa od liczby $K = 3$ klas, dzięki czemu „wymiarowość” gra trochę na naszą korzyść.

	<i>setosa</i>	<i>versicolor</i>	<i>virginica</i>
<i>setosa</i>	22	0	0
<i>versicolor</i>	0	11	2
<i>virginica</i>	0	5	10

Tabela 4: Macierz pomyłek dla zbioru testowego (model liniowy). Wiersz oznacza faktyczny gatunek, a kolumna estymowany.

Dla zbioru testowego błąd klasyfikacji wynosi 14%; zbliżona wartość błędów dla zbioru uczącego i testowego świadczy, że model nie jest przetrenowany i dobrze klasyfikuje dane.



Rysunek 2: Wartości wskaźników klas $\hat{Y}$ (estymatorów indykatorów) dla modelu liniowego (zbiór uczący). Oś x nic nie oznacza i ma na celu tylko rozdzielenie gatunków. Od lewej: *setosa*, *versicolor*, *virginica*.

Na wykresie widać, że najlepszą separowalność uzyskano dla kwiatów z gatunku *setosa*, o czym świadczą wysokie wartości wskaźników dla ich własnej klasy i niskie dla pozostałych.

W przypadku *versicolor* i *virginica*, wartości wskaźników właściwych klas są niższe niż w przypadku *setosa*, niewiele większe od wartości wskaźników o drugich najwyższych wartościach – wskaźników *virginica* w przypadku *versicolor* oraz vice versa. Powoduje to trudność w

rozdzieleniu przez model kwiatów tych dwóch gatunków, co zostało zauważone już przy macierzy pomyłek.

1.6 Model liniowy dla rozszerzonej przestrzeni klas

Teraz przeprowadzimy klasyfikację gatunków irysów na rozszerzonej przestrzeni cech. W tym celu zbudujemy nowy model liniowy dla tych cech. Nasza nowa przestrzeń cech zawiera oryginalne zmienne PL, PW, SL i SW oraz składniki wielomianowe stopnia 2: $PL^2, PW^2, SL^2, SW^2, PL \cdot PW, PL \cdot SL, PL \cdot SW, PW \cdot SL, PW \cdot SW$ oraz $SL \cdot SW$.

Model konstruujemy analogicznie jak poprzednio z uprzednim dodaniem nowych cech.

W celu porównania dokładności klasyfikacji modelu z poprzednim, przeanalizujemy wyniki klasyfikacji w podobny sposób jak wcześniejsze, zaczynając od analizy macierzy pomyłek oraz błędów klasyfikacji.

	setosa	versicolor	virginica
setosa	28	0	0
versicolor	0	36	1
virginica	0	1	34

Tabela 5: Macierz pomyłek dla zbioru uczącego (model wielomianowy)


Od razu widzimy lepszą separowalność gatunków dla samego zbioru uczącego niż w przypadku poprzedniego modelu – błąd klasyfikacji wynosi jedynie 2% w porównaniu do wcześniejszych 15%. Sugeruje to, że zależności gatunków między irysami nie są liniowe, ponieważ wprowadzenie dodatkowych cech pozwoliło na lepsze odseparowanie klas.

Ponownie nie występuje zjawisko maskowania klas.

	setosa	versicolor	virginica
setosa	22	0	0
versicolor	0	13	0
virginica	0	3	12

Tabela 6: Macierz pomyłek dla zbioru testowego (model wielomianowy)

Na zbiorze testowym błąd klasyfikacji wynosi 6%. Jest to gorszy wynik niż w zbiorze uczącym. Może to sugerować drobne przeuczenie modelu, lecz może równie dobrze być to błąd statystyczny wynikający z małej liczebności próby. Wynik ten wciąż jest lepszy od wyniku w poprzednim modelu (14%).



Rysunek 3: Wartości wskaźników klas $\hat{Y}$ (estymatorów indyktorów) dla modelu wielomianowego (zbiór uczący). Oś x nie oznacza i ma na celu tylko rozdzielenie gatunków. Od lewej: *setosa*, *versicolor*, *virginica*.

W nowym modelu wykres wskaźników klas wygląda dużo przyjemniej. Dla wszystkich gatunków wartości właściwych wskaźników są prawie wszystkie w okolicy 1, a niewłaściwych w okolicy 0.

Wciąż jest odrobinę lepiej w przypadku *setosa*, niż w przypadku *versicolor* i *virginica*, lecz dwa ostatnie gatunki są o wiele lepiej traktowane niż w poprzednim modelu i tylko czasami są mylone.

Ogółem, model rozszerzony o składniki wielomianowe stopnia 2 radzi sobie lepiej z klasyfikacją niż model bez tych składników, co pozwala nam na lepszą klasyfikację gatunków naszych kwiatów. Sprawia to że jesteśmy szczęśliwi.

2 Część 2 - porównanie metod klasyfikacji

2.1 Wstęp

W tej części raportu będziemy pracować na zbiorze danych *Wine* z R-pakietu *HDcalssif*. Zbiór danych zawiera informacje o wynikach analizy chemicznej win uprawianych w tych samych regionach Włoch, lecz będących trzech różnych odmian.

Naszym zadaniem będzie zastosowanie i porównanie algorytmów klasyfikacji k-najbliższych sąsiadów, drzewa klasyfikacyjnego oraz naiwnego klasyfikatora Bayesowskiego na tym zbiorze danych.

Cechą według której będziemy klasyfikować wina jest zmienna informująca o przynależności do odmiany wina.

2.2 Opis i wstępna analiza danych

Dane zawierają informacje o 178 winach. Dla każdego z nich mamy informacje o 14 cechach.

Cecha `class` będzie nas informować o przynależności do klasy, natomiast do klasyfikacji posłuży nam 13 pozostałych cech. Zmienna `class` zawiera informacje o przynależności do jednej z 3 klas, czyli odmian wina.

— dotąd zrobiłem, ide spać. to co jest dalej wygląda przerażająco. CZEMU SEKCJA Z OPISEM DANYCH MA 5 STRON???? AAAAAAAGHFASGHDGHKJASHJKAHAAAAA.

	Typ	Opis
class	integer	przynależność do klasy wina
V1	numeric	zawartość alkoholu
V2	numeric	kwas jabłkowy
V3	numeric	zawartość popiołu
V4	numeric	alkaliczność popiołu
V5	integer	zawartość magnezu
V6	numeric	łączna zawartość fenoli
V7	numeric	flawonoidy
V8	numeric	fenole nieflawonoidowe
V9	numeric	proantocyjaniny
V10	numeric	intensywność barwy
V11	numeric	odcień koloru
V12	numeric	OD280/OD315 rozcieńczonych win
V13	integer	zawartość proliny

Tabela 7: Typy oraz opisy cech zbioru wine

Na podstawie powyższej tabeli można stwierdzić że wszystkie typy zmiennych zostały prawidłowo zakodowane, poza zmienną `class`. Dla której zmieniliśmy typ na `factor`.

W poniższej tabli znajdują się statystyki opisowe zmiennych, dzięki czemu możliwe jest wstępne zapoznanie się z danymi oraz identyfikacja podstawowych nieprawidłowości.


class	V1	V2	V3	V4
1:59	Min. :11.03	Min. :0.740	Min. :1.360	Min. :10.60
2:71	1st Qu.:12.36	1st Qu.:1.603	1st Qu.:2.210	1st Qu.:17.20
3:48	Median :13.05	Median :1.865	Median :2.360	Median :19.50
	Mean :13.00	Mean :2.336	Mean :2.367	Mean :19.49
	3rd Qu.:13.68	3rd Qu.:3.083	3rd Qu.:2.558	3rd Qu.:21.50
	Max. :14.83	Max. :5.800	Max. :3.230	Max. :30.00

V5	V6	V7	V8	V9
Min. : 70.00	Min. :0.980	Min. :0.340	Min. :0.1300	Min. :0.410
1st Qu.: 88.00	1st Qu.:1.742	1st Qu.:1.205	1st Qu.:0.2700	1st Qu.:1.250
Median : 98.00	Median :2.355	Median :2.135	Median :0.3400	Median :1.555
Mean : 99.74	Mean :2.295	Mean :2.029	Mean :0.3619	Mean :1.591
3rd Qu.:107.00	3rd Qu.:2.800	3rd Qu.:2.875	3rd Qu.:0.4375	3rd Qu.:1.950
Max. :162.00	Max. :3.880	Max. :5.080	Max. :0.6600	Max. :3.580

V10	V11	V12	V13
Min. : 1.280	Min. :0.4800	Min. :1.270	Min. : 278.0
1st Qu.: 3.220	1st Qu.:0.7825	1st Qu.:1.938	1st Qu.: 500.5
Median : 4.690	Median :0.9650	Median :2.780	Median : 673.5
Mean : 5.058	Mean :0.9574	Mean :2.612	Mean : 746.9
3rd Qu.: 6.200	3rd Qu.:1.1200	3rd Qu.:3.170	3rd Qu.: 985.0
Max. :13.000	Max. :1.7100	Max. :4.000	Max. :1680.0

Tabela 8: Podsumowanie danych zbioru wine

W danych nie występują wartości NA. Na podstawie powyższej tabeli można również stwierdzić brak występowania wartości 0, ponieważ minimalna wartość dla każdej cechy jest różna od 0. Jedynie zmienna v13 cechuje się dużą zmiennością w porównaniu do pozostałych zmiennych.



Na powyższym wykresie widzimy rozkład przynależności poszczególnych obserwacji do danej klasy. Możemy zauważyć, że najwięcej obserwacji należy do klasy 2, natomiast najmniej do klasy 3.

[CO TU NAPISAĆ: (1) ocena rozkładu klas – czy są istotne dysproporcje liczebności (najwięcej obs. w klasie 2, najmniej w 3) i czy mają znaczenie; (2) baseline – jaki błąd dałby klasyfikator przypisujący wszystko do najliczniejszej klasy i interpretacja tej wartości jako punktu odniesienia dla właściwych modeli. Wartości % wstawić inline R z policzonego błędu. (Sprawdzone: liczebności 59/71/48; baseline jest już policzony inline niżej = ok. 60% błędu / 40% trafień, a akapity ciemnoczerwone niżej w większości to pokrywają – wystarczy je scalić i poprawić, nie pisać od zera.)]

Oznacza to, że występują pewne dysproporcje w liczebności klas, jednak nie są one skrajne.


Jeśli wszystkie obserwacje zostałyby przypisane do najczęściej występującej klasy (klasa 2), to błąd klasyfikacji wyniósłby:

$$\text{błąd} = 1 - \frac{n_{\max}}{n},$$


gdzie: $n_{\max}$ to liczba obserwacji na najliczniejszej klasie, a n to liczba wszystkich obserwacji.

Błąd wynosi 0.6011236.

Oznacza to, że około 60% obserwacji zostałoby błędnie sklasyfikowanych, a taki klasyfikator osiągnąłby jedynie około 40% skuteczności.



Na powyższym wykresie znajdują się rozkłady wariancji dla wszystkich cech poza zmienną class. Możemy zauważyć, że ostatnia zmienna cechuje się najwyższą zmiennością i konieczne jest zastosowanie standaryzacji aby algorytmy klasyfikujące działały poprawnie.



widzimy że po standaryzacji zmienne mają zbliżone wariancje, co pozytywnie wpłynie na działanie algorytmów.

	LD1	LD2
V1	-0.403	0.872
V2	0.165	0.305
V3	-0.369	2.346
V4	0.155	-0.146
V5	-0.002	0.000
V6	0.618	-0.032
V7	-1.661	-0.492
V8	-1.496	-1.631
V9	0.134	-0.307
V10	0.355	0.253
V11	-0.818	-1.516
V12	-1.158	0.051
V13	-0.003	0.003

Tabela 9: Współczynniki funkcji dyskryminacyjnych LDA (LD1, LD2)

[CO TU NAPISAĆ (jeden zwięzły akapit – poniższe wersje robocze AI do skasowania): które zmienne najlepiej różnicują klasy (wg wartości bezwzględnych współczynników LD1/LD2) oraz ile zmienności międzyklasowej wyjaśniają LD1 i LD2 – proporcje policzyć inline R z `model$svd^2 / sum(model$svd^2)` (wychodzi 68.75/31.25, ale niech liczy się samo, nie na sztywno). UWAGA – sprawdzone w R: kod liczy `lda` na SUROWYCH danych i to z nich wychodzi zestaw V3, V7, V8, V11, V12 (ten sam, którego używamy dalej jako podzbioru cech `train_small`). Na surowych współczynnikach interpretacja „siły dyskryminacyjnej” jest myląca, bo zależy od skali/jednostek cech; po standaryzacji top zestaw jest INNY: V7, V13, V10, V12, V3. Stąd dawne sformułowanie „na danych ustandaryzowanych” było błędne. DECYZJA OTWARTA – DO SKONSULTOWANIA, na razie NIEROZSTRZYGNIEŃTA: albo (a) zostawić surowe `lda`, skreślić „na danych ustandaryzowanych” i dopisać zastrzeżenie o skali, albo (b) ustandaryzować przed `lda` – ale wtedy trzeba zmienić podzbiór cech na nowy top zestaw (V7, V13, V10, V12, V3) w całej Części 2. Do czasu rozstrzygnięcia NIE ruszamy tego akapitu ani podzbioru cech. Z trzech wersji niżej zostawić docelowo jedną, własnymi słowami.]

W celu znalezienia zmiennych, które charakteryzują się najlepszymi zdolnościami dyskryminacyjnymi, zastosowano model Liniowej Analizy Dyskryminacyjnej (LDA). Model ten dokonuje transformacji pierwotnej przestrzeni cech w nową przestrzeń o niższej wymiarowości ($K - 1$, gdzie K to liczba klas). największe wartości bezwzględne współczynników w funkcjach dyskryminacyjnych LDA.

W szczególności zmienne V3, V7, V8, V11 oraz V12 wykazują największy wkład w separację klas, co oznacza, że najlepiej różnicują obserwacje należące do różnych grup.

Pierwsza funkcja dyskryminacyjna (LD1) wyjaśnia 68.75% zmienności między klasami, natomiast druga (LD2) 31.25%, co oznacza, że większość informacji separacyjnej zawarta jest w

LD1.

geminik Analiza wag pokazała, że największe wartości bezwzględne współczynników w funkcjach dyskryminacyjnych LDA wykazują zmienne V3, V7, V8, V11 oraz V12. To one charakteryzują się największym wkładem w separację i najlepiej różnicują obserwacje. Ponieważ analiza została przeprowadzona na danych ustandaryzowanych, wielkości te bezpośrednio odzwierciedlają realną siłę dyskryminacyjną cech, a ich przeciwne znaki odpowiadają za rozsuwanie klas w przeciwległe krańce przestrzeni.

Pierwsza funkcja dyskryminacyjna (LD1) wyjaśnia 68.75% zmienności między klasami, natomiast druga (LD2) 31.25%

czat: Analiza LDA została wykorzystana do oceny zdolności dyskryminacyjnych zmiennych. Największy wpływ na separację klas mają zmienne V7, V8, V11, V12 oraz V3, ponieważ osiągnęły najwyższe wartości bezwzględne współczynników funkcji dyskryminacyjnych.

Pierwsza funkcja dyskryminacyjna (LD1) odpowiada za 68.75% całkowitej separacji klas, natomiast druga funkcja (LD2) za 31.25%. Oznacza to, że większość informacji potrzebnej do rozróżniania klas zawiera się w LD1.

Dodatkowo analiza średnich grupowych wskazuje, że wybrane zmienne przyjmują wyraźnie różne wartości w poszczególnych klasach, co potwierdza ich wysoką zdolność predykcyjną.

2.3 Ocena dokładności klasyfikacji i porównanie metod

W dalszej części raportu porównamy działanie algorytmów klasyfikujących takich jak naive, tree, i knn na naszym zbiorze wine. Na początku podzielimy zbiór na dwa podzbiory pierwszy treningowy następny uczący. Zbiór uczący będzie zawierał 70% danych. Do podziału została użyta biblioteka caret zachowująca proporcje w danych.

od czacika troche madre

[OPIS POJEDYNCZEGO PODZIAŁU (część wymogu 2d): zarys JEST już w akapicie wyżej (70%, `createDataPartition`, `caret`, proporcje klas), ale w błędach i z placeholderem „od czacika troche madre” do usunięcia. Pełniejsza, poprawna wersja siedzi PONIŻEJ w komentarzu HTML (`<!-- ... -->`) i NIE renderuje się w PDF. CO ZROBIĆ: scalić to w jeden poprawny akapit (po polsku, bez błędów), a duplikaty – placeholder i komentarze HTML – skasować. Treść: podział 70/30 `createDataPartition` z zachowaniem proporcji klas; standaryzacja cech (k-NN działa na odległościach); dla każdej metody macierz pomyłek + błąd na zbiorze uczącym i testowym, a różnica między nimi mówi o przeuczeniu; k-NN liczymy dla $k = 5$.]

1	2	3
42	0	0
3	47	0
0	0	34

Tabela 10: Macierz pomyłek – k-NN, zbiór uczący

1	2	3
17	0	0
1	18	2
0	0	14

Tabela 11: Macierz pomyłek – k-NN, zbiór testowy

Powyzsza tabela zawiera wyniki dziala klasyfikatora knn dla 5 sa saidów dla widzimy ze macierz pomyłek dla train i test nie zawiera maskowania dancyh na przekatnych znajduje sie wiekszosc informacji oraz blad klasyfikacji dla train wynosi 2.3 %b a dla tets 5.7 % wartosci sa relatywnie zblizone do siebie co swiadczy ze mdoel nie jest przetrenowany. (tu sie zastanawiam czy czegos cjeszce nie odaodac z tych wyników)

1	2	3
42	0	0
0	50	0
0	0	34

Tabela 12: Macierz pomyłek – drzewo, zbiór uczący

1	2	3
17	0	0
0	21	0
0	0	14

Tabela 13: Macierz pomyłek – drzewo, zbiór testowy

Otrzymane wyniki swiadcza o bezblednej klasyfikacji zarowno na zbiorze uczacym jak i testowym, co swiadczy od bardzi=o dobrych wlasnoscich kalsyfikacyjnych algorytmu drzew decyzyjnych. Z uwagi na fakt podzial dancyh na zbior uczaci i testowy zostaly wykonany porawnie a wynik 100% wystepuje ronwiesz na danych testowych, mozmy wykluczyc przetre-nowanie modelu. - tego nie jestem pewna

1	2	3
42	0	0
0	50	0
0	0	34

Tabela 14: Macierz pomyłek – naive Bayes, zbiór uczący

1	2	3
16	1	0
0	21	0
0	0	14

Tabela 15: Macierz pomyłek – naive Bayes, zbiór testowy

Wyniki kasyfikacji dla modelu naive bayes dla zbioru uczącego wykazują 100% dokładności model bezblednie dopasował dane, natomiast wynik błędu dla zbioru testowego wynosi 1.92 co świadczy o bardzo dobrym działaniu modelu i braku przetrenowania go. Również nie występuje zjawisko maskowania klas na przekątnej macierzy znajduje się zdecydowanie większość danych.

Następnie w celu porównania działań algorytmów przeprowadzimy klasyfikacje lecz zastosujemy bardziej zaawansowany schemat oceny dokładności. Użyliśmy metody cross validation.

k	Accuracy	Kappa	AccuracySD	KappaSD
5	0.969	0.953	0.041	0.061
7	0.960	0.940	0.057	0.086
9	0.952	0.928	0.057	0.086
11	0.944	0.916	0.066	0.099
13	0.960	0.940	0.057	0.086

Tabela 16: Wyniki 10-krotnej walidacji krzyżowej – k-NN (wg parametru k)

tu tabelę na innym podzbiórze do porównania

k	Accuracy	Kappa	AccuracySD	KappaSD
5	0.856	0.782	0.074	0.112
7	0.857	0.784	0.089	0.134
9	0.856	0.783	0.093	0.140
11	0.840	0.759	0.077	0.116
13	0.848	0.771	0.081	0.124

Tabela 17: Wyniki CV – k-NN na podzbiórce cech V3, V7, V8, V11, V12

[DO PRZEPISANIA: do CV k-NN dodano standaryzację (**preProcess**), bo wcześniej jej brakowało, a przy pojedynczym podziale była. Teraz CV k-NN daje najlepszy wynik (k=5) ok. 96.9%, czyli zbliżony do pojedynczego podziału (ok. 94.2%), a NIE 74%. Dlatego poniższa interpretacja jest nieaktualna i wymaga zmiany: (1) spadek do 74% NIE wynikał z optywizmu pojedynczego podziału, tylko z braku standaryzacji w CV; teraz oba schematy są spójne;

(2) dokładność najlepszego k to ok. 96.9%, a nie 74%; (3) zdanie, że dokładność „generalnie rośnie wraz z k ”, jest błędne — po standaryzacji najlepsze jest $k=5$.]

Wyniki uzyskane metodą cross-validation odnoszą się do zbioru treningowego, który został wielokrotnie dzielony na części uczące i walidacyjne. W związku z tym stanowią one bardziej stabilną ocenę modelu niż pojedynczy wynik na zbiorze treningowym, ale nadal nie są to wyniki na niezależnym zbiorze testowym.

W przypadku pojedynczego podziału uzyskano bardzo wysoką dokładność klasyfikacji na poziomie około 94% dla $k = 5$. Wynik ten może być jednak obarczony dużą zmiennością, ponieważ zależy od konkretnego losowego podziału danych.

Natomiast zastosowanie 10-krotnej walidacji krzyżowej dało bardziej stabilną ocenę skuteczności modelu, gdzie dla $k = 5$ uzyskano średnią dokładność na poziomie około 74%.

Różnica pomiędzy wynikami wskazuje, że pojedynczy podział może prowadzić do zawyżenia oceny jakości klasyfikatora, natomiast walidacja krzyżowa dostarcza bardziej wiarygodnej i uogólnionej oceny.

Zaobserwowano również, że wraz ze wzrostem wartości parametru k dokładność klasyfikacji generalnie rośnie, co sugeruje, że większa liczba sąsiadów stabilizuje decyzje klasyfikatora i zmniejsza wpływ szumu w danych.

Następnie w tabeli przedstawiono wyniki klasyfikatora k -NN dla różnych wartości parametru k na zmniejszonym zbiorze cech. Najwyższą wartość accuracy uzyskano dla $k = 9$. Zaobserwowano również, że wartości accuracy na podzbiorze cech są niższe niż w przypadku pełnego zestawu danych. Wskazuje to, że redukcja liczby cech ogranicza ilość informacji dostępnej dla modelu, co wpływa na pogorszenie jakości klasyfikacji.

cp	Accuracy	Kappa	AccuracySD	KappaSD
0.079	0.887	0.831	0.098	0.145
0.447	0.770	0.648	0.194	0.303
0.461	0.523	0.242	0.112	0.200

Tabela 18: Wyniki 10-krotnej walidacji krzyżowej – drzewo (wg parametru cp)

cp	Accuracy	Kappa	AccuracySD	KappaSD
0.000	0.822	0.730	0.130	0.198
0.201	0.872	0.808	0.077	0.116
0.401	0.573	0.309	0.202	0.350

Tabela 19: Wyniki CV – drzewo na podzbiorze cech V3, V7, V8, V11, V12

[CO TU NAPISAĆ: porównanie drzewa na pojedynczym podziale vs w 10-krotnej CV. Zaznaczyć, że 100% na pojedynczym teście jest zbyt optymistyczne (mały zbiór testowy

/ korzystny podział) i dlatego sięgamy po CV. Podać najlepsze `cp` oraz odpowiadającą dokładność i Kappa z CV (najlepiej inline R z obiektu `tree_cv`), oraz wniossek, że zbyt duże `cp` = za mocne przycinanie i spadek jakości. (Sprawdzone: najlepsze `cp` ok. 0.079, dokładność ok. 88.1%, Kappa ok. 0.821 – wartości wpisane na sztywno w akapicie niżej (88.7%, 0.831) są lekko nieaktualne; inline R z `tree_cv` to naprawi.)]

W pojedynczym podziale accuracy wyniosło 100 dla test set. Wynik ten wskazuje na bardzo wysoką skuteczność modelu drzewa decyzyjnego, jednak należy interpretować go ostrożnie, ponieważ może on wynikać z korzystnego podziału danych, niewielkiej liczby obserwacji w zbiorze testowym lub łatwej separowalności klas.

W celu oceny skuteczności drzewa decyzyjnego zastosowano metodę 10-krotnej walidacji krzyżowej (10-fold cross-validation). Model CART testował różne wartości parametru `cp` (complexity parameter), który kontroluje stopień przycinania drzewa i jego złożoność.

Najlepszy wynik uzyskano dla `cp` = 0.0789, dla którego model osiągnął dokładność klasyfikacji na poziomie około 88.7% oraz współczynnik Kappa równy 0.831. Oznacza to bardzo dobrą zgodność klasyfikacji oraz wysoką zdolność modelu do poprawnego rozróżniania klas.

Wraz ze wzrostem wartości parametru `cp` obserwowano spadek skuteczności modelu, co wskazuje, że zbyt silne przycinanie drzewa prowadzi do utraty informacji i pogorszenia jakości klasyfikacji.

Use kernel	Accuracy
FALSE	0.985
TRUE	0.961

Tabela 20: Wyniki 10-krotnej walidacji krzyżowej – Naive Bayes

Use kernel	Accuracy
FALSE	0.911
TRUE	0.895

Tabela 21: Wyniki CV – Naive Bayes na podzbiorze cech V3, V7, V8, V11, V12

[CO TU NAPISAĆ: wynik naive Bayes w CV — który wariant lepszy (z czy bez estymacji jądrowej, `usekernel`), jaka dokładność i Kappa (są już inline R — zostawić), oraz interpretacja: wysoka skuteczność oznacza, że przy założeniu niezależności cech klasy są dobrze separowalne. Dobrze też porównać z wynikiem naive Bayes na pojedynczym podziale.]

W celu oceny skuteczności klasyfikatora Naive Bayes zastosowano 10-krotną walidację krzyżową. Model testował dwa warianty: z estymacją jądrową (`usekernel` = TRUE) oraz bez niej (`usekernel` = FALSE).

Najlepszy wynik uzyskano dla modelu bez estymacji jądrowej, który osiągnął dokładność klasyfikacji na poziomie około 98.5% oraz współczynnik Kappa równy 0.977. Oznacza to bardzo

wysoką skuteczność klasyfikatora oraz bardzo dobrą zgodność przewidywań z rzeczywistymi klasami.

Wyniki wskazują, że klasy w analizowanym zbiorze danych są dobrze separowalne przy założeniu niezależności zmiennych, co sprzyja wysokiej skuteczności modelu Naive Bayes.

2.4 Różne parametry i podzbiory cech

one przeniesione wyżej lepiej porównywać

[DO NAPISANIA – komentarz do tabel na podzbiorych cech: porównać dokładność modeli na pełnym zestawie cech vs na podzbiorych V3, V7, V8, V11, V12 dla każdej z metod (k-NN, drzewo, naive Bayes); napisać, czy ograniczenie cech pomogło, zaszkodziło, czy nie zmieniło wyników. (Sprawdzone w CV: ograniczenie cech wyraźnie pogarsza k-NN (z ok. 97% do ok. 88%) i naive Bayes (z ok. 98% do ok. 90%), a drzewo prawie bez zmian (z ok. 88% do ok. 87%).)]

2.5 Podsumowanie

[DO NAPISANIA – końcowe wnioski (Zadanie 2f), wymagane w treści listy. Odpowiedzieć na trzy pytania: (1) dla jakiego podzbioru cech i jakich parametrów (np. k w k-NN, cp w drzewie, `usekernel` w naive Bayes) wyniki są najlepsze; (2) która metoda klasyfikacji wypada najlepiej, a która najgorzej na zbiorze wine; (3) czy wybór schematu oceny (pojedynczy podział vs walidacja krzyżowa) wpłynął na wnioski o skuteczności metod. Można podeprzeć się tabelami wyżej. (Sprawdzone w R, CV pełny zestaw cech: naive Bayes ok. 97.6% (najlepszy), k-NN ok. 96.9%, drzewo ok. 88.1% (najsłabsze); najlepsze parametry: k-NN $k=5$, drzewo cp ok. 0.079, naive Bayes `usekernel=FALSE`; pełny zestaw cech lepszy od podzbioru dla wszystkich metod poza drzewem; po dodaniu standaryzacji do CV oba schematy dają spójny ranking – wybór schematu NIE zmienia wniosków, jedynie pojedynczy podział był zbyt optymistyczny dla drzewa (100% vs 88% w CV).)]