

# Sprawozdanie 3

## Eksploatacja danych

Emilia Porczyńska, Michał Szostak

2026-06-02


## Spis treści

|          |                                                             |          |
|----------|-------------------------------------------------------------|----------|
| <b>1</b> | <b>Część 1 – klasyfikacja</b>                               | <b>2</b> |
| 1.1      | Wstęp . . . . .                                             | 2        |
| 1.2      | Przypomnienie struktury danych . . . . .                    | 2        |
| 1.3      | Podział danych na zbiór uczący i testowy . . . . .          | 3        |
| 1.4      | Konstrukcja klasyfikatora i wyznaczanie prognoz . . . . .   | 3        |
| 1.5      | Ocena klasyfikacji . . . . .                                | 4        |
| 1.6      | Model liniowy dla rozszerzonej przestrzeni klas . . . . .   | 5        |
| <b>2</b> | <b>Część 2 - porównanie metod klasyfikacji</b>              | <b>8</b> |
| 2.1      | Wstęp . . . . .                                             | 8        |
| 2.2      | Opis i wstępna analiza danych . . . . .                     | 8        |
| 2.3      | Ocena dokładności klasyfikacji i porównanie metod . . . . . | 13       |
| 2.4      | Różne parametry i podzbiory cech . . . . .                  | 17       |
| 2.5      | Podsumowanie . . . . .                                      | 18       |

# 1 Część 1 – klasyfikacja

## 1.1 Wstęp

Pracujemy na tym samym zbiorze danych co w poprzednim sprawozdaniu. Zbiór zawiera wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*). W przeciągu ostatniego miesiąca wygląd kwiatów się nie zmienił i nadal wyglądają one tak:



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

## 1.2 Przypomnienie struktury danych

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

|              | Typ     | Opis                                                                   |
|--------------|---------|------------------------------------------------------------------------|
| Sepal.Length | numeric | długość działki kielicha (w cm)                                        |
| Sepal.Width  | numeric | szerokość działki kielicha (w cm)                                      |
| Petal.Length | numeric | długość płatka (w cm)                                                  |
| Petal.Width  | numeric | szerokość płatka (w cm)                                                |
| Species      | factor  | gatunek irysa ( <i>setosa</i> / <i>versicolor</i> / <i>virginica</i> ) |

Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

| Sepal.Length   | Sepal.Width    | Petal.Length   | Petal.Width    |
|----------------|----------------|----------------|----------------|
| Min.: 4.300    | Min.: 2.000    | Min.: 1.000    | Min.: 0.100    |
| 1st Qu.: 5.100 | 1st Qu.: 2.800 | 1st Qu.: 1.600 | 1st Qu.: 0.300 |
| Median: 5.800  | Median: 3.000  | Median: 4.350  | Median: 1.300  |
| Mean: 5.843    | Mean: 3.057    | Mean: 3.758    | Mean: 1.199    |
| 3rd Qu.: 6.400 | 3rd Qu.: 3.300 | 3rd Qu.: 5.100 | 3rd Qu.: 1.800 |
| Max.: 7.900    | Max.: 4.400    | Max.: 6.900    | Max.: 2.500    |

Tabela 2: Podsumowanie danych

### 1.3 Podział danych na zbiór uczący i testowy

W celu oceny jakości działania klasyfikatora dzielimy zbiór danych na zbiór uczący `train_set` i zbiór testowy `test_set` w proporcjach 1 do 2:

```
set.seed(67) # ustawiamy seed losowania

n <- nrow(dane) # liczba obserwacji

# losujemy które obserwacje będą w zbiorze uczącym a które w testowym
train_index <- sample(1:n, size = round(2/3 * n))

# tworzymy osobne ramki danych dla obu zbiorów
train_set <- dane[train_index, ]
test_set <- dane[-train_index, ]
```

Zbiór uczący zawiera 100 obserwacji, a zbiór testowy 50.

### 1.4 Konstrukcja klasyfikatora i wyznaczanie prognoz

Na podstawie zbioru `train_set` będziemy estymować parametry modelu regresji liniowej w celu konstrukcji następnie sprawdzac i jakosc dopasowania do wartosci prawdziwej gatunku. Dla zbioru testowego i wyuczonych parametrów będziemy dopasujemy gatunek kwiatu.

[WYMÓG 1c NIE jest spełniony. Kod jest `echo=FALSE`, więc w PDF nie widać nic poza tymi dwoma zniekształconymi zdaniami i tym placeholderem — metoda nie jest opisana. CO TRZEBA NAPISAĆ (kilka zdań): (1) że klasyfikator budujemy metodą regresji liniowej na zakodowanych binarnie klasach; (2) WYJAŚNIĆ kodowanie klas przez wskaźniki (*class indicators*) — dla  $K = 3$  klas tworzymy macierz  $Y$  o 3 kolumnach, gdzie w wierszu danego kwiatu jest 1 w kolumnie jego gatunku i 0 w pozostałych (treść listy wyraźnie tego wymaga — „Uwaga” przy 1c); (3) że estymujemy  $\hat{B} = (X^T X)^{-1} X^T Y$ , gdzie  $X$  ma dodatkową kolumnę jedynek (wyraz wolny); (4) że dla nowego kwiatu liczymy  $\hat{Y} = X \hat{B}$  i przypisujemy klasę o największej wartości ( $\text{argmax}$  wiersza). To samo trzeba zrobić dla zbioru uczącego i testowego. JAK: opisać to słowami nad chunkami `klasyfikacja-train/klasyfikacja-test` i usunąć ten placeholder oraz poprawić dwa zdania wyżej.]

## 1.5 Ocena klasyfikacji

następnie w celu oceny klasyfikacji została wyznaczona macierz pomyłek i błąd klasyfikacji na zbiorze uczącym oraz testowym.

|            | setosa | versicolor | virginica |
|------------|--------|------------|-----------|
| setosa     | 28     | 0          | 0         |
| versicolor | 0      | 28         | 9         |
| virginica  | 0      | 6          | 29        |

Tabela 3: Macierz pomyłek dla zbioru uczącego (model liniowy)


Na powyższej tabeli widzimy wyniki oceny dopasowania gatunków do kwiatów. Analizując wyniki możemy stwierdzić, że nie występuje zjawisko maskowania danych, ponieważ na przekątnej wartości diagonalnej tabeli oraz błąd klasyfikacji wynosi 15%, co świadczy o dobrym działaniu klasyfikatora.

|            | setosa | versicolor | virginica |
|------------|--------|------------|-----------|
| setosa     | 22     | 0          | 0         |
| versicolor | 0      | 11         | 2         |
| virginica  | 0      | 5          | 10        |

Tabela 4: Macierz pomyłek dla zbioru testowego (model liniowy)

Dla zbioru testowego również nie obserwujemy zjawiska maskowania danych i błąd klasyfikacji wynosi 14%, zbliżona wartość błędów klasyfikacji dla zbioru uczącego i testowego świadczy o tym, że model nie jest przetrenowany i dobrze klasyfikuje dane. Na przekątnej znajduje się zdecydowana większość wystąpień, co świadczy o braku maskowania i dobrej klasyfikacji.

[Usunąć dopisek „to zdanie ggeminik”— to ślad roboczy. Samo zdanie poniżej jest poprawne (zweryfikowane: każda z 3 klas bywa prognozowana, żadna nie jest maskowana), wystarczy zostawić je bez prefiksu.] to zdanie ggeminik Brak maskowania wynika z faktu wykorzystania w klasyfikatorze indykatorem pełnego zestawu 4 cech irysa.



Rysunek 2: Dopasowane wartości wskaźników klas  $\hat{Y}$  dla modelu liniowego (zbiór uczący), obiekty uporządkowane wg gatunku.

Powyższy wykres został skonstruowany następująco: obiekty zostały uporządkowane tak, aby wszystkie próbki tego samego gatunku znajdowały się obok siebie. Następnie dla każdego obiektu przedstawiono wartości przypisane przez model do poszczególnych klas. Dodatkowo wprowadzono pionowe linie przerywane, które wyznaczają granice pomiędzy kolejnymi grupami gatunków.

Na podstawie wykresu można zauważyć, że najlepszą separowalność uzyskano dla klasy Setosa, która tworzy wyraźnie odseparowany blok. Klasa Versicolor jest mniej jednoznaczna i częściowo nakłada się z pozostałymi klasami, co wskazuje na trudniejszą klasyfikację. Największe trudności model ma w rozróżnieniu klasy Virginica, która wykazuje największe podobieństwo do pozostałych klas, szczególnie w zakresie wartości predykcji.

## 1.6 Model liniowy dla rozszerzonej przestrzeni klas

Następniei przeprowadzimy klasyfikację gatunków irysów na rozszerzonej przestrzeni cech. W tym celu zbudujemy nowy model liniowy dla tych cech i porównamy dokładność klasyfikacji z poprzednim modelem. Nasza nowa przestrzeń cech zawiera takie zmienne jak  $PL^2$  tutaj dopisz to.

[Dokończyć ten akapit i usunąć „tutaj dopisz to”. Wymóg 1e JEST spełniony w kodzie (14 cech: 4 oryginalne + 4 kwadraty + 6 iloczynów par), brakuje tylko opisu. CO WPISAĆ: kwadraty  $PL^2, PW^2, SL^2, SW^2$  oraz iloczyny par  $PL \cdot PW, PL \cdot SL, PL \cdot SW, PW \cdot SL, PW \cdot SW, SL \cdot SW$ .]

|            | setosa | versicolor | virginica |
|------------|--------|------------|-----------|
| setosa     | 28     | 0          | 0         |
| versicolor | 0      | 36         | 1         |
| virginica  | 0      | 1          | 34        |


Tabela 5: Macierz pomyłek dla zbioru uczącego (model wielomianowy)

W tabeli zostały przedstawione wyniki dla macierzy pomyłek i błąd klasyfikacji widzimy że nie występuje zjawisko maskowania danych, ponieważ na przekątnej znajdują zdecydowanie większość danych, co świadczy o jej dobrym skategoryzowaniu. Błąd klasyfikacji wynosi 0.02 co świadczy o bardzo dobrym dopasowaniu gatunków do kaitów. Błąd klasyfikacji jest znacząco mniejszy niż dla poprzedniego modelu, co świadczy o zależności gatunków między irysami nie są liniowe, ponieważ wprowadzenie dodatkowych cech pozwoliło na lepsze odseparowanie klas.

|            | setosa | versicolor | virginica |
|------------|--------|------------|-----------|
| setosa     | 22     | 0          | 0         |
| versicolor | 0      | 13         | 0         |
| virginica  | 0      | 3          | 12        |

Tabela 6: Macierz pomyłek dla zbioru testowego (model wielomianowy)

dla zbioru testowego również nie występuje zjawisko maskowania zmiennych zdecydowanie większość została dobrze sklasyfikowana. Na zbiorze testowym błąd klasyfikacji wynosi 0.06, co oznacza, że większość obserwacji została poprawnie sklasyfikowana. Jednak w porównaniu do błędów na zbiorze treningowym (0.02) widoczna jest różnica, co wskazuje na umiarkowane przeuczenie modelu. Model wielomianowy (stopnia 2) lepiej odwzorowuje nieliniowe zależności niż model liniowy, ale kosztem mniejszej stabilności na danych testowych.



Rysunek 3: Dopasowane wartości wskaźników klas  $\hat{Y}$  dla modelu wielomianowego (zbiór uczący), obiekty uporządkowane wg gatunku.

na podstawie powyższego wykresu można zauważyć, że setosa klasyfikuje się w pierwszej grupie, w drugim segmencie versicolor, a w trzecim virginica i widzimy zdecydowanie bardziej wyraźne separacje klas w 2 i 3 segmencie, co świadczy o tym, że model wielomianowy lepiej poradził sobie z zadaniem klasyfikacji niż model liniowy.

[Usunąć dopisek „nwm czy nie pisze bzdur...”. Treść jest merytorycznie OK — model wielomianowy wyraźniej separuje versicolor i virginica (zgodnie z wykresem i ze spadkiem błędów z 0.14 do 0.06). Wystarczy dokończyć/wygładzić ten akapit. Wymóg 1d/1e (ilustracja maskowania dla modelu rozszerzonego) jest spełniony.]

| Model                | Zbiór uczący | Zbiór testowy |
|----------------------|--------------|---------------|
| liniowy              | 0.15         | 0.14          |
| wielomianowy (st. 2) | 0.02         | 0.06          |

Tabela 7: Porównanie błędów klasyfikacji: model liniowy vs wielomianowy

Powyższe tabele przedstawiają błędy klasyfikacji dla modeli liniowego i wielomianowego dla zbiorów uczących i testowych. Widzimy, że błąd modelu liniowego na zbiorze uczącym wynosi 0.15, a na testowym 0.14. To świadczy o tym, że model liniowy nie wystarczająco uczy się złożonych zależności w danych. Natomiast błąd modelu wielomianowego na zbiorze uczącym wynosi 0.02, a na testowym 0.06. Wyższa wartość błędów na zbiorze testowym sygnalizuje przeuczenie modelu. Ogólnie model dobrze dopasował się do danych treningowych, lecz gorzej

sobie poradził na danych testowych. podsumowując model liniowy jest stabilniejszy lecz zbyt prosty co skutkuje błędami, natomiast wielomiany lepiej dopasowuje się do danych lecz traci zdolność generalizacji. Model liniowy jest bezpieczniejszym wyborem, pomimo wyższego błędu treningowego.

## 2 Część 2 - porównanie metod klasyfikacji

### 2.1 Wstęp

W następnej części raportu będziemy pracować na zbiorze danych Wine z biblioteki HDclassif. Naszym zadaniem będzie zastosowanie i porównanie algorytmów klasyfikacji takich jak metoda k-najbliższych sąsiadów, drzewa klasyfikacyjnego oraz naiwnego klasyfikatora bayesowskiego na zaimportowanej bazie danych.

### 2.2 Opis i wstępna analiza danych

Baza danych na której będziemy pracować zawiera informacje o wynikach analizy chemicznej win uprawianych w tych samych regionach Włoch, lecz pochodzących z trzech różnych odmian. Cechą dzięki której będziemy klasyfikować dane wino jest zmienna informująca o przynależności do odmiany wina.

Dane zawierają informacje o 178 winach, dla każdego z nich mamy 14 cech. Cecha class będzie nas informować o przynależności do klasy natomiast klasyfikacji posłużą nam 13 pozostałych cech. zmienna class zawiera 3 klasy służących do pogrupowania win.

|       | Typ     | Opis                           |
|-------|---------|--------------------------------|
| class | integer | przynależność do klasy wina    |
| V1    | numeric | zawartość alkoholu             |
| V2    | numeric | kwas jabłkowy                  |
| V3    | numeric | zawartość popiołu              |
| V4    | numeric | alkaliczność popiołu           |
| V5    | integer | zawartość magnezu              |
| V6    | numeric | łączna zawartość fenoli        |
| V7    | numeric | flawonoidy                     |
| V8    | numeric | fenole nieflawonoidowe         |
| V9    | numeric | proantocyjaniny                |
| V10   | numeric | intensywność barwy             |
| V11   | numeric | odcień koloru                  |
| V12   | numeric | OD280/OD315 rozcieńczonych win |
| V13   | integer | zawartość proliny              |

Tabela 8: Typy oraz opisy cech zbioru wine

Na podstawie powyższej tabeli można stwierdzić ze wszystkie typy zmiennych zostały prawidłowo zakodowane, poza zmienną class. Dla której zmienili typ na factor.

W poniższej tabeli znajdują się statystyki opisowe zmiennych, dzięki czemu możliwe jest wstępne zapoznanie się z danymi oraz identyfikacja podstawowych nieprawidłowości.


| class | V1            | V2            | V3            | V4            |
|-------|---------------|---------------|---------------|---------------|
| 1:59  | Min. :11.03   | Min. :0.740   | Min. :1.360   | Min. :10.60   |
| 2:71  | 1st Qu.:12.36 | 1st Qu.:1.603 | 1st Qu.:2.210 | 1st Qu.:17.20 |
| 3:48  | Median :13.05 | Median :1.865 | Median :2.360 | Median :19.50 |
|       | Mean :13.00   | Mean :2.336   | Mean :2.367   | Mean :19.49   |
|       | 3rd Qu.:13.68 | 3rd Qu.:3.083 | 3rd Qu.:2.558 | 3rd Qu.:21.50 |
|       | Max. :14.83   | Max. :5.800   | Max. :3.230   | Max. :30.00   |

| V5             | V6            | V7            | V8             | V9            |
|----------------|---------------|---------------|----------------|---------------|
| Min. : 70.00   | Min. :0.980   | Min. :0.340   | Min. :0.1300   | Min. :0.410   |
| 1st Qu.: 88.00 | 1st Qu.:1.742 | 1st Qu.:1.205 | 1st Qu.:0.2700 | 1st Qu.:1.250 |
| Median : 98.00 | Median :2.355 | Median :2.135 | Median :0.3400 | Median :1.555 |
| Mean : 99.74   | Mean :2.295   | Mean :2.029   | Mean :0.3619   | Mean :1.591   |
| 3rd Qu.:107.00 | 3rd Qu.:2.800 | 3rd Qu.:2.875 | 3rd Qu.:0.4375 | 3rd Qu.:1.950 |
| Max. :162.00   | Max. :3.880   | Max. :5.080   | Max. :0.6600   | Max. :3.580   |

| V10            | V11            | V12           | V13            |
|----------------|----------------|---------------|----------------|
| Min. : 1.280   | Min. :0.4800   | Min. :1.270   | Min. : 278.0   |
| 1st Qu.: 3.220 | 1st Qu.:0.7825 | 1st Qu.:1.938 | 1st Qu.: 500.5 |
| Median : 4.690 | Median :0.9650 | Median :2.780 | Median : 673.5 |
| Mean : 5.058   | Mean :0.9574   | Mean :2.612   | Mean : 746.9   |
| 3rd Qu.: 6.200 | 3rd Qu.:1.1200 | 3rd Qu.:3.170 | 3rd Qu.: 985.0 |
| Max. :13.000   | Max. :1.7100   | Max. :4.000   | Max. :1680.0   |

Tabela 9: Podsumowanie danych zbioru wine

W danych nie występują wartości NA. Na podstawie powyższej tabeli można również stwierdzić brak występowania wartości 0, ponieważ minimalna wartość dla każdej cechy jest różna od 0. Jedynie zmienna v13 cechuje się dużą zmiennością w porównaniu do pozostałych zmiennych.



Na powyższym wykresie widzimy rozkład przynależności poszczególnych obserwacji do danej klasy. Możemy zauważyć, że najwięcej obserwacji należy do klasy 2, natomiast najmniej do klasy 3.

[CO TU NAPISAĆ: (1) ocena rozkładu klas — czy są istotne dysproporcje liczebności (najwięcej obs. w klasie 2, najmniej w 3) i czy mają znaczenie; (2) baseline — jaki błąd dałby klasyfikator przypisujący wszystko do najliczniejszej klasy i interpretacja tej wartości jako punktu odniesienia dla właściwych modeli. Wartości % najlepiej wstawić inline R z policzonego błędu.]

Oznacza to, że występują pewne dysproporcje w liczebności klas, jednak nie są one skrajne.


Jeśli wszystkie obserwacje zostałyby przypisane do najczęściej występującej klasy (klasa 2), to błąd klasyfikacji wyniósłby:

$$\text{błąd} = 1 - \frac{n_{\max}}{n},$$


gdzie:  $n_{\max}$  to liczba obserwacji na najliczniejszej klasie, a  $n$  to liczba wszystkich obserwacji.

Błąd wynosi 0.6011236.

Oznacza to, że około 60% obserwacji zostałoby błędnie sklasyfikowanych, a taki klasyfikator osiągnąłby jedynie około 40% skuteczności.



Na powyższym wykresie znajdują się rozkłady wariancji dla wszystkich cech poza zmienną class. Możemy zauważyć, że ostatnia zmienna cechuje się najwyższą zmiennością i konieczne jest zastosowanie standaryzacji aby algorytmy klasyfikujące działały poprawnie.



widzimy że po standaryzacji zmienne mają zbliżone wariancje, co pozytywnie wpłynie na działanie algorytmów.

|     | LD1    | LD2    |
|-----|--------|--------|
| V1  | -0.403 | 0.872  |
| V2  | 0.165  | 0.305  |
| V3  | -0.369 | 2.346  |
| V4  | 0.155  | -0.146 |
| V5  | -0.002 | 0.000  |
| V6  | 0.618  | -0.032 |
| V7  | -1.661 | -0.492 |
| V8  | -1.496 | -1.631 |
| V9  | 0.134  | -0.307 |
| V10 | 0.355  | 0.253  |
| V11 | -0.818 | -1.516 |
| V12 | -1.158 | 0.051  |
| V13 | -0.003 | 0.003  |

Tabela 10: Współczynniki funkcji dyskryminacyjnych LDA (LD1, LD2)

[CO TU NAPISAĆ (jeden zwięzły akapit — poniższe to wersje robocze AI do skasowania): które zmienne najlepiej różnicują klasy, na podstawie wartości bezwzględnych współczynników funkcji dyskryminacyjnych LDA policzonych na danych ustandaryzowanych (wychodzą V3, V7, V8, V11, V12), oraz ile zmienności międzyklasowej wyjaśniają LD1 i LD2. Te % policzyć inline R z `model$svd^2 / sum(model$svd^2)`, nie wpisywać 68.75/31.25 na sztywno. Z trzech wersji poniżej (zwykła, „geminik”, „czat:”) zostawić jedną, napisaną własnymi słowami.]

W celu znalezienia zmiennych, które charakteryzują się najlepszymi zdolnościami dyskryminacyjnymi, zastosowano model Liniowej Analizy Dyskryminacyjnej (LDA). Model ten dokonuje transformacji pierwotnej przestrzeni cech w nową przestrzeń o niższej wymiarowości ( $K - 1$ , gdzie  $K$  to liczba klas). największe wartości bezwzględne współczynników w funkcjach dyskryminacyjnych LDA.

W szczególności zmienne V3, V7, V8, V11 oraz V12 wykazują największy wkład w separację klas, co oznacza, że najlepiej różnicują obserwacje należące do różnych grup.

Pierwsza funkcja dyskryminacyjna (LD1) wyjaśnia 68.75% zmienności między klasami, natomiast druga (LD2) 31.25%, co oznacza, że większość informacji separacyjnej zawarta jest w LD1.

geminik Analiza wag pokazała, że największe wartości bezwzględne współczynników w funkcjach dyskryminacyjnych LDA wykazują zmienne V3, V7, V8, V11 oraz V12. To one charakteryzują się największym wkładem w separację i najlepiej różnicują obserwacje. Ponieważ analiza została przeprowadzona na danych ustandaryzowanych, wielkości te bezpośrednio odzwierciedlają realną siłę dyskryminacyjną cech, a ich przeciwne znaki odpowiadają za rozsuwanie klas w przeciwległe krańce przestrzeni.

Pierwsza funkcja dyskryminacyjna (LD1) wyjaśnia 68.75% zmienności między klasami, nato-

miast druga (LD2) 31.25%

czat: Analiza LDA została wykorzystana do oceny zdolności dyskryminacyjnych zmiennych. Największy wpływ na separację klas mają zmienne V7, V8, V11, V12 oraz V3, ponieważ osiągnęły najwyższe wartości bezwzględne współczynników funkcji dyskryminacyjnych.

Pierwsza funkcja dyskryminacyjna (LD1) odpowiada za 68.75% całkowitej separacji klas, natomiast druga funkcja (LD2) za 31.25%. Oznacza to, że większość informacji potrzebnej do rozróżniania klas zawiera się w LD1.

Dodatkowo analiza średnich grupowych wskazuje, że wybrane zmienne przyjmują wyraźnie różne wartości w poszczególnych klasach, co potwierdza ich wysoką zdolność predykcyjną.

## 2.3 Ocena dokładności klasyfikacji i porównanie metod

W dalszej części raportu porównamy działanie algorytmów klasyfikujących takich jak naive, tree, i knn na naszym zbiorze wine. Na początku podzielimy zbiór na dwa podzbiory pierwszy treningowy następny uczący. Zbiór uczący będzie zawierał 70% danych. Do podziału została użyta biblioteka caret zachowująca proporcje w danych.

od czacika troche madre

[OPIS POJEDYNCZEGO PODZIAŁU (część wymogu 2d) praktycznie nie istnieje w renderowanym tekście: jest tylko placeholder „od czacika troche madre”, a właściwy opis siedzi PONIŻEJ w komentarzu HTML (`<!-- ... -->`), więc NIE pojawia się w PDF. CO ZROBIĆ: usunąć placeholder, a treść z komentarzy przepisać do normalnego tekstu (po polsku, bez błędów) — że podziału na 70/30 dokonano funkcją `createDataPartition` z zachowaniem proporcji klas, że dane standaryzujemy (k-NN opiera się na odległościach), oraz że dla każdej metody liczymy macierz pomyłek i błąd na zbiorze uczącym i testowym, a różnica między nimi mówi o przeuczeniu. Trzeba też zaznaczyć, że k-NN liczymy dla  $k = 5$ .]

| 1  | 2  | 3  |
|----|----|----|
| 42 | 0  | 0  |
| 3  | 47 | 0  |
| 0  | 0  | 34 |

Tabela 11: Macierz pomyłek – k-NN, zbiór uczący

| 1  | 2  | 3  |
|----|----|----|
| 17 | 0  | 0  |
| 1  | 18 | 2  |
| 0  | 0  | 14 |

Tabela 12: Macierz pomyłek – k-NN, zbiór testowy

Powyzsza tabela zawira wyniki dziala klasyfikatora knn dla 5 sa saidów dla widzimy ze macierz pomylek dla train i test nie zawiera maskowania dancyh na przekatnych znajduje sie wiekszosc informacji oraz blad klasyfikacji dla train wynosi 2.3 %b a dla tets 5.7 % wartosci sa relatywnie zblizone do siebie co swiadczy ze mdoel nie jest przetrenowany. (tu sie zastanawiam czy czegos cjeszce nie odaodac z tych wyników)

| 1  | 2  | 3  |
|----|----|----|
| 42 | 0  | 0  |
| 0  | 50 | 0  |
| 0  | 0  | 34 |

Tabela 13: Macierz pomylek – drzewo, zbiór uczący

| 1  | 2  | 3  |
|----|----|----|
| 17 | 0  | 0  |
| 0  | 21 | 0  |
| 0  | 0  | 14 |

Tabela 14: Macierz pomylek – drzewo, zbiór testowy

Otrzymane wyniki swiadcza o bezblednej klasyfikacji zarowno na zbiorze uczacym jak i testowym, co swiadczy od bardzi=o dobrych wlasnoscich kalsyfikacyjnych algorytmu drzew decyzyjnych. Z uwagi na fakt podzial dancyh na zbior uczaci i testowy zostaly wykonany porawnie a wynik 100% wystepuje ronwiez na danych testowych, mozmy wykluczyc przetrenowanie modelu. - tego nie jestem pewna

| 1  | 2  | 3  |
|----|----|----|
| 42 | 0  | 0  |
| 0  | 50 | 0  |
| 0  | 0  | 34 |

Tabela 15: Macierz pomylek – naive Bayes, zbiór uczący

| 1  | 2  | 3  |
|----|----|----|
| 16 | 1  | 0  |
| 0  | 21 | 0  |
| 0  | 0  | 14 |

Tabela 16: Macierz pomylek – naive Bayes, zbiór testowy

Wyniki kalsyfikacji dla modelu naive bayes dla zbioru uczącego wykazują 100% dokładności model bezładnie dopasował dane, natomiast wynik błędu dla zbioru testowego wynosi 1.92 co świadczy o bardzo dobrym działaniu modelu i braku przetrenowania go. Również nie występuje zjawisko maskowania danych na przekątnej macierzy znajduje się zdecydowanie większość danych.

Następnie w celu porównania działań algorytmów przeprowadzimy kalsyfikację lecz zastosujemy bardziej zaawansowany schemat oceny dokładności. Użyliśmy metody cross validation.

| k  | Accuracy | Kappa | AccuracySD | KappaSD |
|----|----------|-------|------------|---------|
| 5  | 0.969    | 0.953 | 0.041      | 0.061   |
| 7  | 0.960    | 0.940 | 0.057      | 0.086   |
| 9  | 0.952    | 0.928 | 0.057      | 0.086   |
| 11 | 0.944    | 0.916 | 0.066      | 0.099   |
| 13 | 0.960    | 0.940 | 0.057      | 0.086   |

Tabela 17: Wyniki 10-krotnej walidacji krzyżowej – k-NN (wg parametru k)

tu tabelę na innym podzbiorze do porównania

| k  | Accuracy | Kappa | AccuracySD | KappaSD |
|----|----------|-------|------------|---------|
| 5  | 0.856    | 0.782 | 0.074      | 0.112   |
| 7  | 0.857    | 0.784 | 0.089      | 0.134   |
| 9  | 0.856    | 0.783 | 0.093      | 0.140   |
| 11 | 0.840    | 0.759 | 0.077      | 0.116   |
| 13 | 0.848    | 0.771 | 0.081      | 0.124   |

Tabela 18: Wyniki CV – k-NN na podzbiorze cech V3, V7, V8, V11, V12

[DO PRZEPISANIA: do CV k-NN dodano standaryzację (**preProcess**), bo wcześniej jej brakowało, a przy pojedynczym podziale była. Teraz CV k-NN daje najlepszy wynik (k=5) ok. 96.9%, czyli zbliżony do pojedynczego podziału (ok. 94.2%), a NIE 74%. Dlatego poniższa interpretacja jest nieaktualna i wymaga zmiany: (1) spadek do 74% NIE wynikał z optywizmu pojedynczego podziału, tylko z braku standaryzacji w CV; teraz oba schematy są spójne; (2) dokładność najlepszego k to ok. 96.9%, a nie 74%; (3) zdanie, że dokładność „generalnie rośnie wraz z k”, jest błędne — po standaryzacji najlepsze jest k=5.]

Wyniki uzyskane metodą cross-validation odnoszą się do zbioru treningowego, który został wielokrotnie dzielony na części uczące i walidacyjne. W związku z tym stanowią one bardziej stabilną ocenę modelu niż pojedynczy wynik na zbiorze treningowym, ale nadal nie są to wyniki na niezależnym zbiorze testowym.

W przypadku pojedynczego podziału uzyskano bardzo wysoką dokładność klasyfikacji na poziomie około 94% dla  $k = 5$ . Wynik ten może być jednak obciążony dużą zmiennością, ponieważ zależy od konkretnego losowego podziału danych.

Natomiast zastosowanie 10-krotnej walidacji krzyżowej dało bardziej stabilną ocenę skuteczności modelu, gdzie dla  $k = 5$  uzyskano średnią dokładność na poziomie około 74%.

Różnica pomiędzy wynikami wskazuje, że pojedynczy podział może prowadzić do zawyżenia oceny jakości klasyfikatora, natomiast walidacja krzyżowa dostarcza bardziej wiarygodnej i uogólnionej oceny.

Zaobserwowano również, że wraz ze wzrostem wartości parametru  $k$  dokładność klasyfikacji generalnie rośnie, co sugeruje, że większa liczba sąsiadów stabilizuje decyzje klasyfikatora i zmniejsza wpływ szumu w danych.

Następnie w tabeli przedstawiono wyniki klasyfikatora  $k$ -NN dla różnych wartości parametru  $k$  na zmniejszonym zbiorze cech. Najwyższą wartość *accuracy* uzyskano dla  $k = 9$ . Zaobserwowano również, że wartości *accuracy* na podzbiorze cech są niższe niż w przypadku pełnego zestawu danych. Wskazuje to, że redukcja liczby cech ogranicza ilość informacji dostępnej dla modelu, co wpływa na pogorszenie jakości klasyfikacji.

| cp    | Accuracy | Kappa | AccuracySD | KappaSD |
|-------|----------|-------|------------|---------|
| 0.079 | 0.887    | 0.831 | 0.098      | 0.145   |
| 0.447 | 0.770    | 0.648 | 0.194      | 0.303   |
| 0.461 | 0.523    | 0.242 | 0.112      | 0.200   |

Tabela 19: Wyniki 10-krotnej walidacji krzyżowej – drzewo (wg parametru *cp*)

| cp    | Accuracy | Kappa | AccuracySD | KappaSD |
|-------|----------|-------|------------|---------|
| 0.000 | 0.822    | 0.730 | 0.130      | 0.198   |
| 0.201 | 0.872    | 0.808 | 0.077      | 0.116   |
| 0.401 | 0.573    | 0.309 | 0.202      | 0.350   |

Tabela 20: Wyniki CV – drzewo na podzbiorze cech V3, V7, V8, V11, V12

[CO TU NAPISAĆ: porównanie drzewa na pojedynczym podziale vs w 10-krotnej CV. Zaznaczyć, że 100% na pojedynczym teście jest zbyt optymistyczne (mały zbiór testowy / korzystny podział) i dlatego sięgamy po CV. Podać najlepsze *cp* oraz odpowiadającą dokładność i Kappa z CV (najlepiej inline R z obiektu `tree_cv`), oraz wniosek, że zbyt duże *cp* = za mocne przycinanie i spadek jakości.]

W pojedynczym podziale *accuracy* wyniosło 100 dla testów. Wynik ten wskazuje na bardzo wysoką skuteczność modelu drzewa decyzyjnego, jednak należy interpretować go ostrożnie, ponieważ może on wynikać z korzystnego podziału danych, niewielkiej liczby obserwacji w zbiorze testowym lub łatwej separowalności klas.

W celu oceny skuteczności drzewa decyzyjnego zastosowano metodę 10-krotnej walidacji krzyżowej (10-fold cross-validation). Model CART testował różne wartości parametru *cp* (complexity parameter), który kontroluje stopień przycinania drzewa i jego złożoność.

Najlepszy wynik uzyskano dla  $cp = 0.0789$ , dla którego model osiągnął dokładność klasyfikacji na poziomie około 88.7% oraz współczynnik Kappa równy 0.831. Oznacza to bardzo dobrą zgodność klasyfikacji oraz wysoką zdolność modelu do poprawnego rozróżniania klas.

Wraz ze wzrostem wartości parametru  $cp$  obserwowano spadek skuteczności modelu, co wskazuje, że zbyt silne przycinanie drzewa prowadzi do utraty informacji i pogorszenia jakości klasyfikacji.

| Use kernel | Accuracy |
|------------|----------|
| FALSE      | 0.985    |
| TRUE       | 0.961    |

Tabela 21: Wyniki 10-krotnej walidacji krzyżowej – Naive Bayes

| Use kernel | Accuracy |
|------------|----------|
| FALSE      | 0.911    |
| TRUE       | 0.895    |

Tabela 22: Wyniki CV – Naive Bayes na podzbiorze cech V3, V7, V8, V11, V12

[CO TU NAPISAĆ: wynik naive Bayes w CV — który wariant lepszy (z czy bez estymacji jądrowej, `usekernel`), jaka dokładność i Kappa (są już inline R — zostawić), oraz interpretacja: wysoka skuteczność oznacza, że przy założeniu niezależności cech klasy są dobrze separowalne. Dobrze też porównać z wynikiem naive Bayes na pojedynczym podziale.]

W celu oceny skuteczności klasyfikatora Naive Bayes zastosowano 10-krotną walidację krzyżową. Model testował dwa warianty: z estymacją jądrową (`usekernel = TRUE`) oraz bez niej (`usekernel = FALSE`).

Najlepszy wynik uzyskano dla modelu bez estymacji jądrowej, który osiągnął dokładność klasyfikacji na poziomie około 98.5% oraz współczynnik Kappa równy 0.977. Oznacza to bardzo wysoką skuteczność klasyfikatora oraz bardzo dobrą zgodność przewidywań z rzeczywistymi klasami.

Wyniki wskazują, że klasy w analizowanym zbiorze danych są dobrze separowalne przy założeniu niezależności zmiennych, co sprzyja wysokiej skuteczności modelu Naive Bayes.

## 2.4 Różne parametry i podzbiory cech

one przeniesione wyżej lepiej porównywać

[DO NAPISANIA – komentarz do tabel na podzbiorze cech: porównać dokładność modeli na pełnym zestawie cech vs na podzbiorze V3, V7, V8, V11, V12 dla każdej z metod (k-NN, drzewo, naive Bayes); napisać, czy ograniczenie cech pomogło, zaszkodziło, czy nie zmieniło wyników.]

## 2.5 Podsumowanie

[DO NAPISANIA – końcowe wnioski (Zadanie 2f), wymagane w treści listy. Odpowiedzieć na trzy pytania: (1) dla jakiego podzbioru cech i jakich parametrów (np.  $k$  w  $k$ -NN,  $cp$  w drzewie,  $usekernel$  w naive Bayes) wyniki są najlepsze; (2) która metoda klasyfikacji wypada najlepiej, a która najgorzej na zbiorze wine; (3) czy wybór schematu oceny (pojedynczy podział vs walidacja krzyżowa) wpłynął na wnioski o skuteczności metod. Można podeprzeć się tabelami wyżej.]