

Sprawozdanie 3

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-05-23

Spis treści

1	Część 1 – klasyfikacja	2
1.1	Wstęp	2
1.2	Opis danych	2
1.3	Podział danych na zbiór uczący i testowy	3
1.4	Konstrukcja klasyfikatora i wyznaczanie prognoz	3
1.5	Ocena klasyfikacji	3
1.6	Model liniowy dla rozszerzonej przestrzeni klas	3
2	Część 2 - porównanie metod klasyfikacji	4
2.1	Wstęp	4
2.2	Opis i wstępna analiza danych	4
2.3	Ocena dokładności klasyfikacji i porównanie metod	9

1 Część 1 – klasyfikacja

1.1 Wstęp

Mamy zbiór danych zawierający wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatków (ang. *petal*). Naszym zadaniem będzie klasyfikowanie gatunku płatków na podstawie modelu regresji liniowej. Zmiennymi objaśniającymi będą cechy opisujące kwiaty (Pl, Pw, Sl, Sw), natomiast zmienną objaśnianą będzie gatunek. Cel dla zbioru testowego dopasować gatunek i ocenić jakość klasyfikatora. Dla 3 klas.



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

1.2 Opis danych

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatków (w cm)
Petal.Width	numeric	szerokość płatków (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)

Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

1.3 Podział danych na zbiór uczący i testowy

Następnie w celu oceny jakości działania klasyfikatora podzieliliśmy zbiór danych na zbiór uczący i zbiór testowy w stosunku 1 do 2.

1.4 Konstrukcja klasyfikatora i wyznaczanie prognoz

Na podstawie zbioru testowego będziemy estymować parametry modelu i następnie sprawdzać i jakoś dopasowania do wartości gatunku. Dla zbioru testowego i wyuczonych parametrów będziemy dopasowywać gatunek kwiatu.

1.5 Ocena klasyfikacji

```
##               Prognozowane
## Rzeczywiste  setosa versicolor virginica
##   setosa      28         0         0
##   versicolor  0         28         9
##   virginica   0         6        29
```

```
## [1] 0.15
```

```
##               Prognozowane
## Rzeczywiste  setosa versicolor virginica
##   setosa      22         0         0
##   versicolor  0         11         2
##   virginica   0         5        10
```

```
## [1] 0.14
```

1.6 Model liniowy dla rozszerzonej przestrzeni klas

```
##               Prognozowane
## Rzeczywiste  setosa versicolor virginica
##   setosa      28         0         0
##   versicolor  0         28         9
```

```
## virginica      0      6      29
## [1] 0.15

##          Prognozowane
## Rzeczywiste setosa versicolor virginica
## setosa      22      0      0
## versicolor  0      11      2
## virginica   0      5      10
## [1] 0.14
```

2 Część 2 - porównanie metod klasyfikacji

2.1 Wstęp

W następnej części raportu będziemy pracować na zbiorze danych Wine z biblioteki HDclassif. Naszym zadaniem będzie zastosowanie i porównanie algorytmów klasyfikacji takich jak metoda k-najbliższych sąsiadów, drzewa klasyfikacyjne oraz naiwnego klasyfikatora bayesowskiego na zaimportowanej bazie danych.

2.2 Opis i wstępna analiza danych

Baza danych na której będziemy pracować zawiera informacje o wynikach analizy chemicznej win uprawianych w tych samych regionach Włoch, lecz pochodzących z trzech różnych odmian. Cechą dzięki której będziemy klasyfikować dane wino jest zmienna informująca o przynależności do odmiany wina.

```
## Warning: pakiet 'HDclassif' został zbudowany w wersji R 4.5.3
## Ładowanie wymaganego pakietu: MASS
##
## Dołączanie pakietu: 'MASS'
## Następujący obiekt został zakryty z 'package:dplyr':
##
##      select
```

Dane zawierają informacje o 178 winach, dla każdego z nich mamy 14 cech. Cecha class będzie nas informować o przynależności do klasy natomiast klasyfikacji posłuży nam 13 pozostałych cech.

	Typ	Opis
class	integer	przynależność do klasy wina
V1	numeric	zawartość alkoholu
V2	numeric	kwasy jabłkowe
V3	numeric	zawartość popiołu
V4	numeric	alkaliczność popiołu
V5	integer	zawartość magnezu
V6	numeric	łączna zawartość fenoli
V7	numeric	flawonoidy
V8	numeric	fenole nieflawonoidowe
V9	numeric	proantocyjaniny
V10	numeric	intensywność barwy
V11	numeric	odcień koloru
V12	numeric	OD280/OD315 rozcieńczonych win
V13	integer	zawartość proliny

Tabela 3: Typy oraz opisy cech zbioru wine

Na podstawie powyższej tabeli można stwierdzić, że wszystkie typy zmiennych zostały prawidłowo zakodowane, poza zmienną class. Dla której zmieniliśmy typ na factor.

W poniższej tabeli znajdują się statystyki opisowe zmiennych, dzięki czemu możliwe jest wstępne zapoznanie się z danymi oraz identyfikacja podstawowych nieprawidłowości.

TUTAJ TRZEBA POPRAWIĆ TABELĘ BO JEST ZMIENIONA NA FACTOR ZA ZAMIAST CLASS
CECHY ALBO W TEJ TABELI GŁÓWNO


```
## \begin{table}[H]
## \centering
## \resizebox{\ifdim\width>\linewidth\linewidth\else\width\fi}{!}{
## \begin{tabular}{llllll}
## \toprule
## & class & V1 & V2 & V3 & V4 \\
## \midrule
## \cellcolor{gray!10}{} & \cellcolor{gray!10}{Min. & :1.000} & \cellcolor{gray!10}{Min.
## & 1st Qu.:1.000 & 1st Qu.:12.36 & 1st Qu.:1.603 & 1st Qu.:2.210 & 1st Qu.:17.20 \\
## \cellcolor{gray!10}{} & \cellcolor{gray!10}{Median & :2.000} & \cellcolor{gray!10}{Medi
## & Mean & :1.938 & Mean & :13.00 & Mean & :2.336 & Mean & :2.367 & Mean & :19.49 \\
## \cellcolor{gray!10}{} & \cellcolor{gray!10}{3rd Qu.:3.000} & \cellcolor{gray!10}{3rd
## \addlinespace
## & Max. & :3.000 & Max. & :14.83 & Max. & :5.800 & Max. & :3.230 & Max. & :30.00 \\
## \bottomrule
## \end{tabular}}
## \end{table}
```

```

## \begin{table}[H]
## \centering
## \resizebox{\ifdim\width>\linewidth\linewidth\else\width\fi}{!}{
## \begin{tabular}{l}
## \toprule
## & V5 & V6 & V7 & V8 & V9\\
## \midrule
## \cellcolor{gray!10}{} & \cellcolor{gray!10}{Min. : 70.00} & \cellcolor{gray!10}{Min. : 70.00} & \cellcolor{gray!10}{Min. : 70.00} & \cellcolor{gray!10}{Min. : 70.00} & \cellcolor{gray!10}{Min. : 70.00} \\
## & 1st Qu.: 88.00 & 1st Qu.:1.742 & 1st Qu.:1.205 & 1st Qu.:0.2700 & 1st Qu.:1.250\\
## \cellcolor{gray!10}{} & \cellcolor{gray!10}{Median : 98.00} & \cellcolor{gray!10}{Median : 98.00} & \cellcolor{gray!10}{Median : 98.00} & \cellcolor{gray!10}{Median : 98.00} & \cellcolor{gray!10}{Median : 98.00} \\
## & Mean : 99.74 & Mean :2.295 & Mean :2.029 & Mean :0.3619 & Mean :1.591\\
## \cellcolor{gray!10}{} & \cellcolor{gray!10}{3rd Qu.:107.00} & \cellcolor{gray!10}{3rd Qu.:107.00} & \cellcolor{gray!10}{3rd Qu.:107.00} & \cellcolor{gray!10}{3rd Qu.:107.00} & \cellcolor{gray!10}{3rd Qu.:107.00} \\
## \addlinespace
## & Max. :162.00 & Max. :3.880 & Max. :5.080 & Max. :0.6600 & Max. :3.580\\
## \bottomrule
## \end{tabular}}
## \end{table}
## \begin{table}[H]
## \centering
## \caption{\label{tab:statystyki-opisowe-cech}Podsumowanie danych zbioru wine}
## \centering
## \resizebox{\ifdim\width>\linewidth\linewidth\else\width\fi}{!}{
## \begin{tabular}{t}
## \toprule
## & V10 & V11 & V12 & V13\\
## \midrule
## \cellcolor{gray!10}{} & \cellcolor{gray!10}{Min. : 1.280} & \cellcolor{gray!10}{Min. : 1.280} & \cellcolor{gray!10}{Min. : 1.280} & \cellcolor{gray!10}{Min. : 1.280} \\
## & 1st Qu.: 3.220 & 1st Qu.:0.7825 & 1st Qu.:1.938 & 1st Qu.: 500.5\\
## \cellcolor{gray!10}{} & \cellcolor{gray!10}{Median : 4.690} & \cellcolor{gray!10}{Median : 4.690} & \cellcolor{gray!10}{Median : 4.690} & \cellcolor{gray!10}{Median : 4.690} \\
## & Mean : 5.058 & Mean :0.9574 & Mean :2.612 & Mean : 746.9\\
## \cellcolor{gray!10}{} & \cellcolor{gray!10}{3rd Qu.: 6.200} & \cellcolor{gray!10}{3rd Qu.: 6.200} & \cellcolor{gray!10}{3rd Qu.: 6.200} & \cellcolor{gray!10}{3rd Qu.: 6.200} \\
## \addlinespace
## & Max. :13.000 & Max. :1.7100 & Max. :4.000 & Max. :1680.0\\
## \bottomrule
## \end{tabular}}
## \end{table}

```

W danych nie występują wartości NA. Na podstawie powyższej tabeli można również stwierdzić brak występowania wartości 0, ponieważ minimalna wartość dla każdej cechy jest różna od 0.



Na powyższym wykresie widzimy rozkład przynależności poszczególnych obserwacji do danej klasy. Możemy zauważyć, że najwięcej obserwacji należy do klasy 2, natomiast najmniej do klasy 3.

Oznacza to, że występują pewne dysproporcje w liczebności klas, jednak nie są one skrajne.


Jeśli wszystkie obserwacje zostałyby przypisane do najczęściej występującej klasy (klasa 2), to błąd klasyfikacji wyniósłby:

$$\text{błąd} = 1 - \frac{n_{\max}}{n},$$


gdzie: $n_{\max}$ to liczba obserwacji na najliczniejszej klasie, a n to liczba wszystkich obserwacji.

Błąd wynosi 0.6011236.

Oznacza to, że około 60% obserwacji zostałoby błędnie sklasyfikowanych, a taki klasyfikator osiągnąłby jedynie około 40% skuteczności.



Na powyższym wykresie znajdują się wykresy wariancji dla wszystkich cech poza zmienną class. Możemy zauważyć, że ostatnia zmienna cechuje się najwyższą zmiennością i konieczne jest zastosowanie standaryzacji aby algorytmy klasyfikujące działały poprawnie.



widzimy że po standaryzacji zmienne mają zbliżone wariancje, co pozytywnie wpłynie na działanie algorytmów.

```
## Call:
## lda(class ~ ., data = wine)
##
## Prior probabilities of groups:
##      1      2      3
## 0.3314607 0.3988764 0.2696629
##
## Group means:
##      V1      V2      V3      V4      V5      V6      V7      V8
## 1 13.74475 2.010678 2.455593 17.03729 106.3390 2.840169 2.9823729 0.290000
## 2 12.27873 1.932676 2.244789 20.23803  94.5493 2.258873 2.0808451 0.363662
## 3 13.15375 3.333750 2.437083 21.41667  99.3125 1.678750 0.7814583 0.447500
##      V9      V10      V11      V12      V13
## 1 1.899322 5.528305 1.0620339 3.157797 1115.7119
```



```

## 2 1.630282 3.086620 1.0562817 2.785352 519.5070
## 3 1.153542 7.396250 0.6827083 1.683542 629.8958
##
## Coefficients of linear discriminants:
##          LD1          LD2
## V1 -0.403399781  0.8717930699
## V2  0.165254596  0.3053797325
## V3 -0.369075256  2.3458497486
## V4  0.154797889 -0.1463807654
## V5 -0.002163496 -0.0004627565
## V6  0.618052068 -0.0322128171
## V7 -1.661191235 -0.4919980543
## V8 -1.495818440 -1.6309537953
## V9  0.134092628 -0.3070875776
## V10 0.355055710  0.2532306865
## V11 -0.818036073 -1.5156344987
## V12 -1.157559376  0.0511839665
## V13 -0.002691206  0.0028529846
##
## Proportion of trace:
##      LD1      LD2
## 0.6875 0.3125

```

największe wartości bezwzględne współczynników w funkcjach dyskryminacyjnych LDA.

W szczególności zmienne V3, V7, V8, V11 oraz V12 wykazują największy wkład w separację klas, co oznacza, że najlepiej różnicują obserwacje należące do różnych grup.

Pierwsza funkcja dyskryminacyjna (LD1) wyjaśnia 68.75% zmienności między klasami, natomiast druga (LD2) 31.25%, co oznacza, że większość informacji separacyjnej zawarta jest w LD1.

2.3 Ocena dokładności klasyfikacji i porównanie metod