

Sprawozdanie 3

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-06-02


Spis treści

1	Część 1 – klasyfikacja	2
1.1	Wstęp	2
1.2	Przypomnienie struktury danych	2
1.3	Podział danych na zbiór uczący i testowy	3
1.4	Konstrukcja klasyfikatora i wyznaczanie prognoz	3
1.5	Ocena klasyfikacji	3
1.6	Model liniowy dla rozszerzonej przestrzeni klas	5
2	Część 2 - porównanie metod klasyfikacji	7
2.1	Wstęp	7
2.2	Opis i wstępna analiza danych	7
2.3	Ocena dokładności klasyfikacji i porównanie metod	12
2.4	Różne parametry i podzbiory cech	16
2.5	Podsumowanie	16

1 Część 1 – klasyfikacja

1.1 Wstęp

Pracujemy na tym samym zbiorze danych co w poprzednim sprawozdaniu. Zbiór zawiera wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*). W przeciągu ostatniego miesiąca wygląd kwiatów się nie zmienił i nadal wyglądają one tak:



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

1.2 Przypomnienie struktury danych

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatka (w cm)
Petal.Width	numeric	szerokość płatka (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)

Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

1.3 Podział danych na zbiór uczący i testowy

W celu oceny jakości działania klasyfikatora dzielimy zbiór danych na zbiór uczący i zbiór testowy w proporcjach 1 do 2:

```
set.seed(67)

n <- nrow(dane)
train_index <- sample(1:n, size = round(2/3 * n))

train_set <- dane[train_index, ]
test_set <- dane[-train_index, ]
```

1.4 Konstrukcja klasyfikatora i wyznaczanie prognoz

Na podstawie zbioru train będziemy estymować parametry modelu i następnie sprawdzać i jakość dopasowania do wartości prawdziwej gatunku. Dla zbioru testowego i wyuczonych parametrów będziemy dopasowywać gatunek kwiata.

tutaj coś powinno być jeszcze jakiś kod czy coś

1.5 Ocena klasyfikacji

następnie w celu oceny klasyfikacji została wyznaczona macierz pomyłek i błąd klasyfikacji na zbiorze uczącym oraz testowym.

	setosa	versicolor	virginica
setosa	28	0	0
versicolor	0	28	9
virginica	0	6	29

Tabela 3: Macierz pomyłek dla zbioru uczącego (model liniowy)


Na powyższej tabeli widzimy wyniki oceny dopasowania gatunków do kwiatów. Analizując wyniki możemy stwierdzić, że nie występuje zjawisko maskowania danych, ponieważ na przekątnej wartości zdominowały tabelę oraz błąd klasyfikacji wynosi 15%, co świadczy o dobrym działaniu klasyfikatora.

	setosa	versicolor	virginica
setosa	22	0	0
versicolor	0	11	2
virginica	0	5	10

Tabela 4: Macierz pomyłek dla zbioru testowego (model liniowy)

Dla zbioru testowego również nie obserwujemy zjawiska maskowania danych i błąd klasyfikacji wynosi 14%, zbliżona wartość błędów klasyfikacji dla zbioru uczącego i testowego świadczy o tym, że model nie jest przetrenowany i dobrze klasyfikuje dane. Na przekątnej znajduje się zdecydowana większość wystąpień, co świadczy o braku maskowania i dobrej klasyfikacji.

to zdanie ggemini Brak maskowania wynika z faktu wykorzystania w klasyfikatorze indicatorowym pełnego zestawu 4 cech irysa.



Rysunek 2: Dopasowane wartości wskaźników klas $\hat{Y}$ dla modelu liniowego (zbiór uczący), obiekty uporządkowane wg gatunku.

Powyższy wykres został skonstruowany następująco: obiekty zostały uporządkowane tak, aby wszystkie próbki tego samego gatunku znajdowały się obok siebie. Następnie dla każdego obiektu przedstawiono wartości przypisane przez model do poszczególnych klas. Dodatkowo

wprowadzono pionowe linie przerywane, które wyznaczają granice pomiędzy kolejnymi grupami gatunków.

Na podstawie wykresu można zauważyć, że najlepszą separowalność uzyskano dla klasy Setosa, która tworzy wyraźnie odseparowany blok. Klasa Versicolor jest mniej jednoznaczna i częściowo nakłada się z pozostałymi klasami, co wskazuje na trudniejszą klasyfikację. Największe trudności model ma w rozróżnieniu klasy Virginica, która wykazuje największe podobieństwo do pozostałych klas, szczególnie w zakresie wartości predykcji.

1.6 Model liniowy dla rozszerzonej przestrzeni klas

Następnie przeprowadzimy klasyfikację gatunków irysów na rozszerzonej przestrzeni cech. W tym celu zbudujemy nowy model liniowy dla tych cech i porównamy dokładność klasyfikacji z poprzednim modelem. Nasza nowa przestrzeń cech zawiera takie zmienne jak Pl^2 tutaj dopisz to.

	setosa	versicolor	virginica
setosa	28	0	0
versicolor	0	36	1
virginica	0	1	34


Tabela 5: Macierz pomyłek dla zbioru uczącego (model wielomianowy)

W tabeli zostały przedstawione wyniki dla macierzy pomyłek i błąd klasyfikacji widzimy że nie występuje zjawisko maskowania danych, ponieważ na przekątnej znajdują zdecydowana większość danych, co świadczy o jej dobrym skategoryzowaniu. Błąd klasyfikacji wynosi 0.02 co świadczy o bardzo dobrym dopasowaniu gatunków do kwiatów. Błąd klasyfikacji jest znacząco mniejszy niż dla poprzedniego modelu, co świadczy o zależności gatunków między irysami nie są liniowe, ponieważ wprowadzenie dodatkowych cech pozwoliło na lepsze odseparowanie klas.

	setosa	versicolor	virginica
setosa	22	0	0
versicolor	0	13	0
virginica	0	3	12

Tabela 6: Macierz pomyłek dla zbioru testowego (model wielomianowy)

dla zbioru testowego również nie występuje zjawisko maskowania zmiennych zdecydowana większość została dobrze sklasyfikowana. Na zbiorze testowym błąd klasyfikacji wynosi 0.06, co oznacza, że większość obserwacji została poprawnie sklasyfikowana. Jednak w porównaniu do błędu na zbiorze treningowym (0.02) widoczna jest różnica, co wskazuje na umiarkowane przeuczenie modelu. Model wielomianowy (stopnia 2) lepiej odwzorowuje nieliniowe zależności niż model liniowy, ale kosztem mniejszej stabilności na danych testowych.



Rysunek 3: Dopasowane wartości wskaźników klas $\hat{Y}$ dla modelu wielomianowego (zbiór uczący), obiekty uporządkowane wg gatunku.

na podstawie powyższego wykresu można zauważyć, że setosa klasyfikuje się w pierwszej grupie, w drugim segmencie versicolor, a w trzecim virginica i widzimy zdecydowanie bardziej wyraźne klasy w 2 i 3 segmencie, co świadczy, że model wielomianowy lepiej poradził sobie z zadaniem klasyfikacji niż ten, który nie pisze bzdur, zapytać czata czy czegoś jak to dobrze opisać.

Model	Zbiór uczący	Zbiór testowy
liniowy	0.15	0.14
wielomianowy (st. 2)	0.02	0.06

Tabela 7: Porównanie błędów klasyfikacji: model liniowy vs wielomianowy

Powyższa tabela przedstawia błędy klasyfikacji dla modeli liniowego i wielomianowego dla zbiorów uczących i testowych. Widzimy, że błąd modelu liniowego na zbiorze uczącym wynosi 0.15, a na testowym 0.14. To świadczy, że dobrze generalizuje, lecz jest nie wystarczająco uczony złożonych zależności w danych. Natomiast błąd modelu wielomianowego na zbiorze uczącym wynosi 0.02, a na testowym 0.06. Wyższa wartość błędów na zbiorze testowym sygnalizuje przeuczenie modelu. Ogólnie model dobrze dopasował się do danych treningowych, lecz gorzej poradził na danych testowych. Podsumowując, model liniowy jest stabilniejszy, lecz zbyt prosty, co skutkuje błędami, natomiast wielomianowy lepiej dopasowuje się do danych, lecz traci zdolność generalizacji. Model liniowy jest bezpieczniejszym wyborem, mimo wyższego błędów treningowego.

2 Część 2 - porównanie metod klasyfikacji

2.1 Wstęp

W następnej części raportu będziemy pracować na zbiorze danych Wine z biblioteki HDcalssif. Naszym zadaniem będzie zastosowanie i porównanie algorytmów klasyfikacji takich jak metoda k-najbliższych sąsiadów, drzewa klasyfikacyjnego oraz naiwnego klasyfikatora bayesowskiego na zaimportowanej bazie danych.

2.2 Opis i wstępna analiza danych

Baza danych na której będziemy pracować zawiera informacje o wynikach analizy chemicznej win uprawianych w tych samych regionach Włoch, lecz pochodzących z trzech różnych odmian. Cechą dzięki której będziemy klasyfikować dane wino jest zmienna informująca o przynależności do odmiany wino.

Dane zawierają informacje o 178 winach, dla każdego z nich mamy 14 cech. Cecha class będzie nas informować o przynależności do klasy natomiast klasyfikacji posłuży nam 13 pozostałych cech. zmienna class zawiera 3 klasy służących do pogrupowania win.

	Typ	Opis
class	integer	przynależność do klasy wina
V1	numeric	zawartość alkoholu
V2	numeric	kwasy jabłkowe
V3	numeric	zawartość popiołu
V4	numeric	alkaliczność popiołu
V5	integer	zawartość magnezu
V6	numeric	łączna zawartość fenoli
V7	numeric	flawonoidy
V8	numeric	fenole nieflawonoidowe
V9	numeric	proantocyjaniny
V10	numeric	intensywność barwy
V11	numeric	odcień koloru
V12	numeric	OD280/OD315 rozcieńczonych win
V13	integer	zawartość proliny

Tabela 8: Typy oraz opisy cech zbioru wine

Na podstawie powyższej tabeli można stwierdzić że wszystkie typy zmiennych zostały prawidłowo zakodowane, poza zmienną class. Dla której zmieniliśmy typ na factor.

W poniższej tabeli znajdują się statystyki opisowe zmiennych, dzięki czemu możliwe jest wstępne zapoznanie się z danymi oraz identyfikacja podstawowych nieprawidłowości.


class	V1	V2	V3	V4
1:59	Min. :11.03	Min. :0.740	Min. :1.360	Min. :10.60
2:71	1st Qu.:12.36	1st Qu.:1.603	1st Qu.:2.210	1st Qu.:17.20
3:48	Median :13.05	Median :1.865	Median :2.360	Median :19.50
	Mean :13.00	Mean :2.336	Mean :2.367	Mean :19.49
	3rd Qu.:13.68	3rd Qu.:3.083	3rd Qu.:2.558	3rd Qu.:21.50
	Max. :14.83	Max. :5.800	Max. :3.230	Max. :30.00

V5	V6	V7	V8	V9
Min. : 70.00	Min. :0.980	Min. :0.340	Min. :0.1300	Min. :0.410
1st Qu.: 88.00	1st Qu.:1.742	1st Qu.:1.205	1st Qu.:0.2700	1st Qu.:1.250
Median : 98.00	Median :2.355	Median :2.135	Median :0.3400	Median :1.555
Mean : 99.74	Mean :2.295	Mean :2.029	Mean :0.3619	Mean :1.591
3rd Qu.:107.00	3rd Qu.:2.800	3rd Qu.:2.875	3rd Qu.:0.4375	3rd Qu.:1.950
Max. :162.00	Max. :3.880	Max. :5.080	Max. :0.6600	Max. :3.580

V10	V11	V12	V13
Min. : 1.280	Min. :0.4800	Min. :1.270	Min. : 278.0
1st Qu.: 3.220	1st Qu.:0.7825	1st Qu.:1.938	1st Qu.: 500.5
Median : 4.690	Median :0.9650	Median :2.780	Median : 673.5
Mean : 5.058	Mean :0.9574	Mean :2.612	Mean : 746.9
3rd Qu.: 6.200	3rd Qu.:1.1200	3rd Qu.:3.170	3rd Qu.: 985.0
Max. :13.000	Max. :1.7100	Max. :4.000	Max. :1680.0

Tabela 9: Podsumowanie danych zbioru wine

W danych nie występują wartości NA. Na podstawie powyższej tabeli można również stwierdzić brak występowania wartości 0, ponieważ minimalna wartość dla każdej cechy jest różna od 0. Jedynie zmienna v13 cechuje się dużą zmiennością w porównaniu do pozostałych zmiennych.



Na powyższym wykresie widzimy rozkład przynależności poszczególnych obserwacji do danej klasy. Możemy zauważyć, że najwięcej obserwacji należy do klasy 2, natomiast najmniej do klasy 3.

Oznacza to, że występują pewne dysproporcje w liczebności klas, jednak nie są one skrajne.


Jeśli wszystkie obserwacje zostałyby przypisane do najczęściej występującej klasy (klasa 2), to błąd klasyfikacji wyniósłby:

$$\text{błąd} = 1 - \frac{n_{\max}}{n},$$


gdzie: $n_{\max}$ to liczba obserwacji na najliczniejszej klasie, a n to liczba wszystkich obserwacji.

Błąd wynosi 0.6011236.

Oznacza to, że około 60% obserwacji zostałoby błędnie sklasyfikowanych, a taki klasyfikator osiągnąłby jedynie około 40% skuteczności.



Na powyższym wykresie znajdują się rozkłady wariancji dla wszystkich cech poza zmienną class. Możemy zauważyć, że ostatnia zmienna cechuje się najwyższą zmiennością i konieczne jest zastosowanie standaryzacji aby algorytm klasyfikujący działał poprawnie.



widzimy że po standaryzacji zmienne mają zbliżone wariancje, co pozytywnie wpłynie na działanie algorytmów.

	LD1	LD2
V1	-0.403	0.872
V2	0.165	0.305
V3	-0.369	2.346
V4	0.155	-0.146
V5	-0.002	0.000
V6	0.618	-0.032
V7	-1.661	-0.492
V8	-1.496	-1.631
V9	0.134	-0.307
V10	0.355	0.253
V11	-0.818	-1.516
V12	-1.158	0.051
V13	-0.003	0.003

Tabela 10: Współczynniki funkcji dyskryminacyjnych LDA (LD1, LD2)

W celu znalezienia zmiennych, które charakteryzują się najlepszymi zdolnościami dyskryminacyjnymi, zastosowano model Liniowej Analizy Dyskryminacyjnej (LDA). Model ten dokonuje transformacji pierwotnej przestrzeni cech w nową przestrzeń o niższej wymiarowości ($K - 1$, gdzie K to liczba klas). największe wartości bezwzględne współczynników w funkcjach dyskryminacyjnych LDA.

W szczególności zmienne V3, V7, V8, V11 oraz V12 wykazują największy wkład w separację klas, co oznacza, że najlepiej różnicują obserwacje należące do różnych grup.

Pierwsza funkcja dyskryminacyjna (LD1) wyjaśnia 68.75% zmienności między klasami, natomiast druga (LD2) 31.25%, co oznacza, że większość informacji separacyjnej zawarta jest w LD1.

geminik Analiza wag pokazała, że największe wartości bezwzględne współczynników w funkcjach dyskryminacyjnych LDA wykazują zmienne V3, V7, V8, V11 oraz V12. To one charakteryzują się największym wkładem w separację i najlepiej różnicują obserwacje. Ponieważ analiza została przeprowadzona na danych ustandaryzowanych, wielkości te bezpośrednio odzwierciedlają realną siłę dyskryminacyjną cech, a ich przeciwne znaki odpowiadają za rozsuwanie klas w przeciwległe krańce przestrzeni.

Pierwsza funkcja dyskryminacyjna (LD1) wyjaśnia 68.75% zmienności między klasami, natomiast druga (LD2) 31.25%

czat: Analiza LDA została wykorzystana do oceny zdolności dyskryminacyjnych zmiennych. Największy wpływ na separację klas mają zmienne V7, V8, V11, V12 oraz V3, ponieważ osiągnęły najwyższe wartości bezwzględne współczynników funkcji dyskryminacyjnych.

Pierwsza funkcja dyskryminacyjna (LD1) odpowiada za 68.75% całkowitej separacji klas, natomiast druga funkcja (LD2) za 31.25%. Oznacza to, że większość informacji potrzebnej do

rozdzielania klas zawiera się w LD1.

Dodatkowo analiza średnich grupowych wskazuje, że wybrane zmienne przyjmują wyraźnie różne wartości w poszczególnych klasach, co potwierdza ich wysoką zdolność predykcyjną.

2.3 Ocena dokładności klasyfikacji i porównanie metod

W dalszej części raportu porównamy działanie algorytmów klasyfikujących takich jak naive, tree, i knn na naszym zbiorze wine. Na początku podzielimy zbiór na dwa podzbiory pierwszy treningowy następny uczący. Zbiór uczący będzie zawierał 70% danych. Do podziału została użyta biblioteka `caret` zachowująca proporcje w danych.

od czasu trochę więcej

1	2	3
42	0	0
3	47	0
0	0	34

Tabela 11: Macierz pomyłek – k-NN, zbiór uczący

1	2	3
17	0	0
1	18	2
0	0	14

Tabela 12: Macierz pomyłek – k-NN, zbiór testowy

Powyższa tabela zawiera wyniki działania klasyfikatora knn dla 5 sąsiedów dla widzimy że macierz pomyłek dla train i test nie zawiera maskowania danych na przekatnych znajduje się większość informacji oraz błąd klasyfikacji dla train wynosi 2.3 % a dla testu 5.7 % wartości są relatywnie zbliżone do siebie co świadczy że model nie jest przetrenowany. (tu się zastanawiam czy czegoś jeszcze nie dodać z tych wyników)

1	2	3
42	0	0
0	50	0
0	0	34

Tabela 13: Macierz pomyłek – drzewo, zbiór uczący

1	2	3
17	0	0
0	21	0
0	0	14

Tabela 14: Macierz pomyłek – drzewo, zbiór testowy

Otrzymane wyniki świadczą o bezbłędnej klasyfikacji zarówno na zbiorze uczącym jak i testowym, co świadczy o dobrych własnościach klasyfikacyjnych algorytmu drzew decyzyjnych. Z uwagi na fakt podział danych na zbiór uczący i testowy zostały wykonane porównanie a wynik 100% występuje również na danych testowych, możemy wykluczyć przetrenowanie modelu. - tego nie jestem pewna

1	2	3
42	0	0
0	50	0
0	0	34

Tabela 15: Macierz pomyłek – naive Bayes, zbiór uczący

1	2	3
16	1	0
0	21	0
0	0	14

Tabela 16: Macierz pomyłek – naive Bayes, zbiór testowy

Wyniki klasyfikacji dla modelu naive bayes dla zbioru uczącego wykazują 100% dokładności model bezbłędnie dopasował dane, natomiast wynik błędu dla zbioru testowego wynosi 1.92 co świadczy o bardzo dobrym działaniu modelu i braku przetrenowania go. Również nie występuje zjawisko maskowania danych na przekątnej macierzy znajduje się zdecydowanie większość danych.

Następnie w celu porównania działania algorytmów przeprowadzimy klasyfikacje lecz zastosujemy bardziej zaawansowany schemat oceny dokładności. Użyjemy metody cross validation.

k	Accuracy
5	0.969
7	0.960
9	0.952
11	0.944
13	0.960

Tabela 17: Wyniki 10-krotnej walidacji krzyżowej – k-NN (wg parametru k)

tu tabele na innym podzbiorze do porównania

k	Accuracy
5	0.866
7	0.874
9	0.882
11	0.858
13	0.872

Tabela 18: Wyniki CV – k-NN na podzbiorze cech V3, V7, V8, V11, V12

[DO PRZEPISANIA: do CV k-NN dodano standaryzację (**preProcess**), bo wcześniej jej brakowało, a przy pojedynczym podziale była. Teraz CV k-NN daje najlepszy wynik (k=5) ok. 96.9%, czyli zbliżony do pojedynczego podziału (ok. 94.2%), a NIE 74%. Dlatego poniższa interpretacja jest nieaktualna i wymaga zmiany: (1) spadek do 74% NIE wynikał z optywizmu pojedynczego podziału, tylko z braku standaryzacji w CV; teraz oba schematy są spójne; (2) dokładność najlepszego k to ok. 96.9%, a nie 74%; (3) zdanie, że dokładność „generalnie rośnie wraz z k”, jest błędne — po standaryzacji najlepsze jest k=5.]

Wyniki uzyskane metodą cross-validation odnoszą się do zbioru treningowego, który został wielokrotnie dzielony na części uczące i walidacyjne. W związku z tym stanowią one bardziej stabilną ocenę modelu niż pojedynczy wynik na zbiorze treningowym, ale nadal nie są to wyniki na niezależnym zbiorze testowym.

W przypadku pojedynczego podziału uzyskano bardzo wysoką dokładność klasyfikacji na poziomie około 94% dla $k = 5$. Wynik ten może być jednak obarczony dużą zmiennością, ponieważ zależy od konkretnego losowego podziału danych.

Natomiast zastosowanie 10-krotnej walidacji krzyżowej dało bardziej stabilną ocenę skuteczności modelu, gdzie dla $k = 5$ uzyskano średnią dokładność na poziomie około 74%.

Różnica pomiędzy wynikami wskazuje, że pojedynczy podział może prowadzić do zawyżenia oceny jakości klasyfikatora, natomiast walidacja krzyżowa dostarcza bardziej wiarygodnej i uogólnionej oceny.

Zaobserwowano również, że wraz ze wzrostem wartości parametru k dokładność klasyfikacji generalnie rośnie, co sugeruje, że większa liczba sąsiadów stabilizuje decyzje klasyfikatora i zmniejsza wpływ szumu w danych.

Następnie w tabeli przedstawiono wyniki klasyfikatora k -NN dla różnych wartości parametru k na zmniejszonym zbiorze cech. Najwyższą wartość accuracy uzyskano dla $k = 9$. Zaobserwowano również, że wartości accuracy na podzbiorze cech są niższe niż w przypadku pełnego zestawu danych. Wskazuje to, że redukcja liczby cech ogranicza ilość informacji dostępnej dla modelu, co wpływa na pogorszenie jakości klasyfikacji.

cp	Accuracy
0.079	0.881
0.447	0.766
0.461	0.517

Tabela 19: Wyniki 10-krotnej walidacji krzyżowej – drzewo (wg parametru cp)

cp	Accuracy
0.000	0.833
0.201	0.873
0.401	0.566

Tabela 20: Wyniki CV – drzewo na podzbiorze cech V3, V7, V8, V11, V12

W pojedynczym podziale accuracy wyniosło 100 dla testów. Wynik ten wskazuje na bardzo wysoką skuteczność modelu drzewa decyzyjnego, jednak należy interpretować go ostrożnie, ponieważ może on wynikać z korzystnego podziału danych, niewielkiej liczby obserwacji w zbiorze testowym lub łatwej separowalności klas.

W celu oceny skuteczności drzewa decyzyjnego zastosowano metodę 10-krotnej walidacji krzyżowej (10-fold cross-validation). Model CART testował różne wartości parametru cp (complexity parameter), który kontroluje stopień przycinania drzewa i jego złożoność.

Najlepszy wynik uzyskano dla $cp = 0.0789$, dla którego model osiągnął dokładność klasyfikacji na poziomie około 88.7% oraz współczynnik Kappa równy 0.831. Oznacza to bardzo dobrą zgodność klasyfikacji oraz wysoką zdolność modelu do poprawnego rozróżniania klas.

Wraz ze wzrostem wartości parametru cp obserwowano spadek skuteczności modelu, co wskazuje, że zbyt silne przycinanie drzewa prowadzi do utraty informacji i pogorszenia jakości klasyfikacji.

Use kernel	Accuracy
FALSE	0.976
TRUE	0.960

Tabela 21: Wyniki 10-krotnej walidacji krzyżowej – Naive Bayes

Use kernel	Accuracy
FALSE	0.899
TRUE	0.904

Tabela 22: Wyniki CV – Naive Bayes na podzbiorze cech V3, V7, V8, V11, V12

W celu oceny skuteczności klasyfikatora Naive Bayes zastosowano 10-krotną walidację krzyżową. Model testował dwa warianty: z estymacją jądrową (`usekernel = TRUE`) oraz bez niej (`usekernel = FALSE`).

Najlepszy wynik uzyskano dla modelu bez estymacji jądrowej, który osiągnął dokładność klasyfikacji na poziomie około 97.6% oraz współczynnik Kappa równy 0.964. Oznacza to bardzo wysoką skuteczność klasyfikatora oraz bardzo dobrą zgodność przewidywań z rzeczywistymi klasami.

Wyniki wskazują, że klasy w analizowanym zbiorze danych są dobrze separowalne przy założeniu niezależności zmiennych, co sprzyja wysokiej skuteczności modelu Naive Bayes.

2.4 Różne parametry i podzbiory cech

one przeniesione wyżej lepiej porównywać

[DO NAPISANIA – komentarz do tabel na podzbiorze cech: porównać dokładność modeli na pełnym zestawie cech vs na podzbiorze V3, V7, V8, V11, V12 dla każdej z metod (k-NN, drzewo, naive Bayes); napisać, czy ograniczenie cech pomogło, zaszkodziło, czy nie zmieniło wyników.]

2.5 Podsumowanie

[DO NAPISANIA – końcowe wnioski (Zadanie 2f), wymagane w treści listy. Odpowiedzieć na trzy pytania: (1) dla jakiego podzbioru cech i jakich parametrów (np. k w k-NN, cp w drzewie, `usekernel` w naive Bayes) wyniki są najlepsze; (2) która metoda klasyfikacji wypada najlepiej, a która najgorzej na zbiorze wine; (3) czy wybór schematu oceny (pojedynczy podział vs walidacja krzyżowa) wpłynął na wnioski o skuteczności metod. Można podeprzeć się tabelami wyżej.]