

Sprawozdanie 3

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-05-22

Spis treści

1	Część 1 – klasyfikacja	2
1.1	Wstęp	2
1.2	Opis danych	2
2	Część 2 - porównanie metod klasyfikacji	4

1 Część 1 – klasyfikacja

1.1 Wstęp

Mamy zbiór danych zawierający wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatków (ang. *petal*). Naszym zadaniem będzie klasyfikowanie gatunku płatków na podstawie modelu regresji liniowej. Zmiennymi objaśniającymi będą cechy opisujące kwiaty (Pl, Pw, Sl, Sw), natomiast zmienną objaśnianą będzie gatunek. Cel dla zbioru testowego dopasować gatunek i ocenić jakość klasyfikatora. Dla 3 klas.



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

1.2 Opis danych

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

	Typ	Opis
Sepal.Length	numeric	długość działki kielicha (w cm)
Sepal.Width	numeric	szerokość działki kielicha (w cm)
Petal.Length	numeric	długość płatków (w cm)
Petal.Width	numeric	szerokość płatków (w cm)
Species	factor	gatunek irysa (<i>setosa</i> / <i>versicolor</i> / <i>virginica</i>)

Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
Min.: 4.300	Min.: 2.000	Min.: 1.000	Min.: 0.100
1st Qu.: 5.100	1st Qu.: 2.800	1st Qu.: 1.600	1st Qu.: 0.300
Median: 5.800	Median: 3.000	Median: 4.350	Median: 1.300
Mean: 5.843	Mean: 3.057	Mean: 3.758	Mean: 1.199
3rd Qu.: 6.400	3rd Qu.: 3.300	3rd Qu.: 5.100	3rd Qu.: 1.800
Max.: 7.900	Max.: 4.400	Max.: 6.900	Max.: 2.500

Tabela 2: Podsumowanie danych

1.2.1 Podział danych na zbiór uczący i testowy

Następnie w celu oceny jakości działania klasyfikatora podzieliliśmy zbiór danych na zbiór uczący i zbiór testowy w stosunku 1 do 2.

1.2.2 Konstrukcja klasyfikatora i wyznaczanie prognoz

Na podstawie zbioru danych będziemy estymować parametry modelu i następnie sprawdzać i jakos dopasowania do wartości gatunku. Dla zbioru testowego i wyuczonych parametrów będziemy dopasowywać gatunek kwiatu.

1.2.3 Ocena klasyfikacji

```
##               Prognozowane
## Rzeczywiste  setosa versicolor virginica
##   setosa      28         0         0
##   versicolor  0         28         9
##   virginica   0         6        29
## [1] 0.15
```

```
##               Prognozowane
## Rzeczywiste  setosa versicolor virginica
##   setosa      22         0         0
##   versicolor  0        11         2
##   virginica   0         5        10
## [1] 0.14
```

1.2.4 Model liniowy dla rozszerzonej przestrzeni klas

```
##               Prognozowane
## Rzeczywiste  setosa versicolor virginica
##   setosa      28         0         0
##   versicolor  0        28         9
##   virginica   0         6        29
```

```
## [1] 0.15

##          Prognozowane
## Rzeczywiste setosa versicolor virginica
##   setosa      22         0         0
## versicolor   0         11         2
## virginica    0          5        10

## [1] 0.14
```

2 Część 2 - porównanie metod klasyfikacji