

# Sprawozdanie 3

## Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-06-03


### Spis treści

|          |                                                             |          |
|----------|-------------------------------------------------------------|----------|
| <b>1</b> | <b>Część 1 – klasyfikacja</b>                               | <b>2</b> |
| 1.1      | Wstęp . . . . .                                             | 2        |
| 1.2      | Przypomnienie struktury danych . . . . .                    | 2        |
| 1.3      | Podział danych na zbiór uczący i testowy . . . . .          | 3        |
| 1.4      | Konstrukcja klasyfikatora i wyznaczanie prognoz . . . . .   | 3        |
| 1.5      | Ocena klasyfikacji . . . . .                                | 4        |
| 1.6      | Model liniowy dla rozszerzonej przestrzeni klas . . . . .   | 6        |
| <b>2</b> | <b>Część 2 - porównanie metod klasyfikacji</b>              | <b>7</b> |
| 2.1      | Wstęp . . . . .                                             | 7        |
| 2.2      | Opis i wstępna analiza danych . . . . .                     | 8        |
| 2.3      | Ocena dokładności klasyfikacji i porównanie metod . . . . . | 12       |
| 2.4      | Różne parametry i podzbiory cech . . . . .                  | 17       |
| 2.5      | Podsumowanie . . . . .                                      | 17       |

# 1 Część 1 – klasyfikacja

## 1.1 Wstęp

Pracujemy na tym samym zbiorze danych danych co w poprzednim sprawozdaniu. Zbiór zawiera wyniki pomiarów przedstawicieli trzech gatunków irysów: *Iris setosa*, *Iris versicolor* oraz *Iris virginica*. Pomiary dotyczą długości oraz szerokości poszczególnych części kwiatu – działki kielicha (ang. *sepal*) oraz płatka (ang. *petal*). W przeciągu ostatniego miesiąca wygląd kwiatów się nie zmienił i nadal wyglądają one tak:



Rysunek 1: *Iris setosa* (źródło), *Iris versicolor* (źródło) oraz *Iris virginica* (źródło)

## 1.2 Przypomnienie struktury danych

W naszych danych znajdują się pomiary 150 irysów, po 50 z każdego gatunku. Dla każdego z nich mamy wyniki czterech pomiarów, oraz informację o tym do którego gatunku należy:

|              | Typ     | Opis                                                                   |
|--------------|---------|------------------------------------------------------------------------|
| Sepal.Length | numeric | długość działki kielicha (w cm)                                        |
| Sepal.Width  | numeric | szerokość działki kielicha (w cm)                                      |
| Petal.Length | numeric | długość płatka (w cm)                                                  |
| Petal.Width  | numeric | szerokość płatka (w cm)                                                |
| Species      | factor  | gatunek irysa ( <i>setosa</i> / <i>versicolor</i> / <i>virginica</i> ) |

Tabela 1: Typy oraz opisy cech

Wartości pomiarów prezentują się następująco:

| Sepal.Length   | Sepal.Width    | Petal.Length   | Petal.Width    |
|----------------|----------------|----------------|----------------|
| Min.: 4.300    | Min.: 2.000    | Min.: 1.000    | Min.: 0.100    |
| 1st Qu.: 5.100 | 1st Qu.: 2.800 | 1st Qu.: 1.600 | 1st Qu.: 0.300 |
| Median: 5.800  | Median: 3.000  | Median: 4.350  | Median: 1.300  |
| Mean: 5.843    | Mean: 3.057    | Mean: 3.758    | Mean: 1.199    |
| 3rd Qu.: 6.400 | 3rd Qu.: 3.300 | 3rd Qu.: 5.100 | 3rd Qu.: 1.800 |
| Max.: 7.900    | Max.: 4.400    | Max.: 6.900    | Max.: 2.500    |

Tabela 2: Podsumowanie danych

### 1.3 Podział danych na zbiór uczący i testowy

W celu oceny jakości działania klasyfikatora dzielimy zbiór danych na zbiór uczący `train_set` i zbiór testowy `test_set` w proporcjach 1 do 2:

```
set.seed(67) # ustawiamy seed losowania

n <- nrow(dane) # liczba obserwacji

# losujemy które obserwacje będą w zbiorze uczącym a które w testowym
train_index <- sample(1:n, size = round(2/3 * n))

# tworzymy osobne ramki danych dla obu zbiorów
train_set <- dane[train_index, ]
test_set <- dane[-train_index, ]
```

Zbiór uczący zawiera 100 obserwacji, a zbiór testowy 50.

### 1.4 Konstrukcja klasyfikatora i wyznaczanie prognoz

Będziemy konstruować klasyfikator oparty na regresji liniowej. W tym celu na podstawie zbioru uczącego (`train_set`) będziemy estymować parametry modelu.

Aby to zrobić, musimy najpierw zakodować klasy przy użyciu zmiennych binarnych (indykatory klas):

```
etykietki.klas <- train_set$Species

K <- length(unique(etykietki.klas)) # liczba klas (gatunków)
n.train <- nrow(train_set)           # liczba obserwacji uczących

# tworzymy macierz wskaźników klas i przypisujemy jej odpowiednie wartości
Y.train <- matrix(0, nrow = n.train, ncol = K)
etykietki.num <- as.numeric(etykietki.klas)
```

```
for(k in 1:K)
  Y.train[etykietki.num == k, k] <- 1
```

Następnie estymujemy parametry modelu za pomocą zbioru uczącego:

```
# macierz cech z dodatkową kolumną jedynek (wyraz wolny)
X.train <- as.matrix(cbind(1, train_set[,1:4]))

# estymacja współczynników metodą najmniejszych kwadratów:  $B=(X'X)^{-1} X'Y$ 
B.hat <- solve(t(X.train) %*% X.train) %*%
          t(X.train) %*% Y.train
```

Dla każdej obserwacji – zarówno ze zbioru uczącego i testowego – liczymy estymowane indykatory klas:

```
# dopasowane wskaźniki klas dla zbioru uczącego
Y.hat.train <- X.train %*% B.hat
pred.train <- apply(Y.hat.train, 1, which.max) # klasa = kolumna z największą wartością

# to samo dla zbioru testowego (kolumna jedynek jak w zbiorze uczącym)
X.test <- cbind(1, test_set[,1:4])
X.test <- as.matrix(X.test)

Y.hat.test <- X.test %*% B.hat
pred.test <- apply(Y.hat.test, 1, which.max)
```

## 1.5 Ocena klasyfikacji

W celu oceny klasyfikacji wyliczamy macierz pomyłek (ang. *confusion matrix*) oraz błąd klasyfikacji na zbiorze uczącym oraz testowym.

|                   | <i>setosa</i> | <i>versicolor</i> | <i>virginica</i> |
|-------------------|---------------|-------------------|------------------|
| <i>setosa</i>     | 28            | 0                 | 0                |
| <i>versicolor</i> | 0             | 28                | 9                |
| <i>virginica</i>  | 0             | 6                 | 29               |

Tabela 3: Macierz pomyłek dla zbioru uczącego (model liniowy). Wiersz oznacza faktyczny gatunek, a kolumna estymowany.


Na powyższej tabeli widzimy wyniki dopasowania gatunków do kwiatów. Błąd klasyfikacji (proporcja źle sklasyfikowanych obserwacji do wszystkich obserwacji) wynosi 15%. Taka wysoka wartość wynika z mylenia przez model gatunków *versicolor* oraz *virginica* – jak na to że jest to zbiór uczący, sugeruje to że ciężko jest te gatunki rozdzielić.

Zjawisko maskowania klas nie występuje – gdyby występowało, któraś z klas byłaby przewidywana znacząco rzadziej niż występuje. W naszym przypadku tak nie jest. Pomaga nam to, że liczba  $p = 4$  zmiennych objaśniających jest większa od liczby  $K = 3$  klas, dzięki czemu „wymiarowość” gra trochę na naszą korzyść.

|                   | <i>setosa</i> | <i>versicolor</i> | <i>virginica</i> |
|-------------------|---------------|-------------------|------------------|
| <i>setosa</i>     | 22            | 0                 | 0                |
| <i>versicolor</i> | 0             | 11                | 2                |
| <i>virginica</i>  | 0             | 5                 | 10               |

Tabela 4: Macierz pomyłek dla zbioru testowego (model liniowy). Wiersz oznacza faktyczny gatunek, a kolumna estymowany.

Dla zbioru testowego błąd klasyfikacji wynosi 14%; zbliżona wartość błędów dla zbioru uczącego i testowego świadczy, że model nie jest przetrenowany i dobrze klasyfikuje dane.



Rysunek 2: Wartości wskaźników klas  $\hat{Y}$  (estymatorów indykatorów) dla modelu liniowego (zbiór uczący). Oś  $x$  nic nie oznacza i ma na celu tylko rozdzielenie gatunków. Od lewej: *setosa*, *versicolor*, *virginica*.

Na wykresie widać, że najlepszą separowalność uzyskano dla kwiatów z gatunku *setosa*, o czym świadczą wysokie wartości wskaźników dla ich własnej klasy i niskie dla pozostałych.

W przypadku *versicolor* i *virginica*, wartości wskaźników właściwych klas są niższe niż w przypadku *setosa*, niewiele większe od wartości wskaźników o drugich najwyższych wartościach – wskaźników *virginica* w przypadku *versicolor* oraz vice versa. Powoduje to trudność w

rozróżnieniu przez model kwiatów tych dwóch gatunków, co zostało zauważone już przy macierzy pomyłek.

## 1.6 Model liniowy dla rozszerzonej przestrzeni klas

Teraz przeprowadzimy klasyfikację gatunków irysów na rozszerzonej przestrzeni cech. W tym celu zbudujemy nowy model liniowy dla tych cech. Nasza nowa przestrzeń cech zawiera oryginalne zmienne  $PL$ ,  $PW$ ,  $SL$  i  $SW$  oraz składniki wielomianowe stopnia 2:  $PL^2$ ,  $PW^2$ ,  $SL^2$ ,  $SW^2$ ,  $PL \cdot PW$ ,  $PL \cdot SL$ ,  $PL \cdot SW$ ,  $PW \cdot SL$ ,  $PW \cdot SW$  oraz  $SL \cdot SW$ .

Model konstruujemy analogicznie jak poprzednio z uprzednim dodaniem nowych cech.

W celu porównania dokładności klasyfikacji modelu z poprzednim, przeanalizujemy wyniki klasyfikacji w podobny sposób jak wcześniejsze, zaczynając od analizy macierzy pomyłek oraz błędów klasyfikacji.

|            | setosa | versicolor | virginica |
|------------|--------|------------|-----------|
| setosa     | 28     | 0          | 0         |
| versicolor | 0      | 36         | 1         |
| virginica  | 0      | 1          | 34        |

Tabela 5: Macierz pomyłek dla zbioru uczącego (model wielomianowy)


Od razu widzimy lepszą separowalność gatunków dla samego zbioru uczącego niż w przypadku poprzedniego modelu – błąd klasyfikacji wynosi jedynie 2% w porównaniu do wcześniejszych 15%. Sugeruje to, że zależności gatunków między irysami nie są liniowe, ponieważ wprowadzenie dodatkowych cech pozwoliło na lepsze odseparowanie klas.

Ponownie nie występuje zjawisko maskowania klas.

|            | setosa | versicolor | virginica |
|------------|--------|------------|-----------|
| setosa     | 22     | 0          | 0         |
| versicolor | 0      | 13         | 0         |
| virginica  | 0      | 3          | 12        |

Tabela 6: Macierz pomyłek dla zbioru testowego (model wielomianowy)

Na zbiorze testowym błąd klasyfikacji wynosi 6%. Jest to gorszy wynik niż w zbiorze uczącym. Może to sugerować drobne przeuczenie modelu, lecz może równie dobrze być to błąd statystyczny wynikający z małej liczebności próby. Wynik ten wciąż jest lepszy od wyniku w poprzednim modelu (14%).



Rysunek 3: Wartości wskaźników klas  $\hat{Y}$  (estymatorów indyktorów) dla modelu wielomianowego (zbiór uczący). Oś  $x$  nie oznacza i ma na celu tylko rozdzielenie gatunków. Od lewej: *setosa*, *versicolor*, *virginica*.

W nowym modelu wykres wskaźników klas wygląda dużo przyjemniej. Dla wszystkich gatunków wartości właściwych wskaźników są prawie wszystkie w okolicy 1, a niewłaściwych w okolicy 0.

Wciąż jest odrobinę lepiej w przypadku *setosa*, niż w przypadku *versicolor* i *virginica*, lecz dwa ostatnie gatunki są o wiele lepiej traktowane niż w poprzednim modelu i tylko czasami są mylone.

Ogółem, model rozszerzony o składniki wielomianowe stopnia 2 radzi sobie lepiej z klasyfikacją niż model bez tych składników, co pozwala nam na lepszą klasyfikację gatunków naszych kwiatów i sprawia że jesteśmy szczęśliwsi.

## 2 Część 2 - porównanie metod klasyfikacji

### 2.1 Wstęp

W tej części raportu będziemy pracować na zbiorze danych Wine z R-pakietu `HDclassif`. Zbiór danych zawiera informacje o wynikach analizy chemicznej win uprawianych w tych samych regionach Włoch, lecz będących trzech różnych odmian. **jak będzie czas: jakie to odmiany?**

Naszym zadaniem będzie zastosowanie i porównanie algorytmów klasyfikacji k-najbliższych sąsiadów, drzewa klasyfikacyjnego oraz naiwnego klasyfikatora Bayesowskiego na tym zbiorze danych.

Cechą według której będziemy klasyfikować wina jest zmienna informująca o przynależności do odmiany wina.

## 2.2 Opis i wstępna analiza danych

Dane zawierają informacje o 178 winach. Dla każdego z nich mamy informacje o 14 cechach.

Cecha `class` będzie nas informować o przynależności do klasy, natomiast do klasyfikacji posłuży nam 13 pozostałych cech dotyczących różnych parametrów wina. Zmienna `class` zawiera informacje o przynależności do jednej z 3 klas, czyli odmian wina.

|                    | Typ                  | Opis                           |
|--------------------|----------------------|--------------------------------|
| <code>class</code> | <code>integer</code> | przynależność do klasy wina    |
| <code>V1</code>    | <code>numeric</code> | zawartość alkoholu             |
| <code>V2</code>    | <code>numeric</code> | kwask jabłkowy                 |
| <code>V3</code>    | <code>numeric</code> | zawartość popiołu              |
| <code>V4</code>    | <code>numeric</code> | alkaliczność popiołu           |
| <code>V5</code>    | <code>integer</code> | zawartość magnezu              |
| <code>V6</code>    | <code>numeric</code> | łączna zawartość fenoli        |
| <code>V7</code>    | <code>numeric</code> | flawonoidy                     |
| <code>V8</code>    | <code>numeric</code> | fenole nieflawonoidowe         |
| <code>V9</code>    | <code>numeric</code> | proantocyjaniny                |
| <code>V10</code>   | <code>numeric</code> | intensywność barwy             |
| <code>V11</code>   | <code>numeric</code> | odcień koloru                  |
| <code>V12</code>   | <code>numeric</code> | OD280/OD315 rozcieńczonych win |
| <code>V13</code>   | <code>integer</code> | zawartość proliny              |

Tabela 7: Typy oraz opisy cech zbioru wine

Na podstawie powyższej tabeli można stwierdzić że wszystkie typy zmiennych zostały prawidłowo zakodowane, poza zmienną `class`, która została wczytana jako typ `integer` zamiast `factor`.

Zmienne `V5` (zawartość magnezu) oraz `V13` (zawartość proliny) zostały wczytane jako `integer`. Wynika to z tego, że w danych występują jedynie wartości całkowite, prawdopodobnie z powodu zaokrąglenia. Wartości tych cech jak najbardziej mogłyby być niecałkowite, więc bardziej pasuje typ `numeric`.

Korektujemy typy wspomnianych zmiennych:

```
dane2$class <- as.factor(dane2$class)
dane2$V5 <- as.numeric(dane2$V5)
dane2$V13 <- as.numeric(dane2$V13)
```

W poniższej tabeli znajdują się statystyki opisowe zmiennych, dzięki którym możliwe będzie wstępne zapoznanie się z danymi oraz identyfikacja podstawowych nieprawidłowości.



| class | V1            | V2            | V3            | V4            |
|-------|---------------|---------------|---------------|---------------|
| 1:59  | Min. :11.03   | Min. :0.740   | Min. :1.360   | Min. :10.60   |
| 2:71  | 1st Qu.:12.36 | 1st Qu.:1.603 | 1st Qu.:2.210 | 1st Qu.:17.20 |
| 3:48  | Median :13.05 | Median :1.865 | Median :2.360 | Median :19.50 |
|       | Mean :13.00   | Mean :2.336   | Mean :2.367   | Mean :19.49   |
|       | 3rd Qu.:13.68 | 3rd Qu.:3.083 | 3rd Qu.:2.558 | 3rd Qu.:21.50 |
|       | Max. :14.83   | Max. :5.800   | Max. :3.230   | Max. :30.00   |


| V5             | V6            | V7            | V8             | V9            |
|----------------|---------------|---------------|----------------|---------------|
| Min. : 70.00   | Min. :0.980   | Min. :0.340   | Min. :0.1300   | Min. :0.410   |
| 1st Qu.: 88.00 | 1st Qu.:1.742 | 1st Qu.:1.205 | 1st Qu.:0.2700 | 1st Qu.:1.250 |
| Median : 98.00 | Median :2.355 | Median :2.135 | Median :0.3400 | Median :1.555 |
| Mean : 99.74   | Mean :2.295   | Mean :2.029   | Mean :0.3619   | Mean :1.591   |
| 3rd Qu.:107.00 | 3rd Qu.:2.800 | 3rd Qu.:2.875 | 3rd Qu.:0.4375 | 3rd Qu.:1.950 |
| Max. :162.00   | Max. :3.880   | Max. :5.080   | Max. :0.6600   | Max. :3.580   |

| V10            | V11            | V12           | V13            |
|----------------|----------------|---------------|----------------|
| Min. : 1.280   | Min. :0.4800   | Min. :1.270   | Min. : 278.0   |
| 1st Qu.: 3.220 | 1st Qu.:0.7825 | 1st Qu.:1.938 | 1st Qu.: 500.5 |
| Median : 4.690 | Median :0.9650 | Median :2.780 | Median : 673.5 |
| Mean : 5.058   | Mean :0.9574   | Mean :2.612   | Mean : 746.9   |
| 3rd Qu.: 6.200 | 3rd Qu.:1.1200 | 3rd Qu.:3.170 | 3rd Qu.: 985.0 |
| Max. :13.000   | Max. :1.7100   | Max. :4.000   | Max. :1680.0   |

Tabela 8: Podsumowanie danych zbioru wine

W danych nie występują wartości NA. Braki zakodowane w inny sposób raczej nie występują – na pewno nie występują braki zapisane jako 0, ponieważ wartości 0 nie występują wcale.

W podsumowaniu możemy zauważyć także znacząco różną zmienność w przypadku zmiennej V13 (zawartość proliny) niż w przypadku pozostałych zmiennych. Może to wskazywać na ewentualną potrzebę standaryzacji przy niektórych metodach.




Rysunek 4: Rozkład licznosci klas (odmian wina) w zbiorze `wine`.

Na powyższym wykresie widzimy rozkład licznosci klas. Możemy zauważyć, że najwięcej obserwacji należy do klasy 2, natomiast najmniej do klasy 3. Różnice nie są jednak znaczące, licznosci klas są w miarę zbalansowane.


Klasyfikator przypisujący wszystkie obserwacje do najczęściej występującej klasy miałby błąd klasyfikacji na poziomie 60%, czyli częściej by się mylił niż zgadywał dobrze.

Na poniższym wykresie znajdują się rozkłady wariancji dla wszystkich cech ilościowych:



Rysunek 5: Wykresy pudełkowe cech ilościowych przed standaryzacją.

Jak już zauważyliśmy wcześniej, zmienna `V13` (zawartość proliny) cechuje się znacznie wyższą zmiennością. W związku z tym konieczne jest zastosowanie standaryzacji aby algorytmy klasyfikujące działały poprawnie.



Rysunek 6: Wykresy pudełkowe cech ilościowych po standaryzacji.

Widzimy, że po standaryzacji zmienne mają zbliżone wariancje, co pozytywnie wpłynie na działanie algorytmów.

## CO TO JEST TO LDAAAAAAAAAAAA

[LDA – sekcja zostaje. DECYZJA WDROŻONA: lda liczymy na danych ustandaryzowanych. Powód: standaryzacja nie zmienia ani klasyfikacji (błąd resubstytucji = 0), ani udziałów LD1/LD2 (68.75%/31.25%) – zmienia tylko wielkości współczynników `model$scaling`, czyli ranking cech, czyniąc go interpretowalnym i niezależnym od skali. Ranking na danych std (V7, V13, V12, V1, V10) pokrywa się z niezależnym rankingiem opisowym ( $\eta^2$  z jednoczynnikowej ANOVA), podczas gdy surowe lda wypychało do topu cechy słabo separujące (V3, V8) – artefakt jednostek pomiaru. Podzbiór V7, V13, V12, V1, V10 wdrożony w całej Części 2; wariant „bez standaryzacji” odrzucony.]

W celu wskazania zmiennych o najlepszych zdolnościach dyskryminacyjnych zastosowano model liniowej analizy dyskryminacyjnej (LDA) na danych ustandaryzowanych. Model przekształca pierwotną przestrzeń cech w przestrzeń o niższej wymiarowości ( $K - 1$ , gdzie  $K$  to liczba klas). Ponieważ cechy wcześniej ustandaryzowano, wartości bezwzględne współczynników funkcji dyskryminacyjnych odzwierciedlają realną siłę dyskryminacyjną cech, a nie ich skalę (na surowych danych ranking byłby zaburzony jednostkami pomiaru).

|     | LD1    | LD2    |
|-----|--------|--------|
| V1  | -0.327 | 0.708  |
| V2  | 0.185  | 0.341  |
| V3  | -0.101 | 0.644  |
| V4  | 0.517  | -0.489 |
| V5  | -0.031 | -0.007 |
| V6  | 0.387  | -0.020 |
| V7  | -1.659 | -0.491 |
| V8  | -0.186 | -0.203 |
| V9  | 0.077  | -0.176 |
| V10 | 0.823  | 0.587  |
| V11 | -0.187 | -0.346 |
| V12 | -0.822 | 0.036  |
| V13 | -0.847 | 0.898  |

Tabela 9: Współczynniki funkcji dyskryminacyjnych LDA (LD1, LD2)

Największy wkład w separację klas mają zmienne V7 (flawonoidy), V13 (zawartość proliny), V12 (OD280/OD315 rozcieńczonych win), V1 (zawartość alkoholu) oraz V10 (intensywność barwy) – to one najlepiej różnicują obserwacje należące do różnych odmian. Pierwsza funkcja dyskryminacyjna (LD1) wyjaśnia 68.75% zmienności między klasami, a druga (LD2) 31.25%, co oznacza, że większość informacji separacyjnej zawarta jest w LD1. Ten zestaw pięciu cech wykorzystamy dalej do porównania metod klasyfikacji na zmniejszonej liczbie zmiennych.

## 2.3 Ocena dokładności klasyfikacji i porównanie metod

W dalszej części raportu porównamy działanie algorytmów klasyfikujących takich jak naive, tree, i knn na naszym zbiorze wine. Na początku podzielimy zbiór na dwa podzbiory pierwszy treningowy następny uczący. Zbiór uczący będzie zawierał 70% danych. Do podziału została użyta biblioteka caret zachowująca proporcje w danych.

od czacika troche madre

[OPIS POJEDYNCZEGO PODZIAŁU (część wymogu 2d): zarys JEST już w akapicie wyżej (70%, `createDataPartition`, `caret`, proporcje klas), ale w błędach i z placeholderem „od czacika troche madre” do usunięcia. Pełniejsza, poprawna wersja siedzi PONIŻEJ w komentarzu HTML (`<!-- ... -->`) i NIE renderuje się w PDF. CO ZROBIĆ: scalić to w jeden poprawny akapit (po polsku, bez błędów), a duplikaty – placeholder i komentarze HTML – skasować. Treść: podział 70/30 `createDataPartition` z zachowaniem proporcji klas; standaryzacja cech (k-NN działa na odległościach); dla każdej metody macierz pomyłek + błąd na zbiorze uczącym i testowym, a różnica między nimi mówi o przeuczeniu; k-NN liczymy dla  $k = 5$ .]

| 1  | 2  | 3  |
|----|----|----|
| 42 | 0  | 0  |
| 3  | 47 | 0  |
| 0  | 0  | 34 |

Tabela 10: Macierz pomyłek – k-NN, zbiór uczący

| 1  | 2  | 3  |
|----|----|----|
| 17 | 0  | 0  |
| 1  | 18 | 2  |
| 0  | 0  | 14 |

Tabela 11: Macierz pomyłek – k-NN, zbiór testowy

Powyzsza tabela zawiera wyniki dziala klasyfikatora knn dla 5 sa saidów dla widzimy ze macierz pomylek dla train i test nie zawiera maskowania dancyh na przekatnych znajduje sie wiekszosc informacji oraz blad klasyfikacji dla train wynosi 2.4% a dla tets 5.8% wartosci sa relatywnie zblizone do siebie co swiadczy ze mdoel nie jest przetrenowany. (tu sie zastanawiam czy czegos cjeszce nie odaodac z tych wyników)

| 1  | 2  | 3  |
|----|----|----|
| 42 | 0  | 0  |
| 0  | 50 | 0  |
| 0  | 0  | 34 |

Tabela 12: Macierz pomyłek – drzewo, zbiór uczący

| 1  | 2  | 3  |
|----|----|----|
| 17 | 0  | 0  |
| 0  | 21 | 0  |
| 0  | 0  | 14 |

Tabela 13: Macierz pomyłek – drzewo, zbiór testowy

Otrzymane wyniki swiadcza o bezblednej klasyfikacji zarowno na zbiorze uczacym jak i testowym, co swiadczy od bardzi=o dobrych wlasnoscich kalsyfikacyjnych algorytmu drzew decyzyjnych. Z uwagi na fakt podzial dancyh na zbior uczaci i testowy zostaly wykonane porawnie a wynik 100% wystepuje ronwiez na danych testowych, mozmy wykluczyc przetre-nowanie modelu. - tego nie jestem pewna

| 1  | 2  | 3  |
|----|----|----|
| 42 | 0  | 0  |
| 0  | 50 | 0  |
| 0  | 0  | 34 |

Tabela 14: Macierz pomyłek – naive Bayes, zbiór uczący

| 1  | 2  | 3  |
|----|----|----|
| 16 | 1  | 0  |
| 0  | 21 | 0  |
| 0  | 0  | 14 |

Tabela 15: Macierz pomyłek – naive Bayes, zbiór testowy

Wyniki kasyfikacji dla modelu naive bayes dla zbioru uczącego wykazują 100% dokładności model bezlednie dopasował dane, natomiast wynik błędu dla zbioru testowego wynosi 1.92% co świadczy o bardzo dobrym działaniu modelu i braku przetrenowania go. Również nie występuje zjawisko maskowania klas na przekątnej macierzy znajduje się zdecydowanie większość danych.

Następnie w celu porównania działania algorytmów przeprowadzimy klasyfikację lecz zastosujemy bardziej zaawansowany schemat oceny dokładności. Użyliśmy metody cross validation.

| k  | Accuracy |
|----|----------|
| 5  | 0.969    |
| 7  | 0.960    |
| 9  | 0.952    |
| 11 | 0.944    |
| 13 | 0.960    |

Tabela 16: Wyniki 10-krotnej walidacji krzyżowej – k-NN (wg parametru k)

tu tabelę na innym podzbiórzie do porównania

| k  | Accuracy |
|----|----------|
| 5  | 0.968    |
| 7  | 0.985    |
| 9  | 0.977    |
| 11 | 0.977    |
| 13 | 0.985    |

Tabela 17: Wyniki CV – k-NN na podzbiorze cech V7 (flawonoidy), V13 (zawartość proliny), V12 (OD280/OD315 rozcieńczonych win), V1 (zawartość alkoholu), V10 (intensywność barwy)

Wyniki uzyskane metodą cross-validation odnoszą się do zbioru treningowego, który został wielokrotnie dzielony na części uczące i walidacyjne. W związku z tym stanowią one bardziej stabilną ocenę modelu niż pojedynczy wynik na zbiorze treningowym, ale nadal nie są to wyniki na niezależnym zbiorze testowym.

W przypadku pojedynczego podziału k-NN dla  $k = 5$  uzyskano dokładność klasyfikacji na zbiorze testowym na poziomie 94.2%. Wynik ten może być jednak obarczony dużą zmiennością, ponieważ zależy od konkretnego losowego podziału danych.

Zastosowanie 10-krotnej walidacji krzyżowej dało zbliżoną, równie wysoką ocenę skuteczności – najlepszy wynik uzyskano dla  $k = 5$ , ze średnią dokładnością na poziomie 96.9%.

Zbieżność obu ocen świadczy o tym, że wysoka skuteczność k-NN nie jest artefaktem jednego korzystnego podziału. Walidacja krzyżowa pozostaje przy tym oceną bardziej wiarygodną, ponieważ uśrednia wynik po wielu podziałach danych.

Najlepszą dokładność osiągnięto dla niewielkiej liczby sąsiadów ( $k = 5$ ); dokładność nie rośnie monotonicznie wraz z  $k$  – zbyt duże  $k$  nadmiernie wygładza granice decyzyjne i pogarsza klasyfikację.

Następnie w tabeli przedstawiono wyniki k-NN dla różnych wartości parametru  $k$  na podzbiorze pięciu cech wybranych przez LDA – V7 (flawonoidy), V13 (zawartość proliny), V12 (OD280/OD315 rozcieńczonych win), V1 (zawartość alkoholu) oraz V10 (intensywność barwy). Najwyższą dokładność uzyskano dla  $k = 7$ , a jej poziom (98.5%) jest zbliżony do wyniku na pełnym zestawie cech (96.9%). Oznacza to, że te pięć cech niesie niemal całą informację różnicującą klasy, więc redukcja wymiaru praktycznie nie pogarsza jakości klasyfikacji.

| cp    | Accuracy | Kappa | AccuracySD | KappaSD |
|-------|----------|-------|------------|---------|
| 0.079 | 0.887    | 0.831 | 0.098      | 0.145   |
| 0.447 | 0.770    | 0.648 | 0.194      | 0.303   |
| 0.461 | 0.523    | 0.242 | 0.112      | 0.200   |

Tabela 18: Wyniki 10-krotnej walidacji krzyżowej – drzewo (wg parametru cp)

| cp    | Accuracy |
|-------|----------|
| 0.079 | 0.889    |
| 0.447 | 0.797    |
| 0.461 | 0.566    |

Tabela 19: Wyniki CV – drzewo na podzbiorze cech V7 (flawonoidy), V13 (zawartość proliny), V12 (OD280/OD315 rozcieńczonych win), V1 (zawartość alkoholu), V10 (intensywność barwy)

W pojedynczym podziale accuracy wyniosło 100% dla test set. Wynik ten wskazuje na bardzo wysoką skuteczność modelu drzewa decyzyjnego, jednak należy interpretować go ostrożnie, ponieważ może on wynikać z korzystnego podziału danych, niewielkiej liczby obserwacji w zbiorze testowym lub łatwej separowalności klas.

W celu oceny skuteczności drzewa decyzyjnego zastosowano metodę 10-krotnej walidacji krzyżowej (10-fold cross-validation). Model CART testował różne wartości parametru `cp` (complexity parameter), który kontroluje stopień przycinania drzewa i jego złożoność.

Najlepszy wynik uzyskano dla  $cp = 0.0789$ , dla którego model osiągnął dokładność klasyfikacji na poziomie około 88.7% oraz współczynnik Kappa równy 0.831. Oznacza to bardzo dobrą zgodność klasyfikacji oraz wysoką zdolność modelu do poprawnego rozróżniania klas.

Wraz ze wzrostem wartości parametru `cp` obserwowano spadek skuteczności modelu, co wskazuje, że zbyt silne przycinanie drzewa prowadzi do utraty informacji i pogorszenia jakości klasyfikacji.

| Use kernel | Accuracy |
|------------|----------|
| FALSE      | 0.977    |
| TRUE       | 0.962    |

Tabela 20: Wyniki 10-krotnej walidacji krzyżowej – Naive Bayes

| Use kernel | Accuracy |
|------------|----------|
| FALSE      | 0.96     |
| TRUE       | 0.96     |

Tabela 21: Wyniki CV – Naive Bayes na podzbiorze cech V7 (flawonoidy), V13 (zawartość proliny), V12 (OD280/OD315 rozcieńczonych win), V1 (zawartość alkoholu), V10 (intensywność barwy)

[CO TU NAPISAĆ: wynik naive Bayes w CV — który wariant lepszy (z czy bez estymacji jądrowej, `usekernel`), jaka dokładność i Kappa (są już inline R — zostawić), oraz interpretacja: wysoka skuteczność oznacza, że przy założeniu niezależności cech klasy są dobrze separowalne. Dobrze też porównać z wynikiem naive Bayes na pojedynczym podziale.]



W celu oceny skuteczności klasyfikatora Naive Bayes zastosowano 10-krotną walidację krzyżową. Model testował dwa warianty: z estymacją jądrową (`usekernel = TRUE`) oraz bez niej (`usekernel = FALSE`).

Najlepszy wynik uzyskano dla modelu bez estymacji jądrowej, który osiągnął dokładność klasyfikacji na poziomie około 97.7% oraz współczynnik Kappa równy 0.965. Oznacza to bardzo wysoką skuteczność klasyfikatora oraz bardzo dobrą zgodność przewidywań z rzeczywistymi klasami.

Wyniki wskazują, że klasy w analizowanym zbiorze danych są dobrze separowalne przy założeniu niezależności zmiennych, co sprzyja wysokiej skuteczności modelu Naive Bayes.

## 2.4 Różne parametry i podzbiory cech

one przeniesione wyżej lepiej porównywać

[DO NAPISANIA – komentarz do tabel na podzbiorze cech: porównać dokładność modeli na pełnym zestawie cech vs na podzbiorze V7, V13, V12, V1, V10 dla każdej z metod (k-NN, drzewo, naive Bayes); napisać, czy ograniczenie cech pomogło, zaszkodziło, czy nie zmieniło wyników. (Sprawdzone w CV dla NOWEGO podzbioru 5 najlepszych cech wg LDA: ograniczenie cech prawie nie zmienia wyników – k-NN ok. 97% → ok. 98%, naive Bayes ok. 98% → ok. 97%, drzewo ok. 88% → ok. 89%. Wniosek: te 5 cech niesie niemal całą informację różnicującą, więc redukcja wymiaru praktycznie nic nie kosztuje – inaczej niż przy starym podzbiorze, który wyraźnie psuł k-NN i NB.)]

## 2.5 Podsumowanie

[DO NAPISANIA – końcowe wnioski (Zadanie 2f), wymagane w treści listy. Odpowiedzieć na trzy pytania: (1) dla jakiego podzbioru cech i jakich parametrów (np. `k` w k-NN, `cp` w drzewie, `usekernel` w naive Bayes) wyniki są najlepsze; (2) która metoda klasyfikacji wypada najlepiej, a która najgorzej na zbiorze wine; (3) czy wybór schematu oceny (pojedynczy podział vs walidacja krzyżowa) wpłynął na wnioski o skuteczności metod. Można podeprzeć się tabelami wyżej. (Sprawdzone w R, CV pełny zestaw cech: naive Bayes ok. 97.6% (najlepszy), k-NN ok. 96.9%, drzewo ok. 88.1% (najsłabsze); najlepsze parametry: k-NN `k=5`, drzewo `cp` ok. 0.079, naive Bayes `usekernel=FALSE`; po standaryzacji LDA podzbiór 5 najlepszych cech (V7, V13, V12, V1, V10) daje wyniki zbliżone do pełnego zestawu dla wszystkich metod (k-NN i NB praktycznie bez straty, drzewo bez zmian); po dodaniu standaryzacji do CV oba schematy dają spójny ranking – wybór schematu NIE zmienia wniosków, jedynie pojedynczy podział był zbyt optymistyczny dla drzewa (100% vs 88% w CV).)]