

Sprawozdanie 4

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-06-29

Spis treści

1	Wstęp i opis danych	2
1.1	Przypomnienie informacji o zbiorze danych	2
2	Część 1 – zaawansowane metody klasyfikacji	4
2.1	Rodziny klasyfikatorów / uczenie zespołowe	4
2.2	Metoda wektorów nośnych (SVM)	9
2.3	Porównanie skuteczności metod	11
3	Część 2 – analiza skupień	12
3.1	Wybór i przygotowanie danych	12
3.2	Wizualizacja wyników grupowania	12
3.3	Ocena jakości grupowania, wybór liczby skupień i porównanie metod	13
3.4	Interpretacja wyników grupowania – charakterystyki skupień	13

1 Wstęp i opis danych

W obu częściach sprawozdania pracujemy na zbiorze danych `wine` z R-pakietu `HDclassif`. Zbiór danych zawiera informacje o wynikach analizy chemicznej win uprawianych w tych samych regionach Włoch, lecz będących trzech różnych odmian: *Barolo*, *Grignolino* oraz *Barbera*.

Dokładniejszy opis danych znajduje się w poprzedniej części sprawozdania. Przypomnienie podstawowych informacji znajduje się poniżej

1.1 Przypomnienie informacji o zbiorze danych

Dokonujemy takiej samej obróbki danych jak w poprzedniej części, czyli zmieniamy typy wszystkich parametrów cech na `numeric`, a numeryczne etykiety klas zmieniamy na prawdziwe nazwy odmian – 1 na *Barolo*, 2 na *Grignolino*, a 3 na *Barbera*.

```
dane2$class <- factor(
  dane2$class,
  labels = c("Barolo", "Grignolino", "Barbera")
)

dane2$V5 <- as.numeric(dane2$V5)
dane2$V13 <- as.numeric(dane2$V13)
```

Dane zawierają informacje o 178 winach. Dla każdego z nich mamy informacje o 14 cechach:

	Typ	Opis
class	integer	przynależność do klasy wina
V1	numeric	zawartość alkoholu
V2	numeric	kwask jabłkowy
V3	numeric	zawartość popiołu
V4	numeric	alkaliczność popiołu
V5	integer	zawartość magnezu
V6	numeric	łączna zawartość fenoli
V7	numeric	flawonoidy
V8	numeric	fenole nieflawonoidowe
V9	numeric	proantocyjaniny
V10	numeric	intensywność barwy
V11	numeric	odcień koloru
V12	numeric	OD280/OD315 rozcieńczonych win
V13	integer	zawartość proliny

Tabela 1: Typy oraz opisy cech zbioru wine

Statystyki opisowe zmiennych:


class	V1	V2	V3	V4
Barolo :59	Min. :11.03	Min. :0.740	Min. :1.360	Min. :10.60
Grignolino:71	1st Qu.:12.36	1st Qu.:1.603	1st Qu.:2.210	1st Qu.:17.20
Barbera :48	Median :13.05	Median :1.865	Median :2.360	Median :19.50
	Mean :13.00	Mean :2.336	Mean :2.367	Mean :19.49
	3rd Qu.:13.68	3rd Qu.:3.083	3rd Qu.:2.558	3rd Qu.:21.50
	Max. :14.83	Max. :5.800	Max. :3.230	Max. :30.00

V5	V6	V7	V8	V9
Min. : 70.00	Min. :0.980	Min. :0.340	Min. :0.1300	Min. :0.410
1st Qu.: 88.00	1st Qu.:1.742	1st Qu.:1.205	1st Qu.:0.2700	1st Qu.:1.250
Median : 98.00	Median :2.355	Median :2.135	Median :0.3400	Median :1.555
Mean : 99.74	Mean :2.295	Mean :2.029	Mean :0.3619	Mean :1.591
3rd Qu.:107.00	3rd Qu.:2.800	3rd Qu.:2.875	3rd Qu.:0.4375	3rd Qu.:1.950
Max. :162.00	Max. :3.880	Max. :5.080	Max. :0.6600	Max. :3.580

V10	V11	V12	V13
Min. : 1.280	Min. :0.4800	Min. :1.270	Min. : 278.0
1st Qu.: 3.220	1st Qu.:0.7825	1st Qu.:1.938	1st Qu.: 500.5
Median : 4.690	Median :0.9650	Median :2.780	Median : 673.5
Mean : 5.058	Mean :0.9574	Mean :2.612	Mean : 746.9
3rd Qu.: 6.200	3rd Qu.:1.1200	3rd Qu.:3.170	3rd Qu.: 985.0
Max. :13.000	Max. :1.7100	Max. :4.000	Max. :1680.0

Tabela 2: Podsumowanie danych zbioru wine

Na wykresie poniżej znajduje się rozkład licznosci odmian:



Rysunek 1: Rozkład licznosci odmian w zbiorze `wine`. Kolory słupków odpowiadają odmianom: *Barolo*, *Grignolino*, *Barbera*.

2 Część 1 – zaawansowane metody klasyfikacji

W pierwszej części raportu przedstawimy metody Bagging i Random Forest oraz dokonamy oceny dokładności ich klasyfikacji. Następnie przeprowadzimy analizę metody maszyn wektorów nośnych (SVM) z wykorzystaniem różnych funkcji jądrowych. Na końcu porównamy wyniki wszystkich modeli w celu oceny ich skuteczności.

Ocena Części 1 (po przeliczeniu): wymagania listy są w większości spełnione. a) ensemble: bagging + random forest = dwie metody, dokładność oceniona estymatorem .632+ tym samym schematem co lista 3 – jest redukcja błędu (drzewo 10% -> bagging 4% -> RF 1,2%) i RF wyraźnie bije bagging. b) SVM: są trzy jądra (liniowe, wielomianowe, radialne), wpływ kosztu C (pokazany dla liniowego) i jednocześnie dostrojenie gamma + C dla radialnego. c) porównanie istnieje. Same obliczenia są poprawne – liczby z prozy zgadzają się z wynikami chunków.

Nie znalazłem poważnych błędów rachunkowych. Dwa realne problemy MERYTORYCZNE są wskazane czerwonymi uwagami niżej: (1) narracja o tuningu SVM – optymalizacja nie poprawia wyniku na teście, a zhardkodowane C/gamma były błędne; (2) RF i SVM porównywane różnymi miarami (.632+ vs jeden podział testowy).

Do poprawy redakcyjnie (drobne, nie błędy merytoryczne): w całej Części 1 sporo literówek i braków interpunkcji – do doczyszczania przed oddaniem. ‘gbm’ i ‘caret’ są ładowane w ‘setup’, ale nieużywane (nie ma boostingu) – usuń albo dodaj metodę boostingu.

2.1 Rodziny klasyfikatorów / uczenie zespołowe

Na początku analizy zbiór Wine podzielono na zbiór uczący i testowy w proporcji 70% do 30%, co miało na celu rzetelną ocenę zdolności generalizacji modeli. W przypadku metod Bagging

oraz Random Forest zamiast jednorazowego podziału wykorzystano wielokrotne próbkowanie bootstrapowe. Każde drzewo było budowane na losowo wybranej próbie uczącej, a jako miarę jakości zastosowano błąd klasyfikacji wyznaczany na obserwacjach niewykorzystanych podczas budowy danego drzewa (Out-of-Bag, OOB). Takie podejście pozwala na ocenę skuteczności modeli bez konieczności wydzielania osobnego zbioru walidacyjnego oraz zapewnia bardziej stabilną estymację błędu klasyfikacji.

następnie przeprowadzamy predykcje na poszczególnych drzewach w celu porównania czy użycie bardziej złożonych algorytmów będzie skuteczniejsze w metodzie klasyfikacji


Predykcja	Barolo	Grignolino	Barbera
Barolo	13	0	0
Grignolino	4	21	2
Barbera	1	1	11

Tabela 3: Macierz pomyłek pojedynczego drzewa na zbiorze testowym (wiersze: predykcja, kolumny: klasa rzeczywista).

Powyżej widzimy tabele pomyłek. Widzimy że algorytm dobrze sobie poradził z klasyfikacją typów grignolino i barbera gdzie pomylił nie więcej niż dwa razy. natomiast klasyfikacji barolo pomylił się aż 5 razy na 18. dokładność wyniosła około 85%, natomiast współczynnik błędów 15%, co nie jest zadowalającym wynikiem.

Liczba drzew (nbagg)	Błąd OOB
25	0.051

Tabela 4: Bagging: błąd klasyfikacji Out-of-Bag dla 25 drzew.



Rysunek 2: Bagging: błąd klasyfikacji (estymator .632+) w funkcji liczby drzew B. Błąd maleje do ok. 40 drzew, a następnie się stabilizuje.

Powyższy wykres przedstawia zależność błędów klasyfikacji .632+ od liczby drzew, widzimy że do 40 tendencja jest spadkowa wraz ze wzrostem liczby replikacji błąd spada aż do 3%, dzięki czemu możemy stwierdzić że algorytm złożony bagging istotnie redukuje błąd klasyfikacji w porównaniu do pojedynczego drzewa gdzie błąd wyniósł 15%. Widzimy że powyżej wartości 40 aż do 100 nie zauważamy dalszego spadku błędów zaczyna się stabilizować błąd co świadczy że dla naszego zbioru win najlepszym wyborem jest liczba drzew około 40. Większa ilość drzew zwiększa jedynie koszt obliczeniowy i czas wykonania programu, nie wnosząc już istotnej poprawy dokładności klasyfikacji.

Predykcja	Barolo	Grignolino	Barbera
Barolo	17	0	0
Grignolino	1	22	0
Barbera	0	0	13


Tabela 5: Random Forest: macierz pomyłek na zbiorze testowym (wiersze: predykcja, kolumny: klasa rzeczywista).

Klasa	Barolo	Grignolino	Barbera	Błąd klasy
Barolo	40	1	0	0.024
Grignolino	1	46	2	0.061
Barbera	0	0	35	0.000


Tabela 6: Random Forest: macierz pomyłek OOB z błędem klasyfikacji w podziale na odmiany (kolumna „Błąd klasy”).

Obs.	Barolo	Grignolino	Barbera
1	1.00	0.00	0.00
2	0.97	0.03	0.00
3	1.00	0.00	0.00
4	0.97	0.01	0.02
5	0.55	0.40	0.05
6	1.00	0.00	0.00

Tabela 7: Random Forest: prognozowane prawdopodobieństwa a posteriori dla pierwszych sześciu win.



Rysunek 3: Random Forest: błąd klasyfikacji (OOB oraz w podziale na odmiany) w funkcji liczby drzew. Błąd ogólny stabilizuje się od ok. 40 drzew.



Rysunek 4: Random Forest: ranking ważności cech (średni spadek dokładności po permutacji wartości cechy).

Na powyższym wykresie widzimy ogólny zależność błęd klasyfikacji od liczby drzew dla całkowitego błędu (czarna linie) oraz błędy dla poszczególnych trzech odmin. Widzimy że dla około 40 drzew następuje stabilizacja. Dla ogólnego błędu od 40 drzew błąd się stabilizuje i występuje na poziomie około 3%. widzimy że około 50 jest wystarczająca dla klasyfikacji. następnie dla odmiany barbery po około 20 drzewach schodzi do 0 co oznacza że model idealnie klasyfikuje ten gatunek. Natomiast najtrudniejsza do klasyfikacji okazuje się odmiana grignolino błąd utrzymuje się na poziomie około 7%.

Porównując błędy dla pojedynczego otrzymaliśmy błąd na poziomie 15%, natomiast oszacowana macierz pomyłek dla lasu losowego widzimy że pomylił się tylko 1 raz dzięki czemu błąd klasyfikacji wynosi tylko 1.89%. Natomiast błąd baggingu wynosił około 3% co również widzimy że obecnie otrzymaliśmy duży spadek do poprzedniej metody.

Metoda	Błąd .632+	Redukcja błędu vs drzewo [%]
Pojedyncze drzewo	0.1008	—
Bagging	0.0399	60.39
Random Forest	0.0123	87.76

Tabela 8: Porównanie błęd klasyfikacji (estymator .632+) oraz względnej redukcji błęd względem pojedynczego drzewa.

Ponadto widzimy wyniki oceny wydajności działania metod. Widzimy że błąd klasyfikacji spada drastycznie z około 10% do 1.2% dla metody random forest. Stosując te metody otrzymamy o

wiele lepsze wyniki. Złożone algorytmy poprzez urealnianie setek drzew eliminują wysoką wariancję jak była obecna dla pojedynczego drzewa i stabilizują reguły decyzyjne i podnoszą zdolności generalizacji modelu.

Również widzimy istotną różnicę między modelami złożonymi dla baggingu błąd wyniósł 4% natomiast dla random forest 1.2%. Różnica ta wynika z odmiennej techniki budowy drzew. W baggingu każde drzewo analizuje wszystkie dostępne cechy. W zb. wine kilka parametrów silnie różnicuje klasy więc większość drzew w baggingu wybiera te same zmienne, ponieważ drzewa są mocno ze sobą skorelowane. Natomiast random forest wprowadza dodatkowy element losowości w każdym węzle losuje tylko mały podzbiór cech, przez co zmusza drzewo do szukania alternatywnych wzorców i reguł, dzięki czemu drzewa nie są ze sobą skorelowane.

2.2 Metoda wektorów nośnych (SVM)

Następnie wykorzystując metodę wektorów nośnych porównamy klasyfikator dla różnych funkcji jądrowych.

Koszt C	Dokładność (test)
0.1	0.9811
1.0	0.9811
10.0	0.9811

Tabela 9: SVM z jądrem liniowym: dokładność na zbiorze testowym dla różnych wartości kosztu C.

Powyżej znajdują się wyniki dokładności dla jądra liniowego w zależności od różnych wartości parametru c, który kontroluje kompromis między szerokością marginesu separującego a liczbą błędów dopuszczalnych na zb. testowym. Widzimy, że dla jądra liniowego zmiana parametru c od 0.1 do 10 nie wpłynęła na dokładność klasyfikacji na zb. testowym. Jest to skutkiem tego, że w zb. wine w przestrzeni wielowymiarowej nasz zb. cechuje się liniową odseparowalnością klas, co skutkuje, że granica decyzyjna wyznaczona przez SVM jest na tyle stabilna, że zmiana marginesu nie przesunęła jej w sposób, który zmieniłby klasyfikację.

Jądro	Dokładność (test)
wielomianowe (deg = 2)	0.9057
wielomianowe (deg = 4)	0.8302
radialne (domyślne)	1.0000

Tabela 10: SVM: dokładność na zbiorze testowym dla różnych funkcji jądrowych przy parametrach domyślnych.

Powyżej znajdują się wyniki dla różnych funkcji jąder. Jądro radialne okazuje się idealnym wyborem dla naszego zbioru wine, ponieważ bezbłędnie sklasyfikował zb. Następnie jądro liniowe


wspomniane wcześniej rozniweż bardzo dobrze poradziło się z klasyfikacją. Natomiast jądra wielowymiarowe radzą sobie gorzej a zwiększanie stopnia wielomianu jeszcze bardziej obniża dokładność.

Najlepszy koszt C	Najlepsza gamma	Błąd CV (10-fold)
1	0.00391	0.01603

Tabela 11: SVM radialne: najlepsze parametry C i gamma z walidacji krzyżowej oraz odpowiadający im błąd CV.


Model	Dokładność (test)
radialne (domyślne)	1
radialne (dostrojone)	1

Tabela 12: SVM radialne: dokładność na zbiorze testowym przed i po dostrojeniu C oraz gamma.



Rysunek 5: SVM radialne: błąd walidacji krzyżowej w przestrzeni parametrów (osie w skali log2 dla C i gamma). Ciemniejsze pola oznaczają niższy błąd.

Powierzchnia błędu walidacji krzyżowej (SVM radialne)



Rysunek 6: SVM radialne: powierzchnia błędu walidacji krzyżowej w funkcji C i gamma (widok perspektywiczny).

Powyżej mamy wyniki dla jądra radialnego przed i po tuningiem. Skuteczność klasyfikacji na zbiorze testowym wynosi w obu przypadkach 100%. Algorytm optymalizacyjny wskazał jako najlepsze parametry koszt $c=1$ oraz $\gamma=0.00391$.

Uwaga merytoryczna: dostrojony koszt (1) wychodzi równy domyślnemu, a jądro radialne i tak klasyfikuje zbiór testowy bezbłędnie już przed tuningiem – więc na zbiorze testowym optymalizacja NIE poprawiła skuteczności. Trzeba to napisać wprost (lista pyta wprost: „czy optymalizacja pozwoliła poprawić skuteczność?”), zamiast obecnej narracji o „modelu bezpieczniejszym / szerokim marginesie”. Ewentualną przewagę można pokazać tylko na poziomie błędów CV z `'tune()'`, nie na teście.

2.3 Porównanie skuteczności metod

Podsumowując klasyfikator bazowy (pojedyncze drzewo) charakteryzuje się najniższą dokładnością z powodu skłonności do przeuczenia i wysokiej wariancji. Zastosowanie metod złożonych i SVM drastycznie obniża błąd klasyfikacji. Najlepsza metoda jest random forest dla 100 drzew gdzie dokładność wynosiła 98.11% oraz SVM dla jądra radialnego gdzie była 100% dokładności. Również bardzo dobra metoda jest SVM dla jądra liniowego (dokładność 98.11%). **Dokończ zdanie / akapit – urywa się.**

Uwaga merytoryczna do porównania a) vs b): RF oceniasz błędem .632+ (1.2%), a SVM tylko dokładnością na jednym podziale 70/30 (100%). To nie jest ta sama miara – żeby uczciwie wskazać „najlepszą” metodę, najlepiej policzyć dla SVM ten sam estymator .632+ (errorest) co dla drzew, albo dla wszystkich metod podać dokładność na tym samym zbiorze testowym.

Poniższe dwa akapity to robocze notatki do wkomponowania w porównanie powyżej (a nie

osobny tekst). Uwaga: zhardkodowane „ $C = 0.5$ i $\gamma = 0.03125$ ” są nieaktualne – po dodaniu ziarna wychodzi $C = 1$, $\gamma = 0.00391$; popraw albo zastąp inline.

Jako jedyny model bezbłędnie sklasyfikował wszystkie próbki w zbiorze testowym. Jądro radialne potrafi w sposób ciągły i gładki wyginać granice decyzyjne w wielowymiarowej przestrzeni, idealnie dopasowując się do specyfiki chemicznej win. Dodatkowy atut: Dzięki przeprowadzonej optymalizacji (tuningowi) wiesz, że parametry $C = 0.5$ i $\gamma = 0.03125$ dają modelowi bardzo szeroki margines bezpieczeństwa, co czyni go najbardziej stabilnym na przyszłość. Ustępuje SVM zaledwie o jeden mały błąd na zbiorze testowym (pomylił jedno wino Barolo z Grignolino). To potężny i niezwykle bezobsługowy algorytm, który rewelacyjnie uśrednia decyzje setek drzew, ale w tym konkretnym, czystym zbiorze minimalnie przegrał z idealnie dopasowaną geometrią SVM

3 Część 2 – analiza skupień

tam klaudiusz jakieś rzeczy napisał do tej pierwszej części coś

Celem zadania jest zastosowanie poznanych algorytmów analizy skupień (ang. clustering) oraz ocena i porównanie jakości grupowania. Przeprowadzając analizę, należy zastosować przynajmniej jedną wybraną metodę grupującą (np. algorytm PAM) oraz przynajmniej jedną metodę hierarchiczną (np. algorytm AGNES).

3.1 Wybór i przygotowanie danych

- Do analizy wybieramy jeden ze zbiorów wymienionych w zad.2/lista 3. Uwaga: Można wybrać ten sam albo inny zbiór niż w przypadku porównywania metod klasyfikacji.
- Aby ułatwić wizualizację wyników, w przypadku „większych” danych losujemy podzbiór zawierający 200 rekordów (wierszy).
- Przed zastosowaniem metod analizy skupień usuwamy zmienną grupującą zawierającą etykiety klas (grup). Zmienna ta powinna być jednak później wykorzystana do oceny jakości grupowania (→ zewnętrzne wskaźniki walidacyjne).
- Postaraj się rozstrzygnąć, czy konieczne będzie zastosowanie standaryzacji przed wyznaczeniem macierzy odległości/odmienności.

3.2 Wizualizacja wyników grupowania

Przyjmując liczbę skupień K równą rzeczywistej liczbie klas:

- Zilustruj otrzymane wyniki (podział na skupienia) na wykresach rozrzutu, zaznaczając (np. różnymi kolorami) przynależność do poszczególnych skupisk. Dodatkowo, uzupełnij wykresy o informacje nt. rzeczywistej przynależności obiektów do grup/klas (np. różne kolory mogą oznaczać różne skupienia, a różne symbole – przynależność do klas).

* Wskazówka 1: Aby przedstawić dane na dwuwymiarowym wykresie rozproszenia, można wykorzystać odpowiednią metodę redukcji wymiaru (np. PCA lub MDS).

* Wskazówka 2: W przypadku algorytmu hierarchicznego, aby otrzymać partycję dla ustalonej liczby skupień K można wykorzystać funkcję `cutree()`.

- W przypadku metody hierarchicznej porównaj dendrogramy otrzymane dla różnych metod łączenia skupień (ang. linkage methods) Dla chętnych: można zastosować także odpowiednie kolorowanie liści dendrogramów, zgodnie z rzeczywistą przynależnością obiektów do klas.
- Co można powiedzieć o podstawowych własnościach otrzymanych skupień (np. jednorodność/zwartość, separacja itp.)?
- Czy i w jakim stopniu otrzymany podział na klastry zgadza się z rzeczywistą przynależnością obiektów do klas?

3.3 Ocena jakości grupowania, wybór liczby skupień i porównanie metod

Dla ustalonego zakresu liczby skupień ($K \in \{2, 3, \dots, K_{\max}\}$) wykonaj poniższe kroki:

- wskaźniki wewnętrzne: Wykorzystaj średnią wartość indeksu `silhouette` do porównania wyników otrzymanych dla różnych algorytmów analizy skupień (np. algorytmy PAM i AGNES) oraz różnej liczby skupień K .
- wskaźniki zewnętrzne: Wykorzystaj wybraną miarę zgodności dwóch partycji (np. funkcja `matchClasses()`) do porównania wyników grupowania z rzeczywistą przynależnością do klas.

Na podstawie otrzymanych wyników spróbuj rozstrzygnąć, który algorytm lepiej poradził sobie z grupowaniem danych oraz jaka liczba klastrów jest optymalna.

3.4 Interpretacja wyników grupowania – charakterystyki skupień

- Wykorzystując wnioski z poprzedniego punktu, wyznacz podział na skupienia dla optymalnej liczby skupień K .
- Analizując podstawowe charakterystyki poszczególnych cech, zbadaj czym wyróżniają się obiekty należące do danego skupienia (np. dla obiektów należących do poszczególnych skupień można wyznaczyć średnie wartości cech, porównać wykresy pudełkowe itp.).
- W przypadku metody PAM sprawdź także, które obiekty są medoidami (reprezentantami skupień) i co je wyróżnia.