

Sprawozdanie 4

Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-06-06

Spis treści

1	Wstęp i opis danych	2
1.1	Przypomnienie informacji o zbiorze danych	2
2	Część 1 – zaawansowane metody klasyfikacji	4
2.1	Rodziny klasyfikatorów / uczenie zespołowe	4
2.2	Metoda wektorów nośnych (SVM)	4
2.3	Porównanie skuteczności metod	5
3	Część 2 – analiza skupień	5
3.1	Wybór i przygotowanie danych	5
3.2	Wizualizacja wyników grupowania	5
3.3	Ocena jakości grupowania, wybór liczby skupień i porównanie metod	6
3.4	Interpretacja wyników grupowania – charakterystyki skupień	6

1 Wstęp i opis danych

W obu częściach sprawozdania pracujemy na zbiorze danych `wine` z R-pakietu `HDclassif`. Zbiór danych zawiera informacje o wynikach analizy chemicznej win uprawianych w tych samych regionach Włoch, lecz będących trzech różnych odmian.

Dokładniejszy opis danych znajduje się w poprzedniej części sprawozdania. Przypomnienie podstawowych informacji znajduje się poniżej

1.1 Przypomnienie informacji o zbiorze danych

Dokonujemy takiej samej obróbce danych jak w poprzedniej części, czyli zmieniamy typy wszystkich parametrów cech na `numeric`, a numeryczne etykiety klas zmieniamy na prawdziwe nazwy odmian – 1 na *Barolo*, 2 na *Grignolino*, a 3 na *Barbera*.

```
dane2$class <- factor(
  dane2$class,
  labels = c("Barolo", "Grignolino", "Barbera")
)

dane2$V5 <- as.numeric(dane2$V5)
dane2$V13 <- as.numeric(dane2$V13)
```

Dane zawierają informacje o 178 winach. Dla każdego z nich mamy informacje o 14 cechach:

	Typ	Opis
class	integer	przynależność do klasy wina
V1	numeric	zawartość alkoholu
V2	numeric	kwas jabłkowy
V3	numeric	zawartość popiołu
V4	numeric	alkaliczność popiołu
V5	integer	zawartość magnezu
V6	numeric	łączna zawartość fenoli
V7	numeric	flawonoidy
V8	numeric	fenole nieflawonoidowe
V9	numeric	proantocyjaniny
V10	numeric	intensywność barwy
V11	numeric	odcień koloru
V12	numeric	OD280/OD315 rozcieńczonych win
V13	integer	zawartość proliny

Tabela 1: Typy oraz opisy cech zbioru wine

Statystyki opisowe zmiennych:


class	V1	V2	V3	V4
Barolo :59	Min. :11.03	Min. :0.740	Min. :1.360	Min. :10.60
Grignolino:71	1st Qu.:12.36	1st Qu.:1.603	1st Qu.:2.210	1st Qu.:17.20
Barbera :48	Median :13.05	Median :1.865	Median :2.360	Median :19.50
	Mean :13.00	Mean :2.336	Mean :2.367	Mean :19.49
	3rd Qu.:13.68	3rd Qu.:3.083	3rd Qu.:2.558	3rd Qu.:21.50
	Max. :14.83	Max. :5.800	Max. :3.230	Max. :30.00

V5	V6	V7	V8	V9
Min. : 70.00	Min. :0.980	Min. :0.340	Min. :0.1300	Min. :0.410
1st Qu.: 88.00	1st Qu.:1.742	1st Qu.:1.205	1st Qu.:0.2700	1st Qu.:1.250
Median : 98.00	Median :2.355	Median :2.135	Median :0.3400	Median :1.555
Mean : 99.74	Mean :2.295	Mean :2.029	Mean :0.3619	Mean :1.591
3rd Qu.:107.00	3rd Qu.:2.800	3rd Qu.:2.875	3rd Qu.:0.4375	3rd Qu.:1.950
Max. :162.00	Max. :3.880	Max. :5.080	Max. :0.6600	Max. :3.580

V10	V11	V12	V13
Min. : 1.280	Min. :0.4800	Min. :1.270	Min. : 278.0
1st Qu.: 3.220	1st Qu.:0.7825	1st Qu.:1.938	1st Qu.: 500.5
Median : 4.690	Median :0.9650	Median :2.780	Median : 673.5
Mean : 5.058	Mean :0.9574	Mean :2.612	Mean : 746.9
3rd Qu.: 6.200	3rd Qu.:1.1200	3rd Qu.:3.170	3rd Qu.: 985.0
Max. :13.000	Max. :1.7100	Max. :4.000	Max. :1680.0

Tabela 2: Podsumowanie danych zbioru wine

Na wykresie poniżej znajduje się rozkład licznosci odmian:



Rysunek 1: Rozkład licznosci odmian w zbiorze `wine`. Kolory słupków odpowiadają odmianom: *Barolo*, *Grignolino*, *Barbera*.

2 Część 1 – zaawansowane metody klasyfikacji

Celem analizy jest zastosowanie (wybranych) zaawansowanych metod klasyfikacji. Zadanie to jest kontynuacją zad.2 z listy 3 i wykonujemy je dla uprzednio wybranych danych.

2.1 Rodziny klasyfikatorów / uczenie zespołowe

- Zastosuj przynajmniej dwa algorytmy typu ensemble learning (tzn. takie metody jak bagging, boosting i random forest) do konstrukcji reguł klasyfikacyjnych oraz zbadaj ich dokładność¹. Czy otrzymujemy istotną redukcję błędu klasyfikacji w porównaniu do klasyfikatora bazowego (tj. pojedynczego drzewa klasyfikacyjnego)? Czy występują istotne różnice w dokładności klasyfikacji pomiędzy różnymi metodami konstrukcji klasyfikatorów złożonych?

¹ Do oceny dokładności klasyfikacji można zastosować taki sam schemat, jak w przypadku zad.2 z listy nr 3

2.2 Metoda wektorów nośnych (SVM)

- Wykorzystując algorytm SVM, zbuduj klasyfikatory dla różnych funkcji jądrowych (np. jądro liniowe, wielomianowe i radialne) i porównaj ich skuteczność. Czy i w jakim stopniu wybór funkcji jądrowej oraz wybór parametru kosztu C wpływa na dokładność metody SVM?
- Dla jądra radialnego postaraj się „dostroić” jednocześnie parametry γ i C . Porównaj dokładność klasyfikacji dla modelu z optymalnie wybranymi parametrami oraz modelu skonstruowanego dla domyślnych parametrów. Czy optymalizacja parametrów pozwoliła na poprawę skuteczności skonstruowanego klasyfikatora?

2.3 Porównanie skuteczności metod

- Porównując wyniki uzyskane w punktach a) i b), postaraj się rozstrzygnąć, która z rozważanych metod wykazała najlepszą skuteczność.

3 Część 2 – analiza skupień

Celem zadania jest zastosowanie poznanych algorytmów analizy skupień (ang. clustering) oraz ocena i porównanie jakości grupowania. Przeprowadzając analizę, należy zastosować przynajmniej jedną wybraną metodę grupującą (np. algorytm PAM) oraz przynajmniej jedną metodę hierarchiczną (np. algorytm AGNES).

3.1 Wybór i przygotowanie danych

- Do analizy wybieramy jeden ze zbiorów wymienionych w zad.2/lista 3. Uwaga: Można wybrać ten sam albo inny zbiór niż w przypadku porównywania metod klasyfikacji.
- Aby ułatwić wizualizację wyników, w przypadku „większych” danych losujemy podzbiór zawierający 200 rekordów (wierszy).
- Przed zastosowaniem metod analizy skupień usuwamy zmienną grupującą zawierającą etykiety klas (grup). Zmienna ta powinna być jednak później wykorzystana do oceny jakości grupowania (→ zewnętrzne wskaźniki walidacyjne).
- Postaraj się rozstrzygnąć, czy konieczne będzie zastosowanie standaryzacji przed wyznaczeniem macierzy odległości/odmienności.

3.2 Wizualizacja wyników grupowania

Przyjmując liczbę skupień K równą rzeczywistej liczbie klas:

- Zilustruj otrzymane wyniki (podział na skupienia) na wykresach rozrzutu, zaznaczając (np. różnymi kolorami) przynależność do poszczególnych skupisk. Dodatkowo, uzupełnij wykresy o informacje nt. rzeczywistej przynależności obiektów do grup/klas (np. różne kolory mogą oznaczać różne skupienia, a różne symbole – przynależność do klas).
- * Wskazówka 1: Aby przedstawić dane na dwuwymiarowym wykresie rozproszenia, można wykorzystać odpowiednią metodę redukcji wymiaru (np. PCA lub MDS).
- * Wskazówka 2: W przypadku algorytmu hierarchicznego, aby otrzymać partycję dla ustalonej liczby skupień K można wykorzystać funkcję `cutree()`.
- W przypadku metody hierarchicznej porównaj dendrogramy otrzymane dla różnych metod łączenia skupień (ang. linkage methods) Dla chętnych: można zastosować także odpowiednie kolorowanie liści dendrogramów, zgodnie z rzeczywistą przynależnością obiektów do klas.
- Co można powiedzieć o podstawowych własnościach otrzymanych skupień (np. jednorodność/zwartość, separacja itp.)?

- Czy i w jakim stopniu otrzymany podział na klastry zgadza się z rzeczywistą przynależnością obiektów do klas?

3.3 Ocena jakości grupowania, wybór liczby skupień i porównanie metod

Dla ustalonego zakresu liczby skupień ($K \in \{2, 3, \dots, K.\text{max}\}$) wykonaj poniższe kroki:

- wskaźniki wewnętrzne: Wykorzystaj średnią wartość indeksu silhouette do porównania wyników otrzymanych dla różnych algorytmów analizy skupień (np. algorytmy PAM i AGNES) oraz różnej liczby skupień K .
- wskaźniki zewnętrzne: Wykorzystaj wybraną miarę zgodności dwóch partycji (np. funkcja `matchClasses()`{e1071}) do porównania wyników grupowania z rzeczywistą przynależnością do klas.

Na podstawie otrzymanych wyników spróbuj rozstrzygnąć, który algorytm lepiej poradził sobie z grupowaniem danych oraz jaka liczba klastrów jest optymalna.

3.4 Interpretacja wyników grupowania – charakterystyki skupień

- Wykorzystując wnioski z poprzedniego punktu, wyznacz podział na skupienia dla optymalnej liczby skupień K .
- Analizując podstawowe charakterystyki poszczególnych cech, zbadaj czym wyróżniają się obiekty należące do danego skupienia (np. dla obiektów należących do poszczególnych skupień można wyznaczyć średnie wartości cech, porównać wykresy pudełkowe itp.).
- W przypadku metody PAM sprawdź także, które obiekty są medoidami (reprezentantami skupień) i co je wyróżnia.