

# Sprawozdanie 4

## Eksploracja danych

Emilia Porczyńska, Michał Szostak

2026-07-03

### Spis treści

|          |                                                                             |           |
|----------|-----------------------------------------------------------------------------|-----------|
| <b>0</b> | <b>Wstęp i opis danych</b>                                                  | <b>2</b>  |
| 0.1      | Przypomnienie informacji o zbiorze danych . . . . .                         | 2         |
| <b>1</b> | <b>Część 1 – zaawansowane metody klasyfikacji</b>                           | <b>4</b>  |
| 1.1      | Rodziny klasyfikatorów / uczenie zespołowe . . . . .                        | 4         |
| 1.2      | Metoda wektorów nośnych (SVM) . . . . .                                     | 9         |
| 1.3      | Porównanie skuteczności metod . . . . .                                     | 12        |
| <b>2</b> | <b>Część 2 – analiza skupień</b>                                            | <b>13</b> |
| 2.1      | Wybór i przygotowanie danych . . . . .                                      | 13        |
| 2.2      | Wizualizacja wyników grupowania . . . . .                                   | 14        |
| 2.3      | Ocena jakości grupowania, wybór liczby skupień i porównanie metod . . . . . | 20        |
| 2.4      | Interpretacja wyników grupowania – charakterystyki skupień . . . . .        | 21        |

## 0 Wstęp i opis danych

W obu częściach sprawozdania pracujemy na zbiorze danych `wine` z R-pakietu `HDclassif`. Zbiór danych zawiera informacje o wynikach analizy chemicznej win uprawianych w tych samych regionach Włoch, lecz będących trzech różnych odmian: *Barolo*, *Grignolino* oraz *Barbera*.

Dokładniejszy opis danych znajduje się w poprzedniej części sprawozdania. Przypomnienie podstawowych informacji znajduje się poniżej.

### 0.1 Przypomnienie informacji o zbiorze danych

Dokonujemy takiej samej obróbki danych jak w poprzedniej części, czyli zmieniamy typy wszystkich parametrów cech na `numeric`, a numeryczne etykiety klas zmieniamy na prawdziwe nazwy odmian: 1 na *Barolo*, 2 na *Grignolino*, a 3 na *Barbera*.

```
dane2$class <- factor(
  dane2$class,
  labels = c("Barolo", "Grignolino", "Barbera")
)

dane2$V5 <- as.numeric(dane2$V5)
dane2$V13 <- as.numeric(dane2$V13)
```

Dane zawierają informacje o 178 winach. Dla każdego z nich mamy informacje o 14 cechach:

|       | Typ     | Opis                           |
|-------|---------|--------------------------------|
| class | integer | przynależność do klasy wina    |
| V1    | numeric | zawartość alkoholu             |
| V2    | numeric | kwas jabłkowy                  |
| V3    | numeric | zawartość popiołu              |
| V4    | numeric | alkaliczność popiołu           |
| V5    | integer | zawartość magnezu              |
| V6    | numeric | łączna zawartość fenoli        |
| V7    | numeric | flawonoidy                     |
| V8    | numeric | fenole nieflawonoidowe         |
| V9    | numeric | proantocyjaniny                |
| V10   | numeric | intensywność barwy             |
| V11   | numeric | odcień koloru                  |
| V12   | numeric | OD280/OD315 rozcieńczonych win |
| V13   | integer | zawartość proliny              |

Tabela 1: Typy oraz opisy cech zbioru wine

Statystyki opisowe zmiennych:


| class         | V1            | V2            | V3            | V4            |
|---------------|---------------|---------------|---------------|---------------|
| Barolo :59    | Min. :11.03   | Min. :0.740   | Min. :1.360   | Min. :10.60   |
| Grignolino:71 | 1st Qu.:12.36 | 1st Qu.:1.603 | 1st Qu.:2.210 | 1st Qu.:17.20 |
| Barbera :48   | Median :13.05 | Median :1.865 | Median :2.360 | Median :19.50 |
|               | Mean :13.00   | Mean :2.336   | Mean :2.367   | Mean :19.49   |
|               | 3rd Qu.:13.68 | 3rd Qu.:3.083 | 3rd Qu.:2.558 | 3rd Qu.:21.50 |
|               | Max. :14.83   | Max. :5.800   | Max. :3.230   | Max. :30.00   |

| V5             | V6            | V7            | V8             | V9            |
|----------------|---------------|---------------|----------------|---------------|
| Min. : 70.00   | Min. :0.980   | Min. :0.340   | Min. :0.1300   | Min. :0.410   |
| 1st Qu.: 88.00 | 1st Qu.:1.742 | 1st Qu.:1.205 | 1st Qu.:0.2700 | 1st Qu.:1.250 |
| Median : 98.00 | Median :2.355 | Median :2.135 | Median :0.3400 | Median :1.555 |
| Mean : 99.74   | Mean :2.295   | Mean :2.029   | Mean :0.3619   | Mean :1.591   |
| 3rd Qu.:107.00 | 3rd Qu.:2.800 | 3rd Qu.:2.875 | 3rd Qu.:0.4375 | 3rd Qu.:1.950 |
| Max. :162.00   | Max. :3.880   | Max. :5.080   | Max. :0.6600   | Max. :3.580   |

| V10            | V11            | V12           | V13            |
|----------------|----------------|---------------|----------------|
| Min. : 1.280   | Min. :0.4800   | Min. :1.270   | Min. : 278.0   |
| 1st Qu.: 3.220 | 1st Qu.:0.7825 | 1st Qu.:1.938 | 1st Qu.: 500.5 |
| Median : 4.690 | Median :0.9650 | Median :2.780 | Median : 673.5 |
| Mean : 5.058   | Mean :0.9574   | Mean :2.612   | Mean : 746.9   |
| 3rd Qu.: 6.200 | 3rd Qu.:1.1200 | 3rd Qu.:3.170 | 3rd Qu.: 985.0 |
| Max. :13.000   | Max. :1.7100   | Max. :4.000   | Max. :1680.0   |

Tabela 2: Podsumowanie danych zbioru wine

Na wykresie poniżej znajduje się rozkład licznosci odmian:



Rysunek 1: Rozkład licznosci odmian w zbiorze wine.

## 1 Część 1 – zaawansowane metody klasyfikacji

Na początku, będziemy klasyfikować wina przy użyciu metod uczenia zespołowego (ang. *ensemble learning*) – *bagging* i *random forest* – oraz dokonamy oceny ich dokładności i porównamy je z klasyfikatorem złożonym z pojedynczego drzewa.

Następnie, wypróbujemy metodę wektorów nośnych (SVM) z różnymi funkcjami jądrowymi (liniowe, wielomianowe i radialne) oraz zbadamy wpływ jądra i parametru kosztu  $C$  na jakość klasyfikacji. W szczególności, zajmiemy się zagadnieniem doboru parametrów  $\gamma$  i  $C$  dla jądra radialnego i zbadaniem efektów ich optymalizacji.

Na koniec porównamy wyniki wszystkich metod i ocenimy ich skuteczność.

### 1.1 Rodziny klasyfikatorów / uczenie zespołowe

Dzielimy zbiór na podzbiór uczący i podzbiór testowy w proporcji 70/30, co daje licznosci zbioru uczącego i zbioru testowego odpowiednio 125 i 53 obserwacji. Na zbiorze uczącym będziemy budować klasyfikatory a na zbiorze testowym będziemy sprawdzać ich skuteczność.

Metody *bagging* oraz *random forest* będziemy dodatkowo oceniać za pomocą próbkowania bootstrapowego – każde drzewo będziemy budować na losowo wybranej próbie uczącej, a jako miarę jakości zastosujemy błąd klasyfikacji wyznaczony na obserwacjach niewykorzystanych podczas budowy danego drzewa (*Out-of-Bag*, OOB). Takie podejście pozwala na ocenę skuteczności modeli bez konieczności wydzielania osobnego zbioru walidacyjnego oraz zapewnia bardziej stabilną estymację błędu klasyfikacji.

Zastosujemy także ocenę przy użyciu estymatora błędu .632+.

Najpierw zaczniemy od przeprowadzenia klasyfikacji za pomocą pojedynczego drzewa (`rpart`, parametry domyślne) jako ono punkt odniesienia.

| Pre dykcja | Barolo | Grignolino | Barbera |
|------------|--------|------------|---------|
| Barolo     | 13     | 0          | 0       |
| Grignolino | 4      | 21         | 2       |
| Barbera    | 1      | 1          | 11      |

Tabela 3: Macierz pomyłek pojedynczego drzewa na zbiorze testowym (wiersze: predykcja, kolumny: klasa rzeczywista).


Powyżej widzimy macierz pomyłek. Z macierzy pomyłek widzimy, że drzewo dobrze rozpoznaje odmiany *Grignolino* i *Barbera* (odpowiednio 1 i 2 pomyłki), natomiast aż 5 z 18 win odmiany *Barolo* klasyfikuje błędnie. Dokładność wynosi 84.9%, czyli błąd klasyfikacji 15.1% – wynik przeciętny, z wyraźnym polem do poprawy dla metod zespołowych.

Pierwszą metodą zespołową jest *bagging* (*bootstrap aggregating*). Z danych losujemy ze zwracaniem wiele prób uczących, na każdej budujemy pełne, nieprzycinane drzewo (temu służą parametry `minsplit = 1` i `cp = 0`), a nowe obserwacje klasyfikujemy większością głosów wszystkich drzew. Najpierw budujemy taki model dla `nbagg = 25` drzew z opcją `coob = TRUE`, czyli z błędem liczonym metodą *out-of-bag*, a następnie sprawdzamy, jak błąd klasyfikacji zależy od liczby replikacji B.

Zależność od B oceniamy estymatorem .632+ (funkcja `errorest` z pakietu `ipred`, `nboot = 100` prób bootstrapowych). Estymator ten łączy, z odpowiednimi wagami, błąd liczony na obserwacjach spoza próby bootstrapowej z błędem na zbiorze uczącym, dzięki czemu ocena nie zależy od pojedynczego podziału danych.

| Liczba drzew (nbagg) | Błąd OOB |
|----------------------|----------|
| 25                   | 0.051    |

Tabela 4: Bagging: błąd klasyfikacji Out-of-Bag dla 25 drzew.



Rysunek 2: Bagging: błąd klasyfikacji (estymator .632+) w funkcji liczby drzew B. Błąd maleje do ok. 40 drzew, a następnie się stabilizuje.

Na wykresie widzimy, że błąd .632+ spada z 6.2% dla pojedynczego pełnego drzewa ( $B = 1$ ) do ok. 3.5% przy  $B = 40$ , a dalsze zwiększanie liczby drzew nie przynosi już poprawy – błąd się stabilizuje. *Bagging* istotnie redukuje więc błąd klasyfikacji, a dla naszego zbioru wystarcza ok. 40 replikacji; większa ich liczba zwiększa jedynie koszt obliczeniowy.

Drugą metodą zespołową jest *random forest*. Działa on jak *bagging*, ale przy każdym podziale węzła losuje tylko mały podzbiór cech, spośród których wybiera najlepszy podział – standardowo  $\lfloor \sqrt{p} \rfloor$ , czyli u nas 3 z 13 cech (parametr `mtry`) – co zmniejsza korelację między drzewami. Budujemy las ze 100 drzew (`ntree = 100`); opcja `importance = TRUE` pozwoli nam dodatkowo ocenić ważność poszczególnych cech:

| Predykcja  | Barolo | Grignolino | Barbera |
|------------|--------|------------|---------|
| Barolo     | 17     | 0          | 0       |
| Grignolino | 1      | 22         | 0       |
| Barbera    | 0      | 0          | 13      |


Tabela 5: Random Forest: macierz pomyłek na zbiorze testowym (wiersze: predykcja, kolumny: klasa rzeczywista).

| Klasa      | Barolo | Grignolino | Barbera | Błąd klasy |
|------------|--------|------------|---------|------------|
| Barolo     | 40     | 1          | 0       | 0.024      |
| Grignolino | 1      | 46         | 2       | 0.061      |
| Barbera    | 0      | 0          | 35      | 0.000      |


Tabela 6: Random Forest: macierz pomyłek OOB z błędem klasyfikacji w podziale na odmiany (kolumna „Błąd klasy”).

| Obs. | Barolo | Grignolino | Barbera |
|------|--------|------------|---------|
| 1    | 1.00   | 0.00       | 0.00    |
| 2    | 0.97   | 0.03       | 0.00    |
| 3    | 1.00   | 0.00       | 0.00    |
| 4    | 0.97   | 0.01       | 0.02    |
| 5    | 0.55   | 0.40       | 0.05    |
| 6    | 1.00   | 0.00       | 0.00    |

Tabela 7: Random Forest: prognozowane prawdopodobieństwa a posteriori dla pierwszych sześciu win.



Rysunek 3: Random Forest: błąd klasyfikacji (OOB oraz w podziale na odmiany) w funkcji liczby drzew. Błąd ogólny stabilizuje się od ok. 40 drzew.



Średni spadek dokładności po permutacji

Rysunek 4: Random Forest: ranking ważności cech (średni spadek dokładności po permutacji wartości cechy).

Pierwszy wykres pokazuje zależność błędu klasyfikacji od liczby drzew – łącznego błędu OOB oraz błędów dla poszczególnych odmian. Od ok. 40 drzew błąd OOB stabilizuje się na poziomie ok. 3%. Najłatwiejsza do rozpoznania jest odmiana *Barbera*, której błąd po ok. 20 drzewach spada do zera, a najtrudniejsza – *Grignolino*, z błędem ok. 6.1%.

Drugi wykres przedstawia ranking ważności cech: mierzymy, o ile średnio spada dokładność lasu po losowym przepermutowaniu wartości danej cechy. Najważniejsze okazują się intensywność barwy (V10), zawartość proliny (V13) i flawonoidy (V7), a najmniej do klasyfikacji wnoszą m.in. alkaliczność popiołu (V4) i fenole nieflawonoidowe (V8).

Na zbiorze testowym las pomylił się tylko 1 raz – jedno wino *Barolo* uznał za *Grignolino* – co daje błąd 1.89% wobec 15.1% dla pojedynczego drzewa i ok. 3.5% dla *baggingu*. Obie metody zespołowe wyraźnie redukują błąd, a *random forest* wypada z nich lepiej.

Na koniec porównujemy wszystkie trzy metody jedną wspólną miarą – błędem .632+ (po-  
nownie `nboot = 100`), tak aby wynik nie zależał od konkretnego podziału 70/30:

| Metoda            | Błąd .632+ | Redukcja błędu vs drzewo [%] |
|-------------------|------------|------------------------------|
| Pojedyncze drzewo | 0.1040     | –                            |
| Bagging           | 0.0412     | 60.37                        |
| Random Forest     | 0.0129     | 87.62                        |

Tabela 8: Porównanie błędu klasyfikacji (estymator .632+) oraz względnej redukcji błędu względem pojedynczego drzewa.

Wspólna miara potwierdza wcześniejsze obserwacje: błąd .632+ spada z 10.4% dla pojedynczego drzewa do 4.1% dla *baggingu* (redukcja o 60%) i 1.3% dla *random forest* (redukcja o 88%). Metody zespołowe uśredniają decyzje wielu drzew, dzięki czemu niwelują główną słabość pojedynczego drzewa – wysoką wariancję – i lepiej generalizują.

Wyraźna jest też różnica między samymi metodami zespołowymi – błąd *random forest* jest ponad trzykrotnie mniejszy niż *baggingu*. Wynika to ze sposobu budowy drzew. W *baggingu* każde drzewo wybiera podziały spośród wszystkich cech, a że kilka zmiennych (jak V10 czy V13) bardzo silnie rozdziela odmiany, większość drzew opiera się na tych samych podziałach i ich błędy są mocno skorelowane. *Random forest*, losując w każdym węźle tylko 3 cechy, zmusza drzewa do sięgania także po pozostałe zmienne – drzewa stają się mniej podobne do siebie, a uśrednianie słabiej skorelowanych błędów skuteczniej je redukuje.

## 1.2 Metoda wektorów nośnych (SVM)

Drugą badaną metodą będzie metoda wektorów nośnych (SVM). Metoda ta wyznacza granicę decyzyjną maksymalizującą margines, czyli odległość granicy od najbliższych obserwacji, a za obserwacje leżące po złej stronie płaci karę, której wielkością steruje parametr kosztu  $C$ . O kształcie granicy decyduje funkcja jądrowa: jądro liniowe daje hiperpłaszczyznę, a jądra wielomianowe i radialne – granice krzywoliniowe. Porównamy trzy jądra oraz wpływ parametru  $C$ , korzystając z tego samego podziału 70/30 (to samo ziarno) co dla metod zespołowych:

| Koszt $C$ | Dokładność (test) |
|-----------|-------------------|
| 0.1       | 0.9811            |
| 1.0       | 0.9811            |
| 10.0      | 0.9811            |

Tabela 9: SVM z jądrem liniowym: dokładność na zbiorze testowym dla różnych wartości kosztu  $C$ .

Parametr  $C$  określa kompromis między szerokością marginesu a liczbą błędów dopuszczonych na zbiorze uczącym: małe  $C$  daje szeroki margines kosztem większej liczby błędów, duże  $C$  – ściślejsze dopasowanie do danych. Dla jądra liniowego zmiana  $C$  w zakresie 0.1–10 w ogóle nie zmienia dokładności na zbiorze testowym (98.1%, czyli jedno błędnie sklasyfikowane wino). Odmiany są w 13-wymiarowej przestrzeni cech niemal liniowo separowalne, więc wyznaczona granica jest na tyle stabilna, że zmiana szerokości marginesu praktycznie jej nie przesuwają.

Następnie sprawdzamy pozostałe funkcje jądrowe – wielomianowe stopnia 2 i 4 oraz radialne – na razie z parametrami domyślnymi:

| Jądro                  | Dokładność (test) |
|------------------------|-------------------|
| wielomianowe (deg = 2) | 0.9057            |
| wielomianowe (deg = 4) | 0.8302            |
| radialne (domyślne)    | 1.0000            |

Tabela 10: SVM: dokładność na zbiorze testowym dla różnych funkcji jądrowych przy parametrach domyślnych.

Przy parametrach domyślnych najlepiej wypada jądro radialne, które klasyfikuje cały zbiór testowy bezbłędnie (dokładność 100%). Jądra wielomianowe radzą sobie wyraźnie gorzej – 90.6% dla stopnia 2 i 83% dla stopnia 4 – a wzrost stopnia wielomianu dodatkowo obniża dokładność, bo coraz bardziej giętka granica zaczyna dopasowywać się do przypadkowych własności zbioru uczącego. Jądro liniowe badane wcześniej (98.1%) ustępuje radialnemu tylko minimalnie.

Dla jądra radialnego spróbujemy jeszcze jednocześnie dostroić koszt  $C$  i parametr  $\gamma$ , który steruje zasięgiem oddziaływania pojedynczej obserwacji (im większa  $\gamma$ , tym bardziej lokalna i pofalowana granica decyzyjna). Funkcja `tune()` z pakietu `e1071` przeszukuje siatkę wartości  $C$  od  $2^{-4}$  do  $2^4$  i  $\gamma$  od  $2^{-8}$  do  $2^4$ , oceniając każdą parę 10-krotną walidacją krzyżową na zbiorze uczącym:


| Najlepszy koszt $C$ | Najlepsza gamma | Błąd CV (10-fold) |
|---------------------|-----------------|-------------------|
| 1                   | 0.00391         | 0.01603           |

Tabela 11: SVM radialne: najlepsze parametry  $C$  i gamma z walidacji krzyżowej oraz odpowiadający im błąd CV.

| Model                 | Dokładność (test) |
|-----------------------|-------------------|
| radialne (domyślne)   | 1                 |
| radialne (dostrojone) | 1                 |


Tabela 12: SVM radialne: dokładność na zbiorze testowym przed i po dostrojeniu  $C$  oraz gamma.

### Błąd walidacji krzyżowej (SVM radialne)



Rysunek 5: SVM radialne: błąd walidacji krzyżowej w przestrzeni parametrów (osie w skali log2 dla  $C$  i gamma). Ciemniejsze pola oznaczają niższy błąd.

## Powierzchnia błędu walidacji krzyżowej (SVM radialne)



Rysunek 6: SVM radialne: powierzchnia błędu walidacji krzyżowej w funkcji  $C$  i  $\gamma$  (widok perspektywiczny, osie w skali  $\log_2$ ).

Najniższy błąd walidacji krzyżowej, 1.6%, osiąga para  $C = 1$ ,  $\gamma = 0.00391$ . Dostrojony koszt jest więc równy wartości domyślnej ( $C = 1$ ), a  $\gamma$  wychodzi mniejsza od domyślnej ( $1/13 \approx 0.0769$ ). Optymalizacja nie poprawiła jednak skuteczności na zbiorze testowym – nie miała czego poprawiać, bo już model z parametrami domyślnymi klasyfikował go bezbłędnie i po dostrojeniu dokładność pozostaje na poziomie 100%. Mapa i powierzchnia błędu CV pokazują za to, że wynik nie jest przypadkowy – niski błąd utrzymuje się w szerokim obszarze umiarkowanych  $C$  i małych  $\gamma$ , więc klasyfikator radialny jest mało wrażliwy na dokładny wybór parametrów.

### 1.3 Porównanie skuteczności metod

Takie zestawienie ma jednak słabość: metody zespołowe ocenialiśmy estymatorem .632+, a klasyfikatory SVM – dokładnością na jednym podziale 70/30, czyli innymi miarami. Żeby porównanie było uczciwe, wyznaczamy błąd .632+ (jak poprzednio,  $nboot = 100$ ) również dla trzech wariantów SVM:

| Metoda                    | Błąd .632+ [%] |
|---------------------------|----------------|
| Pojedyncze drzewo         | 10.40          |
| Bagging                   | 4.12           |
| Random Forest             | 1.29           |
| SVM liniowe ( $C = 1$ )   | 2.23           |
| SVM radialne (domyślne)   | 1.32           |
| SVM radialne (dostrojone) | 1.88           |

Tabela 13: Porównanie wszystkich metod Części 1 wspólną miarą – błędem klasyfikacji .632+.

Przy wspólnej mierze najlepsze okazują się *random forest* (1.29%) i SVM z jądrem radialnym o parametrach domyślnych (1.32%) – różnica między nimi jest znikoma, mniejsza niż losowa zmienność samego estymatora. Nieco słabiej wypadają dostrojone SVM radialne (1.88%) i SVM liniowe (2.23%), dalej *bagging* (4.12%), a stawkę zdecydowanie zamyka pojedyncze drzewo (10.4%).

Podsumowując: pojedyncze drzewo jest zdecydowanie najsłabszym klasyfikatorem – cechują je wysoka wariancja i skłonność do przeuczenia. Metody zespołowe redukują jego błąd kilkukrotnie, a porównywalny poziom osiąga SVM: jądro radialne jako jedyne klasyfikuje zbiór testowy bezbłędnie, gładko dopasowując granicę decyzyjną do danych, podczas gdy *random forest* myli na nim jedno wino *Barolo* z *Grignolino*. Strojenie  $C$  i  $\gamma$  niczego już nie poprawiło – model domyślny był na zbiorze testowym bezbłędny, a błąd .632+ po dostrojeniu wyszedł nawet minimalnie wyższy (różnica w granicach losowej zmienności estymatora). Za najskuteczniejsze metody dla zbioru *wine* uznajemy więc *random forest* i SVM z jądrem radialnym, których wyniki są praktycznie nierozróżnialne.


## 2 Część 2 – analiza skupień

W drugiej części raportu zastosujemy dwie metody analizy skupień – algorytm grupujący PAM oraz hierarchiczny AGNES – na tym samym zbiorze *wine*, na którym pracowaliśmy w pierwszej części. Porównamy otrzymane grupowania z rzeczywistym podziałem na odmiany, ocenimy ich jakość wskaźnikami wewnętrznymi i zewnętrznymi, wybierzemy optymalną liczbę skupień, a na koniec zinterpretujemy otrzymane skupienia.

### 2.1 Wybór i przygotowanie danych

Do analizy używamy wszystkich 178 rekordów – zbiór jest na tyle mały, że nie trzeba losować podzbioru 200 obserwacji. Przed grupowaniem usuwamy zmienną `class`; zachowujemy ją jednak osobno, ponieważ posłuży nam później do zewnętrznej oceny jakości grupowania. Do wyznaczania odległości zostaje 13 cech.


Następnie sprawdzamy, czy przed wyznaczeniem macierzy odległości konieczna będzie standaryzacja. Pomogą nam w tym wykresy pudełkowe wszystkich cech:



Rysunek 7: Wykresy pudełkowe cech przed standaryzacją.

Podobnie jak w poprzednim sprawozdaniu zauważamy, że zmienna V13 (zawartość proliny) ma zdecydowanie większą zmienność od pozostałych cech. Bez standaryzacji zdominowałaby ona macierz odległości i grupowanie zależałoby praktycznie tylko od niej, więc standaryzacja jest konieczna.

Poniżej ten sam wykres po standaryzacji – rozrzuty wszystkich zmiennych są teraz porównywalne.




Rysunek 8: Wykresy pudełkowe cech po standaryzacji.

## 2.2 Wizualizacja wyników grupowania

Zaczynamy od metody grupującej – algorytmu PAM. Na danych po standaryzacji wyznaczamy macierz odległości euklidesowych i dzielimy zbiór na  $K = 3$  skupienia, czyli tyle, ile

jest rzeczywistych odmian. Wynik przedstawiamy na wykresie rozrzutu dwóch pierwszych składowych głównych (PCA):



Rysunek 9: Grupowanie PAM ( $K = 3$ ) na tle dwóch pierwszych składowych głównych. Kolor punktu oznacza skupienie PAM, a symbol – rzeczywistą odmianę.

Na powyższym wykresie widzimy dane w rzucie na dwie pierwsze składowe główne, które łącznie wyjaśniają 55% zmienności danych – kolory oznaczają skupienia wyznaczone przez PAM, a symbole rzeczywiste odmiany. Algorytm podzielił dane na trzy zwarte grupy o dobrze zarysowanych granicach, odpowiadające odmianom. Najlepiej odtworzona została odmiana *Barbera* – jej skupienie (fioletowe) zawiera wszystkie 48 obserwacji tej odmiany i tylko 1 obserwację odmiany *Grignolino*. Również wszystkie wina odmiany *Barolo* (kwadraty) trafiły do wspólnego skupienia (czerwonego), jednak dołączyło do nich 15 win *Grignolino*. Sama odmiana *Grignolino* (kółka) okazała się najtrudniejsza – leży na wykresie pomiędzy dwiema pozostałymi i 16 z 71 jej obserwacji zostało odciętych do sąsiednich skupień, do czego przyczynia się też skłonność PAM do tworzenia skupień o kulistych kształtach.

Zgodność podziału PAM z odmianami podsumowuje poniższa tabela:

| Skupienie | <i>Barolo</i> | <i>Grignolino</i> | <i>Barbera</i> |
|-----------|---------------|-------------------|----------------|
| 1         | 59            | 15                | 0              |
| 2         | 0             | 55                | 0              |
| 3         | 0             | 1                 | 48             |

Tabela 14: Liczności skupień PAM ( $K = 3$ ) w podziale na rzeczywiste odmiany.

Do zmierzenia tej zgodności jedną liczbą używamy funkcji `matchClasses` z pakietu `e1071`, która dopasowuje każde skupienie do jednej odmiany tak, aby zmaksymalizować liczbę zgodnych obserwacji. Po takim dopasowaniu zgodne są 162 ze 178 win, czyli 91% obserwacji – podział na skupienia w bardzo dużym stopniu odtwarza podział na odmiany.

Podstawowe własności skupień – zwartość i separację – podsumowuje profil *silhouette*. Wartość *silhouette* obserwacji jest bliska 1, gdy leży ona blisko obiektów ze swojego skupienia i daleko od najbliższego sąsiedniego skupienia, a ujemna, gdy jest jej bliżej do sąsiedniego skupienia niż do własnego:




Rysunek 10: Profil *silhouette* podziału PAM ( $K = 3$ ); każdy słupek to jedna obserwacja. Przerywana linia oznacza średnią wartość *silhouette* całego podziału.


Najbardziej zwarte i najlepiej odseparowane jest skupienie trzecie, odpowiadające odmianie *Barbera* – jego średni *silhouette* wynosi 0.34. Skupienia pierwsze i drugie wypadają słabiej (odpowiednio 0.25 i 0.22), a pojedyncze ujemne wartości odpowiadają winom leżącym na granicy skupień. Skupienia są więc umiarkowanie zwarte – co widać też na wykresie rozrzutu, gdzie grupy sąsiadują ze sobą bez wyraźnych przerw.

Następnie te same dane grupujemy algorytmem hierarchicznym AGNES z trzema metodami łączenia skupień (*linkage*): *single* (odległość najbliższych sąsiadów), *average* (średnia odległość)


i *complete* (odległość najdalszych sąsiadów). Zbudowane drzewa odcinamy funkcją `cutree` na poziomie  $K = 3$  skupień i wyniki przedstawiamy na takich samych wykresach jak dla PAM:



Rysunek 11: Grupowanie AGNES (*single linkage*,  $K = 3$ ) na tle dwóch pierwszych składowych głównych. Kolor punktu oznacza skupienie, a symbol – rzeczywistą odmianę.



Rysunek 12: Grupowanie AGNES (*average linkage*,  $K = 3$ ); oznaczenia jak wyżej.



Rysunek 13: Grupowanie AGNES (*complete linkage*,  $K = 3$ ); oznaczenia jak wyżej.


Na powyższych wykresach widzimy wyniki algorytmu AGNES dla trzech metod łączenia skupień.

Metoda *single linkage* poradziła sobie najgorzej – do jednego skupienia trafiły prawie wszystkie obserwacje (174 ze 178), a dwa pozostałe skupienia liczą łącznie 4 obserwacje. To skrajny przykład efektu łańcuchowego: skoro o połączeniu decyduje odległość dwóch najbliższych punktów, kolejne obserwacje są dołączane do rosnącego skupienia przez pojedyncze bliskie pary i zamiast trzech grup powstaje jedna wielka grupa oraz kilka odciętych obserwacji odstających.

Metoda *average linkage* dała niemal identyczny, zdegenerowany podział – 174 obserwacje w jednym skupieniu i szczątkowe skupienia 3- i 1-elementowe. Z punktu widzenia struktury odmian taki podział jest bezużyteczny.

Zdecydowanie najlepiej wypadła metoda *complete linkage*, której podział przypomina wynik PAM. Wszystkie 48 win odmiany *Barbera* trafiło do wspólnego skupienia (razem z 3 winami *Grignolino*), natomiast odmiany *Barolo* i *Grignolino* wymieszały się mocniej niż przy PAM – łącznie 26 obserwacji trafiło do skupienia zdominowanego przez inną odmianę.

Struktury zbudowane przez trzy metody łączenia porównujemy też na dendrogramach. Dla czytelności nie rysujemy podpisów liści – zamiast tego gałęzie kolorujemy według podziału na trzy skupienia, a pod liśćmi rysujemy paski w kolorach rzeczywistych odmian:



Rysunek 14: Dendrogramy AGNES dla trzech metod łączenia skupień. Gałęzie pokolorowano według podziału na trzy skupienia (*cutree*), a paski pod dendrogramami pokazują rzeczywiste odmiany: *Barolo*, *Grignolino*, *Barbera*.

Na powyższym wykresie znajdują się dendrogramy dla trzech metod łączenia. Pierwszy przedstawia drzewo metody *single linkage* – obiekty są dołączane do drzewa niemal jeden po drugim, brakuje wyraźnych, odrębnych poddrzew, a paski odmian pod liśćmi są silnie przemieszane.

Drzewo metody *complete linkage* jako jedyne dzieli się na trzy wyraźne poddrzewa, które – jak pokazują paski pod liśćmi – w dużym stopniu odpowiadają rzeczywistym odmianom. Potwierdza to obserwację z wykresów rozrzutu, że ta metoda sensownie podzieliła dane na trzy skupienia.

Ostatni dendrogram obrazuje metodę *average linkage*, będącą kompromisem między dwiema poprzednimi. Struktura drzewa przypomina jednak wynik *single linkage* – drzewo narasta „schodkowo” w jedną stronę, bez zrównoważonych poddrzew.

Porównując te trzy metody, najlepiej poradziła sobie metoda *complete linkage* – stworzyła zrównoważone, wyraźnie odseparowane gałęzie. W metodzie *single* widać skrajny efekt łańcuchowy, a *average* zbudowała silnie asymetryczną strukturę, która po odcięciu na poziomie trzech skupień również nie oddaje podziału na odmiany. W dalszej części jako reprezentanta metod hierarchicznych używamy więc AGNES z łączeniem *complete*.

## 2.3 Ocena jakości grupowania, wybór liczby skupień i porównanie metod


Następnie dla liczby skupień  $K$  od 2 do 8 porównujemy oba algorytmy: PAM oraz AGNES (*complete*). Jako wskaźnika wewnętrznego używamy średniego indeksu *silhouette* (ocenia zwartość i separację skupień bez znajomości klas), a jako zewnętrznego – wskaźnika ARI (*Adjusted Rand Index*), mierzącego zgodność grupowania z rzeczywistym podziałem na odmiany: 1 oznacza podział identyczny z podziałem na klasy, a wartości bliskie 0 – podział losowy.

| K | Silhouette (PAM) | ARI (PAM) | Silhouette (AGNES) | ARI (AGNES) |
|---|------------------|-----------|--------------------|-------------|
| 2 | 0.258            | 0.358     | 0.162              | 0.295       |
| 3 | 0.268            | 0.741     | 0.204              | 0.577       |
| 4 | 0.199            | 0.662     | 0.194              | 0.643       |
| 5 | 0.161            | 0.539     | 0.188              | 0.678       |
| 6 | 0.117            | 0.439     | 0.175              | 0.663       |
| 7 | 0.123            | 0.395     | 0.189              | 0.688       |
| 8 | 0.108            | 0.356     | 0.191              | 0.687       |

Tabela 15: Średni indeks *silhouette* (wskaźnik wewnętrzny) oraz ARI (wskaźnik zewnętrzny) dla algorytmów PAM i AGNES (*complete linkage*) w zależności od liczby skupień  $K$ .

Powyższa tabela przedstawia wyniki dla algorytmów PAM i AGNES (*complete*). Najwyższą wartość średniego indeksu *silhouette* oba algorytmy osiągają dla  $K = 3$  – 0.268 dla PAM oraz 0.204 dla AGNES – czyli dokładnie dla rzeczywistej liczby odmian. Wskaźnik ARI dla PAM

również jest najwyższy przy  $K = 3$  (0.741) i wyraźnie spada dla większych  $K$ . Dla AGNES wskaźnik ARI przy  $K = 3$  wynosi 0.577 i dla większych  $K$  nieznacznie rośnie – mieszane skupienie z odmianami *Barolo* i *Grignolino* dzieli się wtedy na czystsze podgrupy – ale nie zmienia to wniosku, że strukturę klas znacznie lepiej odtwarza PAM.



Rysunek 15: Średni indeks *silhouette* (po lewej) oraz ARI (po prawej) dla algorytmów PAM i AGNES (*complete linkage*) w zależności od liczby skupień  $K$ .

Powyższe wykresy obrazują wartości obu wskaźników. Na wykresie po lewej stronie widzimy, że najwyższą wartość średniego *silhouette* oba algorytmy przyjmują dla  $K = 3$ , co pokrywa się z rzeczywistą liczbą odmian, a krzywa PAM leży przy tym wyraźnie powyżej krzywej AGNES.

Na wykresie po prawej stronie algorytm PAM osiąga najwyższą wartość ARI dla  $K = 3$  (0.741), po czym wskaźnik wyraźnie spada – PAM dobrze odgadł strukturę danych właśnie przy trzech skupieniach. Dla AGNES wskaźnik ARI jest niższy i powoli rośnie z  $K$  z powodu opisanego pod tabelą. Podsumowując: optymalna liczba skupień to  $K = 3$ , a z porównywanych algorytmów lepiej poradził sobie PAM – ma wyższy *silhouette* i znacznie wyższą zgodność z odmianami (ARI 0.741 wobec 0.577 dla AGNES).

## 2.4 Interpretacja wyników grupowania – charakterystyki skupień

Zgodnie z wnioskami z poprzedniego punktu interpretujemy podział wyznaczony algorytmem PAM dla optymalnej liczby skupień  $K = 3$  (podział ten wyznaczyliśmy już w punkcie o wizualizacji – to obiekt `wino.pam2`). Zaczynamy od średnich wartości cech w skupieniach, liczonych na danych w oryginalnych skalach (przed standaryzacją), żeby dało się je interpretować w jednostkach cech:


| Cecha | Skupienie 1 | Skupienie 2 | Skupienie 3 |
|-------|-------------|-------------|-------------|
| V1    | 13.43       | 12.29       | 13.15       |
| V2    | 2.01        | 1.88        | 3.34        |
| V3    | 2.44        | 2.20        | 2.43        |
| V4    | 17.92       | 19.88       | 21.44       |
| V5    | 107.01      | 90.60       | 99.02       |
| V6    | 2.84        | 2.11        | 1.68        |
| V7    | 2.93        | 1.91        | 0.80        |
| V8    | 0.28        | 0.39        | 0.45        |
| V9    | 1.97        | 1.47        | 1.16        |
| V10   | 5.11        | 2.96        | 7.34        |
| V11   | 1.06        | 1.06        | 0.69        |
| V12   | 3.13        | 2.73        | 1.69        |
| V13   | 1017.85     | 488.65      | 627.55      |

Tabela 16: Średnie wartości cech w skupieniach PAM ( $K = 3$ ); dane w oryginalnych skalach.

Podsumowując, najlepiej grupującym zbiór *wine* algorytmem okazał się PAM z liczbą skupień  $K = 3$ .

Kolumny tabeli odpowiadają skupieniom 1–3, które – jak pokazał wykres rozrzutu – reprezentują kolejno odmiany *Barolo*, *Grignolino* i *Barbera*; liczą one odpowiednio 74, 55 i 49 win. Dla większości cech najwyższe średnie przyjmuje skupienie 1 – m.in. dla alkoholu (V1), fenoli (V6), flawonoidów (V7) i proliny (V13) – a najniższe skupienie 2. Skupienie 3 wyróżnia się z kolei najwyższymi średnimi kwasu jabłkowego (V2), fenoli nieflawonoidowych (V8) i intensywności barwy (V10) przy najniższych flawonoidach (V7), odcieniu koloru (V11) i OD280/OD315 (V12).

Rozrzuty cech w skupieniach porównujemy na wykresach pudełkowych:



Rysunek 16: Wykresy pudełkowe wszystkich cech w podziale na skupienia PAM ( $K = 3$ ); skala osi pionowej dobrana osobno dla każdej cechy.

Na wykresach pudełkowych widzimy rozrzuty każdej cechy w skupieniach. Najlepiej skupienia rozdziela V13 (zawartość proliny) – w skupieniu 1 (*Barolo*) wartości leżą zdecydowanie wyżej (średnio 1018) niż w dwóch pozostałych (489 i 628). Dla V7 (flawonoidy) widzimy „schodkową” separację prawie bez nakładania się pudełek: skupienie 1 ma wartości najwyższe, skupienie 2 średnie, a skupienie 3 skrajnie niskie. Podobnie przy V12 (OD280/OD315) skupienie 3 wyraźnie odstaje w dół od dwóch pozostałych.

Cechą wyróżniającą pojedyncze skupienie jest np. V2 (kwas jabłkowy), którego wysokie wartości charakteryzują skupienie 3 (*Barbera*) – jego pudełko jest mocno przesunięte w górę względem skupień 1 i 2. Skupienie 2 (*Grignolino*) nie ma jednej cechy o skrajnie wysokich wartościach – wyróżnia się raczej ogólnie niskimi wartościami, m.in. alkoholu (V1), intensywności barwy (V10) i proliny (V13).

Na koniec sprawdzamy, które wina są medoidami, czyli obiektami reprezentującymi skupienia (PAM wybiera je tak, aby suma odległości obiektów skupienia od medoidu była najmniejsza). Medoidami okazały się wina o numerach 36, 107, 149 – po jednym z każdej odmiany, odpowiednio *Barolo*, *Grignolino* i *Barbera*. Ich wartości cech zestawiamy w tabeli:

| Cecha | Wino 36 ( <i>Barolo</i> ) | Wino 107 ( <i>Grignolino</i> ) | Wino 149 ( <i>Barbera</i> ) |
|-------|---------------------------|--------------------------------|-----------------------------|
| V1    | 13.48                     | 12.25                          | 13.32                       |
| V2    | 1.81                      | 1.73                           | 3.24                        |
| V3    | 2.41                      | 2.12                           | 2.38                        |
| V4    | 20.50                     | 19.00                          | 21.50                       |
| V5    | 100.00                    | 80.00                          | 92.00                       |
| V6    | 2.70                      | 1.65                           | 1.93                        |
| V7    | 2.98                      | 2.03                           | 0.76                        |
| V8    | 0.26                      | 0.37                           | 0.45                        |
| V9    | 1.86                      | 1.63                           | 1.25                        |
| V10   | 5.10                      | 3.40                           | 8.42                        |
| V11   | 1.04                      | 1.00                           | 0.55                        |
| V12   | 3.47                      | 3.17                           | 1.62                        |
| V13   | 920.00                    | 510.00                         | 650.00                      |

Tabela 17: Wartości cech medoidów – reprezentantów skupień PAM ( $K = 3$ ).

Porównując wartości cech medoidów ze średnimi skupień z poprzedniej tabeli widzimy, że są one bardzo zbliżone – np. dla wina 36 zawartość proliny V13 wynosi 920 przy średniej skupienia 1018. Medoidy są więc typowymi, przeciętnymi przedstawicielami swoich skupień, a zarazem odmian, do których należą – każde skupienie jest reprezentowane przez wino tej odmiany, która je zdominowała.